Explorační analýza datové sady: přehled korpusu MIMIC-IV

Martin Žoha

Abstrakt Dokument zahajuje explorační analýzu datové sady, na které práce staví. Popisuje zdroje dat (MIMIC-IV, MIMIC-IV-Note a MIMIC-IV-Ext-BHC), cestu dat od stažení po dotazování a ochranu dat podle licence. Přehled korpusu uvádí pro každou tabulku počet záznamů, počet sloupců a velikost souboru a porovnává počty záznamů v databázi s manifestem validace. Dokument tak vymezuje východiska, na kterých staví další části analýzy.

Obsah

1 Úvod 1
2 Data a metody 2
3 Přehled korpusu 2
4 Shrnutí a rozhodnutí 4
5 Omezení 4
Příloha A: provenance renderu 4
Literatura 6

1 Úvod

Tento sešit je prvním z řady sešitů explorační analýzy. Jeho úlohou je charakterizovat datovou sadu, na které stojí celá práce, a zdokumentovat, odkud data pocházejí a jak se k nim dokument dostává. Sešit si klade tři cíle:

- popsat zdroje dat a jejich licenční omezení,
- popsat cestu dat od stažení po dotazování a způsob, jakým dokument chrání data pacientů,
- uvést přehled korpusu: tabulky, jejich obsah, počty záznamů a velikost.

Práce vychází z návrhu, podle kterého jsou primárním korpusem propouštěcí zprávy (tabulka `discharge`), radiologické zprávy jsou doplňkové a štítky klasifikace se odvozují z diagnóz ICD (tabulka `diagnoses_icd`). Dokument tato východiska nepotvrzuje ani nevyvrací; ověřuje jen, že potřebné tabulky existují a zda jsou úplné.

Data pocházejí ze tří projektů PhysioNetu (Goldberger et al. 2000). Strukturovaná data hospitalizací poskytuje MIMIC-IV (Johnson et al. 2024; A. E. W. Johnson et al. 2023), volné texty zpráv MIMIC-IV-Note (A. Johnson et al. 2023) a referenční sekci Brief Hospital Course MIMIC-IV-Ext-BHC (Aali et al. 2025, 2024). Všechny projekty podléhají smlouvě o užívání dat (DUA). Dokument proto zveřejňuje jen agregované výsledky, nikdy řádková data ani texty zpráv.

Dokument je členěn takto. Kapitola 2 popisuje zdroje dat a metody. Kapitola 3 uvádí přehled korpusu. Kapitola 4 shrnuje výsledky a kapitola 5 jmenuje omezení. Příloha A dokumentuje provenance renderu.

2 Data a metody

Práce používá tři projekty PhysioNetu. MIMIC-IV, verze 3.1 (Johnson et al. 2024), obsahuje strukturovaná data hospitalizací; dokument z něj čte moduly `hosp` (pacienti, přijetí, diagnózy, výkony, léky). MIMIC-IV-Note, verze 2.2 (A. Johnson et al. 2023), obsahuje deidentifikované volné texty a dokument z něj čte propouštěcí a radiologické zprávy. MIMIC-IV-Ext-BHC, verze 1.2.0 (Aali et al. 2025, 2024), obsahuje pro zprávy MIMIC-IV-Note sekci Brief Hospital Course vytaženou regulárním výrazem autorů datasetu; práce ji používá jen jako referenci pro validaci parseru sekcí. Popis MIMIC-IV a jeho vzniku uvádí A. E. W. Johnson et al. (2023).

Data podléhají DUA. Dokument dodržuje tato pravidla:

- řádková data a texty zpráv se nevypisují,
- výsledky jsou agregáty; počty a podíly skupin pacientů vymezených kvaziidentifikátorem (například věkem, pohlavím, obdobím nebo diagnózou) se zveřejňují přesně, protože DUA malé počty neupravuje a pacienti se neidentifikují. Práh deseti zpráv platí pro popisky z textu nebo hodnoty z dat mimo zveřejněný číselník MIMIC (hlavičky, n-gramy, zkratky, kódy ICD a jejich názvy); hlavičky a n-gramy navíc potřebují aspoň 1 % korpusu,
- metriky korpusu a textu, například počty záznamů tabulek, nepopisují skupiny pacientů, a proto se uvádějí přesně,
- skutečná data zpracovává jen autor mimo automatizované nástroje; automatizovaná kontrola běží nad syntetickými tabulkami stejného tvaru a ověřuje, že jejich obsah neunikl do výstupu.

Data procházejí těmito kroky: stažení souborů `csv.gz` (MIMIC-IV-Ext-BHC je prosté `csv`) z PhysioNetu, ověření jejich otisků SHA-256 proti oficiálním hodnotám, validace (počet záznamů a sloupců), převod na parquet a dotazování přes DuckDB. Převod do parquetu zachovává všechny sloupce jako text a počet záznamů ověřuje proti validaci. Dotazy nad parquetem provádí DuckDB s omezenou pamětí a s dočasnými soubory mimo verzovaný obsah repozitáře.

Reprodukovatelnost zajišťují dva mechanismy. Výsledky výpočtů se ukládají do zmražené podoby (`freeze`), takže dokument lze znovu vyrenderovat bez přístupu k datům. Příloha A uvádí provenance renderu: revizi kódu, otisk zámku prostředí, zdroj dat a verze použitých nástrojů.

3 Přehled korpusu

Databáze obsahuje 13 tabulek. Tabulka 1 uvádí pro každou z nich projekt a modul, popis obsahu a plánované využití v práci, počet záznamů v databázi, počet sloupců a velikost staženého souboru podle manifestu validace (u `csv.gz` komprimovaného, u BHC nekomprimovaného). Využití tabulek v práci vychází z návrhu práce.

Tabulka 1: Tabulky korpusu: zdroj, obsah a využití, počet záznamů, počet sloupců a velikost souboru (MB).

Tabulka	Zdroj	Obsah a využití	Záznamů	Sloupců	MB
admissions	MIMIC-IV (hosp)	Hospitalizace: čas přijetí a propuštění, typ přijetí; vazba zpráv na pacienty.	546 028	16	20
d_icd_diagnoses	MIMIC-IV (hosp)	Číselník diagnóz ICD; názvy ke kódům.	112 107	3	1
d_icd_procedures	MIMIC-IV (hosp)	Číselník výkonů ICD; názvy ke kódům.	86 423	3	1
diagnoses_icd	MIMIC-IV (hosp)	Diagnózy ICD přiřazené hospitalizacím; zdroj štítků klasifikace.	6 364 488	5	34
discharge	MIMIC-IV--Note (note)	Propouštěcí zprávy; primární korpus práce.	331 793	8	1 139
mimic-iv-bhc	MIMIC-IV--Ext-BHC	Brief Hospital Course vytažený regexem autorů datasetu; reference validace parseru sekcí.	270 033	5	2 726
omr	MIMIC-IV (hosp)	Ambulantní měření (například výška, hmotnost, tlak); kontext zprávy.	7 753 027	5	44
patients	MIMIC-IV (hosp)	Pacienti: pohlaví, věk a rok ukotvení; podklad dělení dat po pacientech.	364 627	6	3
pharmacy	MIMIC-IV (hosp)	Lékárenské záznamy o lécích; kontext zprávy.	17 847 567	27	526
prescriptions	MIMIC-IV (hosp)	Předpisy léků; kontext zprávy.	20 292 611	21	606
procedures_icd	MIMIC-IV (hosp)	Výkony ICD přiřazené hospitalizacím; kontext zprávy.	859 655	6	8
radiology	MIMIC-IV--Note (note)	Radiologické zprávy; dokplňkový korpus.	2 321 355	8	782
services	MIMIC-IV (hosp)	Služby, na kterých pacient během hospitalizace ležel; kontext zprávy.	593 071	5	9

Zdroj: počty záznamů dotazem v DuckDB, počty sloupců a velikosti souborů z manifestu validace, popisy podle veřejné dokumentace MIMIC-IV, MIMIC-IV-Note a MIMIC-IV-Ext-BHC.

Podle návrhu práce je primárním korpusem tabulka `discharge`; obsahuje 331 793 záznamů. Radiologických zpráv je v tabulce `radiology` 2 321 355. Nejvíce záznamů má tabulka prescriptions. Počty záznamů v databázi odpovídají počtům v manifestu validace.

4 Shrnutí a rozhodnutí

Dokument popsal zdroje dat, cestu dat k dotazování a přehled 13 tabulek. Počty záznamů u všech tabulek odpovídají manifestu validace. Data jsou proto úplná a další části analýzy mohou stavět na parquetu bez další kontroly počtu záznamů.

5 Omezení

Přehled uvádí jen počty záznamů, sloupců a velikosti souborů. O obsahu zpráv, pacientech ani rozdělení dat netvrdí nic; to je předmětem dalších částí analýzy. Počty se vztahují k verzím 3.1 (MIMIC-IV), 2.2 (MIMIC-IV-Note) a 1.2.0 (MIMIC-IV-Ext-BHC). Automatizovaná kontrola neprohledává text uvnitř obrázků, proto grafy vyžadují zvláštní zacházení.

Příloha A: provenance renderu

Tabulka 2 uvádí údaje, podle kterých lze render dohledat a zopakovat: revizi kódu, otisk zámku prostředí, zdroj dat a verze použitých nástrojů.

Tabulka 2: Provenance renderu.

Položka	Hodnota
Revize kódu (commit)	83461e23ce9a5ad9166f8eb2962d35806dda4ff4
Necommitnuté změny	ne
Otisk pixi.lock (SHA-256)	c9b8dbd92a0bb8d7 c26f7127af04b8f6 ba06d55dd6a9cc42 21c80324bf149fad
Zdroj dat	tabulky parquet ověřené proti vazbě na otisky CSV
Otisk CSV admissions (SHA-256)	a9584ed88e9ed664 a2f66f86a5cf9fd1 75c8bb0af50e3b61 15598b19e978384e
Otisk parquetu admissions (SHA-256)	511b92c1956c6e0a 17ccff692532bc39 f4d2962a55a8df5a 2404cb22ff0a1b0a
Otisk CSV d_icd_diagnoses (SHA-256)	a81065bf45ccf74f 589bec855bbb0a07 b5c014907b34ff76 fe20583a2c87cc79
Otisk parquetu d_icd_diagnoses (SHA-256)	4bbe089e2f75747a 1f4be3be4a8a3100 294b103af562208d 1b9cc92ffaa1b6a4
Otisk CSV d_icd_procedures (SHA-256)	a2ac8afcb99fd16b ce2e6c7ad445e3bd 1dfd658e52182313 0ab08b66fdd3d6d4
Otisk parquetu d_icd_procedures (SHA-256)	7de5e3083e432019 877ce3598856e558 9030a2876d604a9f b0ff17c1e8e16f9f
Otisk CSV diagnoses_icd (SHA-256)	47665a41b2a3ad99 0d6f314062d5bd6d 29d467b0fd402dd9 4662044ec8b073d2
Otisk parquetu diagnoses_icd (SHA-256)	c98d378ffafb8cf8 a81428570fcef4aa 57106eb8cb60f01e bf8143792ae83922
Otisk CSV discharge (SHA-256)	27bc552edaf81c2a f322040cb7e8eb36 417173b23c79405b b92fcf73bef2dbc5
Otisk parquetu discharge (SHA-256)	0b817f1662e2c085 7f99caca2bda8a5c c6bf677738a3b6eb cf9ed43dbc55aae5
Otisk CSV mimic-iv-bhc (SHA-256)	e45c09997b25d744 abb20573623885eb a052299cf2a721c1 8bbf5ca9a54989c1
Otisk parquetu mimic-iv-bhc (SHA-256)	403dcbe4e6a916ac 30ea647197c4d8e7 08505ee72ce0533d 3500dd64606c3dd0
Otisk CSV omr (SHA-256)	8280a8023203bddc 6cc4419bd8cd253a 015b8bc0bc53852e c92f98c7353f31e2
Otisk parquetu omr (SHA-256)	6566ab088fdb28cf 79985a5fe144d8c3 9587d0bdabd7da81 fd6130f72bf29a66
[illegible] (SHA-256)	[illegible]

Literatura

Aali, Asad, Dave Van Veen, Yamin Ishraq Arefeen, et al. 2024. „A dataset and benchmark for hospital course summarization with adapted large language models". *Journal of the American Medical Informatics Association* 32 (3): 470–79. https://doi.org/10.1093/jamia/ocae312.

Aali, Asad, Dave Van Veen, Yamin Ishraq Arefeen, et al. 2025. *MIMIC-IV-Ext-BHC: Labeled Clinical Notes Dataset for Hospital Course Summarization*. Verze 1.2.0. PhysioNet. https://doi.org/10.13026/5gte-bv70.

Goldberger, Ary L., Luis A. N. Amaral, Leon Glass, et al. 2000. „PhysioBank, PhysioToolkit, and PhysioNet: Components of a new research resource for complex physiologic signals". *Circulation* 101 (23): e215–20. https://doi.org/10.1161/01.CIR.101.23.e215.

Johnson, Alistair E. W., Lucas Bulgarelli, Lu Shen, et al. 2023. „MIMIC-IV, a freely accessible electronic health record dataset". *Scientific Data* 10 (1): 1. https://doi.org/10.1038/s41597-022--01899-x.

Johnson, Alistair, Lucas Bulgarelli, Tom Pollard, et al. 2024. *MIMIC-IV*. Verze 3.1. PhysioNet. https://doi.org/10.13026/kpb9-mt58.

Johnson, Alistair, Tom Pollard, Steven Horng, Leo Anthony Celi, a Roger Mark. 2023. *MIMIC--IV-Note: Deidentified free-text clinical notes*. Verze 2.2. PhysioNet. https://doi.org/10.13026/1n74-ne17.