# Explorační analýza datové sady: přehled korpusu MIMIC-IV

Martin Žoha

**Abstrakt** Dokument zahajuje explorační analýzu datové sady, na které práce staví. Popisuje zdroje dat (MIMIC-IV a MIMIC-IV-Note), cestu dat od stažení po dotazování a ochranu dat podle licence. Přehled korpusu uvádí pro každou tabulku počet záznamů, počet sloupců a velikost souboru a porovnává počty záznamů v databázi s manifestem validace. Dokument tak vymezuje východiska, na kterých staví další části analýzy.

## Obsah

1 Úvod ..... 1
2 Data a metody ..... 2
3 Přehled korpusu ..... 2
4 Shrnutí a rozhodnutí ..... 4
5 Omezení ..... 4
Příloha A: provenance renderu ..... 4
Literatura ..... 6

## 1 Úvod

Tento sešit je prvním z řady sešitů explorační analýzy. Jeho úlohou je charakterizovat datovou sadu, na které stojí celá práce, a zdokumentovat, odkud data pocházejí a jak se k nim dokument dostává. Sešit si klade tři cíle:

- popsat zdroje dat a jejich licenční omezení,
- popsat cestu dat od stažení po dotazování a způsob, jakým dokument chrání data pacientů,
- uvést přehled korpusu: tabulky, jejich obsah, počty záznamů a velikost.

Práce vychází z návrhu, podle kterého jsou primárním korpusem propouštěcí zprávy (tabulka `discharge`), radiologické zprávy jsou doplňkové a štítky klasifikace se odvozují z diagnóz ICD (tabulka `diagnoses_icd`). Dokument tato východiska nepotvrzuje ani nevyvrací; ověřuje jen, že potřebné tabulky existují a zda jsou úplné.

Data pocházejí ze dvou projektů PhysioNetu (Goldberger et al. 2000). Strukturovaná data hospitalizací poskytuje MIMIC-IV (Johnson et al. 2024; A. E. W. Johnson et al. 2023), volné texty zpráv MIMIC-IV-Note (A. Johnson et al. 2023). Oba projekty podléhají smlouvě o užívání dat (DUA). Dokument proto zveřejňuje jen agregované výsledky, nikdy řádková data ani texty zpráv.

Dokument je členěn takto. Kapitola 2 popisuje zdroje dat a metody. Kapitola 3 uvádí přehled korpusu. Kapitola 4 shrnuje výsledky a kapitola 5 jmenuje omezení. Příloha A dokumentuje provenance renderu.

# 2 Data a metody

Práce používá dva projekty PhysioNetu. MIMIC-IV, verze 3.1 (Johnson et al. 2024), obsahuje strukturovaná data hospitalizací; dokument z něj čte moduly `hosp` (pacienti, přijetí, diagnózy, výkony, léky). MIMIC-IV-Note, verze 2.2 (A. Johnson et al. 2023), obsahuje deidentifikované volné texty a dokument z něj čte propouštěcí a radiologické zprávy. Popis MIMIC-IV a jeho vzniku uvádí A. E. W. Johnson et al. (2023).

Data podléhají DUA. Dokument dodržuje tato pravidla:

- řádková data a texty zpráv se nevypisují,
- výsledky jsou agregáty; skupiny pacientů vymezené kvaziidentifikátorem (například věkem, pohlavím, obdobím nebo diagnózou) a kategorie, jejichž popisek je hodnota z dat, se pod deset záznamů sloučí do řádku „ostatní (n < 10)“ a jejich popisky se nezobrazí; práh je pravidlo práce, DUA malé počty neupravuje,
- metriky korpusu a textu, například počty záznamů tabulek, nepopisují skupiny pacientů, a proto se uvádějí přesně,
- skutečná data zpracovává jen autor mimo automatizované nástroje; automatizovaná kontrola běží nad syntetickými tabulkami stejného tvaru a ověřuje, že jejich obsah neunikl do výstupu.

Data procházejí těmito kroky: stažení souborů `csv.gz` z PhysioNetu, ověření jejich otisků SHA-256 proti oficiálním hodnotám, validace (počet záznamů a sloupců), převod na parquet a dotazování přes DuckDB. Převod do parquetu zachovává všechny sloupce jako text a počet záznamů ověřuje proti validaci. Dotazy nad parquetem provádí DuckDB s omezenou pamětí a s dočasnými soubory mimo verzovaný obsah repozitáře.

Reprodukovatelnost zajišťují dva mechanismy. Výsledky výpočtů se ukládají do zmražené podoby (`freeze`), takže dokument lze znovu vyrenderovat bez přístupu k datům. Příloha A uvádí provenance renderu: revizi kódu, otisk zámku prostředí, zdroj dat a verze použitých nástrojů.

# 3 Přehled korpusu

Databáze obsahuje 12 tabulek. Tabulka 1 uvádí pro každou z nich projekt a modul, popis obsahu a plánované využití v práci, počet záznamů v databázi, počet sloupců a velikost komprimovaného souboru podle manifestu validace. Využití tabulek v práci vychází z návrhu práce.

Tabulka 1: Tabulky korpusu: zdroj, obsah a využití, počet záznamů, počet sloupců a velikost souboru (MB).

| Tabulka | Zdroj | Obsah a využití | Záznamů | Sloupců | MB |
|---|---|---|---|---|---|
| admissions | MIMIC-IV (hosp) | Hospitalizace: čas přijetí a propuštění, typ přijetí; vazba zpráv na pacienty. | 546 028 | 16 | 20 |
| d_icd_diagnoses | MIMIC-IV (hosp) | Číselník diagnóz ICD; názvy ke kódům. | 112 107 | 3 | 1 |
| d_icd_procedures | MIMIC-IV (hosp) | Číselník výkonů ICD; názvy ke kódům. | 86 423 | 3 | 1 |
| diagnoses_icd | MIMIC-IV (hosp) | Diagnózy ICD přiřazené hospitalizacím; zdroj štítků klasifikace. | 6 364 488 | 5 | 34 |
| discharge | MIMIC-IV--Note (note) | Propouštěcí zprávy; primární korpus práce. | 331 793 | 8 | 1 139 |
| omr | MIMIC-IV (hosp) | Ambulantní měření (například výška, hmotnost, tlak); kontext zprávy. | 7 753 027 | 5 | 44 |
| patients | MIMIC-IV (hosp) | Pacienti: pohlaví, věk a rok ukotvení; podklad dělení dat po pacientech. | 364 627 | 6 | 3 |
| pharmacy | MIMIC-IV (hosp) | Lékárenské záznamy o lécích; kontext zprávy. | 17 847 567 | 27 | 526 |
| prescriptions | MIMIC-IV (hosp) | Předpisy léků; kontext zprávy. | 20 292 611 | 21 | 606 |
| procedures_icd | MIMIC-IV (hosp) | Výkony ICD přiřazené hospitalizacím; kontext zprávy. | 859 655 | 6 | 8 |
| radiology | MIMIC-IV--Note (note) | Radiologické zprávy; doplňkový korpus. | 2 321 355 | 8 | 782 |
| services | MIMIC-IV (hosp) | Služby, na kterých pacient během hospitalizace ležel; kontext zprávy. | 593 071 | 5 | 9 |

*Zdroj:* počty záznamů dotazem v DuckDB, počty sloupců a velikosti souborů z manifestu validace, popisy podle veřejné dokumentace MIMIC-IV a MIMIC-IV-Note.

Podle návrhu práce je primárním korpusem tabulka `discharge`; obsahuje 331 793 záznamů. Radiologických zpráv je v tabulce `radiology` 2 321 355. Nejvíce záznamů má tabulka prescriptions. Počty záznamů v databázi se shodují s počty v manifestu validace.

## 4 Shrnutí a rozhodnutí

Dokument popsal zdroje dat, cestu dat k dotazování a přehled 12 tabulek. Počty záznamů se u všech tabulek shodují s manifestem validace. Data jsou proto úplná a další části analýzy mohou stavět na parquetu bez další kontroly počtu záznamů.

## 5 Omezení

Přehled uvádí jen počty záznamů, sloupců a velikosti souborů. O obsahu zpráv, pacientech ani rozdělení dat netvrdí nic; to je předmětem dalších částí analýzy. Počty se vztahují k verzím 3.1 (MIMIC-IV) a 2.2 (MIMIC-IV-Note). Automatizovaná kontrola neprohledává text uvnitř obrázků, proto grafy vyžadují zvláštní zacházení.

## Příloha A: provenance renderu

Tabulka 2 uvádí údaje, podle kterých lze render dohledat a zopakovat: revizi kódu, otisk zámku prostředí, zdroj dat a verze použitých nástrojů.

Tabulka 2: Provenance renderu.

| Položka | Hodnota |
|---|---|
| Revize kódu (commit) | b7e815a24e8d0f2e77cd2dcb7d96da5168304006 |
| Necommitnuté změny | ne |
| Otisk pixi.lock (SHA-256) | db114dc073b5d1ab efcd9990c160b069 96379e58ee750d9b afa58a4f203a45b1 |
| Zdroj dat | otisky CSV z config/mimic_tables.json |
| Otisk discharge.csv.gz (SHA-256) | 27bc552edaf81c2a f322040cb7e8eb36 417173b23c79405b b92fcf73bef2dbc5 |
| Otisk radiology.csv.gz (SHA-256) | 2c09bc76ee12d5f3 b8f572deb7218fba f3e59b32eccfdae1 4686e05ae099eebb |
| Otisk admissions.csv.gz (SHA-256) | a9584ed88e9ed664 a2f66f86a5cf9fd1 75c8bb0af50e3b61 15598b19e978384e |
| Otisk d_icd_diagnoses.csv.gz (SHA-256) | a81065bf45ccf74f 589bec855bbb0a07 b5c014907b34ff76 fe20583a2c87cc79 |
| Otisk d_icd_procedures.csv.gz (SHA-256) | 2ac8afcb99fd16b ce2e6c7ad445e3bd 1dfd658e52182313 0ab08b66fdd3d6d4 |
| Otisk diagnoses_icd.csv.gz (SHA-256) | 47665a41b2a3ad99 0d6f314062d5bd6d 29d467b0fd402dd9 4662044ec8b073d2 |
| Otisk omr.csv.gz (SHA-256) | 8280a8023203bddc 6cc4419bd8cd253a 015b8bc0bc53852e c92f98c7353f31e2 |
| Otisk patients.csv.gz (SHA-256) | 4c7507de7ecad8c5 ba7647ea4d26018e 88ff6672c5fc22ab 59c2a5697d687cdd |
| Otisk pharmacy.csv.gz (SHA-256) | c9885721e4c968f0 773145d7f6ba4d3c c3755d5600ee400f f95b1d3238053811 |
| Otisk prescriptions.csv.gz (SHA-256) | 0d8481c7d5d7c9ec 2fea3fc543ddaaad b5a933cd22c7b9dd a4289361e4d77199 |
| Otisk procedures_icd.csv.gz (SHA-256) | 3271397d0517131f 84399b698cbb0c2f 435aaab0f873a380 6e13b097661596f7 |
| Otisk services.csv.gz (SHA-256) | 31c82ebee94e0c04 d6966fbfec30579e c00f9c7816b80852 f9580656e6183888 |
| Python | 3.13.16 |
| DuckDB | 1.5.6 |
| R | R version 4.5.3 (2026-03-11) |

## Literatura

Goldberger, Ary L., Luis A. N. Amaral, Leon Glass, et al. 2000. „PhysioBank, PhysioToolkit, and PhysioNet: Components of a new research resource for complex physiologic signals". *Circulation* 101 (23): e215–20. https://doi.org/10.1161/01.CIR.101.23.e215.

Johnson, Alistair E. W., Lucas Bulgarelli, Lu Shen, et al. 2023. „MIMIC-IV, a freely accessible electronic health record dataset". *Scientific Data* 10 (1): 1. https://doi.org/10.1038/s41597-022--01899-x.

Johnson, Alistair, Lucas Bulgarelli, Tom Pollard, et al. 2024. *MIMIC-IV*. Verze 3.1. PhysioNet. https://doi.org/10.13026/kpb9-mt58.

Johnson, Alistair, Tom Pollard, Steven Horng, Leo Anthony Celi, a Roger Mark. 2023. *MIMIC--IV-Note: Deidentified free-text clinical notes*. Verze 2.2. PhysioNet. https://doi.org/10.13026/1n74-ne17.