Explorační analýza datové sady: přehled korpusu MIMIC-IV

Martin Žoha

Abstrakt Dokument zahajuje explorační analýzu datové sady, na které práce staví. Popisuje zdroje dat (MIMIC-IV, MIMIC-IV-Note a MIMIC-IV-Ext-BHC), cestu dat od stažení po dotazování a ochranu dat podle licence. Přehled korpusu uvádí pro každou tabulku počet záznamů, počet sloupců a velikost souboru a porovnává počty záznamů v databázi s manifestem validace. Dokument tak vymezuje východiska, na kterých staví další části analýzy.

Obsah

1 Úvod 1
2 Data a metody 2
3 Přehled korpusu 2
4 Shrnutí a rozhodnutí 4
5 Omezení 4
Příloha A: provenance renderu 4
Literatura 6

1 Úvod

Tento sešit je prvním z řady sešitů explorační analýzy. Jeho úlohou je charakterizovat datovou sadu, na které stojí celá práce, a zdokumentovat, odkud data pocházejí a jak se k nim dokument dostává. Sešit si klade tři cíle:

- popsat zdroje dat a jejich licenční omezení,
- popsat cestu dat od stažení po dotazování a způsob, jakým dokument chrání data pacientů,
- uvést přehled korpusu: tabulky, jejich obsah, počty záznamů a velikost.

Práce vychází z návrhu, podle kterého jsou primárním korpusem propouštěcí zprávy (tabulka `discharge`), radiologické zprávy jsou doplňkové a štítky klasifikace se odvozují z diagnóz ICD (tabulka `diagnoses_icd`). Dokument tato východiska nepotvrzuje ani nevyvrací; ověřuje jen, že potřebné tabulky existují a zda jsou úplné.

Data pocházejí ze tří projektů PhysioNetu (Goldberger et al. 2000). Strukturovaná data hospitalizací poskytuje MIMIC-IV (Johnson et al. 2024; A. E. W. Johnson et al. 2023), volné texty zpráv MIMIC-IV-Note (A. Johnson et al. 2023) a referenční sekci Brief Hospital Course MIMIC-IV-Ext-BHC (Aali et al. 2025, 2024). Všechny projekty podléhají smlouvě o užívání dat (DUA). Dokument proto zveřejňuje jen agregované výsledky, nikdy řádková data ani texty zpráv.

Dokument je členěn takto. Kapitola 2 popisuje zdroje dat a metody. Kapitola 3 uvádí přehled korpusu. Kapitola 4 shrnuje výsledky a kapitola 5 jmenuje omezení. Příloha A dokumentuje provenance renderu.

2 Data a metody

Práce používá tři projekty PhysioNetu. MIMIC-IV, verze 3.1 (Johnson et al. 2024), obsahuje strukturovaná data hospitalizací; dokument z něj čte moduly `hosp` (pacienti, přijetí, diagnózy, výkony, léky). MIMIC-IV-Note, verze 2.2 (A. Johnson et al. 2023), obsahuje deidentifikované volné texty a dokument z něj čte propouštěcí a radiologické zprávy. MIMIC-IV-Ext-BHC, verze 1.2.0 (Aali et al. 2025, 2024), obsahuje pro zprávy MIMIC-IV-Note sekci Brief Hospital Course vytaženou regulárním výrazem autorů datasetu; práce ji používá jen jako referenci pro validaci parseru sekcí. Popis MIMIC-IV a jeho vzniku uvádí A. E. W. Johnson et al. (2023).

Data podléhají DUA. Dokument dodržuje tato pravidla:

- řádková data a texty zpráv se nevypisují,
- výsledky jsou agregáty; skupiny pacientů vymezené kvaziidentifikátorem (například věkem, pohlavím, obdobím nebo diagnózou) a kategorie, jejichž popisek je hodnota z dat, se pod deset záznamů sloučí do řádku „ostatní (n < 10)“ a jejich popisky se nezobrazí; práh je pravidlo práce, DUA malé počty neupravuje,
- metriky korpusu a textu, například počty záznamů tabulek, nepopisují skupiny pacientů, a proto se uvádějí přesně,
- skutečná data zpracovává jen autor mimo automatizované nástroje; automatizovaná kontrola běží nad syntetickými tabulkami stejného tvaru a ověřuje, že jejich obsah neunikl do výstupu.

Data procházejí těmito kroky: stažení souborů `csv.gz` (MIMIC-IV-Ext-BHC je prosté `csv`) z PhysioNetu, ověření jejich otisků SHA-256 proti oficiálním hodnotám, validace (počet záznamů a sloupců), převod na parquet a dotazování přes DuckDB. Převod do parquetu zachovává všechny sloupce jako text a počet záznamů ověřuje proti validaci. Dotazy nad parquetem provádí DuckDB s omezenou pamětí a s dočasnými soubory mimo verzovaný obsah repozitáře.

Reprodukovatelnost zajišťují dva mechanismy. Výsledky výpočtů se ukládají do zmražené podoby (`freeze`), takže dokument lze znovu vyrenderovat bez přístupu k datům. Příloha A uvádí provenance renderu: revizi kódu, otisk zámku prostředí, zdroj dat a verze použitých nástrojů.

3 Přehled korpusu

Databáze obsahuje 13 tabulek. Tabulka 1 uvádí pro každou z nich projekt a modul, popis obsahu a plánované využití v práci, počet záznamů v databázi, počet sloupců a velikost staženého souboru podle manifestu validace (u `csv.gz` komprimovaného, u BHC nekomprimovaného). Využití tabulek v práci vychází z návrhu práce.

Tabulka 1: Tabulky korpusu: zdroj, obsah a využití, počet záznamů, počet sloupců a velikost souboru (MB).

Tabulka	Zdroj	Obsah a využití	Záznamů	Sloupců	MB
admissions	MIMIC-IV (hosp)	Hospitalizace: čas přijetí a propuštění, typ přijetí; vazba zpráv na pacienty.	546 028	16	20
d_icd_diagnoses	MIMIC-IV (hosp)	Číselník diagnóz ICD; názvy ke kódům.	112 107	3	1
d_icd_procedures	MIMIC-IV (hosp)	Číselník výkonů ICD; názvy ke kódům.	86 423	3	1
diagnoses_icd	MIMIC-IV (hosp)	Diagnózy ICD přiřazené hospitalizacím; zdroj štítků klasifikace.	6 364 488	5	34
discharge	MIMIC-IV--Note (note)	Propouštěcí zprávy; primární korpus práce.	331 793	8	1 139
mimic-iv-bhc	MIMIC-IV--Ext-BHC	Brief Hospital Course vytažený regexem autorů datasetu; reference validace parseru sekcí.	270 033	5	2 726
omr	MIMIC-IV (hosp)	Ambulantní měření (například výška, hmotnost, tlak); kontext zprávy.	7 753 027	5	44
patients	MIMIC-IV (hosp)	Pacienti: pohlaví, věk a rok ukotvení; podklad dělení dat po pacientech.	364 627	6	3
pharmacy	MIMIC-IV (hosp)	Lékárenské záznamy o lécích; kontext zprávy.	17 847 567	27	526
prescriptions	MIMIC-IV (hosp)	Předpisy léků; kontext zprávy.	20 292 611	21	606
procedures_icd	MIMIC-IV (hosp)	Výkony ICD přiřazené hospitalizacím; kontext zprávy.	859 655	6	8
radiology	MIMIC-IV--Note (note)	Radiologické zprávy; dokplňkový korpus.	2 321 355	8	782
services	MIMIC-IV (hosp)	Služby, na kterých pacient během hospitalizace ležel; kontext zprávy.	593 071	5	9

Zdroj: počty záznamů dotazem v DuckDB, počty sloupců a velikosti souborů z manifestu validace, popisy podle veřejné dokumentace MIMIC-IV, MIMIC-IV-Note a MIMIC-IV-Ext-BHC.

Podle návrhu práce je primárním korpusem tabulka `discharge`; obsahuje 331 793 záznamů. Radiologických zpráv je v tabulce `radiology` 2 321 355. Nejvíce záznamů má tabulka prescriptions. Počty záznamů v databázi odpovídají počtům v manifestu validace.

4 Shrnutí a rozhodnutí

Dokument popsal zdroje dat, cestu dat k dotazování a přehled 13 tabulek. Počty záznamů u všech tabulek odpovídají manifestu validace. Data jsou proto úplná a další části analýzy mohou stavět na parquetu bez další kontroly počtu záznamů.

5 Omezení

Přehled uvádí jen počty záznamů, sloupců a velikosti souborů. O obsahu zpráv, pacientech ani rozdělení dat netvrdí nic; to je předmětem dalších částí analýzy. Počty se vztahují k verzím 3.1 (MIMIC-IV), 2.2 (MIMIC-IV-Note) a 1.2.0 (MIMIC-IV-Ext-BHC). Automatizovaná kontrola neprohledává text uvnitř obrázků, proto grafy vyžadují zvláštní zacházení.

Příloha A: provenance renderu

Tabulka 2 uvádí údaje, podle kterých lze render dohledat a zopakovat: revizi kódu, otisk zámku prostředí, zdroj dat a verze použitých nástrojů.

Tabulka 2: Provenance renderu.

Položka	Hodnota
Revize kódu (commit)	79250763bf3ad8bdc7c449bb979ce349faaa74e9
Necommitnuté změny	ne
Otisk pixi.lock (SHA-256)	b6e3a2e9c741dc11 94b6b3e9dc009c37 4a0a9de334962174 f8ded80cac5ea5c5
Zdroj dat	otisky CSV z config/mimic_tables.json
Otisk discharge.csv.gz (SHA-256)	27bc552edaf81c2a f322040cb7e8eb36 417173b23c79405b b92fcf73bef2dbc5
Otisk radiology.csv.gz (SHA-256)	2c09bc76ee12d5f3 b8f572deb7218fba f3e59b32eccfdae1 4686e05ae099eebb
Otisk admissions.csv.gz (SHA-256)	a9584ed88e9ed664 a2f66f86a5cf9fd1 75c8bb0af50e3b61 15598b19e978384e
Otisk d_icd_diagnoses.csv.gz (SHA-256)	a81065bf45ccf74f 589bec855bbb0a07 b5c014907b34ff76 fe20583a2c87cc79
Otisk d_icd_procedures.csv.gz (SHA-256)	2ac8afcb99fd16b ce2e6c7ad445e3bd 1dfd658e52182313 0ab08b66fdd3d6d4
Otisk diagnoses_icd.csv.gz (SHA-256)	47665a41b2a3ad99 0d6f314062d5bd6d 29d467b0fd402dd9 4662044ec8b073d2
Otisk omr.csv.gz (SHA-256)	8280a8023203bddc 6cc4419bd8cd253a 015b8bc0bc53852e c92f98c7353f31e2
Otisk patients.csv.gz (SHA-256)	4c7507de7ecad8c5 ba7647ea4d26018e 88ff6672c5fc22ab 59c2a5697d687cdd
Otisk pharmacy.csv.gz (SHA-256)	c9885721e4c968f0 773145d7f6ba4d3c c3755d5600ee400f f95b1d3238053811
Otisk prescriptions.csv.gz (SHA-256)	0d8481c7d5d7c9ec 2fea3fc543ddaaad b5a933cd22c7b9dd a4289361e4d77199
Otisk procedures_icd.csv.gz (SHA-256)	3271397d0517131f 84399b698cbb0c2f 435aaab0f873a380 6e13b097661596f7
Otisk services.csv.gz (SHA-256)	31c82ebee94e0c04 d6966fbfec30579e c00f9c7816b80852 f9580656e6183888
Otisk mimic-iv-bhc.csv (SHA-256)	e45c09997b25d744 abb20573623885eb a052299cf2a721c1 8bbf5ca9a54989c1
Python	3.13.16
DuckDB	1.5.6

Literatura

Aali, Asad, Dave Van Veen, Yamin Ishraq Arefeen, et al. 2024. „A dataset and benchmark for hospital course summarization with adapted large language models". *Journal of the American Medical Informatics Association* 32 (3): 470–79. https://doi.org/10.1093/jamia/ocae312.

Aali, Asad, Dave Van Veen, Yamin Ishraq Arefeen, et al. 2025. *MIMIC-IV-Ext-BHC: Labeled Clinical Notes Dataset for Hospital Course Summarization*. Verze 1.2.0. PhysioNet. https://doi.org/10.13026/5gte-bv70.

Goldberger, Ary L., Luis A. N. Amaral, Leon Glass, et al. 2000. „PhysioBank, PhysioToolkit, and PhysioNet: Components of a new research resource for complex physiologic signals". *Circulation* 101 (23): e215–20. https://doi.org/10.1161/01.CIR.101.23.e215.

Johnson, Alistair E. W., Lucas Bulgarelli, Lu Shen, et al. 2023. „MIMIC-IV, a freely accessible electronic health record dataset". *Scientific Data* 10 (1): 1. https://doi.org/10.1038/s41597-022--01899-x.

Johnson, Alistair, Lucas Bulgarelli, Tom Pollard, et al. 2024. *MIMIC-IV*. Verze 3.1. PhysioNet. https://doi.org/10.13026/kpb9-mt58.

Johnson, Alistair, Tom Pollard, Steven Horng, Leo Anthony Celi, a Roger Mark. 2023. *MIMIC--IV-Note: Deidentified free-text clinical notes*. Verze 2.2. PhysioNet. https://doi.org/10.13026/1n74-ne17.