

Explorační analýza datové sady: přehled korpusu MIMIC-IV

Martin Žoha

Abstrakt Dokument zahajuje explorační analýzu datové sady, na které práce staví. Popisuje zdroje dat (MIMIC-IV a MIMIC-IV-Note), cestu dat od stažení po dotazování a ochranu dat podle licence. Přehled korpusu uvádí pro každou tabulku počet záznamů, počet sloupců a velikost souboru a porovnává počty záznamů v databázi s manifestem validace. Dokument tak vymezuje východiska, na kterých staví další části analýzy.

Obsah

1 Úvod	1
2 Data a metody	2
3 Přehled korpusu	2
4 Shrnutí a rozhodnutí	4
5 Omezení	4
Příloha A: provenance renderu	4
Literatura	6

1 Úvod

Tento sešit je prvním z řady sešitů explorační analýzy. Jeho úlohou je charakterizovat datovou sadu, na které stojí celá práce, a zdokumentovat, odkud data pocházejí a jak se k nim dokument dostává. Sešit si klade tři cíle:

- popsat zdroje dat a jejich licenční omezení,
- popsat cestu dat od stažení po dotazování a způsob, jakým dokument chrání data pacientů,
- uvést přehled korpusu: tabulky, jejich obsah, počty záznamů a velikost.

Práce vychází z návrhu, podle kterého jsou primárním korpusem propouštěcí zprávy (tabulka [discharge](#)), radiologické zprávy jsou doplňkové a štítky klasifikace se odvozují z diagnóz ICD (tabulka [diagnoses_icd](#)). Dokument tato východiska nepotvrzuje ani nevyvrací; ověřuje jen, že potřebné tabulky existují a zda jsou úplné.

Data pocházejí ze dvou projektů PhysioNetu (Goldberger et al. 2000). Strukturovaná data hospitalizací poskytuje MIMIC-IV (Johnson et al. 2024; A. E. W. Johnson et al. 2023), volné texty zpráv MIMIC-IV-Note (A. Johnson et al. 2023). Oba projekty podléhají smlouvě o užívání dat (DUA). Dokument proto zveřejňuje jen agregované výsledky, v nichž jsou kategorie s méně než deseti záznamy potlačeny.

Dokument je členěn takto. Kapitola 2 popisuje zdroje dat a metody. Kapitola 3 uvádí přehled korpusu. Kapitola 4 shrnuje výsledky a kapitola 5 jmenuje omezení. Příloha A dokumentuje provenance renderu.

2 Data a metody

Práce používá dva projekty PhysioNetu. MIMIC-IV, verze 3.1 (Johnson et al. 2024), obsahuje strukturovaná data hospitalizací; dokument z něj čte moduly `hosp` (pacienti, přijetí, diagnózy, výkony, léky). MIMIC-IV-Note, verze 2.2 (A. Johnson et al. 2023), obsahuje deidentifikované volné texty a dokument z něj čte propouštěcí a radiologické zprávy. Popis MIMIC-IV a jeho vzniku uvádí A. E. W. Johnson et al. (2023).

Data podléhají DUA. Z toho plyne několik pravidel, která dokument dodržuje:

- řádková data a texty zpráv se nevypisují,
- výsledky jsou agregáty a kategorie s méně než deseti záznamy se sloučí do řádku „ostatní ($n < 10$)“ a jejich popisky se nezobrazí; číslo pod prahem se zobrazí jako „ < 10 “,
- skutečná data zpracovává jen autor mimo automatizované nástroje; automatizovaná kontrola běží nad syntetickými tabulkami stejného tvaru a ověřuje, že jejich obsah neunikl do výstupu.

Data procházejí těmito kroky: stažení souborů `csv.gz` z PhysioNetu, ověření jejich otisků SHA-256 proti oficiálním hodnotám, validace (počet záznamů a sloupců), převod na parquet a dotazování přes DuckDB. Přebod do parquetu zachovává všechny sloupce jako text a počet záznamů ověřuje proti validaci. Dotazy nad parquetem provádí DuckDB s omezenou pamětí a s dočasnými soubory mimo verzovaný obsah repozitáře.

Reprodukovatelnost zajišťují dva mechanismy. Výsledky výpočtů se ukládají do zmražené podoby (`freeze`), takže dokument lze znovu vyrenderovat bez přístupu k datům. Příloha A uvádí provenance renderu: revizi kódu, otisk zámku prostředí, zdroj dat a verze použitých nástrojů.

3 Přehled korpusu

Databáze obsahuje 12 tabulek. Tabulka 1 uvádí pro každou z nich projekt a modul, popis obsahu a plánované využití v práci, počet záznamů v databázi, počet sloupců a velikost komprimovaného souboru podle manifestu validace. Využití tabulek v práci vychází z návrhu práce.

Tabulka 1: Tabulky korpusu: zdroj, obsah a využití, počet záznamů, počet sloupců a velikost souboru (MB).

Tabulka	Zdroj	Obsah a využití	Záznamů	Sloupců	MB
<code>admissions</code>	MIMIC-IV (hosp)	Hospitalizace: čas přijetí a propuštění, typ přijetí; vazba zpráv na pacienty.	546 028	16	20
<code>d_icd_diagnoses</code>	MIMIC-IV (hosp)	Číselník diagnóz ICD; názvy ke kódům.	112 107	3	1
<code>d_icd_procedures</code>	MIMIC-IV (hosp)	Číselník výkonů ICD; názvy ke kódům.	86 423	3	1
<code>diagnoses_icd</code>	MIMIC-IV (hosp)	Diagnózy ICD přiřazené hospitalizacím; zdroj štítků klasifikace.	6 364 488	5	34
<code>discharge</code>	MIMIC-IV-Note (note)	Propouštěcí zprávy; primární korpus práce.	331 793	8	1 139
<code>omr</code>	MIMIC-IV (hosp)	Ambulantní měření (například výška, hmotnost, tlak); kontext zprávy.	7 753 027	5	44
<code>patients</code>	MIMIC-IV (hosp)	Pacienti: pohlaví, věk a rok ukotvení; podklad dělení dat po pacientech.	364 627	6	3
<code>pharmacy</code>	MIMIC-IV (hosp)	Lékařenské záznamy a léčby; kontext zprávy.	17 847 567	27	526
<code>prescriptions</code>	MIMIC-IV (hosp)	Předpisy léků; kontext zprávy.	20 292 611	21	606
<code>procedures_icd</code>	MIMIC-IV (hosp)	Výkony ICD přiřazené hospitalizacím; kontext zprávy.	859 655	6	8
<code>radiology</code>	MIMIC-IV-Note (note)	Radiologické zprávy; do-2 plňkový korpus.	2 321 355	8	782
<code>services</code>	MIMIC-IV (hosp)	Služby, na kterých pacient během hospitalizace ležel; kontext zprávy.	593 071	5	9

Zdroj: počty záznamů dotazem v DuckDB, počty sloupců a velikosti souborů z manifestu validace, popisy podle veřejné dokumentace MIMIC-IV a MIMIC-IV-Note.

Podle návrhu práce je primárním korpusem tabulka `discharge`; obsahuje 331 793 záznamů. Radiologických zpráv je v tabulce `radiology` 2 321 355. Nejvíce záznamů má tabulka `prescriptions`. Počty záznamů v databázi se shodují s počty v manifestu validace.

4 Shrnutí a rozhodnutí

Dokument popsal zdroje dat, cestu dat k dotazování a přehled 12 tabulek. Počty záznamů se u všech tabulek shodují s manifestem validace. Data jsou proto úplná a další části analýzy mohou stavět na parquetu bez další kontroly počtu záznamů.

5 Omezení

Přehled uvádí jen počty záznamů, sloupců a velikosti souborů. O obsahu zpráv, pacientech ani rozdělení dat netvrdí nic; to je předmětem dalších částí analýzy. Počty se vztahují k verzím 3.1 (MIMIC-IV) a 2.2 (MIMIC-IV-Note). Potlačení kategorií s $n < 10$ chrání malé skupiny, ale nezabraňuje odvození z rozdílu dvou zveřejněných součtů, proto se zveřejňují jen předem určené agregace. Automatizovaná kontrola neprohledává text uvnitř obrázků, proto grafy vyžadují zvláštní zacházení.

Příloha A: provenance renderu

Tabulka 2 uvádí údaje, podle kterých lze render dohledat a zopakovat: revizi kódu, otisk zámku prostředí, zdroj dat a verze použitých nástrojů.

Tabulka 2: Provenance renderu.

Položka	Hodnota
Revize kódu (commit)	b1c79ebae4ba3c50fd7c987e45f50b24a038bd81
Necommitnuté změny	ne
Otisk pixi.lock (SHA-256)	fddaa503186e36c9 6a2da977486f402d 47bdea58afdc3972 b154c8c586a0e4ca
Zdroj dat	otisky CSV z config/mimic_tables.json
Otisk discharge.csv.gz (SHA-256)	27bc552edaf81c2a f322040cb7e8eb36 417173b23c79405b b92fcf73bef2dbc5
Otisk radiology.csv.gz (SHA-256)	2c09bc76ee12d5f3 b8f572deb7218fba f3e59b32eccfdae1 4686e05ae099eebb
Otisk admissions.csv.gz (SHA-256)	a9584ed88e9ed664 a2f66f86a5cf9fd1 75c8bb0af50e3b61 15598b19e978384e
Otisk d_icd_diagnoses.csv.gz (SHA-256)	a81065bf45ccf74f 589bec855bbb0a07 b5c014907b34ff76 fe20583a2c87cc79
Otisk d_icd_procedures.csv.gz (SHA-256)	2c2c8afcb99fd16b ce2e6c7ad445e3bd 1dfd658e52182313 0ab08b66fdd3d6d4
Otisk diagnoses_icd.csv.gz (SHA-256)	47665a41b2a3ad99 0d6f314062d5bd6d 29d467b0fd402dd9 4662044ec8b073d2
Otisk omr.csv.gz (SHA-256)	8280a8023203bddc 6cc4419bd8cd253a 015b8bc0bc53852e c92f98c7353f31e2
Otisk patients.csv.gz (SHA-256)	4c7507de7ecad8c5 ba7647ea4d26018e 88ff6672c5fc22ab 59c2a5697d687cdd
Otisk pharmacy.csv.gz (SHA-256)	c9885721e4c968f0 773145d7f6ba4d3c c3755d5600ee400f f95b1d3238053811
Otisk prescriptions.csv.gz (SHA-256)	0d8481c7d5d7c9ec 2fea3fc543ddaaad b5a933cd22c7b9dd a4289361e4d77199
Otisk procedures_icd.csv.gz (SHA-256)	3271397d0517131f 84399b698cbb0c2f 435aaab0f873a380 6e13b097661596f7
Otisk services.csv.gz (SHA-256)	31c82ebee94e0c04 d6966fbfec30579e c00f9c7816b80852 f9580656e6183888
Python	3.13.16
DuckDB	1.5.6
R	R version 4.5.3 (2026-03-11)

Literatura

Goldberger, Ary L., Luis A. N. Amaral, Leon Glass, et al. 2000. „PhysioBank, PhysioToolkit, and PhysioNet: Components of a new research resource for complex physiologic signals". *Circulation* 101 (23): e215–20. <https://doi.org/10.1161/01.CIR.101.23.e215>.

Johnson, Alistair E. W., Lucas Bulgarelli, Lu Shen, et al. 2023. „MIMIC-IV, a freely accessible electronic health record dataset". *Scientific Data* 10 (1): 1. <https://doi.org/10.1038/s41597-022-01899-x>.

Johnson, Alistair, Lucas Bulgarelli, Tom Pollard, et al. 2024. *MIMIC-IV*. Verze 3.1. PhysioNet. <https://doi.org/10.13026/kpb9-mt58>.

Johnson, Alistair, Tom Pollard, Steven Horng, Leo Anthony Celi, a Roger Mark. 2023. *MIMIC-IV-Note: Deidentified free-text clinical notes*. Verze 2.2. PhysioNet. <https://doi.org/10.13026/1n74-ne17>.