# Explorační analýza datové sady: pacienti, přijetí a éra ICD

Martin Žoha

**Abstrakt** Dokument popisuje strukturu korpusu z pohledu pacientů a hospitalizací. Uvádí počty pacientů a přijetí, rozdělení počtu propouštěcích zpráv na pacienta a na přijetí, pokrytí zpráv diagnózami ICD přes identifikátor přijetí a rozdělení hospitalizací mezi éry ICD-9 a ICD-10 včetně rozpadu podle tříletého období. Výsledky podkládají volbu primárního korpusu, způsob rozdělení dat na trénovací a testovací část a přípravu štítků z diagnóz ICD.

## Obsah

1 Úvod ..... 1
2 Data a metody ..... 2
3 Výsledky ..... 2
3.1 Pacienti a zprávy ..... 2
3.2 Pokrytí identifikátorem přijetí a diagnózou ICD ..... 3
3.3 Éra ICD ..... 4
4 Shrnutí a rozhodnutí ..... 5
5 Omezení ..... 5
Příloha A: provenance renderu ..... 5
Literatura ..... 7

## 1 Úvod

Tento sešit je druhým z řady sešitů explorační analýzy. Navazuje na přehled korpusu v prvním sešitu a popisuje, jak jsou zprávy rozloženy mezi pacienty a hospitalizace a jak se k nim dají připojit diagnózy ICD. Sešit si klade tři cíle:

- zjistit, kolik pacientů a přijetí korpus obsahuje a kolik zpráv připadá na pacienta a na přijetí,
- změřit, u jakého podílu zpráv lze přes identifikátor přijetí (`hadm_id`) získat diagnózu ICD,
- rozdělit hospitalizace podle verze ICD, ve které jsou kódovány, a zjistit, kdy v čase leží přechod mezi verzemi.

Rozdělení dat na trénovací a testovací část se provádí po pacientech, aby tentýž pacient nebyl v obou částech a nedošlo k úniku informací. Počty zpráv na pacienta proto určují, jak velký vliv má volba jednotky dělení. Štítky klasifikace vznikají z diagnóz ICD připojených přes `hadm_id`; pokrytí tohoto spojení proto rozhoduje, které zprávy mají štítek. Verze ICD ovlivňuje volbu mezi náhodným a časovým rozdělením a přípravu mapování kódů.

Data pocházejí z MIMIC-IV (Johnson et al. 2024; A. E. W. Johnson et al. 2023) a MIMIC-IV-Note (A. Johnson et al. 2023), které podléhají smlouvě o užívání dat (DUA). Dokument proto zveřejňuje jen agregáty, nikdy řádková data ani texty zpráv. Počty pacientů, přijetí a zpráv, pokrytí a rozdělení podle verze ICD jsou metriky korpusu, které nevymezují skupiny pacientů kvaziidentifikátorem, a uvádějí se přesně. Rozpad hospitalizací podle období ukotvení pacienta takové skupiny vymezuje, a proto se v něm kategorie s méně než deseti hospitalizacemi sloučí do řádku „ostatní (n < 10)“; práh je pravidlo práce, DUA malé počty neupravuje.

Dokument je členěn takto. Kapitola 2 popisuje metody. Kapitola 3 uvádí výsledky o pacientech a zprávách, pokrytí a éře ICD. Kapitola 4 shrnuje výsledky a rozhodnutí pro další práci a kapitola 5 jmenuje omezení. Příloha A dokumentuje provenance renderu.

# 2 Data a metody

Sešit čte propouštěcí zprávy (`discharge`), radiologické zprávy (`radiology`), diagnózy ICD přiřazené hospitalizacím (`diagnoses_icd`) a pacienty (`patients`). Všechny sloupce jsou v parquetu uloženy jako text, proto se hodnoty porovnávají jako text; například verze ICD se porovnává s řetězci `'9'` a `'10'`. Dotazy provádí DuckDB nad parquetem. Dotazy jsou v `eda/R/patients.R` a mají testy nad ručně vytvořenými tabulkami; sešit jen volá funkce a formátuje jejich výstup.

Pojmy a jednotky jsou tyto:

- *pacient* je hodnota `subject_id`, *přijetí* je hodnota `hadm_id`; zpráva bez `hadm_id` se jako přijetí nepočítá,
- počet zpráv na pacienta a na přijetí je rozdělení s horním košem: pacienti s deseti a více zprávami tvoří koš „10+“, přijetí se třemi a více zprávami koš „3+“, mezi koši nejsou mezery,
- pokrytí se počítá stejně pro obě tabulky zpráv a rozlišuje dvě samostatná selhání: zpráva nemá `hadm_id`, nebo má `hadm_id`, ale přijetí nemá žádný kód ICD; jmenovatelem jsou všechny zprávy tabulky, zpráva s více kódy se počítá jednou,
- *éra ICD* je vlastnost hospitalizace s propouštěcí zprávou. Hospitalizace je jen ICD-9, jen ICD-10, nese kódy obou verzí, nebo nemá kód ICD jedné z těchto verzí (kategorie „bez kódu“). Kategorie se vylučují, takže tabulka se sečte do počtu hospitalizací.

Éra se rozpadá podle `anchor_year_group` pacienta, tedy tříletého období, do kterého spadá jeho skutečný rok ukotvení. MIMIC-IV posouvá data každého pacienta o náhodný interval (A. E. W. Johnson et al. 2023), takže kalendářní rok přijetí v datech nic nevypovídá. Hospitalizace se proto zařadí do období ukotvení svého pacienta, nikoli do období svého přijetí.

# 3 Výsledky

## 3.1 Pacienti a zprávy

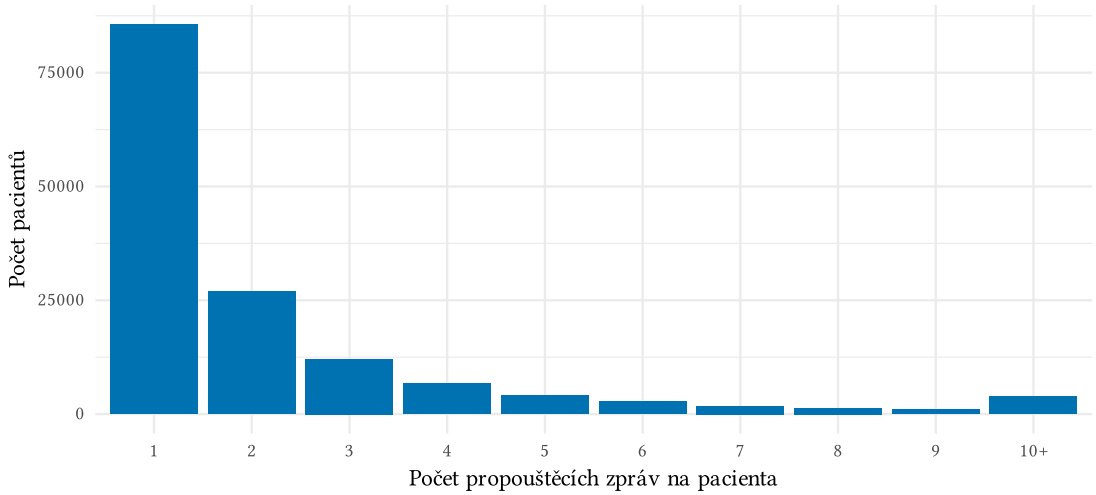
Propouštěcí zprávy pocházejí od 145 914 pacientů a patří k 331 793 přijetím. Na jednoho pacienta připadá v průměru 2,3 zprávy. Tabulka 1 uvádí počty.

Tabulka 1: Struktura propouštěcích zpráv: počty pacientů, přijetí a zpráv.

| Ukazatel | Počet | Podíl pacientů (%) |
|---|---|---|
| Pacienti | 145 914 | |
| Přijetí s propouštěcí zprávou | 331 793 | |
| Propouštěcí zprávy | 331 793 | |
| Pacienti s více než jednou zprávou | 60 308 | 41,3 |

*Zdroj:* dotazy v DuckDB nad tabulkou `discharge`; podíl se počítá z počtu pacientů.

Obrázek 1 ukazuje rozdělení počtu zpráv na pacienta. Pacienti s jedinou zprávou tvoří 58,7 % všech pacientů.




Obrázek 1: Počet propouštěcích zpráv na pacienta (koš 10+ sdružuje pacienty s deseti a více zprávami).

Tabulka 2 uvádí, kolik propouštěcích zpráv připadá na jedno přijetí. Zprávy bez `hadm_id` se do tabulky nezapočítají.

Tabulka 2: Počet propouštěcích zpráv na přijetí (koš 3+ sdružuje přijetí se třemi a více zprávami).

| Zpráv na přijetí | Přijetí | Podíl přijetí (%) |
|---|---|---|
| 1 | 331 793 | 100,0 |

## 3.2 Pokrytí identifikátorem přijetí a diagnózou ICD

Štítky klasifikace se odvozují z tabulky `diagnoses_icd` přes `hadm_id`. Zpráva proto štítek nezíská ve dvou případech: nemá `hadm_id`, nebo má `hadm_id` bez kódu ICD. Tabulka 3 uvádí obě selhání a pokrytí pro obě tabulky zpráv. Kód ICD má 99,9 % propouštěcích zpráv a 49,3 % radiologických.

Tabulka 3: Pokrytí zpráv identifikátorem přijetí a diagnózou ICD; podíly ze všech zpráv tabulky.

| Tabulka | Zpráv | Bez hadm_id | % | Bez kódu ICD | % | S kódem ICD | % |
|---|---|---|---|---|---|---|---|
| `discharge` | 331 793 | 0 | 0,0 | 189 | 0,1 | 331 604 | 99,9 |
| `radiology` | 2 321 355 | 1 176 597 | 50,7 | 660 | 0,0 | 1 144 098 | 49,3 |

*Zdroj:* dotazy v DuckDB. „Bez kódu ICD“ jsou zprávy s `hadm_id`, k němuž `diagnoses_icd` nemá žádný řádek, a tři skupiny se sečtou na počet zpráv tabulky.

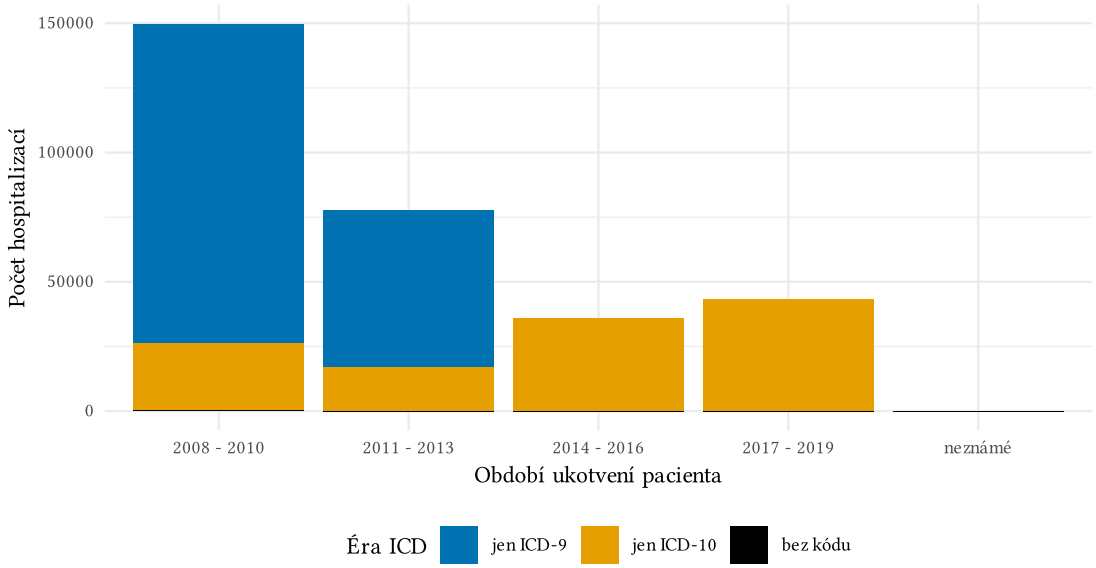
## 3.3 Éra ICD

Hospitalizace s propouštěcí zprávou je 331 793. Tabulka 4 je rozděluje podle verze ICD, ve které jsou kódovány; jen ICD-10 má 36,9 % hospitalizací, jen ICD-9 63,1 %, kódy obou verzí 0,0 % a bez kódu je 0,1 %.

Tabulka 4: Hospitalizace s propouštěcí zprávou podle verze ICD (kategorie se vylučují a sčítají se do celku).

| Éra ICD | Hospitalizací | Podíl (%) |
|---|---|---|
| jen ICD-9 | 209 316 | 63,1 |
| jen ICD-10 | 122 281 | 36,9 |
| obě éry | 7 | 0,0 |
| bez kódu | 189 | 0,1 |

Obrázek 2 rozpadá hospitalizace podle tříletého období `anchor_year_group` pacienta. Ukazuje, kde v čase leží přechod z ICD-9 na ICD-10.




Obrázek 2: Hospitalizace s propouštěcí zprávou podle období ukotvení pacienta a verze ICD; kategorie s n < 10 jsou vynechány.

Éry se překrývají: obě verze se vyskytují společně v obdobích 2008 - 2010, 2011 - 2013.

# 4 Shrnutí a rozhodnutí

Dokument popsal rozložení zpráv mezi pacienty a hospitalizace, pokrytí diagnózami ICD a rozdělení hospitalizací mezi éry ICD. Pro další práci z toho plyne:

- **Dělení po pacientech.** Rozdělení po pacientech je nutné: 41,3 % pacientů má více než jednu propouštěcí zprávu, takže dělení po zprávách by dalo stejného pacienta do trénovací i testovací části. Průměr je 2,3 zprávy na pacienta.
- **Štítky z diagnóz.** Štítky se odvozují z `diagnoses_icd` přes `hadm_id`; pokrytí propouštěcích zpráv je 99,9 %, radiologických 49,3 %. Propouštěcí zprávy mají podíl pokrytí alespoň srovnatelný s radiologickými, takže zůstávají kandidátem na primární korpus. Zprávy bez štítku se z klasifikace vyřadí.
- **Verze ICD.** Obě verze ICD se vyskytují ve stejném období, takže čas přechod čistě neodděluje; společné štítky vyžadují mapování ICD-9 na ICD-10. Hospitalizace s oběma verzemi tvoří 0,0 % a bez kódu 0,1 %.

Konečná volba korpusu a způsobu rozdělení patří do navazujícího sešitu, který vychází z těchto čísel.

# 5 Omezení

Období `anchor_year_group` je tříleté, takže poloha přechodu mezi verzemi ICD je určena jen s touto přesností. Skutečný rok přijetí se nepřepočítává z `anchor_year`, protože jeho přesnost okolo ±1,5 roku by nepřidala informaci. Kalendářní rok přijetí v datech nic neříká, protože MIMIC-IV data posouvá. Éra je určena kódy v `diagnoses_icd`; hospitalizace s kódem jiné verze než 9 a 10 se počítá jako „bez kódu“. Kategorie s n < 10 se potlačují jen v rozpadu podle období, a to uvnitř každé éry: skryté buňky se doplňují nejmenší zachovanou buňkou, dokud jejich součet není aspoň 10, takže z celku éry v Tabulka 4 a zveřejněných buněk nelze odvodit žádnou buňku pod 10. Kategorie vynechané z grafu se nezveřejňují jednotlivě. Sešit nepopisuje délku zpráv, pohlaví ani věk pacientů a nevybírá diagnózy; to je předmětem dalších sešitů.

# Příloha A: provenance renderu

Tabulka 5 uvádí údaje, podle kterých lze render dohledat a zopakovat: revizi kódu, otisk zámku prostředí, zdroj dat a verze použitých nástrojů.

Tabulka 5: Provenance renderu.

| Položka | Hodnota |
|---|---|
| Revize kódu (commit) | 1daf7c12b10c9fc58f6c34496e35447525e74c55 |
| Necommitnuté změny | ne |
| Otisk pixi.lock (SHA-256) | a31fd88e17482254 b6f24ac503afe9ba b66dd5e0b15eece7 03cb59360ba5a6fd |
| Zdroj dat | otisky CSV z config/mimic_tables.json |
| Otisk discharge.csv.gz (SHA-256) | 27bc552edaf81c2a f322040cb7e8eb36 417173b23c79405b b92fcf73bef2dbc5 |
| Otisk radiology.csv.gz (SHA-256) | 2c09bc76ee12d5f3 b8f572deb7218fba f3e59b32eccfdae1 4686e05ae099eebb |
| Otisk admissions.csv.gz (SHA-256) | a9584ed88e9ed664 a2f66f86a5cf9fd1 75c8bb0af50e3b61 15598b19e978384e |
| Otisk d_icd_diagnoses.csv.gz (SHA-256) | a81065bf45ccf74f 589bec855bbb0a07 b5c014907b34ff76 fe20583a2c87cc79 |
| Otisk d_icd_procedures.csv.gz (SHA-256) | 2ac8afcb99fd16b ce2e6c7ad445e3bd 1dfd658e52182313 0ab08b66fdd3d6d4 |
| Otisk diagnoses_icd.csv.gz (SHA-256) | 47665a41b2a3ad99 0d6f314062d5bd6d 29d467b0fd402dd9 4662044ec8b073d2 |
| Otisk omr.csv.gz (SHA-256) | 8280a8023203bddc 6cc4419bd8cd253a 015b8bc0bc53852e c92f98c7353f31e2 |
| Otisk patients.csv.gz (SHA-256) | 4c7507de7ecad8c5 ba7647ea4d26018e 88ff6672c5fc22ab 59c2a5697d687cdd |
| Otisk pharmacy.csv.gz (SHA-256) | c9885721e4c968f0 773145d7f6ba4d3c c3755d5600ee400f f95b1d3238053811 |
| Otisk prescriptions.csv.gz (SHA-256) | 0d8481c7d5d7c9ec 2fea3fc543ddaaad b5a933cd22c7b9dd a4289361e4d77199 |
| Otisk procedures_icd.csv.gz (SHA-256) | 3271397d0517131f 84399b698cbb0c2f 435aaab0f873a380 6e13b097661596f7 |
| Otisk services.csv.gz (SHA-256) | 31c82ebee94e0c04 d6966fbfec30579e c00f9c7816b80852 f9580656e6183888 |
| Python | 3.13.16 |
| DuckDB | 1.5.6 |
| R | R version 4.5.3 (2026-03-11) |

## Literatura

Johnson, Alistair E. W., Lucas Bulgarelli, Lu Shen, et al. 2023. „MIMIC-IV, a freely accessible electronic health record dataset". *Scientific Data* 10 (1): 1. https://doi.org/10.1038/s41597-022--01899-x.

Johnson, Alistair, Lucas Bulgarelli, Tom Pollard, et al. 2024. *MIMIC-IV*. Verze 3.1. PhysioNet. https://doi.org/10.13026/kpb9-mt58.

Johnson, Alistair, Tom Pollard, Steven Horng, Leo Anthony Celi, a Roger Mark. 2023. *MIMIC--IV-Note: Deidentified free-text clinical notes*. Verze 2.2. PhysioNet. https://doi.org/10.13026/1n74-ne17.