Explorační analýza datové sady: délka zpráv a deidentifikace

Martin Žoha

Abstrakt Dokument popisuje délku propouštěcích a radiologických zpráv a stopy deidentifikace v jejich textu. Uvádí rozdělení délky ve znacích a slovech, počty značek ___ na zprávu, zbytkové masky jiného typu, kvalitu dat (prázdné, krátké, extrémně dlouhé a duplicitní zprávy) a masku věku. Výsledky podkládají rozpočet chunků při překladu, volbu primárního korpusu, kontrolu počtu značek mezi originálem a překladem a normalizaci masek v předzpracování.

Obsah

1 Úvod 1
2 Data a metody 2
3 Výsledky 2
3.1 Délka zpráv 2
3.2 Značky ___ 4
3.3 Zbytkové masky 4
3.4 Kvalita dat 4
3.5 Maska věku v textu 5
4 Shrnutí a rozhodnutí 5
5 Omezení 6
Příloha A: provenance renderu 6
Literatura 8

1 Úvod

Tento sešit je třetím z řady sešitů explorační analýzy. Navazuje na přehled korpusu a na rozložení zpráv mezi pacienty a popisuje, jak jsou zprávy dlouhé a co z deidentifikace zůstalo v jejich textu. Sešit klade čtyři otázky:

- jak dlouhé jsou propouštěcí (`discharge`) a radiologické (`radiology`) zprávy ve znacích a ve slovech a kolik textu se vejde do jednoho kroku překladu,
- kolik značek ___ zprávy obsahují, protože překlad musí jejich počet zachovat,
- zda v textu zůstaly masky jiného typu než ___, tedy `[**…**]`, HTML značky a `XXX`,
- zda je v textu zprávy zachycen věk pacienta a jak často ho nahrazuje maska.

Délka zprávy určuje, kolik zpráv se musí při překladu dělit na části. Počet značek ___ je veličina, kterou kontrola překladu porovnává mezi originálem a překladem. Zprávy, které jsou prázdné, příliš krátké nebo duplicitní, se do korpusu nehodí a jejich počet se proto zjišťuje už

zde. Věk pacienta se do textu zpráv v deidentifikované podobě nedostává a případné dosazení závisí na tom, co text skutečně obsahuje.

Data pocházejí z MIMIC-IV (Johnson et al. 2024; A. E. W. Johnson et al. 2023) a MIMIC-IV-Note (A. Johnson et al. 2023). Metriky textu nepopisují skupiny pacientů, a proto se zveřejňují přesně. Z textu zpráv se nezveřejňuje žádný řetězec ani kontext, jen počty a míry.

Kapitola 2 popisuje metody. Kapitola 3 uvádí výsledky o délkách, značkách, zbytkových maskách, kvalitě dat a věku. Kapitola 4 shrnuje výsledky a rozhodnutí pro další práci a kapitola 5 jmenuje omezení. Příloha A dokumentuje provenance renderu.

2 Data a metody

Sešit čte propouštěcí a radiologické zprávy, konkrétně sloupec `text`. Metriky se počítají jedním průchodem textu: dočasná tabulka DuckDB nese pro každou zprávu délku, počet slov, počty značek a masek, příznaky věku a otisk textu, a všechny agregace čtou jen ji. Dotazy jsou v `eda/R/text.R` a mají testy nad ručně vytvořenými tabulkami; sešit jen volá funkce a formátuje jejich výstup.

Pojmy a jednotky jsou tyto:

- *délka* je počet znaků textu, *slovo* je souvislý úsek znaků bez mezer, tabulátorů a konců řádků; věty se neměří a délku v jednotkách jazykového modelu měří až analýza tokenizace,
- *značka* je přesně tři podtržítka mezi znaky, které nejsou podtržítkem; stejnou definici používá kontrola překladu. Úsek čtyř a více podtržítek za značku nepočítá a vykazuje se zvlášť jako *delší úsek*,
- *zbytkové masky* jsou tři vzory: `[**…**]`, HTML značka (`<…>`, od `<` s písmenem po `>`) a tři a více písmen `X` (`XXX`); u každého vzoru se uvádí počet zpráv a počet výskytů,
- *přesná duplicita* je zpráva se shodným textem jako jiná zpráva; počet duplicit je počet zpráv bez počtu různých textů, takže tři stejné zprávy dávají dvě duplicity. Prázdný text se do duplicit nepočítá,
- *kvalita dat* rozlišuje prázdný nebo chybějící text, text kratší než 100 znaků, text o 100 až 500 znacích a text delší než 50 000 znaků,
- *maska věku* je `___` následované zápisem „year old“, „yo“, „y/o“ nebo „y.o.“, *kotva* je maska věku ve větě „is a `___` year old“ a *číselný věk* je číslo před týmž zápisem. Hledá se bez ohledu na velikost písmen a jen v propouštěcích zprávách, kde je věk pacienta cílem extrakce.

Délka se zobrazuje v logaritmických koších o šířce 0,1 dekády; zpráva o délce 0 nebo 1 znaku patří do prvního koše. Uvádí se minimum, maximum a percentily 1., 5., 10., 25., 50., 75., 90., 95. a 99. Strukturovaný věk pacienta (`anchor_age`) sešit nepoužívá, patří do sešitu o demografii.

3 Výsledky

3.1 Délka zpráv

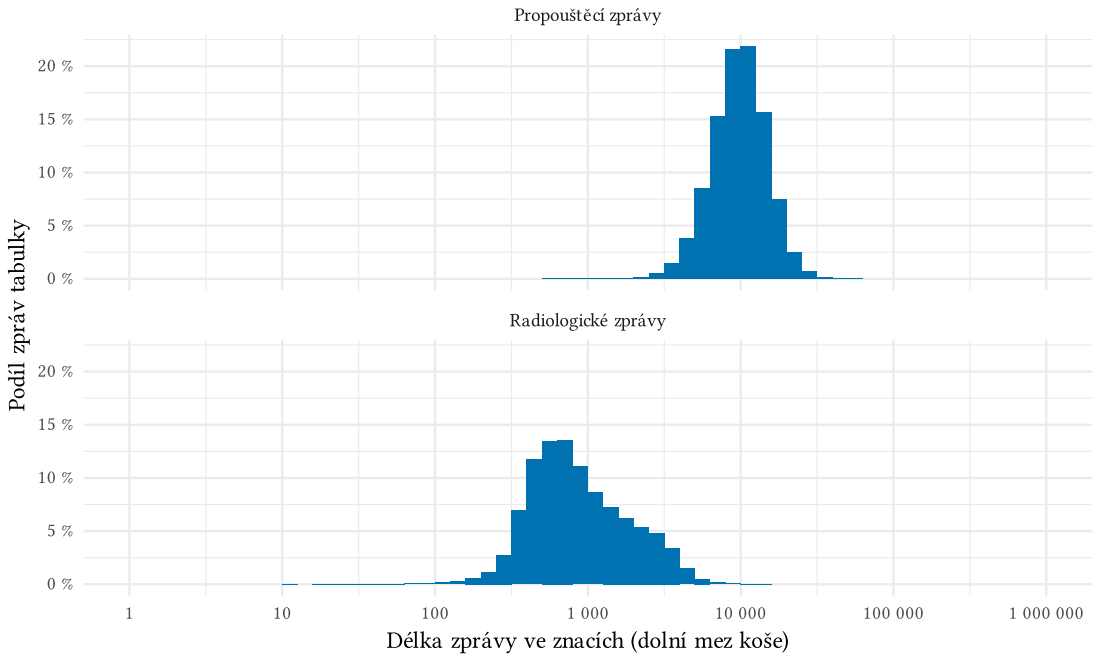
Tabulka 1 uvádí rozdělení délky ve znacích a slovech pro obě tabulky. Medián délky propouštěcí zprávy je 9 847 znaků a 95. percentil 18 619 znaků.

Tabulka 1: Rozdělení délky zpráv ve znacích a slovech (včetně nejmenší a největší hodnoty).

Ukazatel	Propouštěcí: znaky	Propouštěcí: slova	Radiologické: znaky	Radiologické: slova
Zpráv	331 793	331 793	2 321 355	2 321 355
Průměr	10 551,0	1 600,2	1 158,9	168,7
Minimum	353	44	3	1
1. percentil	3 297	486	180	26
5. percentil	4 771	718	313	44
10. percentil	5 676	859	378	53
25. percentil	7 462	1 135	511	73
Medián	9 847	1 501	781	112
75. percentil	12 831	1 952	1 440	210
90. percentil	16 159	2 447	2 566	377
95. percentil	18 619	2 806	3 280	484
99. percentil	24 712	3 691	4 702	699
Maximum	60 381	9 026	35 849	3 081

Zdroj: dotazy v DuckDB nad sloupcem `text`; „–“ znamená, že tabulka nemá žádnou zprávu.

Obrázek 1 ukazuje podíl zpráv v logaritmických koších délky. Každá tabulka má vlastní panel a podíl se počítá z počtu zpráv této tabulky.



Obrázek 1: Rozdělení délky zpráv ve znacích v logaritmických koších (šířka koše 0,1 dekády); podíl neprázdných zpráv tabulky, všechny koše.

3.2 Značky ___

Kontrola překladu porovnává počet značek ___ mezi originálem a překladem. Tabulka 2 uvádí, kolik zpráv značky obsahuje, kolik jich je celkem a jak se počet značek rozděluje na zprávu.

Tabulka 2: Značky na zprávu: zprávy se značkou, součet značek, delší úseky podtržítek a rozdělení počtu značek na zprávu.

Tabulka	Zpráv	Se značkou	%	Značek celkem	Delších úseků	Průměr	Medián	95. perc.
discharge	331 793	331 793	100,0	19 263 079	54 256	58,1	52	112
radiology	2 321 355	2 097 226	90,3	5 981 815	3 355	2,6	2	7

Zdroj: dotazy v DuckDB nad sloupcem `text`.

Průměrný počet přesných značek ___ na propouštěcí zprávu je 58,1 a odpovídá dřívějšímu odhadu 60,6 značky na zprávu. Dřívější odhad počítal podtržítka vzorcem „délka bez podtržítek děleno třemi“, takže delší úsek podtržítek zahrnul mezi značky, a započítal i zbytkové masky. Průměrně připadá na propouštěcí zprávu 58,1 přesných značek, 0,2 delších úseků podtržítek a 0,1 zbytkových masek.

3.3 Zbytkové masky

Kromě značek ___ může text nést masky jiného typu. Tabulka 3 uvádí pro každý vzor počet zpráv a počet výskytů; žádný nalezený řetězec se nezveřejňuje.

Tabulka 3: Zbytkové masky jiného typu než tři podtržítka: počet zpráv a výskytů na vzor.

Tabulka	Vzor	Zpráv	%	Výskytů
discharge	`[**…**]`	5	< 0,1	9
discharge	`<…>`	5 221	1,6	20 819
discharge	`XXX`	436	0,1	557
radiology	`[**…**]`	0	0,0	0
radiology	`<…>`	52	< 0,1	74
radiology	`XXX`	8	< 0,1	8

Zdroj: dotazy v DuckDB; vzory jsou `[**…**]`, HTML značka a `XXX`.

Aspoň jeden ze tří vzorů se v textu vyskytuje; počty zpráv a výskytů uvádí tabulka.

3.4 Kvalita dat

Tabulka 4 uvádí zprávy, které se do korpusu nehodí: prázdné a krátké zprávy, extrémně dlouhé zprávy a přesné duplicity textu.

Tabulka 4: Kvalita dat: prázdné, krátké a extrémně dlouhé zprávy a přesné duplicity textu.

Ukazatel	Propouštěcí: zpráv	Propouštěcí: %	Radiologické: zpráv	Radiologické: %
Zprávy celkem	331 793		2 321 355	
Prázdný nebo chybějící text	0	0,0	0	0,0
Kratší než 100 znaků	0	0,0	6 285	0,3
100 až 500 znaků	2	< 0,1	545 664	23,5
Delší než 50 000 znaků	16	< 0,1	0	0,0
Přesné duplicity textu	1	< 0,1	21 904	0,9

Zdroj: dotazy v DuckDB; skupiny se délkou se vylučují, duplicity se počítají z textu zpráv s neprázdným textem.

3.5 Maska věku v textu

Věk pacienta může text zprávy obsahovat jako masku ___ před zápisem „year old“, nebo jako číslo. Tabulka 5 uvádí propouštěcí zprávy podle počtu masek věku a počet zpráv s kotvou a s číselným věkem.

Tabulka 5: Maska věku v propouštěcích zprávách: počet masek na zprávu, kotva „is a ___ year old“ a číselný věk.

Ukazatel	Zpráv	%
Propouštěcí zprávy celkem	331 793	
Bez masky věku	133 333	40,2
S jednou maskou věku	101 654	30,6
S více maskami věku	96 806	29,2
S kotvou „is a ___ year old“	102 094	30,8
S číselným věkem	0	0,0

Zdroj: dotazy v DuckDB nad tabulkou `discharge`; bez masky, s jednou a s více maskami se vylučují, kotva a číselný věk jsou podmnožiny celku.

4 Shrnutí a rozhodnutí

Dokument popsal délku zpráv, značky ___, zbytkové masky, kvalitu dat a masku věku. Pro další práci z toho plyne:

- **Rozpočet chunků.** Medián délky propouštěcí zprávy je 9 847 znaků a 95. percentil 18 619 znaků. Tato čísla jsou vstupem pro rozpočet chunků při překladu, který se přepočte na tokeny v navazujícím sešitu.
- **Počet značek ___ a reference.** Průměr přesných značek na propouštěcí zprávu je 58,1, průměr delších úseků podtržítek 0,2 a průměr zbytkových masek 0,1. Přesné značky samy odpovídají dřívějšímu odhadu 60,6 značky na zprávu.

- **Podklad pro kontrolu počtu značek.** Kontrola shody počtu značek mezi originálem a překladem dostává tato čísla: zprávy se značkou `___` a součet značek uvádí Tabulka 2, zprávy a výskyty zbytkových masek `[**…**]`, HTML značek a `XXX` uvádí Tabulka 3. Sešit nerozhoduje, které vzory má kontrola zahrnout; poskytuje jen počty, o rozsahu kontroly se rozhodne při její implementaci.
- **Kvalita dat.** Zprávy kratší než 100 znaků a přesné duplicity se z korpusu vyřazují vždy. Mezi propouštěcími zprávami je prázdných nebo kratších zpráv 0 a přesných duplicit 1.
- **Věk v textu.** Číselný věk se v propouštěcích zprávách nevyskytuje, což potvrzuje, že věk z textu extrahovat nejde. Kotvu „is a ___ year old“ nese 30,8 % zpráv, což je horní mez zpráv, do nichž by šel věk dosadit.

5 Omezení

Délka se měří ve znacích a slovech, ne v tokenech; velikost kroku překladu proto určí až tokenizace. Počet slov se odvozuje z úseků bez mezer, takže interpunkce přilepená ke slovu se do slova počítá. Vzor HTML značky se řídí tvarem `<` s písmenem až po `>` a může zachytit i text, který značkou není, například srovnání v klinickém textu. Vzor `XXX` zachytí každý úsek tří a více písmen `X`, včetně zkratky, která se tak píše. Maska věku se hledá jen v zápisech „year old“, „years old“, „yo“, „y/o“ a „y.o.“; jiný zápis, například „aged ___“, mezi ni nepatří, takže její počet je dolní odhad. Přesné duplicity se poznají podle otisku celého textu, takže zprávy lišící se jediným znakem se za duplicity nepovažují. Metriky textu nepopisují skupiny pacientů, a proto se zveřejňují přesně, bez potlačení malých počtů. Percentil je délka jedné konkrétní zprávy a stejně tak nejmenší a největší hodnota; z textu zpráv se nezveřejňuje žádný řetězec ani kontext.

Příloha A: provenance renderu

Tabulka 6 uvádí údaje, podle kterých lze render dohledat a zopakovat: revizi kódu, otisk zámku prostředí, zdroj dat a verze použitých nástrojů.

Tabulka 6: Provenance renderu.

Položka	Hodnota
Revize kódu (commit)	96e72f96ac88185f635c5a0b1cf8a72c27c39e25
Necommitnuté změny	ne
Otisk pixi.lock (SHA-256)	af50ffb1143e322d 2f3de22275341738 bbd0725befb07500 ba5ef6cdcda01b01
Zdroj dat	otisky CSV z config/mimic_tables.json
Otisk discharge.csv.gz (SHA-256)	27bc552edaf81c2a f322040cb7e8eb36 417173b23c79405b b92fcf73bef2dbc5
Otisk radiology.csv.gz (SHA-256)	2c09bc76ee12d5f3 b8f572deb7218fba f3e59b32eccfdae1 4686e05ae099eebb
Otisk admissions.csv.gz (SHA-256)	a9584ed88e9ed664 a2f66f86a5cf9fd1 75c8bb0af50e3b61 15598b19e978384e
Otisk d_icd_diagnoses.csv.gz (SHA-256)	a81065bf45ccf74f 589bec855bbb0a07 b5c014907b34ff76 fe20583a2c87cc79
Otisk d_icd_procedures.csv.gz (SHA-256)	2ac8afcb99fd16b ce2e6c7ad445e3bd 1dfd658e52182313 0ab08b66fdd3d6d4
Otisk diagnoses_icd.csv.gz (SHA-256)	47665a41b2a3ad99 0d6f314062d5bd6d 29d467b0fd402dd9 4662044ec8b073d2
Otisk omr.csv.gz (SHA-256)	8280a8023203bddc 6cc4419bd8cd253a 015b8bc0bc53852e c92f98c7353f31e2
Otisk patients.csv.gz (SHA-256)	4c7507de7ecad8c5 ba7647ea4d26018e 88ff6672c5fc22ab 59c2a5697d687cdd
Otisk pharmacy.csv.gz (SHA-256)	c9885721e4c968f0 773145d7f6ba4d3c c3755d5600ee400f f95b1d3238053811
Otisk prescriptions.csv.gz (SHA-256)	0d8481c7d5d7c9ec 2fea3fc543ddaaad b5a933cd22c7b9dd a4289361e4d77199
Otisk procedures_icd.csv.gz (SHA-256)	3271397d0517131f 84399b698cbb0c2f 435aaab0f873a380 6e13b097661596f7
Otisk services.csv.gz (SHA-256)	31c82ebee94e0c04 d6966fbfec30579e c00f9c7816b80852 f9580656e6183888
Otisk mimic-iv-bhc.csv (SHA-256)	e45c09997b25d744 abb20573623885eb a052299cf2a721c1 8bbf5ca9a54989c1
Python	3.13.16
DuckDB	1.5.6
R	R version 4.5.3 (2026-03-11)
r-duckdb	1.5.5

Literatura

Johnson, Alistair E. W., Lucas Bulgarelli, Lu Shen, et al. 2023. „MIMIC-IV, a freely accessible electronic health record dataset". *Scientific Data* 10 (1): 1. https://doi.org/10.1038/s41597-022--01899-x.

Johnson, Alistair, Lucas Bulgarelli, Tom Pollard, et al. 2024. *MIMIC-IV*. Verze 3.1. PhysioNet. https://doi.org/10.13026/kpb9-mt58.

Johnson, Alistair, Tom Pollard, Steven Horng, Leo Anthony Celi, a Roger Mark. 2023. *MIMIC--IV-Note: Deidentified free-text clinical notes*. Verze 2.2. PhysioNet. https://doi.org/10.13026/1n74-ne17.