Explorační analýza datové sady: tokenizace

Martin Žoha

Abstrakt Dokument přepočítává délky propouštěcích a radiologických zpráv na tokeny modelů, které práce používá: encodery XLM-R a mDeBERTa a překladový model translategemma, každý s vlastním oknem. Uvádí rozdělení délky v tokenech, podíl zpráv, které se vejdou do okna celé, a počet částí, na něž se zbytek rozpadne, u překladu i přesným dělením na vzorku. Z veřejné paralelní syntetiky odhaduje, o kolik tokenů má čeština víc než angličtina. Výsledky podkládají rozpočet požadavků na překlad, volbu mezi chunkováním a ořezem u encoderů a volbu primárního korpusu.

Obsah

1 Úvod 1
2 Data a metody 2
2.1 Tokenizéry 2
2.2 Délka a okno 2
2.3 Čeština 3
3 Výsledky 3
3.1 Délka v tokenech 3
3.2 Okno a počet částí 5
3.3 Přesné dělení překladu na vzorku 5
3.4 Čeština jako odhad 6
4 Shrnutí a rozhodnutí 7
5 Omezení 7
Příloha A: provenance renderu 7
Literatura 9

1 Úvod

Tento sešit je čtvrtým z řady sešitů explorační analýzy. Navazuje na sešit o délce zpráv, který je měřil ve znacích a ve slovech, a přepočítává je na tokeny modelů, které práce používá. Sešit klade čtyři otázky:

- jak dlouhé jsou propouštěcí (`discharge`) a radiologické (`radiology`) zprávy v tokenech tří tokenizérů,
- kolik zpráv se vejde do okna encoderu celých a na kolik částí se zbytek rozpadne, a zda proto encoder potřebuje chunkování, nebo stačí ořez,
- kolik zpráv musí překlad dělit a kolik požadavků to znamená,
- o kolik tokenů je česká zpráva delší než anglická a co to znamená pro okno encoderu.

Odpovědi určují rozpočet požadavků na překlad reálného korpusu, politiku vstupu do encoderů a volbu primárního korpusu. Data pocházejí z MIMIC-IV (Johnson et al. 2024; A. E. W. Johnson et al. 2023) a MIMIC-IV-Note (A. Johnson et al. 2023). Metriky textu nepopisují skupiny pacientů, a proto se zveřejňují přesně. Z textu zpráv se nezveřejňuje žádný řetězec ani kontext, jen počty a míry.

Kapitola 2 popisuje modely a metody. Kapitola 3 uvádí výsledky, kapitola 4 shrnuje rozhodnutí pro další práci a kapitola 5 jmenuje omezení. Příloha A dokumentuje provenance renderu.

2 Data a metody

Sešit čte sloupec `text` propouštěcích a radiologických zpráv. Tokenizuje se celý korpus, ne vzorek: nástroj `mediparse-eda-note-tokens` čte celé tabulky po dávkách 2 000, každou dávku tokenizují všechny tři tokenizéry a počty uloží do parquetu. R soubory čte přes DuckDB s kontrolou kontraktu a agreguje je funkcemi v `eda/R/tokens.R`. Výpočet v Pythonu se testuje lokálním tokenizérem bez sítě.

2.1 Tokenizéry

Tabulka 1 uvádí tokenizéry, jejich pevné revize a okna. Klasické modely (TF-IDF) okno nemají, a proto se netokenizují. Model, revize, okno a poměr dělení překladu se čtou přímo z `translation/prepare.py`, takže se sešit s překladem nerozejde.

Tabulka 1: Tokenizéry modelů práce: model, revize, okno a úloha.

Tokenizér	Model	Revize	Okno	Úloha	Verze transformers
XLM-R	`FacebookAI/xlm-roberta-base`	`e73636d4f797`	512	encoder	5.18.0
mDeBERTa	`microsoft/mdeberta-v3-base`	`a0484667b223`	512	encoder	5.18.0
translategemma	`google/translategemma-27b-it`	`7d10f0b72f89`	2 048	překlad	5.18.0

Zdroj: Hugging Face Hub, revize zkrácena na 12 znaků; okno encoderů je délka předtrénování, okno překladu uvádí karta modelu.

2.2 Délka a okno

Délky se definují takto:

- *délka pro encoder* je počet tokenů včetně speciálních tokenů (`add_special_tokens = TRUE`). Okno 512 zahrnuje oba speciální tokeny, obsah části je tedy 512 minus 2 tokenů. U XLM-R je 512 tvrdý limit (absolutní pozice), u mDeBERTa délka předtrénování: relativní pozice delší vstup technicky připustí, ale model ho neviděl,
- *části encoderu* jsou ceil((n − s) / (512 − s)) bez překryvu, kde `s` je počet speciálních tokenů. Je to odhad, protože politika chunkování encoderu (překryv, ořez) ještě rozhodnutá není,
- *délka pro překlad* je počet tokenů zdroje bez speciálních tokenů po ořezu okrajových mezer, stejně jako v `_fits` přípravy překladu. Zpráva se vejde, když `okno − (s + režie) ≥ poměr`

· `s`. Režie chat šablony se změřila jednou na pevné neklinické větě a je 75 tokenů, poměr dělení je 2,2 a okno 2 048, takže se vejde zpráva do 616 tokenů zdroje,
- *spodní mez částí překladu* je `ceil(s / limit)` s `limit = (okno − režie) / (1 + poměr)`, vychází na 616,6 tokenu. Prázdná zpráva má nula částí, takže součet částí nepočítá prázdné zprávy.

Spodní mez se ověřuje přesným dělením (`note_parts.split` s `_fits`) na deterministickém vzorku 1 000 zpráv na tabulku, vybraném podle `hash(note_id)`. Dělení celého korpusu by trvalo hodiny. Verdikty na konci sešitu se řídí dvěma pravidly. Encoder vystačí s ořezem, když se do okna vejde aspoň 95,0 % propouštěcích zpráv, protože ořez pak zasáhne nejvýš 5,0 % zpráv; jinak se rozhoduje podle mediánu délky. Čeština snižuje podíl v okně, když je anglický podíl větší než odhadovaný český o víc než 5,0 procentního bodu.

Zprávy se v tokenech uvádějí v logaritmických koších o šířce 0,1 dekády a percentily se počítají stejně jako v sešitu o délce (`quantile_disc`).

2.3 Čeština

Český korpus zatím není přeložený. Poměr CS/EN se proto odhaduje z veřejné paralelní syntetiky (400 zpráv v `resources/synthetic/en` a `cs`, párovaných podle jména souboru). Pro každý tokenizér se uvede medián a 95. percentil poměru a podíl syntetických zpráv v okně v obou jazycích. Podíl reálných českých zpráv v okně se odhadne jako podíl anglických zpráv MIMIC, pro něž délka krát medián poměru vyjde do okna. Stejné měřítko přepočte i odhad počtu částí encoderů. Je to odhad, ne měření.

3 Výsledky

3.1 Délka v tokenech

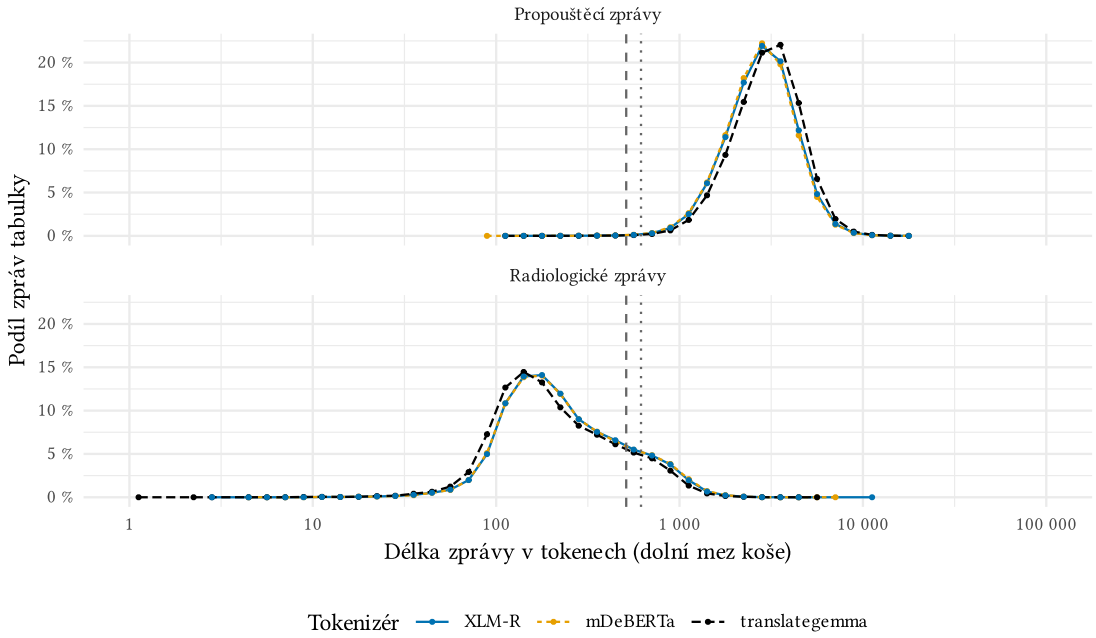
Tabulka 2 uvádí rozdělení délky v tokenech pro obě tabulky a všechny tři tokenizéry. Medián propouštěcí zprávy je 3 054 tokenů v tokenizéru translategemma a 2 824 v XLM-R.

Tabulka 2: Rozdělení délky zpráv v tokenech podle tabulky a tokenizéru (včetně nejmenší a největší hodnoty).

Ukazatel	Prop.: XLM-R	Prop.: mDeBERTa	Prop.: translategemma	Rad.: XLM-R	Rad.: mDeBERTa	Rad.: translategemma
Zpráv	331 793	331 793	331 793	2 321 355	2 321 355	2 321 355
Průměr	3 004,5	2 964,9	3 230,9	307,3	309,6	280,2
Minimum	100	90	109	3	4	1
1. percentil	922	900	999	47	48	42
5. percentil	1 331	1 312	1 434	85	85	77
10. percentil	1 584	1 568	1 709	102	102	93
25. percentil	2 104	2 084	2 279	137	137	124
Medián	2 824	2 785	3 054	207	208	187
75. percentil	3 682	3 629	3 958	381	383	347
90. percentil	4 608	4 545	4 923	677	686	617
95. percentil	5 283	5 212	5 625	872	883	798
99. percentil	6 957	6 868	7 378	1 248	1 267	1 153
Maximum	17 235	16 776	18 646	11 995	7 881	5 087

Zdroj: dotazy v DuckDB nad parquetem počtů tokenů; encodery včetně speciálních tokenů, Gemma bez nich. „Prop.“ jsou propouštěcí, „Rad.“ radiologické zprávy.

Obrázek 1 ukazuje podíl zpráv v logaritmických koších. Svislé čáry označují okno encoderu a limit zdroje v překladu.



Obrázek 1: Rozdělení délky zpráv v tokenech v logaritmických koších (šířka koše 0,1 dekády); podíl neprázdných zpráv tabulky. Čárkovaně okno encoderu, tečkovaně limit zdroje v překladu.

3.2 Okno a počet částí

Tabulka 3 uvádí, kolik zpráv se vejde do okna celých a na kolik částí se rozpadne celý korpus. U encoderů jde o odhad bez překryvu, u překladu o spodní mez.

Tabulka 3: Zprávy v okně a počet částí podle tabulky a tokenizéru (encodery: odhad bez překryvu, překlad: spodní mez).

Tabulka	Tokenizér	Zpráv	V okně	%	Mimo okno	Částí
`discharge`	XLM-R	331 793	351	0,1	331 442	2 119 032
`discharge`	mDeBERTa	331 793	402	0,1	331 391	2 092 877
`discharge`	translategemma	331 793	503	0,2	331 290	1 904 443
`radiology`	XLM-R	2 321 355	1 939 073	83,5	382 282	2 774 929
`radiology`	mDeBERTa	2 321 355	1 933 015	83,3	388 340	2 785 600
`radiology`	translategemma	2 321 355	2 088 667	90,0	232 688	2 573 367

Zdroj: dotazy v DuckDB; okno encoderu je 512 tokenů včetně speciálních, okno překladu 2 048 tokenů s limitem zdroje 616,6.

3.3 Přesné dělení překladu na vzorku

Tabulka 4 porovnává spodní mez s přesným dělením skutečným algoritmem přípravy překladu na deterministickém vzorku. Poměr přesného počtu částí ke spodní mezi říká, o kolik

spodní mez podhodnocuje počet požadavků. Neshody uvádějí zprávy, u nichž se vzorec zvolený pro spodní mez rozchází s `_fits`. Nedělitelná zpráva je ta, jejíž řádek se nevejde do okna ani sám; do částí se nepočítá.

Tabulka 4: Přesné dělení na deterministickém vzorku zpráv: zprávy dělené na více částí, přesný počet částí, spodní mez, jejich poměr, neshody vzorce s kontrolou vejde-se a nedělitelné zprávy.

Tabulka	Zpráv ve vzorku	Dělených	%	Částí přesně	Částí spodní mez	Poměr	Neshod	Nedělitelných
`discharge`	1 000	998	99,8	6 904	5 629	1,23	0	0
`radiology`	1 000	114	11,4	1 128	1 122	1,01	0	0

Zdroj: `note_parts.split` s `prepare._fits` nad vzorkem vybraným podle `hash(note_id)`.

3.4 Čeština jako odhad

Tabulka 5 uvádí poměr CS/EN na paralelní syntetice. Poměr je odhad z 400 syntetických zpráv, ne měření na překladu MIMIC.

Tabulka 5: Odhad poměru délky v tokenech česky a anglicky na paralelní syntetice a podíl syntetických zpráv v okně v obou jazycích.

Tokenizér	Zpráv	Medián poměru	95. perc. poměru	V okně: EN (%)	V okně: CS (%)
XLM-R	400	1,34	1,41	40,0	2,5
mDeBERTa	400	1,48	1,56	47,8	0,5
translategemma	400	1,70	1,80	85,5	3,0

Zdroj: `resources/synthetic/en` a `cs`, páry podle jména souboru; encoder měří obsah bez speciálních tokenů a okno obsahu.

Tabulka 6 přenáší medián poměru na anglické zprávy MIMIC: podíl zpráv v okně a počet částí v angličtině a v odhadu pro češtinu.

Tabulka 6: Podíl zpráv v okně a počet částí v angličtině a v odhadu pro češtinu (délka krát medián poměru CS/EN).

Tabulka	Tokenizér	Zpráv	V okně: EN (%)	V okně: CS (%)	Částí EN	Částí CS
`discharge`	XLM-R	331 793	0,1	< 0,1	2 119 032	2 789 818
`discharge`	mDeBERTa	331 793	0,1	< 0,1	2 092 877	3 013 700
`radiology`	XLM-R	2 321 355	83,5	75,0	2 774 929	3 124 311
`radiology`	mDeBERTa	2 321 355	83,3	71,9	2 785 600	3 284 564

Zdroj: dotazy v DuckDB; sloupce CS jsou odhad.

4 Shrnutí a rozhodnutí

Dokument přepočítal délky zpráv na tokeny tří tokenizérů. Pro další práci z toho plyne:

- **Dělení při překladu.** Překlad musí dělit 331 290 propouštěcích zpráv (99,8 %). Spodní mez počtu požadavků na propouštěcí zprávy je 1 904 443 částí; po přepočtu poměrem přesného dělení ke spodní mezi na vzorku (1,23) vychází odhad 2 335 810 požadavků.
- **Encodery.** XLM-R: v okně je 0,1 % propouštěcích zpráv, medián délky je 2 824 tokenů. Typická zpráva se do okna nevejde, takže ořez ztrácí většinu textu a encoder potřebuje chunkování. mDeBERTa: v okně je 0,1 % propouštěcích zpráv, medián délky je 2 785 tokenů. Typická zpráva se do okna nevejde, takže ořez ztrácí většinu textu a encoder potřebuje chunkování.
- **Čeština.** XLM-R: z 0,1 % v okně v angličtině se podíl v češtině odhaduje na < 0,1 %. Čeština okno prakticky nezmenšuje. mDeBERTa: z 0,1 % v okně v angličtině se podíl v češtině odhaduje na < 0,1 %. Čeština okno prakticky nezmenšuje. Odhad vychází z paralelní syntetiky, ne z překladu MIMIC.
- **Volba korpusu.** Medián propouštěcí zprávy je 3 054 tokenů, radiologické 187 tokenů (translategemma). Radiologické zprávy jsou kratší, takže se do okna vejdou častěji a překlad je dělí méně. Počty zpráv v okně a částí obou korpusů jsou v Tabulka 3 a slouží jako podklad pro volbu primárního korpusu a splitu.

5 Omezení

Počty částí encoderů předpokládají dělení bez překryvu; politika chunkování ještě není rozhodnutá, takže jde o odhad. Spodní mez částí překladu podhodnocuje skutečný počet, protože dělení probíhá po blocích; rozsah rozdílu měří vzorek, který pokrývá 1 000 zpráv na tabulku, nikoli celý korpus. Součet částí nepočítá prázdné zprávy. Odhad pro češtinu vychází z 400 syntetických zpráv a z jediného měřítka pro všechny zprávy, i když poměr CS/EN se mezi zprávami liší (95. percentil je v Tabulka 5); syntetika navíc nemusí mít stejný slovník jako klinické zprávy. U mDeBERTa je okno 512 délka předtrénování, ne technický limit. Délka v tokenech se měří na textu před maskováním značek ___, který používá i příprava překladu pro dělení. Metriky tokenů jsou metriky textu, a proto se zveřejňují přesně, bez potlačení malých počtů. Z textu zpráv se nezveřejňuje žádný řetězec ani kontext.

Příloha A: provenance renderu

Tabulka 7 uvádí údaje, podle kterých lze render dohledat a zopakovat: revizi kódu, otisk zámku prostředí, zdroj dat a verze použitých nástrojů.

Tabulka 7: Provenance renderu.

Položka	Hodnota
Revize kódu (commit)	1d2f638dc5de5bb0e46ad382de9dc806966baf9d
Necommitnuté změny	ne
Otisk pixi.lock (SHA-256)	c9b8dbd92a0bb8d7 c26f7127af04b8f6 ba06d55dd6a9cc42 21c80324bf149fad
Zdroj dat	tabulky parquet ověřené proti vazbě na otisky CSV
Otisk CSV admissions (SHA-256)	a9584ed88e9ed664 a2f66f86a5cf9fd1 75c8bb0af50e3b61 15598b19e978384e
Otisk parquetu admissions (SHA-256)	511b92c1956c6e0a 17ccff692532bc39 f4d2962a55a8df5a 2404cb22ff0a1b0a
Otisk CSV d_icd_diagnoses (SHA-256)	a81065bf45ccf74f 589bec855bbb0a07 b5c014907b34ff76 fe20583a2c87cc79
Otisk parquetu d_icd_diagnoses (SHA-256)	4bbe089e2f75747a 1f4be3be4a8a3100 294b103af562208d 1b9cc92ffaa1b6a4
Otisk CSV d_icd_procedures (SHA-256)	a2ac8afcb99fd16b ce2e6c7ad445e3bd 1dfd658e52182313 0ab08b66fdd3d6d4
Otisk parquetu d_icd_procedures (SHA-256)	7de5e3083e432019 877ce3598856e558 9030a2876d604a9f b0ff17c1e8e16f9f
Otisk CSV diagnoses_icd (SHA-256)	47665a41b2a3ad99 0d6f314062d5bd6d 29d467b0fd402dd9 4662044ec8b073d2
Otisk parquetu diagnoses_icd (SHA-256)	c98d378ffafb8cf8 a81428570fcef4aa 57106eb8cb60f01e bf8143792ae83922
Otisk CSV discharge (SHA-256)	27bc552edaf81c2a f322040cb7e8eb36 417173b23c79405b b92fcf73bef2dbc5
Otisk parquetu discharge (SHA-256)	0b817f1662e2c085 7f99caca2bda8a5c c6bf677738a3b6eb cf9ed43dbc55aae5
Otisk CSV mimic-iv--bhc (SHA-256)	e45c09997b25d744 abb20573623885eb a052299cf2a721c1 8bbf5ca9a54989c1
Otisk parquetu mimic--iv-bhc (SHA-256)	403dcbe4e6a916ac 30ea647197c4d8e7 08505ee72ce0533d 3500dd64606c3dd0
Otisk CSV omr (SHA-256)	8280a8023203bddc 6cc4419bd8cd253a 015b8bc0bc53852e c92f98c7353f31e2
Otisk parquetu omr (SHA-256)	6566ab088fdb28cf 79985a5fe144d8c3 9587d0bdabd7da81 fd6130f72bf29a66
[illegible] (SHA-256)	[illegible]

Literatura

Johnson, Alistair E. W., Lucas Bulgarelli, Lu Shen, et al. 2023. „MIMIC-IV, a freely accessible electronic health record dataset". *Scientific Data* 10 (1): 1. https://doi.org/10.1038/s41597-022--01899-x.

Johnson, Alistair, Lucas Bulgarelli, Tom Pollard, et al. 2024. *MIMIC-IV*. Verze 3.1. PhysioNet. https://doi.org/10.13026/kpb9-mt58.

Johnson, Alistair, Tom Pollard, Steven Horng, Leo Anthony Celi, a Roger Mark. 2023. *MIMIC--IV-Note: Deidentified free-text clinical notes*. Verze 2.2. PhysioNet. https://doi.org/10.13026/1n74-ne17.