Explorační analýza datové sady: volba korpusu a rozdělení dat

Martin Žoha

Abstrakt Dokument uzavírá rozbor datové sady. Z ukazatelů předchozích sešitů srovnává propouštěcí a radiologické zprávy a volí primární korpus. Vymezuje vstupní korpus, tedy propouštěcí zprávy s diagnózou ICD, dostatečnou délkou a bez přesných duplicit, a uvádí jeho velikost po jednotlivých krocích výběru. Nakonec rozhoduje o jednotce a způsobu rozdělení dat na trénovací a testovací část, včetně volby mezi náhodným a časovým dělením podle éry ICD.

Obsah

1 Úvod 1
2 Data a metody 2
3 Výsledky 2
3.1 Srovnání korpusů 2
3.2 Vstupní korpus 3
3.3 Éra ICD a rozdělení dat 3
4 Shrnutí a rozhodnutí 3
5 Omezení 4
Příloha A: provenance renderu 4
Literatura 6

1 Úvod

Tento sešit je pátým z řady sešitů explorační analýzy a uzavírá rozbor datové sady. Druhý sešit popsal pacienty, přijetí, pokrytí diagnózami ICD a éru ICD, třetí délku zpráv a deidentifikaci, čtvrtý délku zpráv v tokenech modelů. Tento sešit z jejich ukazatelů vyvozuje dvě rozhodnutí, na kterých stojí sestavení kohorty i trénink modelů. Klade si tři cíle:

- srovnat propouštěcí a radiologické zprávy podle ukazatelů, které rozhodují o použitelnosti korpusu, a zvolit primární korpus,
- vymezit vstupní korpus, tedy zprávy, které vstupují do rozdělení dat, a změřit jeho velikost,
- rozhodnout o jednotce a způsobu rozdělení dat na trénovací a testovací část.

Data pocházejí z MIMIC-IV (Johnson et al. 2024; A. E. W. Johnson et al. 2023) a MIMIC-IV-Note (A. Johnson et al. 2023), které podléhají smlouvě o užívání dat (DUA). Dokument proto zveřejňuje jen agregáty, nikdy řádková data ani texty zpráv. Všechny tabulky sešitu jsou metriky korpusu, které nevymezují skupiny pacientů kvaziidentifikátorem, a uvádějí se přesně. Rozpad hospitalizací podle období ukotvení pacienta se nezveřejňuje; sešit z něj

po potlačení kategorií s méně než deseti hospitalizacemi přebírá jen závěr o přechodu mezi verzemi ICD, stejně jako druhý sešit.

Dokument je členěn takto. Kapitola 2 popisuje metody. Kapitola 3 srovnává korpusy, vymezuje vstupní korpus a popisuje éru ICD z pohledu rozdělení dat. Kapitola 4 shrnuje rozhodnutí a kapitola 5 jmenuje omezení. Příloha A dokumentuje provenance renderu.

2 Data a metody

Sešit čte propouštěcí zprávy (`discharge`), radiologické zprávy (`radiology`), diagnózy ICD přiřazené hospitalizacím (`diagnoses_icd`) a pacienty (`patients`). Ukazatele počítají tytéž funkce jako druhý a třetí sešit (`eda/R/patients.R`, `eda/R/text.R`), takže čísla se shodují. Nové dotazy jsou v `eda/R/selection.R` a mají testy nad ručně vytvořenými tabulkami. Délky v tokenech se nepřepočítávají; srovnání korpusů v tokenech a podíl zpráv v okně modelů uvádí čtvrtý sešit.

Pojmy a jednotky jsou tyto:

- *pokrytí kódem ICD* je podíl zpráv, jejichž `hadm_id` má v `diagnoses_icd` aspoň jeden kód; jmenovatelem jsou všechny zprávy tabulky,
- *vstupní korpus* vzniká z propouštěcích zpráv ve čtyřech krocích, z nichž každý navazuje na předchozí: všechny zprávy, zprávy s kódem ICD, zprávy dlouhé aspoň 100 znaků a zprávy bez přesných duplicit,
- *přesná duplicita* je zpráva se shodným otiskem textu jako jiná zpráva vstupního korpusu; ze skupiny shodných zpráv zůstane ta s nejmenším `note_id`, takže výběr je deterministický,
- *pacient s více zprávami* je hodnota `subject_id`, ke které v daném kroku patří aspoň dvě zprávy.

Rozdělení dat popisuje sešit jen jako strategii; samotné rozdělení spočítá krok pipeline, který ho uloží jako sdílený artefakt. Volba mezi náhodným a časovým dělením vychází z přechodu mezi verzemi ICD podle tříletého období ukotvení pacienta (`anchor_year_group`), jak ho určil druhý sešit.

3 Výsledky

3.1 Srovnání korpusů

Tabulka 1 staví vedle sebe propouštěcí a radiologické zprávy. Kód ICD má 99,9 % propouštěcích a 49,3 % radiologických zpráv.

Tabulka 1: Srovnání propouštěcích a radiologických zpráv; podíly ze všech zpráv tabulky.

Ukazatel	Propouštěcí	Radiologické
Zpráv	331 793	2 321 355
Pacientů	145 914	237 427
Bez hadm_id (%)	0,0	50,7
S kódem ICD (%)	99,9	49,3
Medián délky (znaky)	9 847	781
95. percentil délky (znaky)	18 619	3 280
Prázdné nebo kratší než 100 znaků	0	6 285
Přesné duplicity	1	21 904

Zdroj: funkce druhého a třetího sešitu nad tabulkami `discharge`, `radiology` a `diagnoses_icd`.

3.2 Vstupní korpus

Tabulka 2 uvádí velikost korpusu po jednotlivých krocích výběru. Do rozdělení dat vstupuje 331 604 propouštěcích zpráv od 145 817 pacientů; více zpráv má 41,3 % z nich.

Tabulka 2: Výběr vstupního korpusu z propouštěcích zpráv; každý krok navazuje na předchozí.

Krok	Zpráv	Pacientů	Pacientů s více zprávami
Všechny propouštěcí zprávy	331 793	145 914	60 308
S kódem ICD	331 604	145 817	60 279
Aspoň 100 znaků	331 604	145 817	60 279
Bez přesných duplicit	331 604	145 817	60 279

Zdroj: dotaz v DuckDB nad tabulkami `discharge` a `diagnoses_icd`; délka a otisk textu jsou tytéž jako ve třetím sešitu.

3.3 Éra ICD a rozdělení dat

Z hospitalizací s propouštěcí zprávou je jen v ICD-10 kódováno 36,9 %, jen v ICD-9 63,1 % a oběma verzemi 0,0 %. Podle druhého sešitu se éry v čase překrývají: hospitalizace jen s ICD-9 a jen s ICD-10 se vyskytují ve stejném období.

4 Shrnutí a rozhodnutí

Dokument srovnal korpusy, vymezil vstupní korpus a popsal éru ICD z pohledu rozdělení dat. Pro další práci z toho plyne:

- **Primární korpus.** Primárním korpusem jsou propouštěcí zprávy. Kód ICD má 99,9 % z nich proti 49,3 % radiologických, takže štítek lze odvodit aspoň u stejného podílu zpráv. Propouštěcí zpráva navíc shrnuje celou hospitalizaci včetně diagnóz, kdežto radiologická popisuje jedno vyšetření. Radiologické zprávy práce nepoužívá.

- **Vstupní korpus.** Do rozdělení dat vstupují propouštěcí zprávy s kódem ICD, dlouhé aspoň 100 znaků a bez přesných duplicit, celkem 331 604 zpráv od 145 817 pacientů. Výběr diagnóz i štítky se počítají nad tímto korpusem.
- **Jednotka dělení.** Dělí se po pacientech (`subject_id`). Více zpráv má 41,3 % pacientů vstupního korpusu a dělení po zprávách by stejného pacienta dalo do trénovací i testovací části.
- **Způsob dělení.** Data se dělí křížovou validací se skupinami a stratifikací (`StratifiedGroupKFold` z knihovny scikit-learn (Pedregosa et al. 2011)): skupinou je pacient a stratifikuje se podle štítků zvolených diagnóz. Metoda přijímá jen jednu třídu na zprávu, takže více štítků jedné zprávy se převede na jednu stratifikační proměnnou, například jejich kombinaci; převod určí krok, který rozdělení ukládá. Rozdělení se spočítá jednou a uloží jako sdílený artefakt, který čte anglická i česká větev, takže obě se testují na stejných pacientech. Počet částí a seed určí krok, který rozdělení ukládá.
- **Náhodné, nebo časové dělení.** Dělení je náhodné po pacientech, protože cílem práce je srovnání modelů a jazyků za shodných podmínek, ne odhad časové generalizace. Éry ICD se v čase překrývají, takže časová hranice je čistě neodděluje a časové dělení by nemělo jasný řez. Štítky obou verzí sjednotí mapování ICD-9 na ICD-10.

5 Omezení

Pokrytí kódem ICD říká jen, že hospitalizace má nějakou diagnózu, ne že má některou z diagnóz, které práce klasifikuje; počet zpráv se štítkem zvolených diagnóz určí až jejich výběr. Přesné duplicity se hledají podle otisku celého textu, takže téměř shodné zprávy (například převzatý text z předchozí hospitalizace) ve vstupním korpusu zůstávají; dělení po pacientech je udrží v téže části, pokud patří témuž pacientovi. Stratifikaci nelze ověřit, dokud nejsou zvoleny diagnózy, a sešit proto rozložení štítků mezi části nepočítá. Éra ICD vychází z tříletých období ukotvení pacienta, takže poloha přechodu mezi verzemi je známa jen s touto přesností. Délky v tokenech sešit nepřepočítává a odkazuje na čtvrtý sešit.

Příloha A: provenance renderu

Tabulka 3 uvádí údaje, podle kterých lze render dohledat a zopakovat: revizi kódu, otisk zámku prostředí, zdroj dat a verze použitých nástrojů.

Tabulka 3: Provenance renderu.

Položka	Hodnota
Revize kódu (commit)	f943c476deeb36804b7c9d91747aeed2e6c5a165
Necommitnuté změny	ne
Otisk pixi.lock (SHA-256)	bc21950a8ed44ddf 0e7bee9094c57500 e90f5e1aa15f5764 95b59d66c6828b72
Zdroj dat	otisky CSV z config/mimic_tables.json
Otisk discharge.csv.gz (SHA-256)	27bc552edaf81c2a f322040cb7e8eb36 417173b23c79405b b92fcf73bef2dbc5
Otisk radiology.csv.gz (SHA-256)	2c09bc76ee12d5f3 b8f572deb7218fba f3e59b32eccfdae1 4686e05ae099eebb
Otisk admissions.csv.gz (SHA-256)	a9584ed88e9ed664 a2f66f86a5cf9fd1 75c8bb0af50e3b61 15598b19e978384e
Otisk d_icd_diagnoses.csv.gz (SHA-256)	a81065bf45ccf74f 589bec855bbb0a07 b5c014907b34ff76 fe20583a2c87cc79
Otisk d_icd_procedures.csv.gz (SHA-256)	2ac8afcb99fd16b ce2e6c7ad445e3bd 1dfd658e52182313 0ab08b66fdd3d6d4
Otisk diagnoses_icd.csv.gz (SHA-256)	47665a41b2a3ad99 0d6f314062d5bd6d 29d467b0fd402dd9 4662044ec8b073d2
Otisk omr.csv.gz (SHA-256)	8280a8023203bddc 6cc4419bd8cd253a 015b8bc0bc53852e c92f98c7353f31e2
Otisk patients.csv.gz (SHA-256)	4c7507de7ecad8c5 ba7647ea4d26018e 88ff6672c5fc22ab 59c2a5697d687cdd
Otisk pharmacy.csv.gz (SHA-256)	c9885721e4c968f0 773145d7f6ba4d3c c3755d5600ee400f f95b1d3238053811
Otisk prescriptions.csv.gz (SHA-256)	0d8481c7d5d7c9ec 2fea3fc543ddaaad b5a933cd22c7b9dd a4289361e4d77199
Otisk procedures_icd.csv.gz (SHA-256)	3271397d0517131f 84399b698cbb0c2f 435aaab0f873a380 6e13b097661596f7
Otisk services.csv.gz (SHA-256)	31c82ebee94e0c04 d6966fbfec30579e c00f9c7816b80852 f9580656e6183888
Python	3.13.16
DuckDB	1.5.6
R	R version 4.5.3 (2026-03-11)

Literatura

Johnson, Alistair E. W., Lucas Bulgarelli, Lu Shen, et al. 2023. „MIMIC-IV, a freely accessible electronic health record dataset". *Scientific Data* 10 (1): 1. https://doi.org/10.1038/s41597-022--01899-x.

Johnson, Alistair, Lucas Bulgarelli, Tom Pollard, et al. 2024. *MIMIC-IV*. Verze 3.1. PhysioNet. https://doi.org/10.13026/kpb9-mt58.

Johnson, Alistair, Tom Pollard, Steven Horng, Leo Anthony Celi, a Roger Mark. 2023. *MIMIC--IV-Note: Deidentified free-text clinical notes*. Verze 2.2. PhysioNet. https://doi.org/10.13026/1n74-ne17.

Pedregosa, Fabian, Gaël Varoquaux, Alexandre Gramfort, et al. 2011. „Scikit-learn: Machine Learning in Python". *Journal of Machine Learning Research* 12: 2825–30.