# Explorační analýza datové sady: demografie vstupního korpusu

Martin Žoha

**Abstrakt** Dokument popisuje demografii vstupního korpusu vymezeného v předchozím sešitu, tedy propouštěcích zpráv s diagnózou ICD, dostatečnou délkou a bez přesných duplicit. Uvádí pohlaví pacientů, věk při přijetí a pojištění, rodinný stav, rasu a jazyk, ze kterých skládá charakteristiku korpusu pro text práce. Nakonec rozhoduje, že demografie do pipeline nevstupuje s jedinou výjimkou: pohlaví slouží jako reference pro extrakci pohlaví z preambule zprávy.

## Obsah

1 Úvod ..... 1
2 Data a metody ..... 2
3 Výsledky ..... 2
3.1 Souhrn vstupního korpusu ..... 2
3.2 Charakteristika ..... 3
3.3 Věk podle pohlaví ..... 5
4 Shrnutí a rozhodnutí ..... 5
5 Omezení ..... 5
Příloha A: provenance renderu ..... 6
Literatura ..... 8

## 1 Úvod

Tento sešit je šestým z řady sešitů explorační analýzy. Pátý sešit vymezil vstupní korpus, tedy zprávy, které vstupují do rozdělení dat na trénovací a testovací část. Tento sešit popisuje, koho se tyto zprávy týkají. Klade si tři cíle:

- charakterizovat vstupní korpus podle pohlaví, věku při přijetí, pojištění, rodinného stavu, rasy a jazyka pacientů,
- ukázat rozložení věku podle pohlaví,
- rozhodnout, zda a jak demografie vstupuje do pipeline.

Sešit demografii jen popisuje. Výkon modelů podle demografických podskupin práce nevykazuje, protože zadání to nevyžaduje; menšinové skupiny jsou navíc malé a intervaly spolehlivosti by byly široké.

Data pocházejí z MIMIC-IV (Johnson et al. 2024; A. E. W. Johnson et al. 2023) a MIMIC-IV-Note (A. Johnson et al. 2023), které podléhají smlouvě o užívání dat (DUA). Dokument proto zveřejňuje jen agregáty, nikdy řádková data ani texty zpráv. Počty pacientů a zpráv, zprávy

bez záznamu přijetí nebo pacienta, medián a kvartily věku jsou metriky korpusu a uvádějí se přesně. Počty a podíly skupin pacientů podle pohlaví, věkového pásma, pojištění, rodinného stavu, rasy a jazyka se zveřejňují přesně, protože DUA malé počty neupravuje a pacienti se neidentifikují.

Dokument je členěn takto. Kapitola 2 popisuje metody. Kapitola 3 uvádí výsledky. Kapitola 4 shrnuje rozhodnutí pro další práci a kapitola 5 jmenuje omezení. Příloha A dokumentuje provenance renderu.

# 2 Data a metody

Sešit čte propouštěcí zprávy (`discharge`), diagnózy ICD (`diagnoses_icd`), pacienty (`patients`) a přijetí (`admissions`). Všechny sloupce jsou v parquetu uloženy jako text a převádějí se přes `TRY_CAST`, takže nečíselná hodnota dá neznámý věk, ne chybu. Dotazy provádí DuckDB nad parquetem. Dotazy jsou v `eda/R/demographics.R` a mají testy nad ručně vytvořenými tabulkami; výběr vstupního korpusu sdílí se sešitem 5 (`eda/R/selection.R`), takže populace je v obou sešitech táž.

Pojmy a jednotky jsou tyto:

- *populací* je vstupní korpus: propouštěcí zprávy s kódem ICD, dlouhé aspoň 100 znaků a bez přesných duplicit,
- *zrnitost*: pohlaví je atribut pacienta a počítá se jednou na pacienta; věk při přijetí, pojištění, rodinný stav, rasa a jazyk jsou atributy přijetí a počítají se jednou na zprávu, protože zpráva je jednotkou klasifikace; podíly různých zrnitostí se proto nesrovnávají,
- *připojení*: `patients` a `admissions` se připojují zleva. Chybějící řádek dá kategorii „neuvedeno“, takže se každá tabulka sečte do velikosti korpusu; počet zpráv bez záznamu přijetí a bez záznamu pacienta se uvádí zvlášť,
- *popisky kategorií* pocházejí z kódu, ne z dat: pevné slovníky mapují každou známou hodnotu na její popisek, hodnotu mimo slovník na „jiné“ a chybějící hodnotu na „neuvedeno“. Rasa se slučuje podle předpony do skupin bílá, černá, hispánská a asijská; hodnoty „UNKNOWN“, „UNABLE TO OBTAIN“ a „PATIENT DECLINED TO ANSWER“ jsou „neuvedeno“, ostatní „jiná“. Jazyk má jen angličtinu a „jiný jazyk“. Surový popisek z dat se tak do výstupu nedostane,
- *věk při přijetí* je `anchor_age` plus rozdíl roku přijetí a `anchor_year`. Pacient, který byl v roce ukotvení starší než 89 let, má `anchor_age` nastavené na 91 (A. E. W. Johnson et al. 2023); jeho věk se nepočítá a zpráva patří do pásma 90+. Všechny věky od 90 let se seřezávají do jednoho pásma 90+. Pásma mají deset let (do 29, 30–39 až 80–89, 90+) a „neuvedeno“. Zveřejňují se jen medián a kvartily seřezaného věku, nikdy minimum ani maximum; maskovaní pacienti mají v seřezaném věku hodnotu 90, což vnitřní kvantily neovlivní.

# 3 Výsledky

## 3.1 Souhrn vstupního korpusu

Vstupní korpus tvoří 331 604 zpráv od 145 817 pacientů. Medián věku při přijetí je 63,0 let, kvartily jsou 50,0 a 76,0. Bez záznamu přijetí je 0 zpráv a bez záznamu pacienta 0 zpráv. Maskovaný věk (pacient starší než 89 let v roce ukotvení) má 10 835 zpráv. Tabulka 1 uvádí souhrn.

Tabulka 1: Souhrn vstupního korpusu: počty a věk při přijetí.

| Ukazatel | Hodnota |
|---|---|
| Pacienti | 145 817 |
| Zprávy | 331 604 |
| Medián věku při přijetí (kvartily) | 63,0 (50,0–76,0) |
| Zprávy bez záznamu přijetí | 0 |
| Zprávy bez záznamu pacienta | 0 |

*Zdroj:* dotaz v DuckDB nad tabulkami `discharge`, `diagnoses_icd`, `patients` a `admissions`; věk je seřezaný na 90 let.

## 3.2 Charakteristika

Tabulka 2 uvádí charakteristiku korpusu. Jmenovatelem podílu jsou u pohlaví pacienti, u ostatních atributů zprávy.

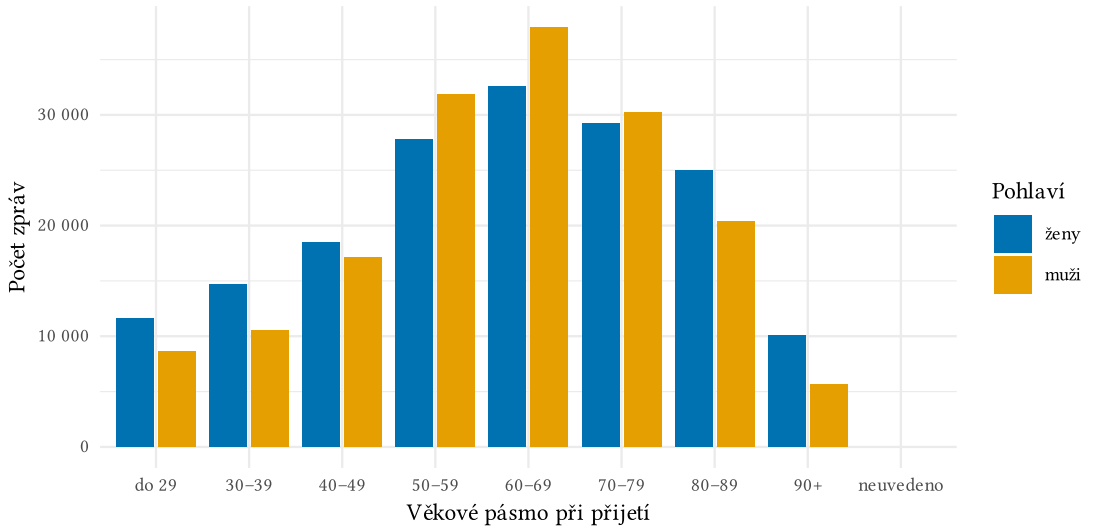
Tabulka 2: Charakteristika vstupního korpusu; podíl pacientů u pohlaví, podíl zpráv u ostatních atributů.

| Atribut | Kategorie | Počet | Podíl (%) |
|---|---|---|---|
| Pohlaví | ženy | 74 849 | 51,3 |
| | muži | 70 968 | 48,7 |
| Věkové pásmo | do 29 | 20 210 | 6,1 |
| | 30–39 | 25 154 | 7,6 |
| | 40–49 | 35 608 | 10,7 |
| | 50–59 | 59 608 | 18,0 |
| | 60–69 | 70 506 | 21,3 |
| | 70–79 | 59 450 | 17,9 |
| | 80–89 | 45 326 | 13,7 |
| | 90+ | 15 742 | 4,7 |
| Pojištění | Medicare | 164 324 | 49,6 |
| | Medicaid | 53 646 | 16,2 |
| | soukromé | 100 968 | 30,4 |
| | jiné pojištění | 8 809 | 2,7 |
| | jiné | 59 | < 0,1 |
| | neuvedeno | 3 798 | 1,1 |
| Rodinný stav | v manželství | 145 672 | 43,9 |
| | svobodní | 113 157 | 34,1 |
| | ovdovělí | 39 674 | 12,0 |
| | rozvedení | 25 333 | 7,6 |
| | neuvedeno | 7 768 | 2,3 |
| Rasa | bílá | 228 560 | 68,9 |
| | černá | 49 001 | 14,8 |
| | hispánská | 17 555 | 5,3 |
| | asijská | 10 654 | 3,2 |
| | jiná | 13 737 | 4,1 |
| | neuvedeno | 12 097 | 3,6 |
| Jazyk | angličtina | 298 375 | 90,0 |
| | jiný jazyk | 32 649 | 9,8 |
| | neuvedeno | 580 | 0,2 |

*Zdroj:* stejné tabulky jako u souhrnu.

### 3.3 Věk podle pohlaví

Obrázek 1 ukazuje počty zpráv podle věkového pásma a pohlaví pacienta.




Obrázek 1: Počet zpráv vstupního korpusu podle věkového pásma při přijetí a pohlaví pacienta.

## 4 Shrnutí a rozhodnutí

Dokument popsal demografii vstupního korpusu. Pro další práci z toho plyne:

- **Demografie není příznakem ani stratifikací.** Pohlaví, věk, pojištění, rodinný stav, rasa ani jazyk nevstupují jako příznak modelů ani jako proměnná stratifikace. Dělení dat stratifikuje jen podle štítků (pátý sešit).
- **Pohlaví je reference pro extrakci.** Sloupec patients.gender je reference pro extrakci pohlaví z preambule zprávy. Většinové pohlaví (ženy) tvoří 51,3 % pacientů se známým pohlavím. To je přesnost konstantní odpovědi, kterou musí extrakce překonat.
- **Věk se z textu neextrahuje.** Věk je ve zprávách maskovaný (třetí sešit), a zůstává proto jen popisem.
- **Jazyk přijetí není jazyk zprávy.** Sloupec `admissions.language` je preferovaný jazyk pacienta. Zprávy jsou anglicky a jazyková osa práce (čeština a angličtina) s ním nesouvisí.
- **Výkon podle podskupin se nevykazuje.** Největší rasovou skupinou je skupina „bílá“ s podílem 68,9 % zpráv. Korpus pochází z jednoho centra, a výsledky se proto nemusí zobecnit na jiné populace.

## 5 Omezení

Korpus pochází z jednoho centra, takže jeho demografie nemusí odpovídat jiným populacím. Podíly různých zrnitostí se nesrovnávají: pohlaví se počítá na pacienta, ostatní atributy na zprávu, a pacient s více zprávami proto v ostatních atributech váží víc. Rasa a jazyk jsou zapsány při přijetí a rasa je sloučena do hrubých skupin, takže nevystihuje původ pacienta. Věk starších pacientů je v MIMIC-IV maskovaný, proto pásmo 90+ spojuje všechny pacienty nad 89 let a medián a kvartily vycházejí ze seřezaného věku. Rok přijetí je posunutý o náhodný interval, ale věk při přijetí zůstává vůči roku ukotvení správný (A. E. W. Johnson et al. 2023).

## Příloha A: provenance renderu

Tabulka 3 uvádí údaje, podle kterých lze render dohledat a zopakovat: revizi kódu, otisk zámku prostředí, zdroj dat a verze použitých nástrojů.

Tabulka 3: Provenance renderu.

| Položka | Hodnota |
|---|---|
| Revize kódu (commit) | e3cf538767b447de0f608c750332afed5beb3956 |
| Necommitnuté změny | ne |
| Otisk pixi.lock (SHA-256) | af50ffb1143e322d2f3de22275341738bbd0725befb07500ba5ef6cdcda01b01 |
| Zdroj dat | otisky CSV z config/mimic_tables.json |
| Otisk discharge.csv.gz (SHA-256) | 27bc552edaf81c2af322040cb7e8eb36417173b23c79405bb92fcf73bef2dbc5 |
| Otisk radiology.csv.gz (SHA-256) | 2c09bc76ee12d5f3b8f572deb7218fbaf3e59b32eccfdae14686e05ae099eebb |
| Otisk admissions.csv.gz (SHA-256) | a9584ed88e9ed664a2f66f86a5cf9fd175c8bb0af50e3b6115598b19e978384e |
| Otisk d_icd_diagnoses.csv.gz (SHA-256) | a81065bf45ccf74f589bec855bbb0a07b5c014907b34ff76fe20583a2c87cc79 |
| Otisk d_icd_procedures.csv.gz (SHA-256) | a2ac8afcb99fd16bce2e6c7ad445e3bd1dfd658e52182313 0ab08b66fdd3d6d4 |
| Otisk diagnoses_icd.csv.gz (SHA-256) | 47665a41b2a3ad990d6f314062d5bd6d29d467b0fd402dd94662044ec8b073d2 |
| Otisk omr.csv.gz (SHA-256) | 8280a8023203bddc6cc4419bd8cd253a015b8bc0bc53852ec92f98c7353f31e2 |
| Otisk patients.csv.gz (SHA-256) | 4c7507de7ecad8c5ba7647ea4d26018e88ff6672c5fc22ab59c2a5697d687cdd |
| Otisk pharmacy.csv.gz (SHA-256) | c9885721e4c968f0773145d7f6ba4d3cc3755d5600ee400ff95b1d3238053811 |
| Otisk prescriptions.csv.gz (SHA-256) | 0d8481c7d5d7c9ec2fea3fc543ddaaadb5a933cd22c7b9dda4289361e4d77199 |
| Otisk procedures_icd.csv.gz (SHA-256) | 3271397d0517131f84399b698cbb0c2f435aaab0f873a3806e13b097661596f7 |
| Otisk services.csv.gz (SHA-256) | 31c82ebee94e0c04d6966fbfec30579ec00f9c7816b80852f9580656e6183888 |
| Otisk mimic-iv-bhc.csv (SHA-256) | e45c09997b25d744abb20573623885eba052299cf2a721c18bbf5ca9a54989c1 |
| Python | 3.13.16 |
| DuckDB | 1.5.6 |
| R | R version 4.5.3 (2026-03-11) |
| r-duckdb | 1.5.5 |

## Literatura

Johnson, Alistair E. W., Lucas Bulgarelli, Lu Shen, et al. 2023. „MIMIC-IV, a freely accessible electronic health record dataset". *Scientific Data* 10 (1): 1. https://doi.org/10.1038/s41597-022--01899-x.

Johnson, Alistair, Lucas Bulgarelli, Tom Pollard, et al. 2024. *MIMIC-IV*. Verze 3.1. PhysioNet. https://doi.org/10.13026/kpb9-mt58.

Johnson, Alistair, Tom Pollard, Steven Horng, Leo Anthony Celi, a Roger Mark. 2023. *MIMIC--IV-Note: Deidentified free-text clinical notes*. Verze 2.2. PhysioNet. https://doi.org/10.13026/1n74-ne17.