Explorační analýza datové sady: demografie vstupního korpusu

Martin Žoha

Abstrakt Dokument popisuje demografii vstupního korpusu vymezeného v předchozím sešitu, tedy propouštěcích zpráv s diagnózou ICD, dostatečnou délkou a bez přesných duplicit. Uvádí pohlaví pacientů, věk při přijetí a pojištění, rodinný stav, rasu a jazyk, ze kterých skládá charakteristiku korpusu pro text práce. Nakonec rozhoduje, že demografie do pipeline nevstupuje s jedinou výjimkou: pohlaví slouží jako reference pro extrakci pohlaví z preambule zprávy.

Obsah

1 Úvod 1
2 Data a metody 2
3 Výsledky 2
3.1 Souhrn vstupního korpusu 2
3.2 Charakteristika 3
3.3 Věk podle pohlaví 5
4 Shrnutí a rozhodnutí 5
5 Omezení 5
Příloha A: provenance renderu 6
Literatura 8

1 Úvod

Tento sešit je šestým z řady sešitů explorační analýzy. Pátý sešit vymezil vstupní korpus, tedy zprávy, které vstupují do rozdělení dat na trénovací a testovací část. Tento sešit popisuje, koho se tyto zprávy týkají. Klade si tři cíle:

- charakterizovat vstupní korpus podle pohlaví, věku při přijetí, pojištění, rodinného stavu, rasy a jazyka pacientů,
- ukázat rozložení věku podle pohlaví,
- rozhodnout, zda a jak demografie vstupuje do pipeline.

Sešit demografii jen popisuje. Výkon modelů podle demografických podskupin práce nevykazuje, protože zadání to nevyžaduje; menšinové skupiny jsou navíc malé a intervaly spolehlivosti by byly široké.

Data pocházejí z MIMIC-IV (Johnson et al. 2024; A. E. W. Johnson et al. 2023) a MIMIC-IV-Note (A. Johnson et al. 2023), které podléhají smlouvě o užívání dat (DUA). Dokument proto zveřejňuje jen agregáty, nikdy řádková data ani texty zpráv. Počty pacientů a zpráv, zprávy

bez záznamu přijetí nebo pacienta, medián a kvartily věku jsou metriky korpusu a uvádějí se přesně. Pohlaví, věkové pásmo, pojištění, rodinný stav, rasa a jazyk vymezují skupiny pacientů kvaziidentifikátorem, a proto se v každém atributu kategorie s méně než deseti pacienty nebo zprávami sloučí do řádku „ostatní (n < 10)“; práh je pravidlo práce, DUA malé počty neupravuje.

Dokument je členěn takto. Kapitola 2 popisuje metody. Kapitola 3 uvádí výsledky. Kapitola 4 shrnuje rozhodnutí pro další práci a kapitola 5 jmenuje omezení. Příloha A dokumentuje provenance renderu.

2 Data a metody

Sešit čte propouštěcí zprávy (`discharge`), diagnózy ICD (`diagnoses_icd`), pacienty (`patients`) a přijetí (`admissions`). Všechny sloupce jsou v parquetu uloženy jako text a převádějí se přes `TRY_CAST`, takže nečíselná hodnota dá neznámý věk, ne chybu. Dotazy provádí DuckDB nad parquetem. Dotazy jsou v `eda/R/demographics.R` a mají testy nad ručně vytvořenými tabulkami; výběr vstupního korpusu sdílí se sešitem 5 (`eda/R/selection.R`), takže populace je v obou sešitech táž.

Pojmy a jednotky jsou tyto:

- *populací* je vstupní korpus: propouštěcí zprávy s kódem ICD, dlouhé aspoň 100 znaků a bez přesných duplicit,
- *zrnitost*: pohlaví je atribut pacienta a počítá se jednou na pacienta; věk při přijetí, pojištění, rodinný stav, rasa a jazyk jsou atributy přijetí a počítají se jednou na zprávu, protože zpráva je jednotkou klasifikace; podíly různých zrnitostí se proto nesrovnávají,
- *připojení*: `patients` a `admissions` se připojují zleva. Chybějící řádek dá kategorii „neuvedeno“, takže se každá tabulka sečte do velikosti korpusu; počet zpráv bez záznamu přijetí a bez záznamu pacienta se uvádí zvlášť,
- *popisky kategorií* pocházejí z kódu, ne z dat: pevné slovníky mapují každou známou hodnotu na její popisek, hodnotu mimo slovník na „jiné“ a chybějící hodnotu na „neuvedeno“. Rasa se slučuje podle předpony do skupin bílá, černá, hispánská a asijská; hodnoty „UNKNOWN“, „UNABLE TO OBTAIN“ a „PATIENT DECLINED TO ANSWER“ jsou „neuvedeno“, ostatní „jiná“. Jazyk má jen angličtinu a „jiný jazyk“. Surový popisek z dat se tak do výstupu nedostane,
- *věk při přijetí* je `anchor_age` plus rozdíl roku přijetí a `anchor_year`. Pacient, který byl v roce ukotvení starší než 89 let, má `anchor_age` nastavené na 91 (A. E. W. Johnson et al. 2023); jeho věk se nepočítá a zpráva patří do pásma 90+. Všechny věky od 90 let se seřezávají do jednoho pásma 90+. Pásma mají deset let (do 29, 30–39 až 80–89, 90+) a „neuvedeno“. Zveřejňují se jen medián a kvartily seřezaného věku, nikdy minimum ani maximum; maskovaní pacienti mají v seřezaném věku hodnotu 90, což vnitřní kvantily neovlivní.

3 Výsledky

3.1 Souhrn vstupního korpusu

Vstupní korpus tvoří 331 604 zpráv od 145 817 pacientů. Medián věku při přijetí je 63,0 let, kvartily jsou 50,0 a 76,0. Bez záznamu přijetí je 0 zpráv a bez záznamu pacienta 0 zpráv. Maskovaný věk (pacient starší než 89 let v roce ukotvení) má 10 835 zpráv. Tabulka 1 uvádí souhrn.

Tabulka 1: Souhrn vstupního korpusu: počty a věk při přijetí.

Ukazatel	Hodnota
Pacienti	145 817
Zprávy	331 604
Medián věku při přijetí (kvartily)	63,0 (50,0–76,0)
Zprávy bez záznamu přijetí	0
Zprávy bez záznamu pacienta	0

Zdroj: dotaz v DuckDB nad tabulkami `discharge`, `diagnoses_icd`, `patients` a `admissions`; věk je seřezaný na 90 let.

3.2 Charakteristika

Tabulka 2 uvádí charakteristiku korpusu. Jmenovatelem podílu jsou u pohlaví pacienti, u ostatních atributů zprávy.

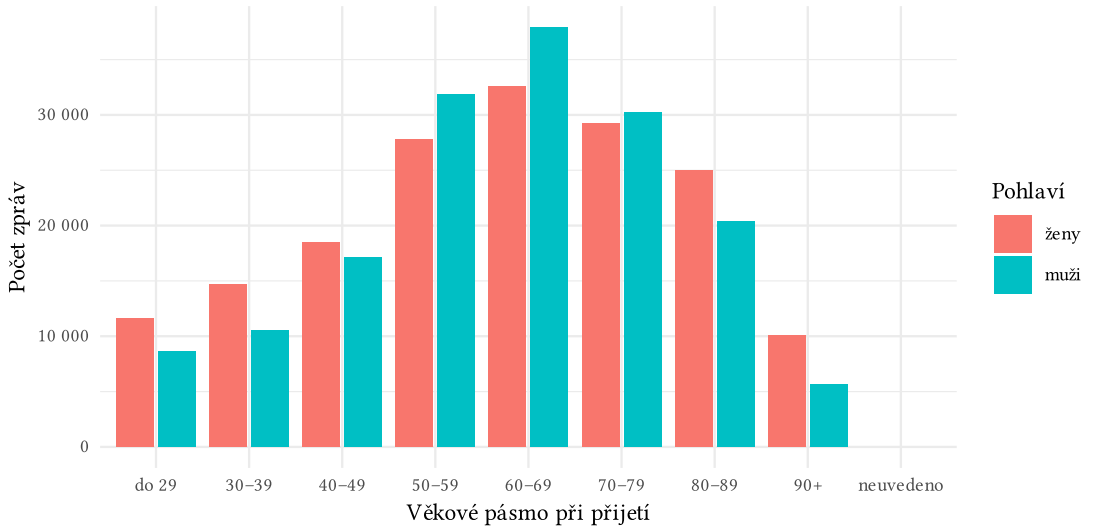
Tabulka 2: Charakteristika vstupního korpusu; podíl pacientů u pohlaví, podíl zpráv u ostatních atributů.

Atribut	Kategorie	Počet	Podíl (%)
Pohlaví	ženy	74 849	51,3
	muži	70 968	48,7
Věkové pásmo	do 29	20 210	6,1
	30–39	25 154	7,6
	40–49	35 608	10,7
	50–59	59 608	18,0
	60–69	70 506	21,3
	70–79	59 450	17,9
	80–89	45 326	13,7
	90+	15 742	4,7
Pojištění	Medicare	164 324	49,6
	Medicaid	53 646	16,2
	soukromé	100 968	30,4
	jiné pojištění	8 809	2,7
	jiné	59	0,0
	neuvedeno	3 798	1,1
Rodinný stav	v manželství	145 672	43,9
	svobodní	113 157	34,1
	ovdovělí	39 674	12,0
	rozvedení	25 333	7,6
	neuvedeno	7 768	2,3
Rasa	bílá	228 560	68,9
	černá	49 001	14,8
	hispánská	17 555	5,3
	asijská	10 654	3,2
	jiná	13 737	4,1
	neuvedeno	12 097	3,6
Jazyk	angličtina	298 375	90,0
	jiný jazyk	32 649	9,8
	neuvedeno	580	0,2

Zdroj: stejné tabulky jako u souhrnu; kategorie s méně než deseti pacienty nebo zprávami jsou v rámci atributu sloučeny.

3.3 Věk podle pohlaví

Obrázek 1 ukazuje počty zpráv podle věkového pásma a pohlaví pacienta.



Obrázek 1: Počet zpráv vstupního korpusu podle věkového pásma při přijetí a pohlaví pacienta; nezobrazeny jsou buňky sloučené podle pohlaví nebo podle věkového pásma.

4 Shrnutí a rozhodnutí

Dokument popsal demografii vstupního korpusu. Pro další práci z toho plyne:

- **Demografie není příznakem ani stratifikací.** Pohlaví, věk, pojištění, rodinný stav, rasa ani jazyk nevstupují jako příznak modelů ani jako proměnná stratifikace. Dělení dat stratifikuje jen podle štítků (pátý sešit).
- **Pohlaví je reference pro extrakci.** Sloupec patients.gender je reference pro extrakci pohlaví z preambule zprávy. Většinové pohlaví (ženy) tvoří 51,3 % pacientů se známým pohlavím. To je přesnost konstantní odpovědi, kterou musí extrakce překonat.
- **Věk se z textu neextrahuje.** Věk je ve zprávách maskovaný (třetí sešit), a zůstává proto jen popisem.
- **Jazyk přijetí není jazyk zprávy.** Sloupec `admissions.language` je preferovaný jazyk pacienta. Zprávy jsou anglicky a jazyková osa práce (čeština a angličtina) s ním nesouvisí.
- **Výkon podle podskupin se nevykazuje.** Největší rasovou skupinou je skupina „bílá“ s podílem 68,9 % zpráv. Korpus pochází z jednoho centra, a výsledky se proto nemusí zobecnit na jiné populace.

5 Omezení

Korpus pochází z jednoho centra, takže jeho demografie nemusí odpovídat jiným populacím. Podíly různých zrnitostí se nesrovnávají: pohlaví se počítá na pacienta, ostatní atributy na zprávu, a pacient s více zprávami proto v ostatních atributech váží víc. Rasa a jazyk jsou zapsány při přijetí a rasa je sloučena do hrubých skupin, takže nevystihuje původ pacienta. Věk starších pacientů je v MIMIC-IV maskovaný, proto pásmo 90+ spojuje všechny pacienty nad 89 let a medián a kvartily vycházejí ze seřezaného věku. Rok přijetí je posunutý o náhodný interval, ale věk při přijetí zůstává vůči roku ukotvení správný (A. E. W. Johnson

et al. 2023). Kategorie s méně než deseti pacienty nebo zprávami se v tabulce a grafu slučují, proto menšinové skupiny nejsou vidět.

Příloha A: provenance renderu

Tabulka 3 uvádí údaje, podle kterých lze render dohledat a zopakovat: revizi kódu, otisk zámku prostředí, zdroj dat a verze použitých nástrojů.

Tabulka 3: Provenance renderu.

Položka	Hodnota
Revize kódu (commit)	7116069ca681da41a878ab99291571dac51ce848
Necommitnuté změny	ne
Otisk pixi.lock (SHA-256)	bc21950a8ed44ddf 0e7bee9094c57500 e90f5e1aa15f5764 95b59d66c6828b72
Zdroj dat	otisky CSV z config/mimic_tables.json
Otisk discharge.csv.gz (SHA-256)	27bc552edaf81c2a f322040cb7e8eb36 417173b23c79405b b92fcf73bef2dbc5
Otisk radiology.csv.gz (SHA-256)	2c09bc76ee12d5f3 b8f572deb7218fba f3e59b32eccfdae1 4686e05ae099eebb
Otisk admissions.csv.gz (SHA-256)	a9584ed88e9ed664 a2f66f86a5cf9fd1 75c8bb0af50e3b61 15598b19e978384e
Otisk d_icd_diagnoses.csv.gz (SHA-256)	a81065bf45ccf74f 589bec855bbb0a07 b5c014907b34ff76 fe20583a2c87cc79
Otisk d_icd_procedures.csv.gz (SHA-256)	2ac8afcb99fd16b ce2e6c7ad445e3bd 1dfd658e52182313 0ab08b66fdd3d6d4
Otisk diagnoses_icd.csv.gz (SHA-256)	47665a41b2a3ad99 0d6f314062d5bd6d 29d467b0fd402dd9 4662044ec8b073d2
Otisk omr.csv.gz (SHA-256)	8280a8023203bddc 6cc4419bd8cd253a 015b8bc0bc53852e c92f98c7353f31e2
Otisk patients.csv.gz (SHA-256)	4c7507de7ecad8c5 ba7647ea4d26018e 88ff6672c5fc22ab 59c2a5697d687cdd
Otisk pharmacy.csv.gz (SHA-256)	c9885721e4c968f0 773145d7f6ba4d3c c3755d5600ee400f f95b1d3238053811
Otisk prescriptions.csv.gz (SHA-256)	0d8481c7d5d7c9ec 2fea3fc543ddaaad b5a933cd22c7b9dd a4289361e4d77199
Otisk procedures_icd.csv.gz (SHA-256)	3271397d0517131f 84399b698cbb0c2f 435aaab0f873a380 6e13b097661596f7
Otisk services.csv.gz (SHA-256)	31c82ebee94e0c04 d6966fbfec30579e c00f9c7816b80852 f9580656e6183888
Python	3.13.16
DuckDB	1.5.6
R	R version 4.5.3 (2026-03-11)

Literatura

Johnson, Alistair E. W., Lucas Bulgarelli, Lu Shen, et al. 2023. „MIMIC-IV, a freely accessible electronic health record dataset". *Scientific Data* 10 (1): 1. https://doi.org/10.1038/s41597-022--01899-x.

Johnson, Alistair, Lucas Bulgarelli, Tom Pollard, et al. 2024. *MIMIC-IV*. Verze 3.1. PhysioNet. https://doi.org/10.13026/kpb9-mt58.

Johnson, Alistair, Tom Pollard, Steven Horng, Leo Anthony Celi, a Roger Mark. 2023. *MIMIC--IV-Note: Deidentified free-text clinical notes*. Verze 2.2. PhysioNet. https://doi.org/10.13026/1n74-ne17.