Explorační analýza datové sady: krajina diagnóz

Martin Žoha

Abstrakt Dokument popisuje, jaké diagnózy nese vstupní korpus propouštěcích zpráv, a vychází jen z tabulky diagnóz ICD, bez textu zpráv. Uvádí zastoupení Charlsonových kategorií komorbidit, nejčastější tříznakové kódy zvlášť pro ICD-9 a ICD-10, prevalenci a souběh deseti kandidátních diagnóz a kódy kapitoly příznaků a symptomů. Z prevalence vybírá kandidáty v předem stanoveném pásmu, ověřuje, zda pool nevynechal častou kategorii, a jmenuje rizika pro mapování ICD-9 na ICD-10 a pro diverzitu štítků.

Obsah

1 Úvod 1
2 Data a metody 2
3 Výsledky 3
3.1 Souhrn vstupního korpusu 3
3.2 Charlsonovy kategorie 3
3.3 Nejčastější kódy 5
3.4 Kandidátní diagnózy 7
3.5 Souběh kandidátů 8
3.6 Příznaky a symptomy 9
4 Shrnutí a rozhodnutí 11
5 Omezení 12
Příloha A: provenance renderu 12
Literatura 14

1 Úvod

Tento sešit je sedmým z řady sešitů explorační analýzy. Předchozí sešity vymezily vstupní korpus a popsaly jeho pacienty. Tento sešit popisuje, jaké diagnózy korpus nese. Klade si tyto cíle:

- popsat krajinu komorbidit podle Charlsonových kategorií,
- uvést nejčastější tříznakové kódy zvlášť pro ICD-9 a ICD-10,
- změřit prevalenci a souběh deseti kandidátních diagnóz a vybrat z nich kandidáty podle předem stanoveného pásma,
- spočítat kódy kapitoly příznaků a symptomů jako první odhad rozsahu extrakce symptomů.

Sešit pracuje jen s tabulkou diagnóz ICD. Zmínky diagnóz v textu zpráv, jejich shodu s kódy a výběr pětice diagnóz řeší následující sešit; tento sešit mu předává kandidáty a rizika.

Data pocházejí z MIMIC-IV (Johnson et al. 2024; A. E. W. Johnson et al. 2023) a MIMIC-IV-Note (A. Johnson et al. 2023), které podléhají smlouvě o užívání dat (DUA). Dokument proto zveřejňuje jen agregáty. Počty a podíly skupin pacientů podle diagnóz se zveřejňují přesně, protože DUA malé počty neupravuje a pacienti se neidentifikují. Práh deseti zpráv platí jen pro kódy ICD a jejich názvy, protože jde o popisky z dat.

Dokument je členěn takto. Kapitola 2 popisuje metody. Kapitola 3 uvádí výsledky. Kapitola 4 shrnuje rozhodnutí pro další práci a kapitola 5 jmenuje omezení. Příloha A dokumentuje provenance renderu.

2 Data a metody

Sešit čte propouštěcí zprávy (`discharge`), diagnózy ICD (`diagnoses_icd`) a číselník diagnóz (`d_icd_diagnoses`). Všechny sloupce jsou v parquetu uloženy jako text a převádějí se přes `TRY_CAST`, takže nečíselná verze ICD nedá chybu, jen kód bez shody. Dotazy provádí DuckDB nad parquetem a jsou v `eda/R/diagnoses.R` s testy nad ručně vytvořenými tabulkami.

Pojmy a jednotky jsou tyto:

- *populací* je vstupní korpus z pátého sešitu: propouštěcí zprávy s kódem ICD, dlouhé aspoň 100 znaků a bez přesných duplicit; jednotkou je zpráva a kódy se připojují přes `hadm_id`. Výběr diagnóz se podle pátého sešitu počítá nad tímto korpusem. Prevalence proto nejsou srovnatelné s hodnotami počítanými nad všemi propouštěcími zprávami,
- *shoda kódu s předponou*: kód se shoduje s kandidátem, když velkými písmeny a bez okrajových mezer začíná některou předponou své verze a verze ICD je 9, resp. 10. Kód téže předpony v jiné verzi se neshoduje,
- *pool kandidátů* je deset diagnóz převzatých z konfigurace předchozího projektu (diabetes, srdeční selhání, CHOPN, chronické onemocnění ledvin, pneumonie, akutní infarkt myokardu, cerebrovaskulární onemocnění, fibrilace síní, sepse a akutní selhání ledvin). Předpony kandidátů, které odpovídají Charlsonově kategorii, vycházejí z map Quan 2005 (Quan et al. 2005); předpony pneumonie, fibrilace síní, sepse a akutního selhání ledvin jsou podle klasifikace ICD. Předpony diabetu a CHOPN se od map Quan odchylují a předpony pneumonie jsou rozšířené; všechny tři jsou sladěné mezi ICD-9 a ICD-10 podle mapování GEMs (Centers for Medicare & Medicaid Services 2017) a kategorií CCS (Agency for Healthcare Research and Quality, Healthcare Cost and Utilization Project 2015) a CCSR (Agency for Healthcare Research and Quality, Healthcare Cost and Utilization Project 2025) (diabetes zahrnuje i sekundární formy, CHOPN chronickou bronchitidu a emfyzém bez bronchiektázií a pneumonie i pneumonii u infekcí zařazených jinde a plicní antrax), takže stejný kód znamená v obou érách tutéž diagnózu. Předpony jsou v `config/diagnosis_candidates.json`, aby definice, kterou sešit měří, byla táž, kterou použije výběr štítků. Obezita ani hypertenze v poolu nejsou,
- *Charlsonovy kategorie* počítá balík R `comorbidity` (Gasparini 2018) podle map Quan 2005 (Quan et al. 2005), které dávají 17 kategorií. Mapy se volají zvlášť pro ICD-9 a ICD-10 a zpráva má kategorii, když ji má kterýkoli kód jejího přijetí v kterékoli verzi. Hierarchie se neuplatňuje, protože jde o přítomnost každé kategorie, a diabetes bez komplikací a s komplikacemi se proto počítají každý zvlášť,
- *žebříček* seskupuje kódy na první tři znaky (kódy ICD-9 začínající E na první čtyři) a řadí skupiny podle počtu zpráv, při shodě podle kódu. Jmenovatelem podílu je počet zpráv vstupního korpusu s aspoň jedním kódem dané verze; zpráva s kódy obou verzí patří do

obou jmenovatelů. Název skupiny je název jejího nejčastějšího plného kódu s aspoň deseti zprávami z číselníku `d_icd_diagnoses`; nemá-li skupina takový kód, název je „neuvedeno“. Při shodě počtu rozhoduje nejmenší kód. Skupiny s méně než deseti zprávami se v žebříčku neukazují, protože jejich kód je popisek z dat,

- *pásmo prevalence* 5–60 % zpráv je první kritérium výběru štítků a je stanoveno předem. Dolní mez zajišťuje dost pozitivních zpráv v každé části křížové validace, horní vyřazuje diagnózy tak časté, že klasifikace ztrácí rozlišovací smysl. Hodnoty pocházejí z pravidla stanoveného před měřením; měnit je po pohledu na data by bylo cherry-picking. Sešit pásmo jen aplikuje,
- *souběh* je matice podílů P(sloupec | řádek), tedy podíl zpráv s kandidátem řádku, které mají i kandidáta sloupce.

3 Výsledky

3.1 Souhrn vstupního korpusu

Vstupní korpus tvoří 331 604 zpráv. Jen kódy ICD-9 má 209 316 zpráv, jen kódy ICD-10 122 281 a kódy obou verzí 7 zpráv. Tabulka 1 uvádí souhrn včetně podílu zpráv s kódem kapitoly příznaků a symptomů.

Tabulka 1: Souhrn vstupního korpusu podle éry ICD a podíl zpráv s kódem kapitoly příznaků.

Ukazatel	Zprávy	Podíl (%)
Zprávy vstupního korpusu	331 604	100,0
Jen kódy ICD-9	209 316	63,1
Jen kódy ICD-10	122 281	36,9
Kódy obou verzí	7	< 0,1
Bez kódu s platnou verzí	0	0,0
Zprávy s kódem kapitoly R (780–799)	163 376	49,3

Zdroj: dotaz v DuckDB nad tabulkami `discharge` a `diagnoses_icd`.

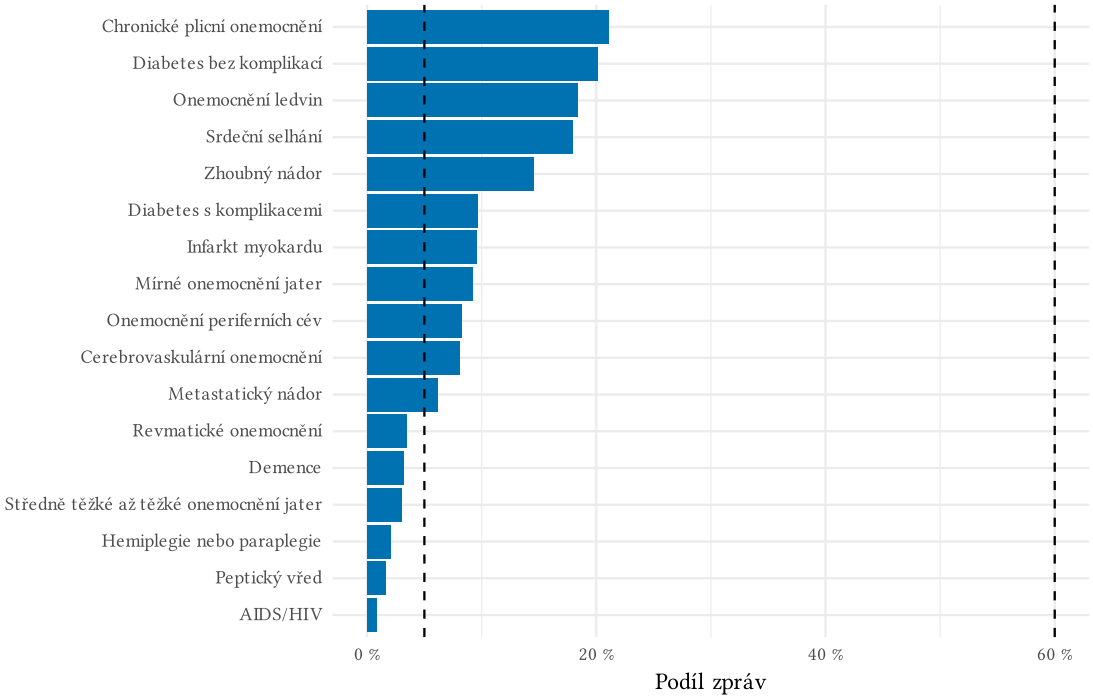
3.2 Charlsonovy kategorie

Tabulka 2 a Obrázek 1 uvádějí podíl zpráv s každou z 17 Charlsonových kategorií. Svislé čáry v grafu vymezují pásmo prevalence.

Tabulka 2: Zprávy vstupního korpusu podle Charlsonových kategorií komorbidit.

Kategorie	Zprávy	Podíl (%)
Infarkt myokardu	31 551	9,5
Srdeční selhání	59 403	17,9
Onemocnění periferních cév	27 230	8,2
Cerebrovaskulární onemocnění	26 810	8,1
Demence	10 432	3,1
Chronické plicní onemocnění	69 814	21,1
Revmatické onemocnění	11 386	3,4
Peptický vřed	5 223	1,6
Mírné onemocnění jater	30 539	9,2
Diabetes bez komplikací	66 793	20,1
Diabetes s komplikacemi	31 880	9,6
Hemiplegie nebo paraplegie	6 860	2,1
Onemocnění ledvin	60 985	18,4
Zhoubný nádor	48 303	14,6
Středně těžké až těžké onemocnění jater	10 049	3,0
Metastatický nádor	20 304	6,1
AIDS/HIV	2 733	0,8

Zdroj: kódy z `diagnoses_icd`, mapy Quan 2005 v balíku `comorbidity`.



Obrázek 1: Podíl zpráv vstupního korpusu podle Charlsonových kategorií; svislé čáry vymezují pásmo prevalence 5–60 %.

3.3 Nejčastější kódy

Tabulka 3 a Tabulka 4 uvádějí 20 nejčastějších tříznakových skupin kódů zvlášť pro ICD-10 a ICD-9, protože tříznakové kódy obou verzí nejsou srovnatelné. Zobrazují se jen skupiny s aspoň deseti zprávami; práh chrání popisek kódu z dat.

Tabulka 3: Nejčastější tříznakové skupiny kódů ICD-10 podle počtu zpráv.

Kód	Název nejčastějšího kódu skupiny	Zprávy	Podíl (%)
E78	Hyperlipidemia, unspecified	49 306	40,3
I10	Essential (primary) hypertension	43 570	35,6
Z79	Long term (current) use of anticoagulants	40 390	33,0
Z87	Personal history of nicotine dependence	40 252	32,9
Y92	Unspecified place or not applicable	35 293	28,9
E11	Type 2 diabetes mellitus without complications	31 576	25,8
K21	Gastro-esophageal reflux disease without esophagitis	31 108	25,4
I25	Atherosclerotic heart disease of native coronary artery without angina pectoris	27 164	22,2
E87	Hypo-osmolality and hyponatremia	25 636	21,0
Z68	Body mass index [BMI] 40.0-44.9, adult	23 934	19,6
F32	Major depressive disorder, single episode, unspecified	23 511	19,2
I50	Chronic diastolic (congestive) heart failure	23 451	19,2
N18	Chronic kidney disease, unspecified	23 359	19,1
I48	Unspecified atrial fibrillation	22 475	18,4
N17	Acute kidney failure, unspecified	22 226	18,2
Z86	Personal history of transient ischemic attack (TIA), and cerebral infarction without residual deficits	21 413	17,5
F41	Anxiety disorder, unspecified	21 090	17,2
Z85	Personal history of other malignant neoplasm of skin	20 949	17,1
G47	Obstructive sleep apnea (adult) (pediatric)	19 385	15,9
Z95	Presence of coronary angioplasty implant and graft	18 011	14,7

Zdroj: `diagnoses_icd` a `d_icd_diagnoses`; jmenovatelem je počet zpráv s aspoň jedním kódem ICD-10.

Tabulka 4: Nejčastější tříznakové skupiny kódů ICD-9 podle počtu zpráv.

Kód	Název nejčastějšího kódu skupiny	Zprávy	Podíl (%)
401	Unspecified essential hypertension	85 330	40,8
272	Other and unspecified hyperlipidemia	72 613	34,7
250	Diabetes mellitus without mention of complication, type II or unspecified type, not stated as uncontrolled	55 764	26,6
V58	Long-term (current) use of anticoagulants	51 870	24,8
V45	Percutaneous transluminal coronary angioplasty status	48 167	23,0
530	Esophageal reflux	45 366	21,7
276	Hyposmolality and/or hyponatremia	44 332	21,2
285	Anemia, unspecified	42 604	20,4
427	Atrial fibrillation	42 090	20,1
V15	Personal history of tobacco use	41 713	19,9
414	Coronary atherosclerosis of native coronary artery	40 738	19,5
585	Chronic kidney disease, unspecified	35 189	16,8
428	Congestive heart failure, unspecified	33 227	15,9
403	Hypertensive chronic kidney disease, unspecified, with chronic kidney disease stage I through stage IV, or unspecified	30 573	14,6
V10	Personal history of malignant neoplasm of breast	30 541	14,6
584	Acute kidney failure, unspecified	30 089	14,4
305	Tobacco use disorder	28 602	13,7
311	Depressive disorder, not elsewhere classified	28 243	13,5
V12	Personal history of venous thrombosis and embolism	27 616	13,2
780	Insomnia, unspecified	27 081	12,9

Zdroj: `diagnoses_icd` a `d_icd_diagnoses`; jmenovatelem je počet zpráv s aspoň jedním kódem ICD-9.

3.4 Kandidátní diagnózy

Tabulka 5 uvádí prevalenci deseti kandidátů v celém korpusu a zvlášť mezi zprávami s kódy ICD-9 a ICD-10. Velký rozdíl mezi érami ukazuje, že předpony obou verzí nemusí znamenat totéž. Poslední sloupec zařazuje kandidáta k pásmu 5–60 %.

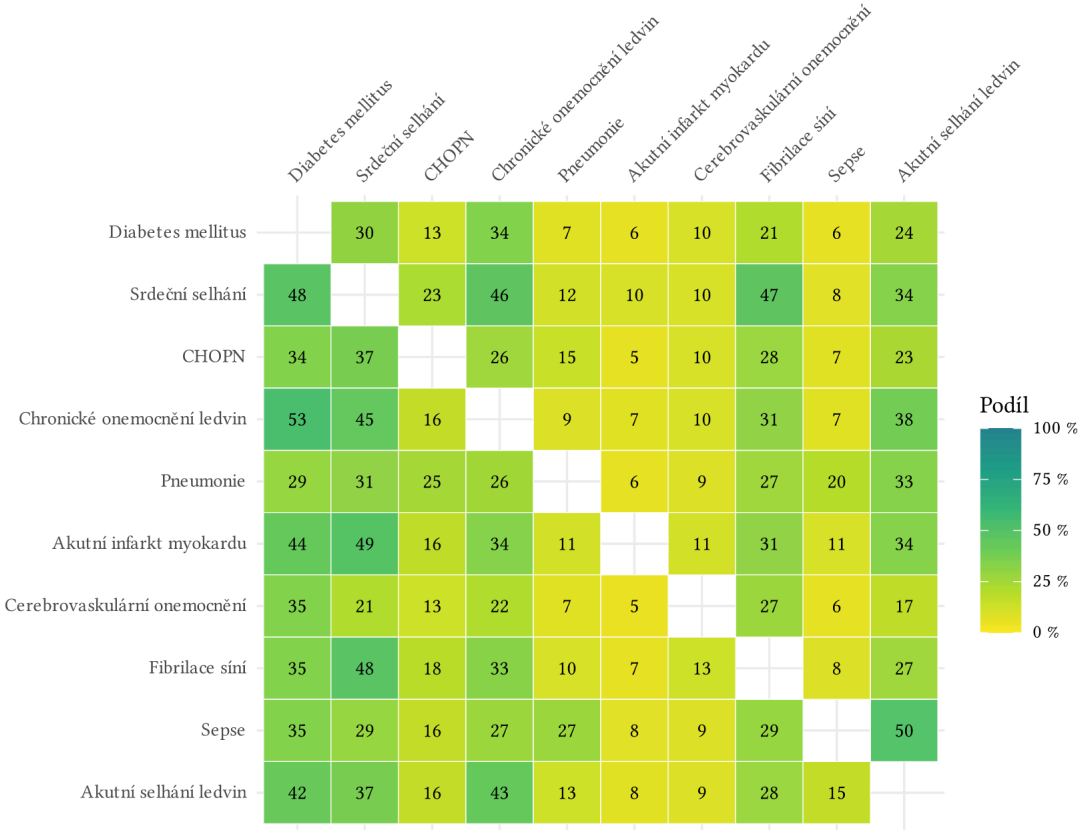
Tabulka 5: Prevalence kandidátních diagnóz ve vstupním korpusu a podle éry ICD a jejich poloha vůči pásmu prevalence.

Kandidát	Zprávy	Korpus (%)	ICD-9 (%)	ICD-10 (%)	Pásmo
Diabetes mellitus	91 149	27,5	27,0	28,3	v pásmu
Srdeční selhání	56 676	17,1	15,9	19,2	v pásmu
CHOPN	35 462	10,7	10,3	11,4	v pásmu
Chronické onemocnění ledvin	58 547	17,7	16,8	19,1	v pásmu
Pneumonie	21 173	6,4	6,3	6,5	v pásmu
Akutní infarkt myokardu	11 827	3,6	2,9	4,7	pod pásmem
Cerebrovaskulární onemocnění	26 371	8,0	7,6	8,6	v pásmu
Fibrilace síní	55 410	16,7	15,7	18,4	v pásmu
Sepse	15 764	4,8	3,9	6,2	pod pásmem
Akutní selhání ledvin	52 315	15,8	14,4	18,2	v pásmu

Zdroj: `diagnoses_icd`; jmenovatelem je počet zpráv korpusu, resp. zpráv s kódem dané verze.

3.5 Souběh kandidátů

Obrázek 2 ukazuje, jaký podíl zpráv s kandidátem na řádku má i kandidáta ve sloupci. Buňky s nulovým jmenovatelem jsou prázdné a diagonála se nekreslí.



Obrázek 2: Souběh kandidátních diagnóz: podíl zpráv s kandidátem na řádku, které mají i kandidáta ve sloupci; buňky s nulovým jmenovatelem jsou prázdné.

3.6 Příznaky a symptomy

Kapitola R mezinárodní klasifikace ICD-10 a kódy 780–799 klasifikace ICD-9 označují příznaky a symptomy. Tabulka 6 a Tabulka 7 uvádějí jejich nejčastější tříznakové skupiny. Slouží jako reference symptomů pro extrakci; zmínky symptomů v textu měří následující sešit.

Tabulka 6: Nejčastější tříznakové skupiny kódů kapitoly R (ICD-10).

Kód	Název nejčastějšího kódu skupiny	Zprávy	Podíl (%)
R33	Retention of urine, unspecified	6 568	5,4
R00	Tachycardia, unspecified	5 979	4,9
R11	Nausea with vomiting, unspecified	5 012	4,1
R09	Hypoxemia	4 671	3,8
R74	Nonspecific elevation of levels of transaminase and lactic acid dehydrogenase [LDH]	4 305	3,5
R65	Severe sepsis with septic shock	4 271	3,5
R13	Dysphagia, unspecified	4 256	3,5
R19	Diarrhea, unspecified	4 139	3,4
R10	Unspecified abdominal pain	4 061	3,3
R50	Fever, unspecified	3 921	3,2
R07	Other chest pain	3 778	3,1
R91	Other nonspecific abnormal finding of lung field	3 216	2,6
R41	Disorientation, unspecified	3 103	2,5
R79	Abnormal coagulation profile	3 068	2,5
R29	Facial weakness	2 999	2,5
R47	Aphasia	2 880	2,4
R45	Suicidal ideations	2 603	2,1
R18	Other ascites	2 492	2,0
R57	Cardiogenic shock	2 440	2,0
R53	Weakness	2 319	1,9

Zdroj: `diagnoses_icd` a `d_icd_diagnoses`; jmenovatelem je počet zpráv s aspoň jedním kódem ICD-10.

Tabulka 7: Nejčastější tříznakové skupiny kódů 780–799 (ICD-9).

Kód	Název nejčastějšího kódu skupiny	Zprávy	Podíl (%)
780	Insomnia, unspecified	27 081	12,9
787	Diarrhea	18 870	9,0
790	Abnormal coagulation profile	15 629	7,5
789	Other ascites	14 239	6,8
786	Other chest pain	13 335	6,4
788	Retention of urine, unspecified	12 572	6,0
785	Septic shock	10 065	4,8
784	Headache	8 116	3,9
782	Edema	6 655	3,2
799	Hypoxemia	6 484	3,1
783	Loss of weight	5 427	2,6
781	Abnormality of gait	5 216	2,5
793	Solitary pulmonary nodule	2 597	1,2
794	Nonspecific abnormal electrocardiogram [ECG] [EKG]	1 902	0,9
791	Other nonspecific findings on examination of urine	1 505	0,7
795	Nonspecific reaction to tuberculin skin test without active tuberculosis	948	0,5
792	Nonspecific abnormal findings in stool contents	828	0,4
796	Elevated blood pressure reading without diagnosis of hypertension	723	0,3

Zdroj: `diagnoses_icd` a `d_icd_diagnoses`; jmenovatelem je počet zpráv s aspoň jedním kódem ICD-9.

4 Shrnutí a rozhodnutí

Dokument popsal krajinu diagnóz vstupního korpusu. Pro další práci z toho plyne:

- **Předvýběr kandidátů.** Do rubriky následujícího sešitu postupují kandidáti v pásmu 5–60 % zpráv: Diabetes mellitus, Srdeční selhání, CHOPN, Chronické onemocnění ledvin, Pneumonie, Cerebrovaskulární onemocnění, Fibrilace síní a Akutní selhání ledvin. Pod pásmem jsou: Akutní infarkt myokardu a Sepse. Nad pásmem jsou: žádný. O pětici sešit nerozhoduje, protože mu chybí shoda s textem.
- **Audit proti cherry-pickingu.** Charlsonovy kategorie v pásmu 5–60 %, které nepokrývá žádný kandidát: Onemocnění periferních cév, Mírné onemocnění jater, Zhoubný nádor

a Metastatický nádor. Následující sešit je posoudí podle stejné rubriky, aby výběr nevynechal častou diagnózu.

- **Redundance kandidátů.** Dvojice s P(sloupec | řádek) aspoň 0,5 jsou riziko pro kritérium diverzity, protože většina zpráv s prvním kandidátem má i druhého: Chronické onemocnění ledvin → Diabetes mellitus a Sepse → Akutní selhání ledvin.
- **Rozdíly mezi érami.** Prevalence v jedné éře je víc než 1,5krát větší než v druhé u kandidátů: Akutní infarkt myokardu a Sepse. Předpony diabetu, CHOPN, chronického onemocnění ledvin, pneumonie a fibrilace síní jsou mezi érami sladěné podle GEMs (viz metody), takže jejich zbylý rozdíl odráží kódovací praxi nebo populaci; předpony ostatních kandidátů sladěné nejsou a rozdíl u nich může vzniknout i odlišným významem předpon.
- **Příznaky.** Referencí symptomů pro extrakci jsou kódy kapitoly R a 780–799, které má 49,3 % zpráv korpusu. Zmínky symptomů v textu měří následující sešit, který z nich odhadne rozsah úlohy.

5 Omezení

Kód ICD říká, že hospitalizace měla diagnózu, ne že ji zpráva zmiňuje; shodu s textem měří následující sešit. Prevalence se počítá nad vstupním korpusem, a proto nejsou srovnatelné s hodnotami nad všemi propouštěcími zprávami. Prevalence v různých érách ICD mohou odrážet změnu kódovací praxe i změnu populace, sešit je od sebe neodliší. Předpony pěti diagnóz, ze kterých se vybírají štítky (diabetes, CHOPN, chronické onemocnění ledvin, pneumonie a fibrilace síní), jsou sladěné mezi ICD-9 a ICD-10 podle GEMs, předpony ostatních pěti kandidátů jsou ruční mapování z konfigurace předchozího projektu; GEMs jsou z velké části přibližné, takže předpony nemusí odpovídat klinické představě o diagnóze. Charlsonovy kategorie vycházejí z map Quan 2005, které se omezují na komorbidity a nepokrývají všechny časté diagnózy. Skupiny kódů s méně než deseti zprávami nejsou v žebříčcích vidět, protože práh chrání popisky z dat. Název skupiny je název jejího nejčastějšího plného kódu a nemusí vystihovat celou skupinu.

Příloha A: provenance renderu

Tabulka 8 uvádí údaje, podle kterých lze render dohledat a zopakovat: revizi kódu, otisk zámku prostředí, zdroj dat a verze použitých nástrojů.

Tabulka 8: Provenance renderu.

Položka	Hodnota
Revize kódu (commit)	42c685bff292a12ec7aa4d2d2a7cbac8e5c9d345
Necommitnuté změny	ne
Otisk pixi.lock (SHA-256)	c9b8dbd92a0bb8d7 c26f7127af04b8f6 ba06d55dd6a9cc42 21c80324bf149fad
Zdroj dat	tabulky parquet ověřené proti vazbě na otisky CSV
Otisk CSV admissions (SHA-256)	a9584ed88e9ed664 a2f66f86a5cf9fd1 75c8bb0af50e3b61 15598b19e978384e
Otisk parquetu admissions (SHA-256)	511b92c1956c6e0a 17ccff692532bc39 f4d2962a55a8df5a 2404cb22ff0a1b0a
Otisk CSV d_icd_diagnoses (SHA-256)	a81065bf45ccf74f 589bec855bbb0a07 b5c014907b34ff76 fe20583a2c87cc79
Otisk parquetu d_icd_diagnoses (SHA-256)	4bbe089e2f75747a 1f4be3be4a8a3100 294b103af562208d 1b9cc92ffaa1b6a4
Otisk CSV d_icd_procedures (SHA-256)	a2ac8afcb99fd16b ce2e6c7ad445e3bd 1dfd658e52182313 0ab08b66fdd3d6d4
Otisk parquetu d_icd_procedures (SHA-256)	7de5e3083e432019 877ce3598856e558 9030a2876d604a9f b0ff17c1e8e16f9f
Otisk CSV diagnoses_icd (SHA-256)	47665a41b2a3ad99 0d6f314062d5bd6d 29d467b0fd402dd9 4662044ec8b073d2
Otisk parquetu diagnoses_icd (SHA-256)	c98d378ffafb8cf8 a81428570fcef4aa 57106eb8cb60f01e bf8143792ae83922
Otisk CSV discharge (SHA-256)	27bc552edaf81c2a f322040cb7e8eb36 417173b23c79405b b92fcf73bef2dbc5
Otisk parquetu discharge (SHA-256)	0b817f1662e2c085 7f99caca2bda8a5c c6bf677738a3b6eb cf9ed43dbc55aae5
Otisk CSV mimic-iv--bhc (SHA-256)	e45c09997b25d744 abb20573623885eb a052299cf2a721c1 8bbf5ca9a54989c1
Otisk parquetu mimic--iv-bhc (SHA-256)	403dcbe4e6a916ac 30ea647197c4d8e7 08505ee72ce0533d 3500dd64606c3dd0
Otisk CSV omr (SHA-256)	8280a8023203bddc 6cc4419bd8cd253a 015b8bc0bc53852e c92f98c7353f31e2
Otisk parquetu omr (SHA-256)	6566ab088fdb28cf 79985a5fe144d8c3 9587d0bdabd7da81 fd6130f72bf29a66
[illegible] (SHA-256)	[illegible]

Literatura

Agency for Healthcare Research and Quality, Healthcare Cost and Utilization Project. 2015. *Clinical Classifications Software (CCS) for ICD-9-CM*. Agency for Healthcare Research; Quality. https://hcup-us.ahrq.gov/toolssoftware/ccs/ccs.jsp.

Agency for Healthcare Research and Quality, Healthcare Cost and Utilization Project. 2025. *Clinical Classifications Software Refined (CCSR) for ICD-10-CM Diagnoses*. Verze v2026.1. Agency for Healthcare Research; Quality. https://hcup-us.ahrq.gov/toolssoftware/ccsr/dxccsr.jsp.

Centers for Medicare & Medicaid Services. 2017. *2018 ICD-10-CM and GEMs: General Equivalence Mappings*. Centers for Medicare & Medicaid Services. https://www.cms.gov/medicare/coding/icd10/downloads/2018-icd-10-cm-general-equivalence-mappings.zip.

Gasparini, Alessandro. 2018. „comorbidity: An R package for computing comorbidity scores". *Journal of Open Source Software* 3 (23): 648. https://doi.org/10.21105/joss.00648.

Johnson, Alistair E. W., Lucas Bulgarelli, Lu Shen, et al. 2023. „MIMIC-IV, a freely accessible electronic health record dataset". *Scientific Data* 10 (1): 1. https://doi.org/10.1038/s41597-022--01899-x.

Johnson, Alistair, Lucas Bulgarelli, Tom Pollard, et al. 2024. *MIMIC-IV*. Verze 3.1. PhysioNet. https://doi.org/10.13026/kpb9-mt58.

Johnson, Alistair, Tom Pollard, Steven Horng, Leo Anthony Celi, a Roger Mark. 2023. *MIMIC--IV-Note: Deidentified free-text clinical notes*. Verze 2.2. PhysioNet. https://doi.org/10.13026/1n74-ne17.

Quan, Hude, Vijaya Sundararajan, Patricia Halfon, et al. 2005. „Coding algorithms for defining comorbidities in ICD-9-CM and ICD-10 administrative data". *Medical Care* 43 (11): 1130–39. https://doi.org/10.1097/01.mlr.0000182534.19832.83.