# Explorační analýza datové sady: krajina diagnóz

Martin Žoha

**Abstrakt** Dokument popisuje, jaké diagnózy nese vstupní korpus propouštěcích zpráv, a vychází jen z tabulky diagnóz ICD, bez textu zpráv. Uvádí zastoupení Charlsonových kategorií komorbidit, nejčastější tříznakové kódy zvlášť pro ICD-9 a ICD-10, prevalenci a souběh deseti kandidátních diagnóz a kódy kapitoly příznaků a symptomů. Z prevalence vybírá kandidáty v předem stanoveném pásmu, ověřuje, zda pool nevynechal častou kategorii, a jmenuje rizika pro mapování ICD-9 na ICD-10 a pro diverzitu štítků.

## Obsah

1 Úvod ..... 1
2 Data a metody ..... 2
3 Výsledky ..... 3
3.1 Souhrn vstupního korpusu ..... 3
3.2 Charlsonovy kategorie ..... 3
3.3 Nejčastější kódy ..... 5
3.4 Kandidátní diagnózy ..... 7
3.5 Souběh kandidátů ..... 8
3.6 Příznaky a symptomy ..... 9
4 Shrnutí a rozhodnutí ..... 11
5 Omezení ..... 12
Příloha A: provenance renderu ..... 12
Literatura ..... 14

## 1 Úvod

Tento sešit je sedmým z řady sešitů explorační analýzy. Předchozí sešity vymezily vstupní korpus a popsaly jeho pacienty. Tento sešit popisuje, jaké diagnózy korpus nese. Klade si tyto cíle:

- popsat krajinu komorbidit podle Charlsonových kategorií,
- uvést nejčastější tříznakové kódy zvlášť pro ICD-9 a ICD-10,
- změřit prevalenci a souběh deseti kandidátních diagnóz a vybrat z nich kandidáty podle předem stanoveného pásma,
- spočítat kódy kapitoly příznaků a symptomů jako první odhad rozsahu extrakce symptomů.

Sešit pracuje jen s tabulkou diagnóz ICD. Zmínky diagnóz v textu zpráv, jejich shodu s kódy a výběr pětice diagnóz řeší následující sešit; tento sešit mu předává kandidáty a rizika.

Data pocházejí z MIMIC-IV (Johnson et al. 2024; A. E. W. Johnson et al. 2023) a MIMIC-IV-Note (A. Johnson et al. 2023), které podléhají smlouvě o užívání dat (DUA). Dokument proto zveřejňuje jen agregáty. Počty a podíly skupin pacientů podle diagnóz se zveřejňují přesně, protože DUA malé počty neupravuje a pacienti se neidentifikují. Práh deseti zpráv platí jen pro kódy ICD a jejich názvy, protože jde o popisky z dat.

Dokument je členěn takto. Kapitola 2 popisuje metody. Kapitola 3 uvádí výsledky. Kapitola 4 shrnuje rozhodnutí pro další práci a kapitola 5 jmenuje omezení. Příloha A dokumentuje provenance renderu.

# 2 Data a metody

Sešit čte propouštěcí zprávy (`discharge`), diagnózy ICD (`diagnoses_icd`) a číselník diagnóz (`d_icd_diagnoses`). Všechny sloupce jsou v parquetu uloženy jako text a převádějí se přes `TRY_CAST`, takže nečíselná verze ICD nedá chybu, jen kód bez shody. Dotazy provádí DuckDB nad parquetem a jsou v `eda/R/diagnoses.R` s testy nad ručně vytvořenými tabulkami.

Pojmy a jednotky jsou tyto:

- *populací* je vstupní korpus z pátého sešitu: propouštěcí zprávy s kódem ICD, dlouhé aspoň 100 znaků a bez přesných duplicit; jednotkou je zpráva a kódy se připojují přes `hadm_id`. Výběr diagnóz se podle pátého sešitu počítá nad tímto korpusem. Prevalence proto nejsou srovnatelné s hodnotami počítanými nad všemi propouštěcími zprávami,
- *shoda kódu s předponou*: kód se shoduje s kandidátem, když velkými písmeny a bez okrajových mezer začíná některou předponou své verze a verze ICD je 9, resp. 10. Kód téže předpony v jiné verzi se neshoduje,
- *pool kandidátů* je deset diagnóz převzatých z konfigurace předchozího projektu (diabetes, srdeční selhání, CHOPN, chronické onemocnění ledvin, pneumonie, akutní infarkt myokardu, cerebrovaskulární onemocnění, fibrilace síní, sepse a akutní selhání ledvin). Předpony kandidátů, které odpovídají Charlsonově kategorii, vycházejí z map Quan 2005 (Quan et al. 2005); předpony pneumonie, fibrilace síní, sepse a akutního selhání ledvin jsou podle klasifikace ICD. Předpony diabetu a CHOPN se od map Quan odchylují a předpony pneumonie jsou rozšířené; všechny tři jsou sladěné mezi ICD-9 a ICD-10 podle mapování GEMs (Centers for Medicare & Medicaid Services 2017) a kategorií CCS (Agency for Healthcare Research and Quality, Healthcare Cost and Utilization Project 2015) a CCSR (Agency for Healthcare Research and Quality, Healthcare Cost and Utilization Project 2025) (diabetes zahrnuje i sekundární formy, CHOPN chronickou bronchitidu a emfyzém bez bronchiektázií a pneumonie i pneumonii u infekcí zařazených jinde a plicní antrax), takže stejný kód znamená v obou érách tutéž diagnózu. Předpony jsou v `config/diagnosis_candidates.json`, aby definice, kterou sešit měří, byla táž, kterou použije výběr štítků. Obezita ani hypertenze v poolu nejsou,
- *Charlsonovy kategorie* počítá balík R `comorbidity` (Gasparini 2018) podle map Quan 2005 (Quan et al. 2005), které dávají 17 kategorií. Mapy se volají zvlášť pro ICD-9 a ICD-10 a zpráva má kategorii, když ji má kterýkoli kód jejího přijetí v kterékoli verzi. Hierarchie se neuplatňuje, protože jde o přítomnost každé kategorie, a diabetes bez komplikací a s komplikacemi se proto počítají každý zvlášť,
- *žebříček* seskupuje kódy na první tři znaky (kódy ICD-9 začínající E na první čtyři) a řadí skupiny podle počtu zpráv, při shodě podle kódu. Jmenovatelem podílu je počet zpráv vstupního korpusu s aspoň jedním kódem dané verze; zpráva s kódy obou verzí patří do

obou jmenovatelů. Název skupiny je název jejího nejčastějšího plného kódu s aspoň deseti zprávami z číselníku `d_icd_diagnoses`; nemá-li skupina takový kód, název je „neuvedeno“. Při shodě počtu rozhoduje nejmenší kód. Skupiny s méně než deseti zprávami se v žebříčku neukazují, protože jejich kód je popisek z dat,

- *pásmo prevalence* 5–60 % zpráv je první kritérium výběru štítků a je stanoveno předem. Dolní mez zajišťuje dost pozitivních zpráv v každé části křížové validace, horní vyřazuje diagnózy tak časté, že klasifikace ztrácí rozlišovací smysl. Hodnoty pocházejí z pravidla stanoveného před měřením; měnit je po pohledu na data by bylo cherry-picking. Sešit pásmo jen aplikuje,
- *souběh* je matice podílů P(sloupec | řádek), tedy podíl zpráv s kandidátem řádku, které mají i kandidáta sloupce.

# 3 Výsledky

## 3.1 Souhrn vstupního korpusu

Vstupní korpus tvoří 331 604 zpráv. Jen kódy ICD-9 má 209 316 zpráv, jen kódy ICD-10 122 281 a kódy obou verzí 7 zpráv. Tabulka 1 uvádí souhrn včetně podílu zpráv s kódem kapitoly příznaků a symptomů.

Tabulka 1: Souhrn vstupního korpusu podle éry ICD a podíl zpráv s kódem kapitoly příznaků.

| Ukazatel | Zprávy | Podíl (%) |
|---|---:|---:|
| Zprávy vstupního korpusu | 331 604 | 100,0 |
| Jen kódy ICD-9 | 209 316 | 63,1 |
| Jen kódy ICD-10 | 122 281 | 36,9 |
| Kódy obou verzí | 7 | < 0,1 |
| Bez kódu s platnou verzí | 0 | 0,0 |
| Zprávy s kódem kapitoly R (780–799) | 163 376 | 49,3 |

*Zdroj:* dotaz v DuckDB nad tabulkami `discharge` a `diagnoses_icd`.

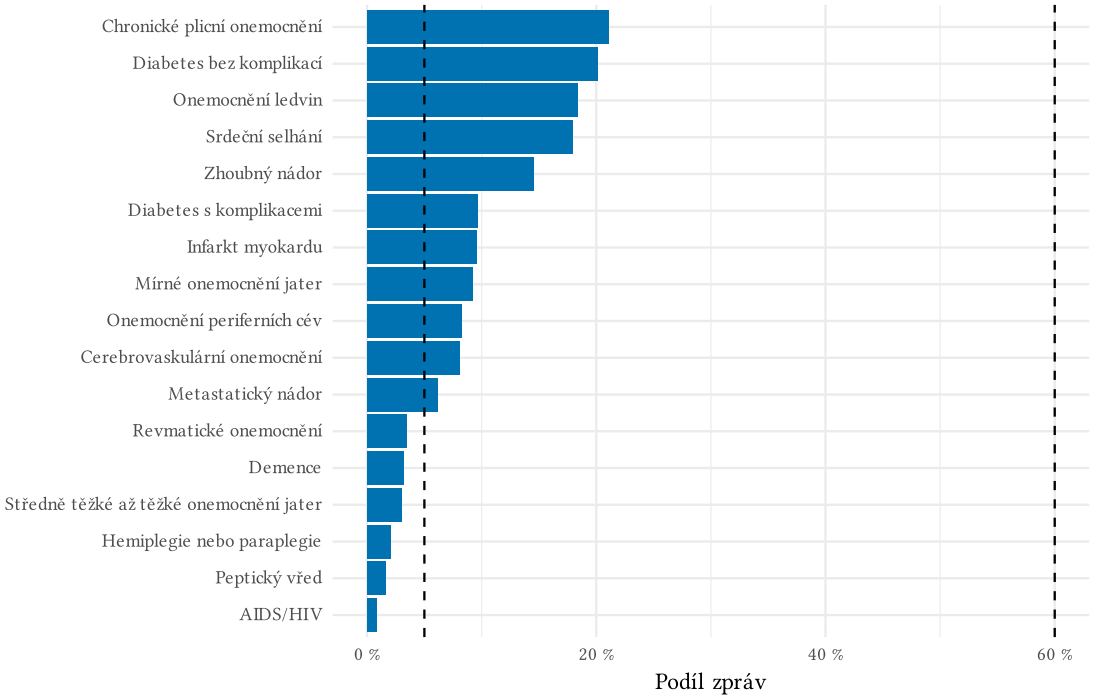
## 3.2 Charlsonovy kategorie

Tabulka 2 a Obrázek 1 uvádějí podíl zpráv s každou z 17 Charlsonových kategorií. Svislé čáry v grafu vymezují pásmo prevalence.

Tabulka 2: Zprávy vstupního korpusu podle Charlsonových kategorií komorbidit.

| Kategorie | Zprávy | Podíl (%) |
|---|---|---|
| Infarkt myokardu | 31 551 | 9,5 |
| Srdeční selhání | 59 403 | 17,9 |
| Onemocnění periferních cév | 27 230 | 8,2 |
| Cerebrovaskulární onemocnění | 26 810 | 8,1 |
| Demence | 10 432 | 3,1 |
| Chronické plicní onemocnění | 69 814 | 21,1 |
| Revmatické onemocnění | 11 386 | 3,4 |
| Peptický vřed | 5 223 | 1,6 |
| Mírné onemocnění jater | 30 539 | 9,2 |
| Diabetes bez komplikací | 66 793 | 20,1 |
| Diabetes s komplikacemi | 31 880 | 9,6 |
| Hemiplegie nebo paraplegie | 6 860 | 2,1 |
| Onemocnění ledvin | 60 985 | 18,4 |
| Zhoubný nádor | 48 303 | 14,6 |
| Středně těžké až těžké onemocnění jater | 10 049 | 3,0 |
| Metastatický nádor | 20 304 | 6,1 |
| AIDS/HIV | 2 733 | 0,8 |

*Zdroj:* kódy z `diagnoses_icd`, mapy Quan 2005 v balíku `comorbidity`.




Obrázek 1: Podíl zpráv vstupního korpusu podle Charlsonových kategorií; svislé čáry vymezují pásmo prevalence 5–60 %.

## 3.3 Nejčastější kódy

Tabulka 3 a Tabulka 4 uvádějí 20 nejčastějších tříznakových skupin kódů zvlášť pro ICD-10 a ICD-9, protože tříznakové kódy obou verzí nejsou srovnatelné. Zobrazují se jen skupiny s aspoň deseti zprávami; práh chrání popisek kódu z dat.

Tabulka 3: Nejčastější tříznakové skupiny kódů ICD-10 podle počtu zpráv.

| Kód | Název nejčastějšího kódu skupiny | Zprávy | Podíl (%) |
|---|---|---|---|
| E78 | Hyperlipidemia, unspecified | 49 306 | 40,3 |
| I10 | Essential (primary) hypertension | 43 570 | 35,6 |
| Z79 | Long term (current) use of anticoagulants | 40 390 | 33,0 |
| Z87 | Personal history of nicotine dependence | 40 252 | 32,9 |
| Y92 | Unspecified place or not applicable | 35 293 | 28,9 |
| E11 | Type 2 diabetes mellitus without complications | 31 576 | 25,8 |
| K21 | Gastro-esophageal reflux disease without esophagitis | 31 108 | 25,4 |
| I25 | Atherosclerotic heart disease of native coronary artery without angina pectoris | 27 164 | 22,2 |
| E87 | Hypo-osmolality and hyponatremia | 25 636 | 21,0 |
| Z68 | Body mass index [BMI] 40.0-44.9, adult | 23 934 | 19,6 |
| F32 | Major depressive disorder, single episode, unspecified | 23 511 | 19,2 |
| I50 | Chronic diastolic (congestive) heart failure | 23 451 | 19,2 |
| N18 | Chronic kidney disease, unspecified | 23 359 | 19,1 |
| I48 | Unspecified atrial fibrillation | 22 475 | 18,4 |
| N17 | Acute kidney failure, unspecified | 22 226 | 18,2 |
| Z86 | Personal history of transient ischemic attack (TIA), and cerebral infarction without residual deficits | 21 413 | 17,5 |
| F41 | Anxiety disorder, unspecified | 21 090 | 17,2 |
| Z85 | Personal history of other malignant neoplasm of skin | 20 949 | 17,1 |
| G47 | Obstructive sleep apnea (adult) (pediatric) | 19 385 | 15,9 |
| Z95 | Presence of coronary angioplasty implant and graft | 18 011 | 14,7 |

*Zdroj:* `diagnoses_icd` a `d_icd_diagnoses`; jmenovatelem je počet zpráv s aspoň jedním kódem ICD-10.

Tabulka 4: Nejčastější tříznakové skupiny kódů ICD-9 podle počtu zpráv.

| Kód | Název nejčastějšího kódu skupiny | Zprávy | Podíl (%) |
|---|---|---|---|
| 401 | Unspecified essential hypertension | 85 330 | 40,8 |
| 272 | Other and unspecified hyperlipidemia | 72 613 | 34,7 |
| 250 | Diabetes mellitus without mention of complication, type II or unspecified type, not stated as uncontrolled | 55 764 | 26,6 |
| V58 | Long-term (current) use of anticoagulants | 51 870 | 24,8 |
| V45 | Percutaneous transluminal coronary angioplasty status | 48 167 | 23,0 |
| 530 | Esophageal reflux | 45 366 | 21,7 |
| 276 | Hyposmolality and/or hyponatremia | 44 332 | 21,2 |
| 285 | Anemia, unspecified | 42 604 | 20,4 |
| 427 | Atrial fibrillation | 42 090 | 20,1 |
| V15 | Personal history of tobacco use | 41 713 | 19,9 |
| 414 | Coronary atherosclerosis of native coronary artery | 40 738 | 19,5 |
| 585 | Chronic kidney disease, unspecified | 35 189 | 16,8 |
| 428 | Congestive heart failure, unspecified | 33 227 | 15,9 |
| 403 | Hypertensive chronic kidney disease, unspecified, with chronic kidney disease stage I through stage IV, or unspecified | 30 573 | 14,6 |
| V10 | Personal history of malignant neoplasm of breast | 30 541 | 14,6 |
| 584 | Acute kidney failure, unspecified | 30 089 | 14,4 |
| 305 | Tobacco use disorder | 28 602 | 13,7 |
| 311 | Depressive disorder, not elsewhere classified | 28 243 | 13,5 |
| V12 | Personal history of venous thrombosis and embolism | 27 616 | 13,2 |
| 780 | Insomnia, unspecified | 27 081 | 12,9 |

*Zdroj:* `diagnoses_icd` a `d_icd_diagnoses`; jmenovatelem je počet zpráv s aspoň jedním kódem ICD-9.

## 3.4 Kandidátní diagnózy

Tabulka 5 uvádí prevalenci deseti kandidátů v celém korpusu a zvlášť mezi zprávami s kódy ICD-9 a ICD-10. Velký rozdíl mezi érami ukazuje, že předpony obou verzí nemusí znamenat totéž. Poslední sloupec zařazuje kandidáta k pásmu 5–60 %.

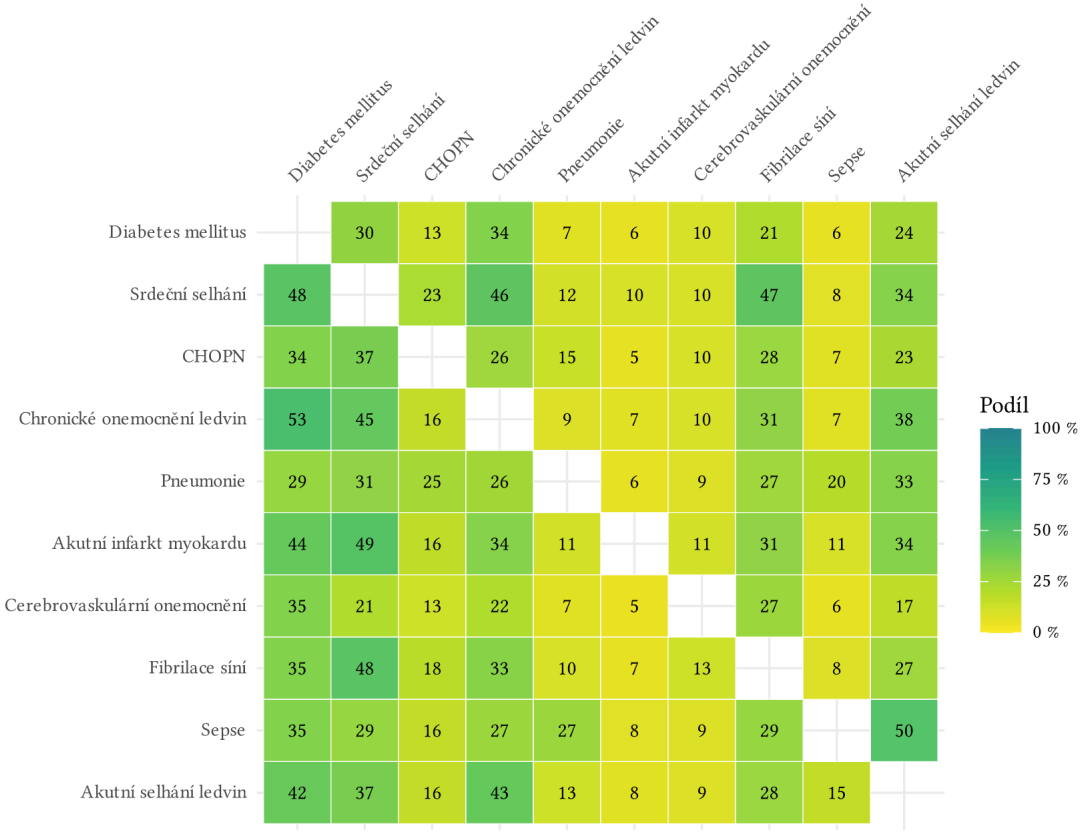
Tabulka 5: Prevalence kandidátních diagnóz ve vstupním korpusu a podle éry ICD a jejich poloha vůči pásmu prevalence.

| Kandidát | Zprávy | Korpus (%) | ICD-9 (%) | ICD-10 (%) | Pásmo |
|---|---|---|---|---|---|
| Diabetes mellitus | 91 149 | 27,5 | 27,0 | 28,3 | v pásmu |
| Srdeční selhání | 56 676 | 17,1 | 15,9 | 19,2 | v pásmu |
| CHOPN | 35 462 | 10,7 | 10,3 | 11,4 | v pásmu |
| Chronické onemocnění ledvin | 58 547 | 17,7 | 16,8 | 19,1 | v pásmu |
| Pneumonie | 21 173 | 6,4 | 6,3 | 6,5 | v pásmu |
| Akutní infarkt myokardu | 11 827 | 3,6 | 2,9 | 4,7 | pod pásmem |
| Cerebrovaskulární onemocnění | 26 371 | 8,0 | 7,6 | 8,6 | v pásmu |
| Fibrilace síní | 55 410 | 16,7 | 15,7 | 18,4 | v pásmu |
| Sepse | 15 764 | 4,8 | 3,9 | 6,2 | pod pásmem |
| Akutní selhání ledvin | 52 315 | 15,8 | 14,4 | 18,2 | v pásmu |

*Zdroj:* `diagnoses_icd`; jmenovatelem je počet zpráv korpusu, resp. zpráv s kódem dané verze.

## 3.5 Souběh kandidátů

Obrázek 2 ukazuje, jaký podíl zpráv s kandidátem na řádku má i kandidáta ve sloupci. Buňky s nulovým jmenovatelem jsou prázdné a diagonála se nekreslí.




Obrázek 2: Souběh kandidátních diagnóz: podíl zpráv s kandidátem na řádku, které mají i kandidáta ve sloupci; buňky s nulovým jmenovatelem jsou prázdné.

## 3.6 Příznaky a symptomy

Kapitola R mezinárodní klasifikace ICD-10 a kódy 780–799 klasifikace ICD-9 označují příznaky a symptomy. Tabulka 6 a Tabulka 7 uvádějí jejich nejčastější tříznakové skupiny. Slouží jako reference symptomů pro extrakci; zmínky symptomů v textu měří následující sešit.

Tabulka 6: Nejčastější tříznakové skupiny kódů kapitoly R (ICD-10).

| Kód | Název nejčastějšího kódu skupiny | Zprávy | Podíl (%) |
|---|---|---|---|
| R33 | Retention of urine, unspecified | 6 568 | 5,4 |
| R00 | Tachycardia, unspecified | 5 979 | 4,9 |
| R11 | Nausea with vomiting, unspecified | 5 012 | 4,1 |
| R09 | Hypoxemia | 4 671 | 3,8 |
| R74 | Nonspecific elevation of levels of transaminase and lactic acid dehydrogenase [LDH] | 4 305 | 3,5 |
| R65 | Severe sepsis with septic shock | 4 271 | 3,5 |
| R13 | Dysphagia, unspecified | 4 256 | 3,5 |
| R19 | Diarrhea, unspecified | 4 139 | 3,4 |
| R10 | Unspecified abdominal pain | 4 061 | 3,3 |
| R50 | Fever, unspecified | 3 921 | 3,2 |
| R07 | Other chest pain | 3 778 | 3,1 |
| R91 | Other nonspecific abnormal finding of lung field | 3 216 | 2,6 |
| R41 | Disorientation, unspecified | 3 103 | 2,5 |
| R79 | Abnormal coagulation profile | 3 068 | 2,5 |
| R29 | Facial weakness | 2 999 | 2,5 |
| R47 | Aphasia | 2 880 | 2,4 |
| R45 | Suicidal ideations | 2 603 | 2,1 |
| R18 | Other ascites | 2 492 | 2,0 |
| R57 | Cardiogenic shock | 2 440 | 2,0 |
| R53 | Weakness | 2 319 | 1,9 |

*Zdroj:* `diagnoses_icd` a `d_icd_diagnoses`; jmenovatelem je počet zpráv s aspoň jedním kódem ICD-10.

Tabulka 7: Nejčastější tříznakové skupiny kódů 780–799 (ICD-9).

| Kód | Název nejčastějšího kódu skupiny | Zprávy | Podíl (%) |
|---|---|---|---|
| 780 | Insomnia, unspecified | 27 081 | 12,9 |
| 787 | Diarrhea | 18 870 | 9,0 |
| 790 | Abnormal coagulation profile | 15 629 | 7,5 |
| 789 | Other ascites | 14 239 | 6,8 |
| 786 | Other chest pain | 13 335 | 6,4 |
| 788 | Retention of urine, unspecified | 12 572 | 6,0 |
| 785 | Septic shock | 10 065 | 4,8 |
| 784 | Headache | 8 116 | 3,9 |
| 782 | Edema | 6 655 | 3,2 |
| 799 | Hypoxemia | 6 484 | 3,1 |
| 783 | Loss of weight | 5 427 | 2,6 |
| 781 | Abnormality of gait | 5 216 | 2,5 |
| 793 | Solitary pulmonary nodule | 2 597 | 1,2 |
| 794 | Nonspecific abnormal electrocardiogram [ECG] [EKG] | 1 902 | 0,9 |
| 791 | Other nonspecific findings on examination of urine | 1 505 | 0,7 |
| 795 | Nonspecific reaction to tuberculin skin test without active tuberculosis | 948 | 0,5 |
| 792 | Nonspecific abnormal findings in stool contents | 828 | 0,4 |
| 796 | Elevated blood pressure reading without diagnosis of hypertension | 723 | 0,3 |

*Zdroj:* `diagnoses_icd` a `d_icd_diagnoses`; jmenovatelem je počet zpráv s aspoň jedním kódem ICD-9.

# 4 Shrnutí a rozhodnutí

Dokument popsal krajinu diagnóz vstupního korpusu. Pro další práci z toho plyne:

- **Předvýběr kandidátů.** Do rubriky následujícího sešitu postupují kandidáti v pásmu 5–60 % zpráv: Diabetes mellitus, Srdeční selhání, CHOPN, Chronické onemocnění ledvin, Pneumonie, Cerebrovaskulární onemocnění, Fibrilace síní a Akutní selhání ledvin. Pod pásmem jsou: Akutní infarkt myokardu a Sepse. Nad pásmem jsou: žádný. O pětici sešit nerozhoduje, protože mu chybí shoda s textem.
- **Audit proti cherry-pickingu.** Charlsonovy kategorie v pásmu 5–60 %, které nepokrývá žádný kandidát: Onemocnění periferních cév, Mírné onemocnění jater, Zhoubný nádor

a Metastatický nádor. Následující sešit je posoudí podle stejné rubriky, aby výběr nevynechal častou diagnózu.

- **Redundance kandidátů.** Dvojice s P(sloupec | řádek) aspoň 0,5 jsou riziko pro kritérium diverzity, protože většina zpráv s prvním kandidátem má i druhého: Chronické onemocnění ledvin → Diabetes mellitus a Sepse → Akutní selhání ledvin.
- **Rozdíly mezi érami.** Prevalence v jedné éře je víc než 1,5krát větší než v druhé u kandidátů: Akutní infarkt myokardu a Sepse. Předpony diabetu, CHOPN, chronického onemocnění ledvin, pneumonie a fibrilace síní jsou mezi érami sladěné podle GEMs (viz metody), takže jejich zbylý rozdíl odráží kódovací praxi nebo populaci; předpony ostatních kandidátů sladěné nejsou a rozdíl u nich může vzniknout i odlišným významem předpon.
- **Příznaky.** Referencí symptomů pro extrakci jsou kódy kapitoly R a 780–799, které má 49,3 % zpráv korpusu. Zmínky symptomů v textu měří následující sešit, který z nich odhadne rozsah úlohy.

## 5 Omezení

Kód ICD říká, že hospitalizace měla diagnózu, ne že ji zpráva zmiňuje; shodu s textem měří následující sešit. Prevalence se počítá nad vstupním korpusem, a proto nejsou srovnatelné s hodnotami nad všemi propouštěcími zprávami. Prevalence v různých érách ICD mohou odrážet změnu kódovací praxe i změnu populace, sešit je od sebe neodliší. Předpony pěti diagnóz, ze kterých se vybírají štítky (diabetes, CHOPN, chronické onemocnění ledvin, pneumonie a fibrilace síní), jsou sladěné mezi ICD-9 a ICD-10 podle GEMs, předpony ostatních pěti kandidátů jsou ruční mapování z konfigurace předchozího projektu; GEMs jsou z velké části přibližné, takže předpony nemusí odpovídat klinické představě o diagnóze. Charlsonovy kategorie vycházejí z map Quan 2005, které se omezují na komorbidity a nepokrývají všechny časté diagnózy. Skupiny kódů s méně než deseti zprávami nejsou v žebříčcích vidět, protože práh chrání popisky z dat. Název skupiny je název jejího nejčastějšího plného kódu a nemusí vystihovat celou skupinu.

## Příloha A: provenance renderu

Tabulka 8 uvádí údaje, podle kterých lze render dohledat a zopakovat: revizi kódu, otisk zámku prostředí, zdroj dat a verze použitých nástrojů.

Tabulka 8: Provenance renderu.

| Položka | Hodnota |
|---|---|
| Revize kódu (commit) | b0e4c8c868ecac02f6cd6f3caf0723625f1061fe |
| Necommitnuté změny | ne |
| Otisk pixi.lock (SHA-256) | af50ffb1143e322d 2f3de22275341738 bbd0725befb07500 ba5ef6cdcda01b01 |
| Zdroj dat | otisky CSV z config/mimic_tables.json |
| Otisk discharge.csv.gz (SHA-256) | 27bc552edaf81c2a f322040cb7e8eb36 417173b23c79405b b92fcf73bef2dbc5 |
| Otisk radiology.csv.gz (SHA-256) | 2c09bc76ee12d5f3 b8f572deb7218fba f3e59b32eccfdae1 4686e05ae099eebb |
| Otisk admissions.csv.gz (SHA-256) | a9584ed88e9ed664 a2f66f86a5cf9fd1 75c8bb0af50e3b61 15598b19e978384e |
| Otisk d_icd_diagnoses.csv.gz (SHA-256) | a81065bf45ccf74f 589bec855bbb0a07 b5c014907b34ff76 fe20583a2c87cc79 |
| Otisk d_icd_procedures.csv.gz (SHA-256) | a2ac8afcb99fd16b ce2e6c7ad445e3bd 1dfd658e52182313 0ab08b66fdd3d6d4 |
| Otisk diagnoses_icd.csv.gz (SHA-256) | 47665a41b2a3ad99 0d6f314062d5bd6d 29d467b0fd402dd9 4662044ec8b073d2 |
| Otisk omr.csv.gz (SHA-256) | 8280a8023203bddc 6cc4419bd8cd253a 015b8bc0bc53852e c92f98c7353f31e2 |
| Otisk patients.csv.gz (SHA-256) | 4c7507de7ecad8c5 ba7647ea4d26018e 88ff6672c5fc22ab 59c2a5697d687cdd |
| Otisk pharmacy.csv.gz (SHA-256) | c9885721e4c968f0 773145d7f6ba4d3c c3755d5600ee400f f95b1d3238053811 |
| Otisk prescriptions.csv.gz (SHA-256) | 0d8481c7d5d7c9ec 2fea3fc543ddaaad b5a933cd22c7b9dd a4289361e4d77199 |
| Otisk procedures_icd.csv.gz (SHA-256) | 3271397d0517131f 84399b698cbb0c2f 435aaab0f873a380 6e13b097661596f7 |
| Otisk services.csv.gz (SHA-256) | 31c82ebee94e0c04 d6966fbfec30579e c00f9c7816b80852 f9580656e6183888 |
| Otisk mimic-iv-bhc.csv (SHA-256) | e45c09997b25d744 abb20573623885eb a052299cf2a721c1 8bbf5ca9a54989c1 |
| Python | 3.13.16 |
| DuckDB | 1.5.6 |
| R | R version 4.5.3 (2026-03-11) |
| r-duckdb | 1.5.5 |

# Literatura

Agency for Healthcare Research and Quality, Healthcare Cost and Utilization Project. 2015. *Clinical Classifications Software (CCS) for ICD-9-CM*. Agency for Healthcare Research; Quality. https://hcup-us.ahrq.gov/toolssoftware/ccs/ccs.jsp.

Agency for Healthcare Research and Quality, Healthcare Cost and Utilization Project. 2025. *Clinical Classifications Software Refined (CCSR) for ICD-10-CM Diagnoses*. Verze v2026.1. Agency for Healthcare Research; Quality. https://hcup-us.ahrq.gov/toolssoftware/ccsr/dxccsr.jsp.

Centers for Medicare & Medicaid Services. 2017. *2018 ICD-10-CM and GEMs: General Equivalence Mappings*. Centers for Medicare & Medicaid Services. https://www.cms.gov/medicare/coding/icd10/downloads/2018-icd-10-cm-general-equivalence-mappings.zip.

Gasparini, Alessandro. 2018. „comorbidity: An R package for computing comorbidity scores". *Journal of Open Source Software* 3 (23): 648. https://doi.org/10.21105/joss.00648.

Johnson, Alistair E. W., Lucas Bulgarelli, Lu Shen, et al. 2023. „MIMIC-IV, a freely accessible electronic health record dataset". *Scientific Data* 10 (1): 1. https://doi.org/10.1038/s41597-022--01899-x.

Johnson, Alistair, Lucas Bulgarelli, Tom Pollard, et al. 2024. *MIMIC-IV*. Verze 3.1. PhysioNet. https://doi.org/10.13026/kpb9-mt58.

Johnson, Alistair, Tom Pollard, Steven Horng, Leo Anthony Celi, a Roger Mark. 2023. *MIMIC--IV-Note: Deidentified free-text clinical notes*. Verze 2.2. PhysioNet. https://doi.org/10.13026/1n74-ne17.

Quan, Hude, Vijaya Sundararajan, Patricia Halfon, et al. 2005. „Coding algorithms for defining comorbidities in ICD-9-CM and ICD-10 administrative data". *Medical Care* 43 (11): 1130–39. https://doi.org/10.1097/01.mlr.0000182534.19832.83.