Explorační analýza datové sady: krajina diagnóz

Martin Žoha

Abstrakt Dokument popisuje, jaké diagnózy nese vstupní korpus propouštěcích zpráv, a vychází jen z tabulky diagnóz ICD, bez textu zpráv. Uvádí zastoupení Charlsonových kategorií komorbidit, nejčastější tříznakové kódy zvlášť pro ICD-9 a ICD-10, prevalenci a souběh deseti kandidátních diagnóz a kódy kapitoly příznaků a symptomů. Z prevalence vybírá kandidáty v předem stanoveném pásmu, ověřuje, zda pool nevynechal častou kategorii, a jmenuje rizika pro mapování ICD-9 na ICD-10 a pro diverzitu štítků.

Obsah

1 Úvod 1
2 Data a metody 2
3 Výsledky 3
3.1 Souhrn vstupního korpusu 3
3.2 Charlsonovy kategorie 3
3.3 Nejčastější kódy 5
3.4 Kandidátní diagnózy 7
3.5 Souběh kandidátů 8
3.6 Příznaky a symptomy 9
4 Shrnutí a rozhodnutí 11
5 Omezení 12
Příloha A: provenance renderu 12
Literatura 14

1 Úvod

Tento sešit je sedmým z řady sešitů explorační analýzy. Předchozí sešity vymezily vstupní korpus a popsaly jeho pacienty. Tento sešit popisuje, jaké diagnózy korpus nese. Klade si tyto cíle:

- popsat krajinu komorbidit podle Charlsonových kategorií,
- uvést nejčastější tříznakové kódy zvlášť pro ICD-9 a ICD-10,
- změřit prevalenci a souběh deseti kandidátních diagnóz a vybrat z nich kandidáty podle předem stanoveného pásma,
- spočítat kódy kapitoly příznaků a symptomů jako první odhad rozsahu extrakce symptomů.

Sešit pracuje jen s tabulkou diagnóz ICD. Zmínky diagnóz v textu zpráv, jejich shodu s kódy a výběr pětice diagnóz řeší následující sešit; tento sešit mu předává kandidáty a rizika.

Data pocházejí z MIMIC-IV (Johnson et al. 2024; A. E. W. Johnson et al. 2023) a MIMIC-IV-Note (A. Johnson et al. 2023), které podléhají smlouvě o užívání dat (DUA). Dokument proto zveřejňuje jen agregáty. Diagnóza je kvaziidentifikátor, a proto se potlačuje každá buňka skupiny pacientů vymezené diagnózou, která má méně než deset zpráv nebo jejíž doplněk do počtu zpráv má méně než deset; doplněk by jinak šel dopočítat z přesně zveřejněného jmenovatele. Práh je pravidlo práce, DUA malé počty neupravuje. Přesně se zveřejňují jen metriky korpusu: počet zpráv a počty zpráv podle éry ICD.

Dokument je členěn takto. Kapitola 2 popisuje metody. Kapitola 3 uvádí výsledky. Kapitola 4 shrnuje rozhodnutí pro další práci a kapitola 5 jmenuje omezení. Příloha A dokumentuje provenance renderu.

2 Data a metody

Sešit čte propouštěcí zprávy (`discharge`), diagnózy ICD (`diagnoses_icd`) a číselník diagnóz (`d_icd_diagnoses`). Všechny sloupce jsou v parquetu uloženy jako text a převádějí se přes `TRY_CAST`, takže nečíselná verze ICD nedá chybu, jen kód bez shody. Dotazy provádí DuckDB nad parquetem a jsou v `eda/R/diagnoses.R` s testy nad ručně vytvořenými tabulkami.

Pojmy a jednotky jsou tyto:

- *populací* je vstupní korpus z pátého sešitu: propouštěcí zprávy s kódem ICD, dlouhé aspoň 100 znaků a bez přesných duplicit; jednotkou je zpráva a kódy se připojují přes `hadm_id`. Výběr diagnóz se podle pátého sešitu počítá nad tímto korpusem. Prevalence proto nejsou srovnatelné s hodnotami počítanými nad všemi propouštěcími zprávami,
- *shoda kódu s předponou*: kód se shoduje s kandidátem, když velkými písmeny a bez okrajových mezer začíná některou předponou své verze a verze ICD je 9, resp. 10. Kód téže předpony v jiné verzi se neshoduje,
- *pool kandidátů* je deset diagnóz převzatých z konfigurace předchozího projektu (diabetes, srdeční selhání, CHOPN, chronické onemocnění ledvin, pneumonie, akutní infarkt myokardu, cerebrovaskulární onemocnění, fibrilace síní, sepse a akutní selhání ledvin). Předpony kandidátů, které odpovídají Charlsonově kategorii, odpovídají mapám Quan 2005 (Quan et al. 2005); předpony pneumonie, fibrilace síní, sepse a akutního selhání ledvin jsou podle klasifikace ICD. Předpony jsou v `config/diagnosis_candidates.json`, aby definice, kterou sešit měří, byla táž, kterou použije výběr štítků. Obezita ani hypertenze v poolu nejsou,
- *Charlsonovy kategorie* počítá balík R `comorbidity` (Gasparini 2018) podle map Quan 2005 (Quan et al. 2005), které dávají 17 kategorií. Mapy se volají zvlášť pro ICD-9 a ICD-10 a zpráva má kategorii, když ji má kterýkoli kód jejího přijetí v kterékoli verzi. Hierarchie se neuplatňuje, protože jde o přítomnost každé kategorie, a diabetes bez komplikací a s komplikacemi se proto počítají každý zvlášť,
- *žebříček* seskupuje kódy na první tři znaky (kódy ICD-9 začínající E na první čtyři) a řadí skupiny podle počtu zpráv, při shodě podle kódu. Jmenovatelem podílu je počet zpráv vstupního korpusu s aspoň jedním kódem dané verze; zpráva s kódy obou verzí patří do obou jmenovatelů. Název skupiny je název jejího nejčastějšího plného kódu s aspoň deseti zprávami z číselníku `d_icd_diagnoses`; nemá-li skupina takový kód, název je „neuvedeno“. Při shodě počtu rozhoduje nejmenší kód. Skupiny pod prahem potlačení se v žebříčku neukazují ani se nedoplňují řádkem „ostatní“,
- *pásmo prevalence* 5–60 % zpráv je první kritérium výběru štítků a je stanoveno předem. Dolní mez zajišťuje dost pozitivních zpráv v každé části křížové validace, horní vyřazuje diagnózy

tak časté, že klasifikace ztrácí rozlišovací smysl. Hodnoty pocházejí z pravidla stanoveného před měřením; měnit je po pohledu na data by bylo cherry-picking. Sešit pásmo jen aplikuje,

- *souběh* je matice podílů P(sloupec | řádek), tedy podíl zpráv s kandidátem řádku, které mají i kandidáta sloupce. Dvojice se skryje v obou směrech, když má méně než deset zpráv s oběma kandidáty, méně než deset zpráv s kandidátem řádku bez kandidáta sloupce nebo méně než deset zpráv s kandidátem sloupce bez kandidáta řádku. Prevalence kandidáta v jedné éře se skryje spolu s prevalencí v druhé, protože rozdíl by prozradil počet zpráv obou verzí. Počet zpráv kandidáta a Charlsonovy kategorie, kterou kandidát pokrývá (pole `charlson`), se skryje, když absolutní rozdíl počtů kategorie a kandidáta, případně součtu kategorií a kandidáta, je pod deseti.

3 Výsledky

3.1 Souhrn vstupního korpusu

Vstupní korpus tvoří 331 604 zpráv. Jen kódy ICD-9 má 209 316 zpráv, jen kódy ICD-10 122 281 a kódy obou verzí 7 zpráv. Tabulka 1 uvádí souhrn včetně podílu zpráv s kódem kapitoly příznaků a symptomů.

Tabulka 1: Souhrn vstupního korpusu podle éry ICD a podíl zpráv s kódem kapitoly příznaků.

Ukazatel	Zprávy	Podíl (%)
Zprávy vstupního korpusu	331 604	100,0
Jen kódy ICD-9	209 316	63,1
Jen kódy ICD-10	122 281	36,9
Kódy obou verzí	7	0,0
Bez kódu s platnou verzí	0	0,0
Zprávy s kódem kapitoly R (780–799)	163 376	49,3

Zdroj: dotaz v DuckDB nad tabulkami `discharge` a `diagnoses_icd`; počty podle éry jsou metriky korpusu a uvádějí se přesně, podíl zpráv s kódem kapitoly R je potlačen podle pravidla výše.

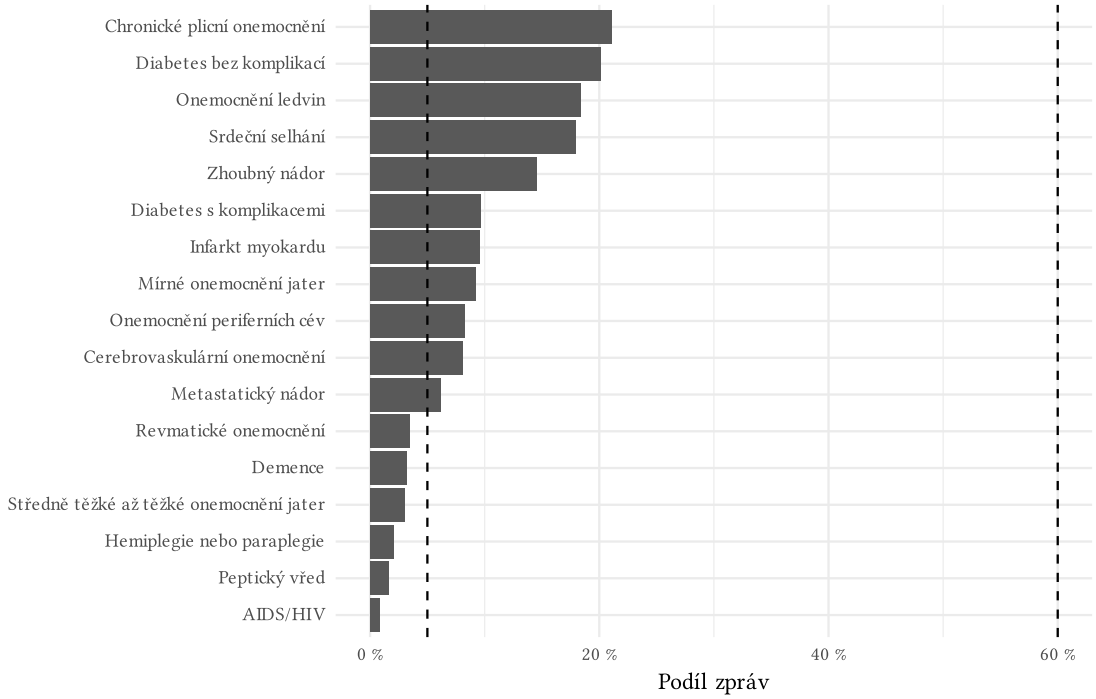
3.2 Charlsonovy kategorie

Tabulka 2 a Obrázek 1 uvádějí podíl zpráv s každou z 17 Charlsonových kategorií. Svislé čáry v grafu vymezují pásmo prevalence. Potlačené kategorie se v grafu nekreslí a v tabulce mají místo počtu text „potlačeno“.

Tabulka 2: Zprávy vstupního korpusu podle Charlsonových kategorií komorbidit.

Kategorie	Zprávy	Podíl (%)
Infarkt myokardu	31 551	9,5
Srdeční selhání	59 403	17,9
Onemocnění periferních cév	27 230	8,2
Cerebrovaskulární onemocnění	26 810	8,1
Demence	10 432	3,1
Chronické plicní onemocnění	69 814	21,1
Revmatické onemocnění	11 386	3,4
Peptický vřed	5 223	1,6
Mírné onemocnění jater	30 539	9,2
Diabetes bez komplikací	66 793	20,1
Diabetes s komplikacemi	31 880	9,6
Hemiplegie nebo paraplegie	6 860	2,1
Onemocnění ledvin	60 985	18,4
Zhoubný nádor	48 303	14,6
Středně těžké až těžké onemocnění jater	10 049	3,0
Metastatický nádor	20 304	6,1
AIDS/HIV	2 733	0,8

Zdroj: kódy z `diagnoses_icd`, mapy Quan 2005 v balíku `comorbidity`.



Obrázek 1: Podíl zpráv vstupního korpusu podle Charlsonových kategorií; svislé čáry vymezují pásmo prevalence 5–60 %, potlačené kategorie nejsou zobrazeny.

3.3 Nejčastější kódy

Tabulka 3 a Tabulka 4 uvádějí 20 nejčastějších tříznakových skupin kódů zvlášť pro ICD-10 a ICD-9, protože tříznakové kódy obou verzí nejsou srovnatelné. Zobrazují se jen skupiny, jejichž počet i doplněk do jmenovatele dosahují deseti zpráv.

Tabulka 3: Nejčastější tříznakové skupiny kódů ICD-10 podle počtu zpráv.

Kód	Název nejčastějšího kódu skupiny	Zprávy	Podíl (%)
E78	Hyperlipidemia, unspecified	49 306	40,3
I10	Essential (primary) hypertension	43 570	35,6
Z79	Long term (current) use of anticoagulants	40 390	33,0
Z87	Personal history of nicotine dependence	40 252	32,9
Y92	Unspecified place or not applicable	35 293	28,9
E11	Type 2 diabetes mellitus without complications	31 576	25,8
K21	Gastro-esophageal reflux disease without esophagitis	31 108	25,4
I25	Atherosclerotic heart disease of native coronary artery without angina pectoris	27 164	22,2
E87	Hypo-osmolality and hyponatremia	25 636	21,0
Z68	Body mass index [BMI] 40.0-44.9, adult	23 934	19,6
F32	Major depressive disorder, single episode, unspecified	23 511	19,2
I50	Chronic diastolic (congestive) heart failure	23 451	19,2
N18	Chronic kidney disease, unspecified	23 359	19,1
I48	Unspecified atrial fibrillation	22 475	18,4
N17	Acute kidney failure, unspecified	22 226	18,2
Z86	Personal history of transient ischemic attack (TIA), and cerebral infarction without residual deficits	21 413	17,5
F41	Anxiety disorder, unspecified	21 090	17,2
Z85	Personal history of other malignant neoplasm of skin	20 949	17,1
G47	Obstructive sleep apnea (adult) (pediatric)	19 385	15,9
Z95	Presence of coronary angioplasty implant and graft	18 011	14,7

Zdroj: `diagnoses_icd` a `d_icd_diagnoses`; jmenovatelem je počet zpráv s aspoň jedním kódem ICD-10.

Tabulka 4: Nejčastější tříznakové skupiny kódů ICD-9 podle počtu zpráv.

Kód	Název nejčastějšího kódu skupiny	Zprávy	Podíl (%)
401	Unspecified essential hypertension	85 330	40,8
272	Other and unspecified hyperlipidemia	72 613	34,7
250	Diabetes mellitus without mention of complication, type II or unspecified type, not stated as uncontrolled	55 764	26,6
V58	Long-term (current) use of anticoagulants	51 870	24,8
V45	Percutaneous transluminal coronary angioplasty status	48 167	23,0
530	Esophageal reflux	45 366	21,7
276	Hyposmolality and/or hyponatremia	44 332	21,2
285	Anemia, unspecified	42 604	20,4
427	Atrial fibrillation	42 090	20,1
V15	Personal history of tobacco use	41 713	19,9
414	Coronary atherosclerosis of native coronary artery	40 738	19,5
585	Chronic kidney disease, unspecified	35 189	16,8
428	Congestive heart failure, unspecified	33 227	15,9
403	Hypertensive chronic kidney disease, unspecified, with chronic kidney disease stage I through stage IV, or unspecified	30 573	14,6
V10	Personal history of malignant neoplasm of breast	30 541	14,6
584	Acute kidney failure, unspecified	30 089	14,4
305	Tobacco use disorder	28 602	13,7
311	Depressive disorder, not elsewhere classified	28 243	13,5
V12	Personal history of venous thrombosis and embolism	27 616	13,2
780	Insomnia, unspecified	27 081	12,9

Zdroj: `diagnoses_icd` a `d_icd_diagnoses`; jmenovatelem je počet zpráv s aspoň jedním kódem ICD-9.

3.4 Kandidátní diagnózy

Tabulka 5 uvádí prevalenci deseti kandidátů v celém korpusu a zvlášť mezi zprávami s kódy ICD-9 a ICD-10. Velký rozdíl mezi érami ukazuje, že předpony obou verzí nemusí znamenat totéž. Poslední sloupec zařazuje kandidáta k pásmu 5–60 %.

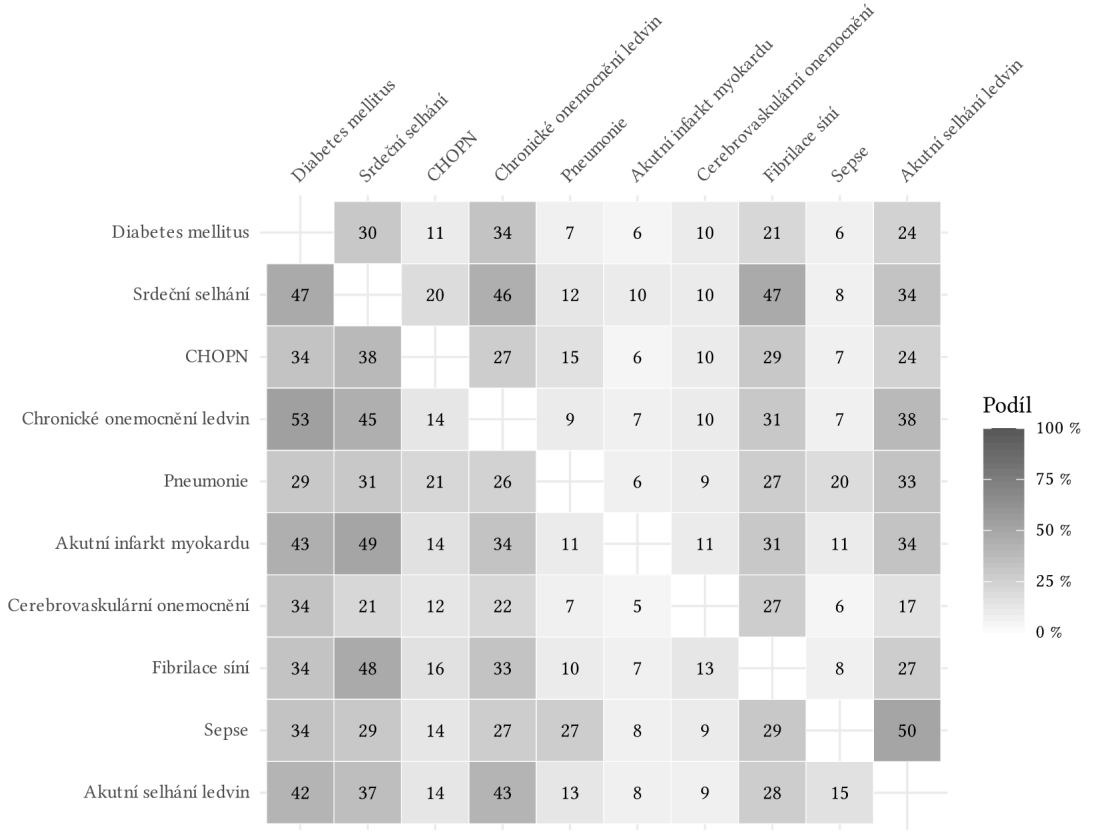
Tabulka 5: Prevalence kandidátních diagnóz ve vstupním korpusu a podle éry ICD a jejich poloha vůči pásmu prevalence.

Kandidát	Zprávy	Korpus (%)	ICD-9 (%)	ICD-10 (%)	Pásmo
Diabetes mellitus	90 006	27,1	26,6	28,0	v pásmu
Srdeční selhání	56 676	17,1	15,9	19,2	v pásmu
CHOPN	29 908	9,0	8,3	10,2	v pásmu
Chronické onemocnění ledvin	58 547	17,7	16,8	19,1	v pásmu
Pneumonie	21 110	6,4	6,3	6,4	v pásmu
Akutní infarkt myokardu	11 827	3,6	2,9	4,7	pod pásmem
Cerebrovaskulární onemocnění	26 371	8,0	7,6	8,6	v pásmu
Fibrilace síní	55 410	16,7	15,7	18,4	v pásmu
Sepse	15 764	4,8	3,9	6,2	pod pásmem
Akutní selhání ledvin	52 315	15,8	14,4	18,2	v pásmu

Zdroj: `diagnoses_icd`; jmenovatelem je počet zpráv korpusu, resp. zpráv s kódem dané verze.

3.5 Souběh kandidátů

Obrázek 2 ukazuje, jaký podíl zpráv s kandidátem na řádku má i kandidáta ve sloupci. Skryté buňky jsou prázdné a diagonála se nekreslí.



Obrázek 2: Souběh kandidátních diagnóz: podíl zpráv s kandidátem na řádku, které mají i kandidáta ve sloupci; skryté buňky jsou prázdné.

3.6 Příznaky a symptomy

Kapitola R mezinárodní klasifikace ICD-10 a kódy 780–799 klasifikace ICD-9 označují příznaky a symptomy. Tabulka 6 a Tabulka 7 uvádějí jejich nejčastější tříznakové skupiny. Slouží jako reference symptomů pro extrakci; zmínky symptomů v textu měří následující sešit.

Tabulka 6: Nejčastější tříznakové skupiny kódů kapitoly R (ICD-10).

Kód	Název nejčastějšího kódu skupiny	Zprávy	Podíl (%)
R33	Retention of urine, unspecified	6 568	5,4
R00	Tachycardia, unspecified	5 979	4,9
R11	Nausea with vomiting, unspecified	5 012	4,1
R09	Hypoxemia	4 671	3,8
R74	Nonspecific elevation of levels of transaminase and lactic acid dehydrogenase [LDH]	4 305	3,5
R65	Severe sepsis with septic shock	4 271	3,5
R13	Dysphagia, unspecified	4 256	3,5
R19	Diarrhea, unspecified	4 139	3,4
R10	Unspecified abdominal pain	4 061	3,3
R50	Fever, unspecified	3 921	3,2
R07	Other chest pain	3 778	3,1
R91	Other nonspecific abnormal finding of lung field	3 216	2,6
R41	Disorientation, unspecified	3 103	2,5
R79	Abnormal coagulation profile	3 068	2,5
R29	Facial weakness	2 999	2,5
R47	Aphasia	2 880	2,4
R45	Suicidal ideations	2 603	2,1
R18	Other ascites	2 492	2,0
R57	Cardiogenic shock	2 440	2,0
R53	Weakness	2 319	1,9

Zdroj: `diagnoses_icd` a `d_icd_diagnoses`; jmenovatelem je počet zpráv s aspoň jedním kódem ICD-10.

Tabulka 7: Nejčastější tříznakové skupiny kódů 780–799 (ICD-9).

Kód	Název nejčastějšího kódu skupiny	Zprávy	Podíl (%)
780	Insomnia, unspecified	27 081	12,9
787	Diarrhea	18 870	9,0
790	Abnormal coagulation profile	15 629	7,5
789	Other ascites	14 239	6,8
786	Other chest pain	13 335	6,4
788	Retention of urine, unspecified	12 572	6,0
785	Septic shock	10 065	4,8
784	Headache	8 116	3,9
782	Edema	6 655	3,2
799	Hypoxemia	6 484	3,1
783	Loss of weight	5 427	2,6
781	Abnormality of gait	5 216	2,5
793	Solitary pulmonary nodule	2 597	1,2
794	Nonspecific abnormal electrocardiogram [ECG] [EKG]	1 902	0,9
791	Other nonspecific findings on examination of urine	1 505	0,7
795	Nonspecific reaction to tuberculin skin test without active tuberculosis	948	0,5
792	Nonspecific abnormal findings in stool contents	828	0,4
796	Elevated blood pressure reading without diagnosis of hypertension	723	0,3

Zdroj: `diagnoses_icd` a `d_icd_diagnoses`; jmenovatelem je počet zpráv s aspoň jedním kódem ICD-9.

4 Shrnutí a rozhodnutí

Dokument popsal krajinu diagnóz vstupního korpusu. Pro další práci z toho plyne:

- **Předvýběr kandidátů.** Do rubriky následujícího sešitu postupují kandidáti v pásmu 5–60 % zpráv: Diabetes mellitus, Srdeční selhání, CHOPN, Chronické onemocnění ledvin, Pneumonie, Cerebrovaskulární onemocnění, Fibrilace síní a Akutní selhání ledvin. Pod pásmem jsou: Akutní infarkt myokardu a Sepse. Nad pásmem jsou: žádný. Pro potlačení nelze posoudit: žádný. O pětici sešit nerozhoduje, protože mu chybí shoda s textem.
- **Audit proti cherry-pickingu.** Charlsonovy kategorie v pásmu 5–60 %, které nepokrývá žádný kandidát: Onemocnění periferních cév, Mírné onemocnění jater, Zhoubný nádor a

Metastatický nádor. Následující sešit je posoudí podle stejné rubriky, aby výběr nevynechal častou diagnózu.

- **Redundance kandidátů.** Dvojice s P(sloupec | řádek) aspoň 0,5 jsou riziko pro kritérium diverzity, protože většina zpráv s prvním kandidátem má i druhého: Chronické onemocnění ledvin → Diabetes mellitus a Sepse → Akutní selhání ledvin. Skrytých buněk souběhu je 0.
- **Rozdíly mezi érami.** Prevalence v jedné éře je víc než 1,5krát větší než v druhé u kandidátů: Akutní infarkt myokardu a Sepse. Mapování jejich předpon mezi ICD-9 a ICD-10 ověří úloha o sjednocení štítků přes mapování GEMs. Neposouditelní kvůli potlačení: žádný.
- **Příznaky.** Referencí symptomů pro extrakci jsou kódy kapitoly R a 780–799, které má 49,3 % zpráv korpusu. Zmínky symptomů v textu měří následující sešit, který z nich odhadne rozsah úlohy.

5 Omezení

Kód ICD říká, že hospitalizace měla diagnózu, ne že ji zpráva zmiňuje; shodu s textem měří následující sešit. Prevalence se počítá nad vstupním korpusem, a proto nejsou srovnatelné s hodnotami nad všemi propouštěcími zprávami. Prevalence v různých érách ICD mohou odrážet změnu kódovací praxe i změnu populace, sešit je od sebe neodliší. Předpony kandidátů jsou ruční mapování z konfigurace předchozího projektu a nemusí odpovídat klinické představě o diagnóze. Charlsonovy kategorie vycházejí z map Quan 2005, které se omezují na komorbidity a nepokrývají všechny časté diagnózy. Skupiny pod prahem potlačení nejsou vidět, takže žebříčky ukazují jen časté kódy a ani Charlsonovy kategorie ani kandidáti s malým počtem se nedají posoudit. Název skupiny je název jejího nejčastějšího plného kódu a nemusí vystihovat celou skupinu.

Příloha A: provenance renderu

Tabulka 8 uvádí údaje, podle kterých lze render dohledat a zopakovat: revizi kódu, otisk zámku prostředí, zdroj dat a verze použitých nástrojů.

Tabulka 8: Provenance renderu.

Položka	Hodnota
Revize kódu (commit)	474ae504489a5c120bbd356c0a0c1ead846b1ebd
Necommitnuté změny	ne
Otisk pixi.lock (SHA-256)	a31fd88e17482254 b6f24ac503afe9ba b66dd5e0b15eece7 03cb59360ba5a6fd
Zdroj dat	otisky CSV z config/mimic_tables.json
Otisk discharge.csv.gz (SHA-256)	27bc552edaf81c2a f322040cb7e8eb36 417173b23c79405b b92fcf73bef2dbc5
Otisk radiology.csv.gz (SHA-256)	2c09bc76ee12d5f3 b8f572deb7218fba f3e59b32eccfdae1 4686e05ae099eebb
Otisk admissions.csv.gz (SHA-256)	a9584ed88e9ed664 a2f66f86a5cf9fd1 75c8bb0af50e3b61 15598b19e978384e
Otisk d_icd_diagnoses.csv.gz (SHA-256)	a81065bf45ccf74f 589bec855bbb0a07 b5c014907b34ff76 fe20583a2c87cc79
Otisk d_icd_procedures.csv.gz (SHA-256)	2ac8afcb99fd16b ce2e6c7ad445e3bd 1dfd658e52182313 0ab08b66fdd3d6d4
Otisk diagnoses_icd.csv.gz (SHA-256)	47665a41b2a3ad99 0d6f314062d5bd6d 29d467b0fd402dd9 4662044ec8b073d2
Otisk omr.csv.gz (SHA-256)	8280a8023203bddc 6cc4419bd8cd253a 015b8bc0bc53852e c92f98c7353f31e2
Otisk patients.csv.gz (SHA-256)	4c7507de7ecad8c5 ba7647ea4d26018e 88ff6672c5fc22ab 59c2a5697d687cdd
Otisk pharmacy.csv.gz (SHA-256)	c9885721e4c968f0 773145d7f6ba4d3c c3755d5600ee400f f95b1d3238053811
Otisk prescriptions.csv.gz (SHA-256)	0d8481c7d5d7c9ec 2fea3fc543ddaaad b5a933cd22c7b9dd a4289361e4d77199
Otisk procedures_icd.csv.gz (SHA-256)	3271397d0517131f 84399b698cbb0c2f 435aaab0f873a380 6e13b097661596f7
Otisk services.csv.gz (SHA-256)	31c82ebee94e0c04 d6966fbfec30579e c00f9c7816b80852 f9580656e6183888
Python	3.13.16
DuckDB	1.5.6
R	R version 4.5.3 (2026-03-11)

Literatura

Gasparini, Alessandro. 2018. „comorbidity: An R package for computing comorbidity scores". *Journal of Open Source Software* 3 (23): 648. https://doi.org/10.21105/joss.00648.

Johnson, Alistair E. W., Lucas Bulgarelli, Lu Shen, et al. 2023. „MIMIC-IV, a freely accessible electronic health record dataset". *Scientific Data* 10 (1): 1. https://doi.org/10.1038/s41597-022--01899-x.

Johnson, Alistair, Lucas Bulgarelli, Tom Pollard, et al. 2024. *MIMIC-IV*. Verze 3.1. PhysioNet. https://doi.org/10.13026/kpb9-mt58.

Johnson, Alistair, Tom Pollard, Steven Horng, Leo Anthony Celi, a Roger Mark. 2023. *MIMIC--IV-Note: Deidentified free-text clinical notes*. Verze 2.2. PhysioNet. https://doi.org/10.13026/1n74-ne17.

Quan, Hude, Vijaya Sundararajan, Patricia Halfon, et al. 2005. „Coding algorithms for defining comorbidities in ICD-9-CM and ICD-10 administrative data". *Medical Care* 43 (11): 1130–39. https://doi.org/10.1097/01.mlr.0000182534.19832.83.