Explorační analýza datové sady: zmínky diagnóz a příznaků v textu

Martin Žoha

Abstrakt Dokument měří, jak často propouštěcí zprávy vstupního korpusu zmiňují kandidátní diagnózy, jak se zmínky v textu shodují s kódy ICD v obou směrech, s negací i bez ní, a jak často se v textu objevují příznaky ze seed lexikonu. Na kandidáty uplatňuje předem stanovenou rubriku (pásmo prevalence a podíl zpráv s kódem, které diagnózu zmiňují) a vybírá pětici diagnóz pro klasifikaci tak, aby každá pocházela z jiné kapitoly ICD-10. Zároveň vysvětluje Charlsonovy kategorie komorbidit, které používal předchozí sešit.

Obsah

1 Úvod 1
2 Data a metody 2
3 Výsledky 3
3.1 Shoda kódu ICD a zmínky v textu 3
3.2 Zmínky příznaků 5
3.3 Rubrika a výběr pětice 6
4 Shrnutí a rozhodnutí 7
5 Omezení 7
Příloha A: provenance renderu 8
Literatura 10

1 Úvod

Tento sešit je osmým z řady sešitů explorační analýzy. Předchozí sešit popsal diagnózy vstupního korpusu podle kódů ICD. Kód ICD ale říká jen to, že hospitalizace měla diagnózu, ne že ji zpráva zmiňuje; klasifikace a extrakce z textu potřebují diagnózy, které se v textu skutečně objevují. Sešit si klade tyto cíle:

- změřit, jak se kód ICD kandidátní diagnózy shoduje se zmínkou diagnózy v textu zprávy, a to v obou směrech, s negací i bez ní,
- změřit, jak často se v textu objevují příznaky ze seed lexikonu,
- uplatnit na kandidáty předem stanovenou rubriku a vybrat pětici diagnóz pro klasifikaci,
- vysvětlit Charlsonovy kategorie komorbidit, které předchozí sešit jen používal.

Data pocházejí z MIMIC-IV (Johnson et al. 2024; A. E. W. Johnson et al. 2023) a MIMIC-IV-Note (A. Johnson et al. 2023), které podléhají smlouvě o užívání dat (DUA). Dokument proto zveřejňuje jen agregáty. Kandidátní diagnóza i příznak vymezují skupinu pacientů klinickým

atributem, a proto se potlačuje každý řádek, jehož některá buňka má méně než deset zpráv; podrobná pravidla jsou v kapitole 2. Práh je pravidlo práce, DUA malé počty neupravuje.

Dokument je členěn takto. Kapitola 2 popisuje metody. Kapitola 3 uvádí výsledky. Kapitola 4 shrnuje rozhodnutí pro další práci a kapitola 5 jmenuje omezení. Příloha A dokumentuje provenance renderu.

2 Data a metody

Sešit čte propouštěcí zprávy (`discharge`) a diagnózy ICD (`diagnoses_icd`). Dotazy provádí DuckDB nad parquetem a jsou v `eda/R/mentions.R` s testy nad ručně vytvořenými tabulkami. Text zprávy se prochází jednou: dočasná tabulka nese pro každý termín příznak zmínky a příznak tvrzené zmínky a ostatní výpočty čtou jen ji.

Pojmy a jednotky jsou tyto:

- *populací* je vstupní korpus z pátého sešitu, tedy tentýž jako v sedmém sešitu: propouštěcí zprávy s kódem ICD, dlouhé aspoň 100 znaků a bez přesných duplicit. Vstupní korpus tvoří 331 604 zpráv. Jednotkou je zpráva,
- *pool kandidátů* tvoří 10 kandidátů z `config/diagnosis_candidates.json`; předpony a Charlsonovy kategorie jsou stejné jako v sedmém sešitu. Konfigurace nese u každého kandidáta i klíčová slova pro hledání v textu: fráze (bez ohledu na velikost písmen) a zkratky (s rozlišením velikosti písmen). Mezera ve frázi se shoduje s libovolným bílým znakem, takže fráze zalomená řádkem je také zmínka. Zkratky jsou odděleny proto, že „mi“, „af“ nebo „hf“ malými písmeny jsou běžná slova a nadhodnocovala by zmínky. Čísla předchozího projektu jsou proto s tímto sešitem srovnatelná jen přibližně,
- *zmínka* je shoda regulárního výrazu RE2 s frází nebo zkratkou na hranicích slov. Fráze a zkratky se před vložením do výrazu escapují. Příznaky seed lexikonu (20 příznaků v `config/text_mentions.json`) se hledají stejně jako fráze,
- *tvrzená zmínka* vzniká tak, že se z textu vyříznou negované úseky a zbylý text se prohledá znovu. Negovaný úsek začíná negačním výrazem (například „no“, „denies“, „without“, „family history“; konfigurace obsahuje 11 negačních výrazů) a sahá až 40 znaků dál, nejvýš ke konci věty, středníku nebo řádku, a končí zmínkou. Hladový rozsah pokryje výčty typu „no fever, chills or cough“. Zpráva má tvrzenou zmínku, když výraz najde zmínku i ve zbylém textu. Zpráva s jednou negovanou a jednou kladnou zmínkou tak tvrzení má. Odečtení negace je dolní odhad negace, a tvrzení je proto spíš nadhodnocené: výraz nepozná negaci za termínem, hypotézy ani rodinnou anamnézu mimo výraz „family history“. Hladové okno naopak může přes čárku vyříznout i kladnou zmínku („no distress, but pneumonia“) a tvrzení podhodnotit, směr chyby tedy není jednoznačný,
- *shoda kódu a zmínky*: ze čtyř počtů (zprávy s kódem, zprávy se zmínkou, zprávy s kódem i zmínkou, zprávy celkem) se počítají P(zmínka | ICD+), P(tvrzení | ICD+), P(ICD+ | zmínka) a P(ICD+ | tvrzení). Počet zpráv s kódem je tentýž, který uvádí sedmý sešit,
- *Charlsonovy kategorie*: Charlsonův index komorbidit (Charlson et al. 1987) je prognostický index roční mortality, který váží 19 komorbidit. Deyo a kol. (1992) ho přizpůsobili kódům ICD-9-CM a sloučili do 17 kategorií. Quan a kol. (2005) převedli těchto 17 kategorií do ICD-10 a rozšířili mapu ICD-9-CM; tu používá sedmý sešit. Kategorie jsou přítomnost komorbidity, ne vážený index,
- *rubrika* je stanovena předem, před pohledem na data, a má dvě kritéria: pásmo prevalence 5–60 % zpráv a P(zmínka | ICD+) aspoň 50 % na surové zmínce. Pásmo zajišťuje dost

pozitivních zpráv a vyřazuje příliš časté diagnózy, práh shody vyřazuje diagnózy, které se v textu téměř neobjevují, takže by pro extrakci z textu neměly oporu. P(ICD+ | zmínka) a varianta po odečtení negace jsou jen diagnostika a výběr neovlivní; kandidáty s P(ICD+ | zmínka) pod 50 % sešit jmenuje jako riziko šumu v negativní třídě, což je popisná hranice, ne brána rubriky. Předběžná čísla z předchozího projektu byla při návrhu známa; výběrové pravidlo se proto zdůvodňuje metodou, ne čísly,

- *výběr pětice*: z kandidátů, kteří projdou rubrikou, se z každé kapitoly ICD-10 vybere ten s nejvyšší P(zmínka | ICD+); při shodě rozhoduje pořadí v konfiguraci. Pool pokrývá 5 kapitol (E, I, J, N a A), takže pravidlo zajišťuje diverzitu orgánových systémů objektivně. Kapitolu bez prošlého kandidáta doplní nejlepší zbývající prošlý kandidát podle téže metriky. Projde-li rubrikou méně než pět kandidátů, vyberou se všichni prošlí a o doplnění rozhodne navazující úloha. Zamítnuto bylo vybrat pět nejlepších podle shody s diverzitou jen jako kontrolou, protože by mohlo vybrat tři srdeční diagnózy, a vybírat po pohledu na data, protože to je cherry-picking, před kterým rubrika chrání,
- *potlačení*: řádek kandidáta se skryje celý (všechny počty i podíly), když kterákoli ze šesti atomických buněk rozkladu zpráv podle kódu (ICD+, ICD−) a zmínky (žádná, jen negovaná, tvrzená) má méně než deset zpráv. Každá buňka tabulek 2×2 je součtem atomických, takže šest buněk stačí a žádná nejde dopočítat ze zveřejněných podílů. Řádek příznaku se skryje, když zmínky nebo tvrzení nebo jejich doplněk do počtu zpráv nebo jejich rozdíl nedosahuje deseti. Kandidát, kterého sedmý sešit nezveřejnil, se skryje také, aby čísla obou sešitů byla táž. Skrytý kandidát rubrikou neprojde a ve výběru je mezi těmi, které nelze posoudit.

3 Výsledky

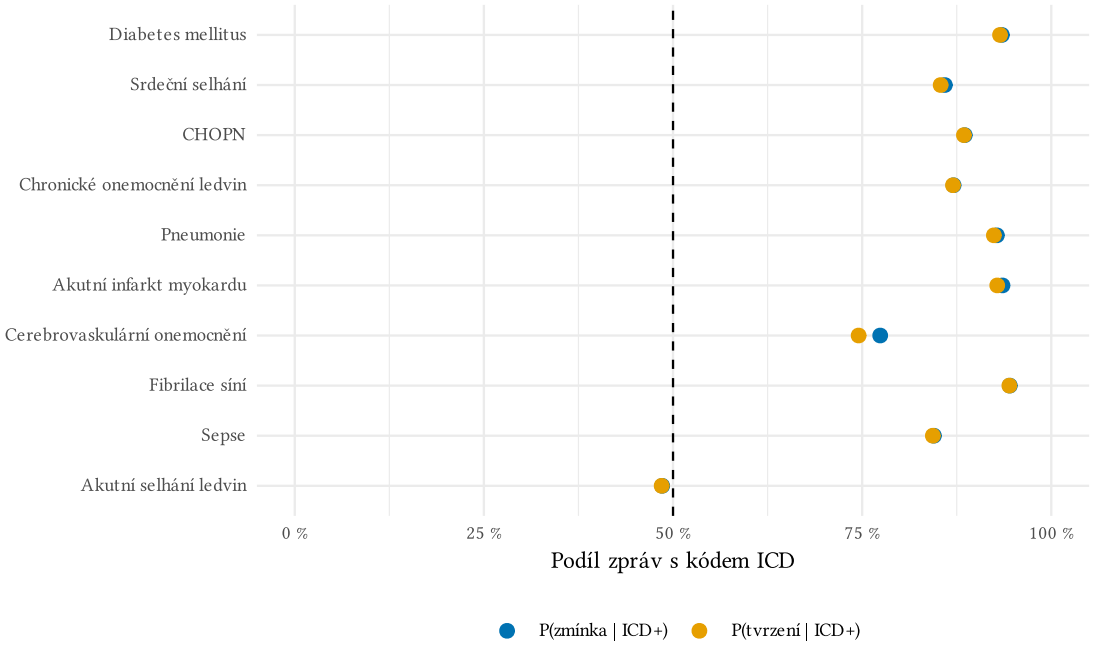
3.1 Shoda kódu ICD a zmínky v textu

Tabulka 1 a Obrázek 1 uvádějí shodu kódu ICD a zmínky pro 10 kandidátů. Čtyři podíly se liší jmenovatelem: první dva říkají, kolik zpráv s kódem diagnózu v textu zmiňuje, resp. tvrdí; poslední dva říkají, jak často zpráva se zmínkou, resp. s tvrzením má i kód. Potlačení neskrylo žádný řádek.

Tabulka 1: Shoda kódu ICD a zmínky diagnózy v textu zprávy vstupního korpusu.

Kandidát	Zprávy s ICD	P(zmínka | ICD+) (%)	P(tvrzení | ICD+) (%)	P(ICD+ | zmínka) (%)	P(ICD+ | tvrzení) (%)
Diabetes mellitus	91 149	93,5	93,2	67,6	70,5
Srdeční selhání	56 676	85,9	85,4	72,4	76,3
CHOPN	35 462	88,6	88,5	70,0	71,0
Chronické onemocnění ledvin	58 547	87,1	87,0	87,8	88,1
Pneumonie	21 173	92,8	92,4	26,6	31,2
Akutní infarkt myokardu	11 827	93,5	92,9	13,7	15,7
Cerebrovaskulární onemocnění	26 371	77,4	74,5	22,4	26,6
Fibrilace síní	55 410	94,5	94,5	82,1	82,9
Sepse	15 764	84,5	84,3	36,1	37,1
Akutní selhání ledvin	52 315	48,6	48,5	85,1	85,6

Zdroj: kódy z `diagnoses_icd` a text z `discharge`; zmínka je shoda klíčového slova kandidáta, tvrzení zmínka mimo negovaný úsek.



Obrázek 1: Podíl zpráv s kódem ICD kandidáta, které diagnózu v textu zmiňují, resp. tvrdí; svislá čára vyznačuje práh rubriky. Skryté řádky nejsou zobrazeny.

Riziko šumu v negativní třídě se týká 4 kandidátů s P(ICD+ | zmínka) pod 50 %: Pneumonie, Akutní infarkt myokardu, Cerebrovaskulární onemocnění a Sepse. U diagnóz s nízkou hodnotou nemusí být zpráva bez kódu, ale se zmínkou, opravdu negativní.

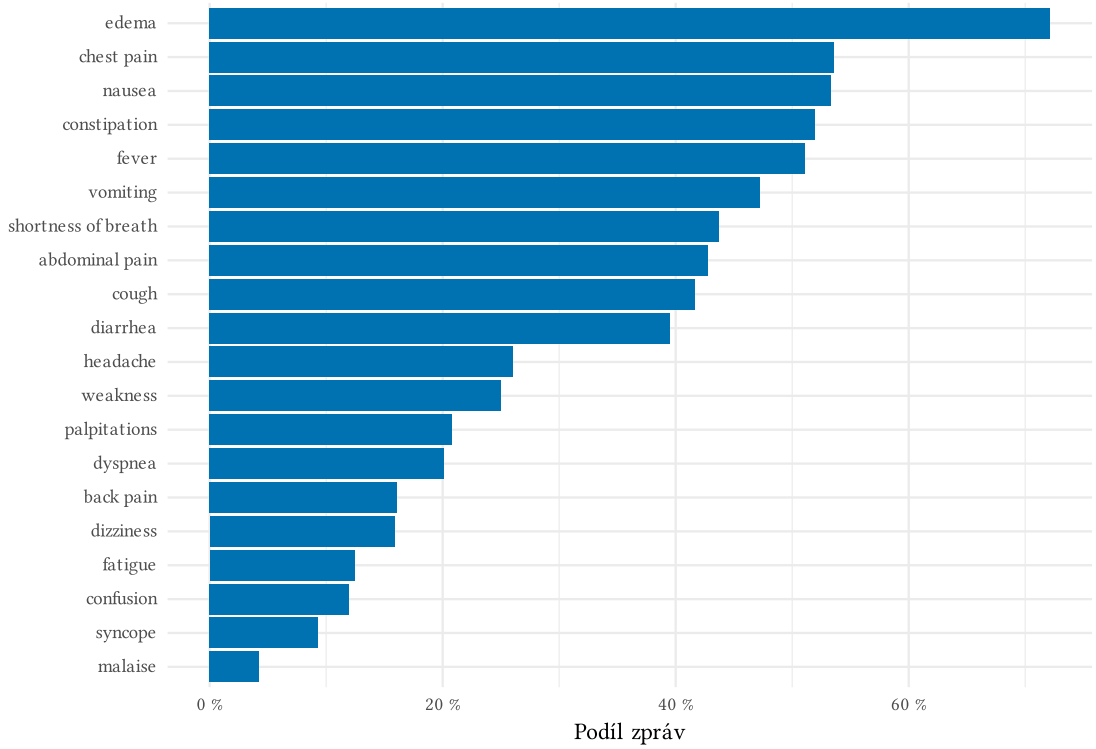
3.2 Zmínky příznaků

Tabulka 2 a Obrázek 2 uvádějí, jak často se v textu zpráv objevují příznaky z seed lexikonu. Slouží k odhadu rozsahu extrakce příznaků a jako základ budoucího lexikonu. Potlačení neskrylo žádný řádek.

Tabulka 2: Zprávy vstupního korpusu se zmínkou příznaku ze seed lexikonu a podíl po odečtení negace.

Příznak	Zprávy se zmínkou	Podíl (%)	Podíl po odečtení negace (%)
`chest pain`	177 607	53,6	39,5
`shortness of breath`	145 036	43,7	37,4
`dyspnea`	66 613	20,1	17,9
`fever`	169 462	51,1	40,3
`cough`	138 214	41,7	33,6
`nausea`	176 849	53,3	44,6
`vomiting`	156 683	47,3	38,6
`headache`	86 388	26,1	16,9
`edema`	239 204	72,1	45,9
`syncope`	30 893	9,3	8,3
`fatigue`	41 234	12,4	12,0
`dizziness`	52 654	15,9	13,4
`abdominal pain`	141 745	42,7	38,1
`weakness`	82 854	25,0	22,4
`confusion`	39 709	12,0	10,9
`palpitations`	68 946	20,8	16,5
`diarrhea`	131 072	39,5	32,4
`constipation`	172 272	52,0	49,3
`back pain`	53 266	16,1	15,3
`malaise`	14 138	4,3	4,1

Zdroj: text z `discharge`; příznaky jsou klíčová slova z `config/text_mentions.json`, ne hodnoty z dat.



Obrázek 2: Podíl zpráv vstupního korpusu se zmínkou příznaku; skryté příznaky nejsou zobrazeny.

Podíl lze zveřejnit u 20 příznaků z 20. Nejčastější je edema, zmínku má 72,1 % zpráv korpusu.

3.3 Rubrika a výběr pětice

Tabulka 3 uplatňuje rubriku na 10 kandidátů a uvádí výsledek výběru. Kandidát prošel, když leží v pásmu prevalence 5–60 % a jeho P(zmínka | ICD+) je aspoň 50 %. Z prošlých se vybírá jeden na kapitolu.

Tabulka 3: Rubrika výběru pětice: pásmo prevalence, shoda kódu a zmínky a výsledek.

Kandidát	Kapitola	Pásmo	P(zmínka | ICD+) (%)	Výsledek
Diabetes mellitus	E	v pásmu	93,5	vybrán
Srdeční selhání	I	v pásmu	85,9	prošel
CHOPN	J	v pásmu	88,6	vybrán doplněním
Chronické onemocnění ledvin	N	v pásmu	87,1	vybrán
Pneumonie	J	v pásmu	92,8	vybrán
Akutní infarkt myokardu	I	pod pásmem	93,5	neprošel
Cerebrovaskulární onemocnění	I	v pásmu	77,4	prošel
Fibrilace síní	I	v pásmu	94,5	vybrán
Sepse	A	pod pásmem	84,5	neprošel
Akutní selhání ledvin	N	v pásmu	48,6	neprošel

Zdroj: prevalence ze sedmého sešitu (`candidate_prevalence`) a shoda uvedená v Tabulka 1.

4 Shrnutí a rozhodnutí

Dokument změřil shodu kódů ICD a zmínek v textu a vybral pětici diagnóz. Pro další práci z toho plyne:

- **Pětice diagnóz.** Rubrika vybrala 5 diagnóz: Diabetes mellitus (`diabetes`), CHOPN (`copd`), Chronické onemocnění ledvin (`ckd`), Pneumonie (`pneumonia`) a Fibrilace síní (`atrial_fibrillation`). Doplněním prázdných kapitol vznikla část výběru: CHOPN (`copd`).
- **Riziko pro negativní třídu.** Riziko šumu v negativní třídě se týká 4 kandidátů s P(ICD+ | zmínka) pod 50 %: Pneumonie, Akutní infarkt myokardu, Cerebrovaskulární onemocnění a Sepse. U diagnóz s nízkou hodnotou nemusí být zpráva bez kódu, ale se zmínkou, opravdu negativní.
- **Příznaky.** Podíl lze zveřejnit u 20 příznaků z 20. Nejčastější je edema, zmínku má 72,1 % zpráv korpusu.
- **Potlačení.** Potlačení neskrylo žádný řádek.
- **Parametry syntetiky.** Sešit zapíše pro vybranou pětici po potlačení prevalenci, matici P(j | i) a míry zmínek do `results/eda/8-mentions/parametry-syntetiky.json`; příkaz `mediparse-synthetic-parameters` je převezme do plánu syntetického korpusu.

5 Omezení

Zmínky v oddílu Discharge Diagnosis nadhodnocují P(zmínka | ICD+), protože parser sekcí vznikne až později a odebrání oddílu je jen ablace. Regulární výraz nepozná synonyma mimo lexikon, překlepy, hypotézy ani časovost. Odečtení negace je dolní odhad negace, takže tvrzení je spíš nadhodnocené, ale hladové okno může kladnou zmínku vyříznout a tvrzení podhodnotit. Zkratky jsou víceznačné (AF, MI). Čísla předchozího projektu jsou kvůli oddělení zkratek

a odlišné definici tvrzené zmínky srovnatelná jen přibližně. Kód ICD je od zmínky nezávislý strukturovaný protějšek, ne výstup modelu; sešit proto mluví o shodě kódu a zmínky, ne o kvalitě štítků.

Příloha A: provenance renderu

Tabulka 4 uvádí údaje, podle kterých lze render dohledat a zopakovat: revizi kódu, otisk zámku prostředí, zdroj dat a verze použitých nástrojů.

Tabulka 4: Provenance renderu.

Položka	Hodnota
Revize kódu (commit)	0df66ea9c7ac9eb54c7234c02ae6da1014c63a15
Necommitnuté změny	ne
Otisk pixi.lock (SHA-256)	a31fd88e17482254 b6f24ac503afe9ba b66dd5e0b15eece7 03cb59360ba5a6fd
Zdroj dat	otisky CSV z config/mimic_tables.json
Otisk discharge.csv.gz (SHA-256)	27bc552edaf81c2a f322040cb7e8eb36 417173b23c79405b b92fcf73bef2dbc5
Otisk radiology.csv.gz (SHA-256)	2c09bc76ee12d5f3 b8f572deb7218fba f3e59b32eccfdae1 4686e05ae099eebb
Otisk admissions.csv.gz (SHA-256)	a9584ed88e9ed664 a2f66f86a5cf9fd1 75c8bb0af50e3b61 15598b19e978384e
Otisk d_icd_diagnoses.csv.gz (SHA-256)	a81065bf45ccf74f 589bec855bbb0a07 b5c014907b34ff76 fe20583a2c87cc79
Otisk d_icd_procedures.csv.gz (SHA-256)	2ac8afcb99fd16b ce2e6c7ad445e3bd 1dfd658e52182313 0ab08b66fdd3d6d4
Otisk diagnoses_icd.csv.gz (SHA-256)	47665a41b2a3ad99 0d6f314062d5bd6d 29d467b0fd402dd9 4662044ec8b073d2
Otisk omr.csv.gz (SHA-256)	8280a8023203bddc 6cc4419bd8cd253a 015b8bc0bc53852e c92f98c7353f31e2
Otisk patients.csv.gz (SHA-256)	4c7507de7ecad8c5 ba7647ea4d26018e 88ff6672c5fc22ab 59c2a5697d687cdd
Otisk pharmacy.csv.gz (SHA-256)	c9885721e4c968f0 773145d7f6ba4d3c c3755d5600ee400f f95b1d3238053811
Otisk prescriptions.csv.gz (SHA-256)	0d8481c7d5d7c9ec 2fea3fc543ddaaad b5a933cd22c7b9dd a4289361e4d77199
Otisk procedures_icd.csv.gz (SHA-256)	3271397d0517131f 84399b698cbb0c2f 435aaab0f873a380 6e13b097661596f7
Otisk services.csv.gz (SHA-256)	31c82ebee94e0c04 d6966fbfec30579e c00f9c7816b80852 f9580656e6183888
Python	3.13.16
DuckDB	1.5.6
R	R version 4.5.3 (2026-03-11)

Literatura

Deyo, Richard A., Daniel C. Cherkin, a Marcia A. Ciol. 1992. „Adapting a clinical comorbidity index for use with ICD-9-CM administrative databases". *Journal of Clinical Epidemiology* 45 (6): 613–19. https://doi.org/10.1016/0895-4356(92)90133-8.

Charlson, Mary E., Peter Pompei, Kathy L. Ales, a C. Ronald MacKenzie. 1987. „A new method of classifying prognostic comorbidity in longitudinal studies: development and validation". *Journal of Chronic Diseases* 40 (5): 373–83. https://doi.org/10.1016/0021-9681(87)90171-8.

Johnson, Alistair E. W., Lucas Bulgarelli, Lu Shen, et al. 2023. „MIMIC-IV, a freely accessible electronic health record dataset". *Scientific Data* 10 (1): 1. https://doi.org/10.1038/s41597-022--01899-x.

Johnson, Alistair, Lucas Bulgarelli, Tom Pollard, et al. 2024. *MIMIC-IV*. Verze 3.1. PhysioNet. https://doi.org/10.13026/kpb9-mt58.

Johnson, Alistair, Tom Pollard, Steven Horng, Leo Anthony Celi, a Roger Mark. 2023. *MIMIC--IV-Note: Deidentified free-text clinical notes*. Verze 2.2. PhysioNet. https://doi.org/10.13026/1n74-ne17.

Quan, Hude, Vijaya Sundararajan, Patricia Halfon, et al. 2005. „Coding algorithms for defining comorbidities in ICD-9-CM and ICD-10 administrative data". *Medical Care* 43 (11): 1130–39. https://doi.org/10.1097/01.mlr.0000182534.19832.83.