# Explorační analýza datové sady: hlavičky, lexikon a kostra sekcí

Martin Žoha

**Abstrakt** Dokument zjišťuje, které hlavičky začínají v propouštěcích zprávách vstupního korpusu oddíly, a ověřuje na nich seed lexikon sekcí šablony MIMIC. Počítá dokumentovou frekvenci všech hlaviček, pokrytí sekcí a synonym lexikonu, mrtvá synonyma a synonyma, která se ve zprávě opakují, což je signál falešné hranice sekce. Hlavičky mimo lexikon s vysokým pokrytím jmenuje jako kandidáty na doplnění, o kterých rozhodne autor. Zprávy pak rozdělí parserem sekcí a zjistí kostru šablony (pořadí sekcí, jejich pokrytí a konzistenci pořadí), počet sekcí na zprávu, délky těl sekcí ve znacích, podíl textu, který odstraní vystřižení sekce Discharge Diagnosis, a zprávy bez nadpisů.

## Obsah

1 Úvod ..... 1
2 Data a metody ..... 2
3 Výsledky ..... 4
3.1 Objevení hlaviček ..... 4
3.2 Audit lexikonu ..... 6
4 Segmentace a kostra šablony ..... 8
4.1 Kostra šablony ..... 8
4.2 Sekce na zprávu ..... 11
4.3 Délky těl sekcí ..... 12
4.4 Zprávy bez nadpisů ..... 13
5 Shrnutí a rozhodnutí ..... 14
6 Omezení ..... 15
Příloha A: provenance renderu ..... 15
Literatura ..... 17

## 1 Úvod

Tento sešit je devátým z řady sešitů explorační analýzy a otevírá fázi zpracování struktury textu. Předchozí sešity popsaly korpus, diagnózy a jejich zmínky v textu. Propouštěcí zpráva MIMIC má ale vnitřní strukturu: je rozdělená na oddíly, jako jsou Chief Complaint, Hospital Course nebo Discharge Diagnosis. Parser sekcí rozpoznává oddíly podle seznamu hlaviček, tedy lexikonu sekcí (kapitola 4 používá parser k rozdělení zpráv). Lexikon musí odpovídat datům, ne odhadu. Sešit si klade tyto cíle:

- zjistit, které hlavičky se v textu zpráv vyskytují a v kolika zprávách,

- změřit, jak lexikon sekcí šablony MIMIC tyto hlavičky pokrývá,
- najít mrtvá synonyma lexikonu a synonyma, která se ve zprávě opakují a nejspíš se používají i uvnitř těl sekcí,
- jmenovat hlavičky mimo lexikon, které má většina zpráv a které by do lexikonu mohly patřit,
- rozdělit zprávy na sekce a popsat kostru šablony: pořadí sekcí, jejich pokrytí a konzistenci pořadí,
- změřit počet sekcí na zprávu a délky těl sekcí ve znacích,
- zjistit, kolik zpráv má sekci Discharge Diagnosis a jaký podíl textu odstraní její vystřižení (ablace D2),
- popsat zprávy bez jediného nadpisu.

Data pocházejí z MIMIC-IV (Johnson et al. 2024; A. E. W. Johnson et al. 2023) a MIMIC-IV-Note (A. Johnson et al. 2023), které podléhají smlouvě o užívání dat (DUA). Dokument proto zveřejňuje jen agregáty. Řetězec hlavičky je popisek z dat, a zveřejní se proto jen hlavička, kterou má aspoň 1 % zpráv a nejméně 10 zpráv; podrobná pravidla jsou v kapitole 2.

Dokument je členěn takto. Kapitola 2 popisuje metody. Kapitola 3 uvádí výsledky hlaviček a lexikonu a kapitola 4 výsledky rozdělení zpráv na sekce. Kapitola 5 shrnuje rozhodnutí pro další práci a kapitola 6 jmenuje omezení. Příloha A dokumentuje provenance renderu.

# 2 Data a metody

Sešit čte propouštěcí zprávy (`discharge`). Dotazy provádí DuckDB nad parquetem a jsou v `eda/R/sections.R` (hlavičky a lexikon) a `eda/R/segments.R` (segmentace a kostra) s testy nad ručně vytvořenými tabulkami. Hlavičky se z textu vytáhnou jednou do dočasné tabulky a audit lexikonu čte jen ji. Segmentaci zprávy na sekce dělá parser sekcí, ne dotaz: kapitola o segmentaci čte druhou dočasnou tabulku, kterou naplní parser.

Pojmy a jednotky jsou tyto:

- *populací* je vstupní korpus z pátého sešitu, tedy tentýž jako v sedmém a osmém sešitu: propouštěcí zprávy s kódem ICD, dlouhé aspoň 100 znaků a bez přesných duplicit. Vstupní korpus tvoří 331 604 zpráv. Jednotkou je zpráva a počítá se celý korpus, ne vzorek,
- *hlavička* je řádek, který po volitelném odsazení (mezery, tabulátory) začíná velkým písmenem a dalším písmenem, pokračuje až čtyřiceti sedmi znaky z množiny písmen, mezery, pomlčky, lomítka, ampersandu, závorek, apostrofu a tečky a končí dvojtečkou. Normalizovaný tvar zachyceného řetězce má aspoň 3 znaky. Výraz RE2 s režimem po řádcích (`(?m)`) je v konstantě `HEADER_PATTERN`. Číslice v něm nejsou, takže čas „10:30“ hlavičkou není. Hlavičku, která stojí na řádku za jiným polem, výraz nevidí,
- *normalizace* hlavičky je převod na malá písmena, sloučení bílých znaků do jedné mezery a odříznutí koncových mezer a teček. Je to jediná funkce (`normalized_sql`), kterou se normalizují hlavičky z textu i synonyma z lexikonu. Hlavička je v lexikonu nalezená, když se její normalizovaný tvar rovná normalizovanému synonymu; stejné pravidlo používá parser sekcí (`domain/section_headers.py`), který rozděluje zprávy v kapitole 4. Zobrazuje se nejčastější původní zápis, při shodě první podle pořadí znaků (velká písmena před malými),
- *lexikon* je `config/section_headers.json`: 17 sekcí šablony MIMIC, každá s českým popiskem a celofrázovými synonymy (celkem 22 synonym), a seznam administrativních polí zprávy (8 polí), která nejsou sekcemi. Seed vychází z lexikonu předchozího projektu autora,

jehož čísla byla předběžná. Oproti němu přidává sekce Major Surgical or Invasive Procedure a Discharge Disposition, zkratka HPI ze sekce Chief Complaint vypadla a vypouští podsekce (vitální funkce, chirurgická anamnéza) i generická jednoslovná synonyma, která by otevírala sekci uvnitř těla jiné sekce. Zkratky se nepřebírají, protože se na začátku řádku s dvojtečkou objevují i uvnitř těl. Synonyma jsou pravopisné varianty názvu sekce ze šablony MIMIC (člen, číslo, přípona -ation, pomlčka, mezera); vyřazeny jsou podnadpisy uvnitř sekcí (například Primary a Secondary Diagnosis, Hospital Course by Problem), alternativní názvy a zkratky. Čísla v tomto sešitu pocházejí z dat tohoto projektu,

- *dokumentová frekvence* hlavičky je počet zpráv, v nichž se vyskytuje aspoň jednou; podíl je vztažený k počtu zpráv korpusu. *Opakování* sekce je počet zpráv s aspoň dvěma výskyty kteréhokoli jejího synonyma; opakování synonyma je počet zpráv s aspoň dvěma výskyty téhož synonyma. Synonymum, které se ve zprávě objeví dvakrát, se nejspíš používá i uvnitř těla, a je tedy kandidátem na falešnou hranici sekce,
- *potlačení*: řetězec hlavičky je popisek z dat. Zveřejní se jen hlavička, kterou má aspoň 1 % zpráv korpusu a nejméně 10 zpráv. Samotný práh 10 zpráv nestačí, protože výraz zachytí i úlomky vět končící dvojtečkou. Žebříček uvádí nejvýše 40 hlaviček. Synonyma a klíče sekcí pocházejí z konfigurace, ne z dat, a zveřejňují se všechna včetně nuly. Počty zpráv jsou metrika textu a nepotlačují se; počet unikátních hlaviček je číslo bez popisku,
- *rozhodnutí sešitu* jsou texty generované z dat: kandidáti na doplnění (hlavičky mimo lexikon s pokrytím aspoň 50 %), mrtvá synonyma a synonyma s opakováním aspoň v 5 % zpráv. Hranice 50 % je popisná, ne brána: odděluje „většina zpráv“ od podsekcí, o zařazení rozhoduje autor,
- *segmentace*: zprávu rozdělí parser sekcí (`split_sections` v `domain/section_headers.py`) voláním z R přes reticulate po dávkách 2 000 zpráv; sešit pravidlo hranice nekopíruje. Hranicí je první výskyt sekce v textu, opakovaná hlavička je jen text těla. Část `other` je text před první hlavičkou a text od administrativního pole lexikonu do další hlavičky, protože šablona MIMIC má pole Attending za sekcí Allergies; hranicí je první výskyt pole na začátku řádku a sousední části `other` se slijí. Hlavičku sekce tvoří text od začátku řádku po dvojtečku, tělo je text do další hlavičky nebo administrativního pole. *Pozice* sekce je její pořadí mezi sekcemi lexikonu ve zprávě od 0 (`other` se nepočítá). `span_chars` je délka hlavičky a těla dohromady, takže součet přes zprávu je délka zprávy. `body_chars` je délka těla bez okrajových bílých znaků. Tělo, které je po ořezu jen maska de-identifikace `___`, nese příznak; jeho délka (3 znaky) nepopisuje obsah, protože ten odstranila de-identifikace. Do R přicházejí jen tyto délky, příznaky a pozice, ne text,
- *kostra šablony* jsou sekce lexikonu, které má aspoň 50 % zpráv, seřazené podle mediánu pozice (při shodě podle pokrytí sestupně a pak podle pořadí v lexikonu). *Konzistence pořadí* je podíl zpráv s aspoň dvěma sekcemi kostry, v nichž sekce jdou v pořadí kostry. *Matice precedence* uvádí pro dvojici sekcí kostry podíl zpráv, kde řádek předchází sloupec, mezi zprávami, které mají obě sekce,
- *strip D2* je vystřižení sekce `discharge_diagnosis` ze zprávy. Podíl odstraněného textu je součet `span_chars` této sekce lomený součtem délek zpráv. Klíč sekce je konstanta sešitu `STRIP_SECTION`, kterou ověří lexikon,
- *zprávy bez nadpisů* jsou zprávy, jejichž jedinou částí je `other`. Délka zprávy je součet `span_chars`,

- *potlačení u segmentace*: všechny výstupy jsou metriky textu a korpusu (počty zpráv, délky, pozice) s popisky z konfigurace, takže se nic nepotlačuje; řetězce z textu se v kapitole neukazují.

# 3 Výsledky

## 3.1 Objevení hlaviček

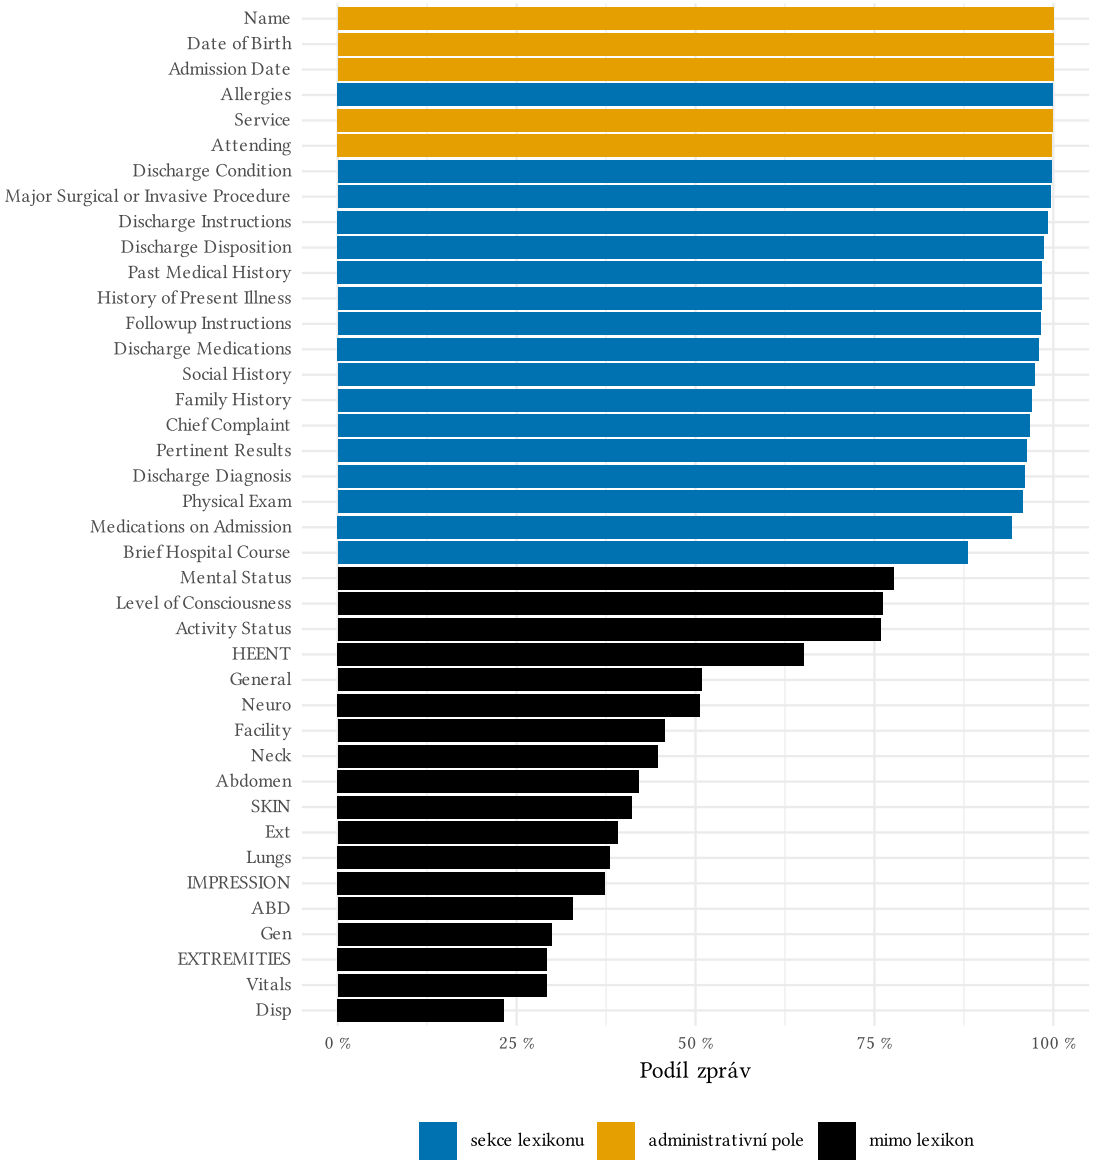
Aspoň jednu sekci lexikonu má 100,0 % zpráv korpusu, žádnou hlavičku 0,0 %. Korpus obsahuje 99 417 unikátních hlaviček.

Tabulka 1 a Obrázek 1 uvádějí hlavičky podle dokumentové frekvence a jejich zařazení: do sekce lexikonu, mezi administrativní pole, nebo mimo lexikon.

Tabulka 1: Nejčastější hlavičky vstupního korpusu podle dokumentové frekvence a jejich zařazení.

| Hlavička | Zařazení | Zprávy | Podíl (%) |
|---|---|---|---|
| Name | administrativní pole | 331 603 | 100,0 |
| Date of Birth | administrativní pole | 331 598 | 100,0 |
| Admission Date | administrativní pole | 331 593 | 100,0 |
| Allergies | Alergie | 331 478 | 100,0 |
| Service | administrativní pole | 331 392 | 99,9 |
| Attending | administrativní pole | 330 917 | 99,8 |
| Discharge Condition | Stav při propuštění | 330 735 | 99,7 |
| Major Surgical or Invasive Procedure | Významný chirurgický nebo invazivní výkon | 330 244 | 99,6 |
| Discharge Instructions | Pokyny při propuštění | 329 038 | 99,2 |
| Discharge Disposition | Místo určení po propuštění | 327 295 | 98,7 |
| Past Medical History | Dřívější anamnéza | 326 449 | 98,4 |
| History of Present Illness | Anamnéza současného onemocnění | 326 206 | 98,4 |
| Followup Instructions | Pokyny k navazující péči | 325 605 | 98,2 |
| Discharge Medications | Léky při propuštění | 324 856 | 98,0 |
| Social History | Sociální anamnéza | 322 783 | 97,3 |
| Family History | Rodinná anamnéza | 321 464 | 96,9 |
| Chief Complaint | Hlavní obtíže | 320 472 | 96,6 |
| Pertinent Results | Významné výsledky | 319 149 | 96,2 |
| Discharge Diagnosis | Diagnóza při propuštění | 318 168 | 95,9 |
| Physical Exam | Fyzikální vyšetření | 317 360 | 95,7 |
| Medications on Admission | Léky při přijetí | 312 557 | 94,3 |
| Brief Hospital Course | Průběh hospitalizace | 291 741 | 88,0 |
| Mental Status | mimo lexikon | 257 535 | 77,7 |
| Level of Consciousness | mimo lexikon | 252 410 | 76,1 |
| Activity Status | mimo lexikon | 251 520 | 75,8 |
| HEENT | mimo lexikon | 215 963 | 65,1 |
| General | mimo lexikon | 168 607 | 50,8 |
| Neuro | mimo lexikon | 167 760 | 50,6 |
| Facility | mimo lexikon | 151 512 | 45,7 |
| Neck | mimo lexikon | 148 144 | 44,7 |
| Abdomen | mimo lexikon | 139 566 | 42,1 |
| SKIN | mimo lexikon | 136 483 | 41,2 |
| [illegible] | mimo lexikon | [illegible] | [illegible] |

*Zdroj:* text z `discharge`; zařazení podle `config/section_headers.json`.




Obrázek 1: Pokrytí nejčastějších hlaviček obarvené podle zařazení.

## 3.2 Audit lexikonu

Tabulka 2 uvádí, v kolika zprávách se vyskytuje hlavička každé sekce lexikonu a v kolika se opakuje; Tabulka 3 totéž pro jednotlivá synonyma včetně mrtvých.

Tabulka 2: Sekce lexikonu: zprávy s hlavičkou sekce a zprávy, kde se hlavička sekce opakuje.

| Sekce | Popisek | Zprávy s hlavičkou (%) | Zprávy s opakováním (%) |
|---|---|---|---|
| allergies | Alergie | 100,0 | 1,3 |
| chief_complaint | Hlavní obtíže | 96,6 | 0,5 |
| major_procedure | Významný chirurgický nebo invazivní výkon | 99,6 | < 0,1 |
| history_of_present_illness | Anamnéza současného onemocnění | 98,4 | 1,2 |
| past_medical_history | Dřívější anamnéza | 98,4 | 10,0 |
| social_history | Sociální anamnéza | 97,3 | 0,7 |
| family_history | Rodinná anamnéza | 96,9 | 2,1 |
| physical_exam | Fyzikální vyšetření | 95,9 | 6,8 |
| pertinent_results | Významné výsledky | 96,2 | 0,3 |
| hospital_course | Průběh hospitalizace | 88,0 | 0,5 |
| medications_on_admission | Léky při přijetí | 94,3 | 0,1 |
| discharge_medications | Léky při propuštění | 98,0 | < 0,1 |
| discharge_disposition | Místo určení po propuštění | 98,7 | < 0,1 |
| discharge_diagnosis | Diagnóza při propuštění | 96,1 | < 0,1 |
| discharge_condition | Stav při propuštění | 99,7 | 0,2 |
| discharge_instructions | Pokyny při propuštění | 99,2 | 0,8 |
| followup_instructions | Pokyny k navazující péči | 98,3 | < 0,1 |

*Zdroj:* text z discharge; sekce a synonyma jsou hodnoty z config/section_headers.json, ne z dat.

Tabulka 3: Synonyma lexikonu: zprávy se synonymem a zprávy, kde se synonymum opakuje.

| Sekce | Synonymum | Zprávy se synonymem (%) | Zprávy s opakováním (%) |
|---|---|---|---|
| allergies | Allergies | 100,0 | 1,3 |
| chief_complaint | Chief Complaint | 96,6 | 0,5 |
| major_procedure | Major Surgical or Invasive Procedure | 99,6 | < 0,1 |
| history_of_present_illness | History of Present Illness | 98,4 | 1,2 |
| history_of_present_illness | History of the Present Illness | < 0,1 | 0,0 |
| past_medical_history | Past Medical History | 98,4 | 10,0 |
| social_history | Social History | 97,3 | 0,7 |
| family_history | Family History | 96,9 | 2,1 |
| physical_exam | Physical Exam | 95,7 | 5,0 |
| physical_exam | Physical Examination | 2,0 | 0,1 |
| pertinent_results | Pertinent Results | 96,2 | 0,3 |
| hospital_course | Brief Hospital Course | 88,0 | 0,5 |
| medications_on_admission | Medications on Admission | 94,3 | 0,1 |
| discharge_medications | Discharge Medications | 98,0 | < 0,1 |
| discharge_disposition | Discharge Disposition | 98,7 | < 0,1 |
| discharge_diagnosis | Discharge Diagnosis | 95,9 | < 0,1 |
| discharge_diagnosis | Discharge Diagnoses | 0,1 | < 0,1 |
| discharge_condition | Discharge Condition | 99,7 | 0,2 |
| discharge_instructions | Discharge Instructions | 99,2 | 0,8 |
| followup_instructions | Followup Instructions | 98,2 | < 0,1 |
| followup_instructions | Follow-up Instructions | 0,1 | 0,0 |
| followup_instructions | Follow up Instructions | < 0,1 | 0,0 |

Lexikon neobsahuje žádné mrtvé synonymum. V aspoň 5 % zpráv se opakuje 1 synonymum: `Past Medical History` (10,0 %).

# 4 Segmentace a kostra šablony

Zprávy vstupního korpusu rozdělil parser sekcí. Kapitola popisuje kostru šablony, počet sekcí na zprávu, délky těl sekcí a zprávy bez nadpisů.

## 4.1 Kostra šablony

Kostru šablony tvoří 17 sekcí s pokrytím aspoň 50 % (podle mediánu pozice): `allergies`, `chief_complaint`, `major_procedure`, `history_of_present_illness`, `past_medical_history`, `social_history`, `family_history`,

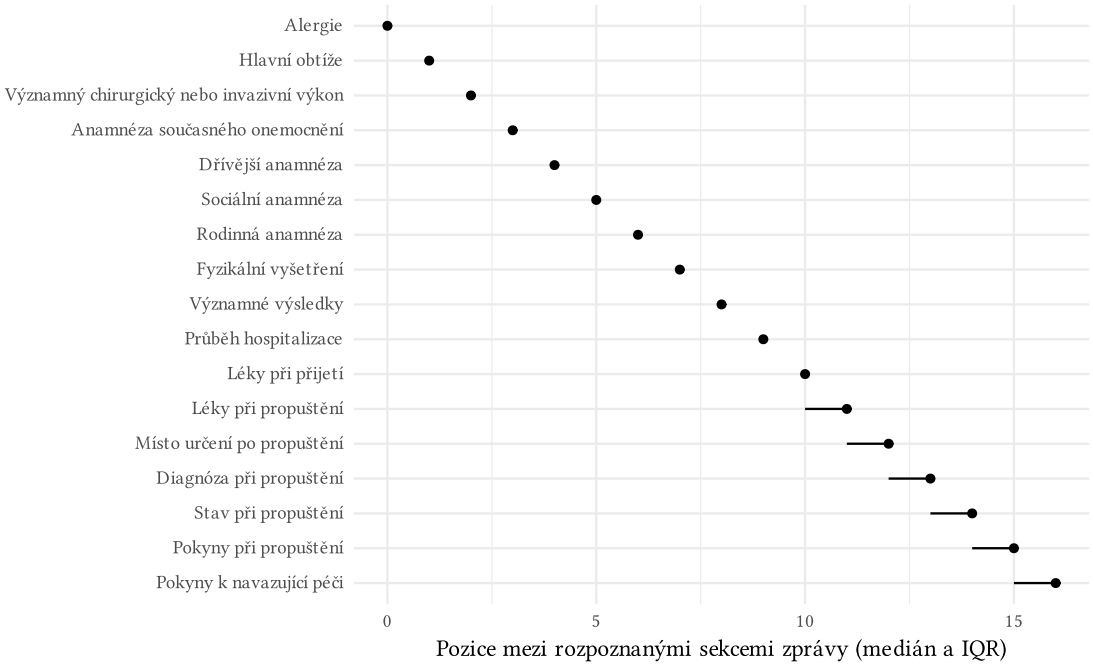
`physical_exam`, `pertinent_results`, `hospital_course`, `medications_on_admission`, `discharge_medications`, `discharge_disposition`, `discharge_diagnosis`, `discharge_condition`, `discharge_instructions` a `followup_instructions`. Pořadí kostry dodržuje 99,6 % ze 331 558 zpráv s aspoň dvěma sekcemi kostry.

Tabulka 4 uvádí všechny sekce lexikonu s pokrytím, mediánem pozice a IQR (rozdíl třetího a prvního kvartilu pozice); kostru tvoří sekce označené „ano“. Obrázek 2 ukazuje medián a IQR pozice sekcí kostry a Obrázek 3 matici precedence.

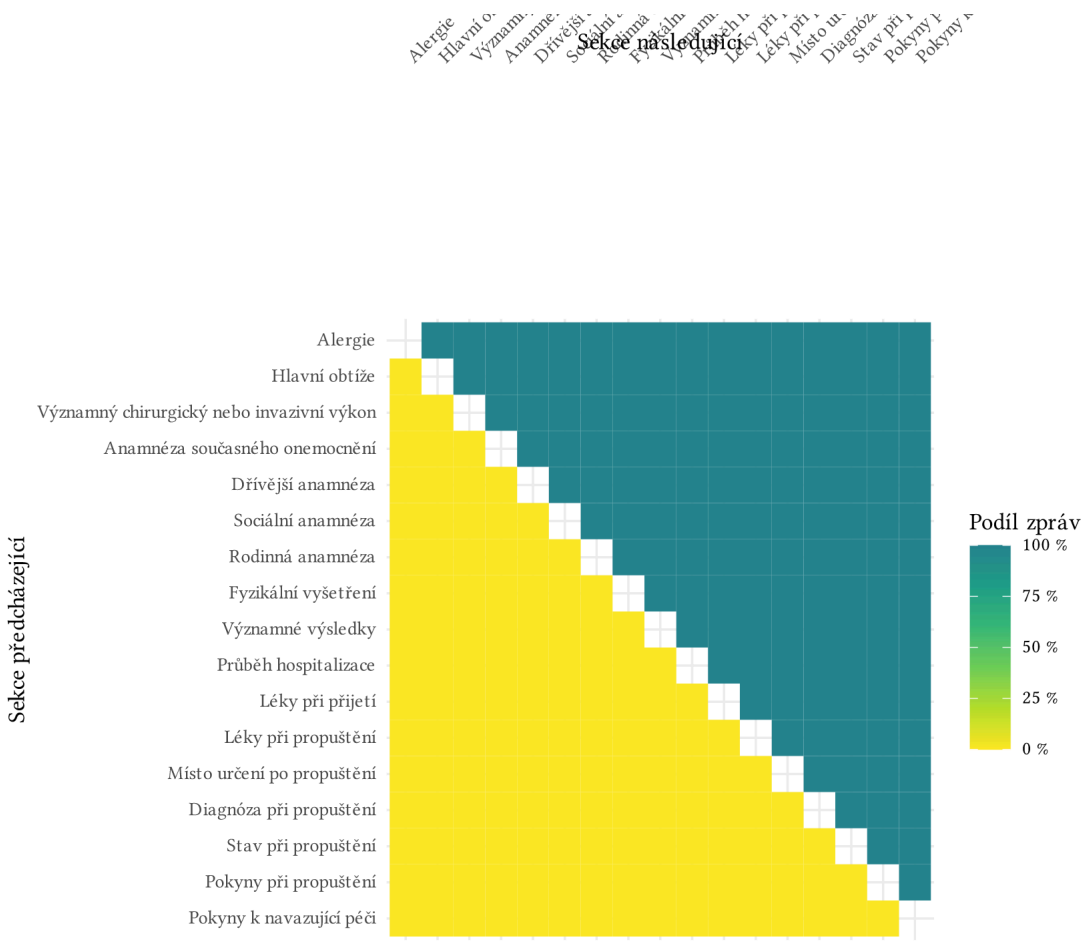
Tabulka 4: Sekce lexikonu v pořadí kostry: pokrytí, medián a IQR pozice mezi rozpoznanými sekcemi zprávy.

| Sekce | Popisek | V kostře | Pokrytí (%) | Medián pozice | IQR pozice |
|---|---|---|---|---|---|
| `allergies` | Alergie | ano | 100,0 | 0,0 | 0,0 |
| `chief_complaint` | Hlavní obtíže | ano | 96,6 | 1,0 | 0,0 |
| `major_procedure` | Významný chirurgický nebo invazivní výkon | ano | 99,6 | 2,0 | 0,0 |
| `history_of_present_illness` | Anamnéza současného onemocnění | ano | 98,4 | 3,0 | 0,0 |
| `past_medical_history` | Dřívější anamnéza | ano | 98,4 | 4,0 | 0,0 |
| `social_history` | Sociální anamnéza | ano | 97,3 | 5,0 | 0,0 |
| `family_history` | Rodinná anamnéza | ano | 96,9 | 6,0 | 0,0 |
| `physical_exam` | Fyzikální vyšetření | ano | 95,9 | 7,0 | 0,0 |
| `pertinent_results` | Významné výsledky | ano | 96,2 | 8,0 | 0,0 |
| `hospital_course` | Průběh hospitalizace | ano | 88,0 | 9,0 | 0,0 |
| `medications_on_admission` | Léky při přijetí | ano | 94,3 | 10,0 | 0,0 |
| `discharge_medications` | Léky při propuštění | ano | 98,0 | 11,0 | 1,0 |
| `discharge_disposition` | Místo určení po propuštění | ano | 98,7 | 12,0 | 1,0 |
| `discharge_diagnosis` | Diagnóza při propuštění | ano | 96,1 | 13,0 | 1,0 |
| `discharge_condition` | Stav při propuštění | ano | 99,7 | 14,0 | 1,0 |
| `discharge_instructions` | Pokyny při propuštění | ano | 99,2 | 15,0 | 1,0 |
| `followup_instructions` | Pokyny k navazující péči | ano | 98,3 | 16,0 | 1,0 |

*Zdroj:* text z `discharge` rozdělený parserem sekcí; sekce jsou hodnoty z `config/section_headers.json`.



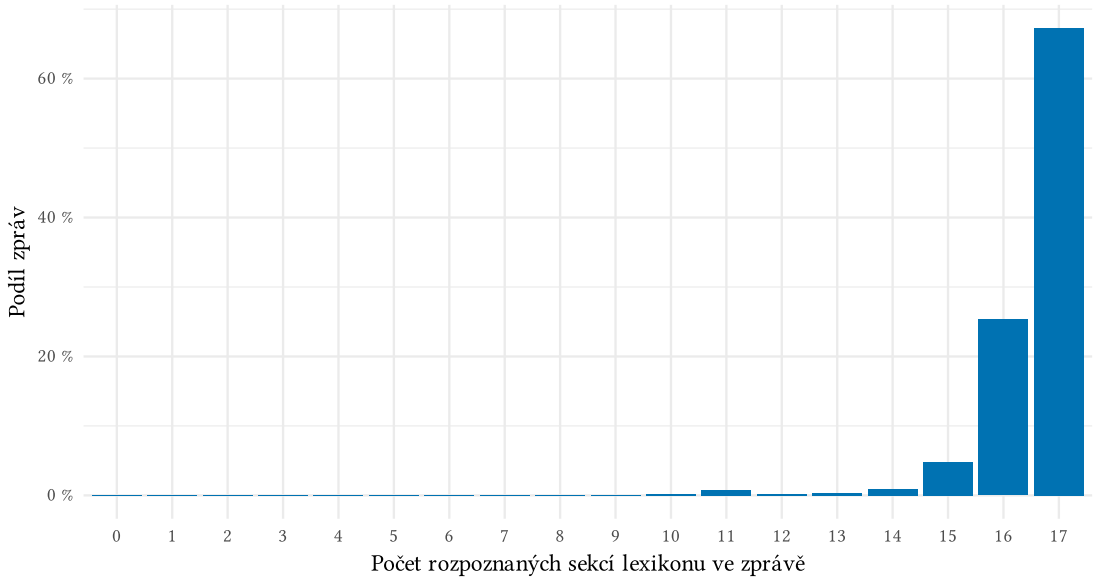

Obrázek 2: Medián a IQR pozice sekcí kostry mezi rozpoznanými sekcemi zprávy.




Obrázek 3: Matice precedence: podíl zpráv, kde sekce v řádku předchází sekci ve sloupci, mezi zprávami s oběma sekcemi.

## 4.2 Sekce na zprávu

Počet rozpoznaných sekcí lexikonu na zprávu: medián 17 (p10 16, p75 17, p95 17, maximum 17). Žádnou sekci nemá 22 zpráv (< 0,1 %).




Obrázek 4: Rozdělení počtu rozpoznaných sekcí lexikonu ve zprávě.

## 4.3 Délky těl sekcí

Nejdelší tělo má v mediánu sekce `hospital_course` (1 974 znaků), nejkratší sekce `discharge_disposition` (4 znaky). Text mimo sekce má medián 178 znaků. Tělo sekcí `social_history` a `followup_instructions` je u většiny zpráv jen maska `___` (u 96,9 % a 100,0 % zpráv se sekcí): obsah odstranila de-identifikace, délka proto nepopisuje text.

Tabulka 5 uvádí délky těl sekcí ve znacích v pořadí kostry a poslední řádek patří textu mimo sekce, sečtenému za zprávu.

Tabulka 5: Délky těl sekcí ve znacích: zprávy se sekcí, medián, 75. a 95. percentil a podíl těl, která jsou jen maska ___.

| Sekce | Popisek | Zprávy se sekcí | Medián | p75 | p95 | Jen maska (%) |
|---|---|---|---|---|---|---|
| allergies | Alergie | 331 478 | 43 | 46 | 88 | 1,4 |
| chief_complaint | Hlavní obtíže | 320 472 | 19 | 29 | 59 | 0,4 |
| major_procedure | Významný chirurgický nebo invazivní výkon | 330 244 | 13 | 44 | 159 | 0,1 |
| history_of_present_illness | Anamnéza současného onemocnění | 326 207 | 1 302 | 1 910 | 3 023 | < 0,1 |
| past_medical_history | Dřívější anamnéza | 326 449 | 249 | 493 | 1 383 | < 0,1 |
| social_history | Sociální anamnéza | 322 783 | 3 | 3 | 3 | 96,9 |
| family_history | Rodinná anamnéza | 321 464 | 65 | 126 | 303 | 0,3 |
| physical_exam | Fyzikální vyšetření | 318 005 | 834 | 1 302 | 2 207 | < 0,1 |
| pertinent_results | Významné výsledky | 319 149 | 1 671 | 3 108 | 6 876 | < 0,1 |
| hospital_course | Průběh hospitalizace | 291 741 | 1 974 | 3 111 | 5 615 | 0,0 |
| medications_on_admission | Léky při přijetí | 312 557 | 311 | 550 | 1 067 | < 0,1 |
| discharge_medications | Léky při propuštění | 324 856 | 717 | 1 072 | 1 782 | < 0,1 |
| discharge_disposition | Místo určení po propuštění | 327 295 | 4 | 33 | 33 | < 0,1 |
| discharge_diagnosis | Diagnóza při propuštění | 318 522 | 67 | 128 | 271 | 0,1 |
| discharge_condition | Stav při propuštění | 330 735 | 124 | 150 | 184 | < 0,1 |
| discharge_instructions | Pokyny při propuštění | 329 038 | 866 | 1 458 | 3 174 | < 0,1 |
| followup_instructions | Pokyny k navazující péči | 325 920 | 3 | 3 | 3 | 100,0 |
| other | Text mimo sekce | 331 604 | 178 | 180 | 187 | 0,0 |

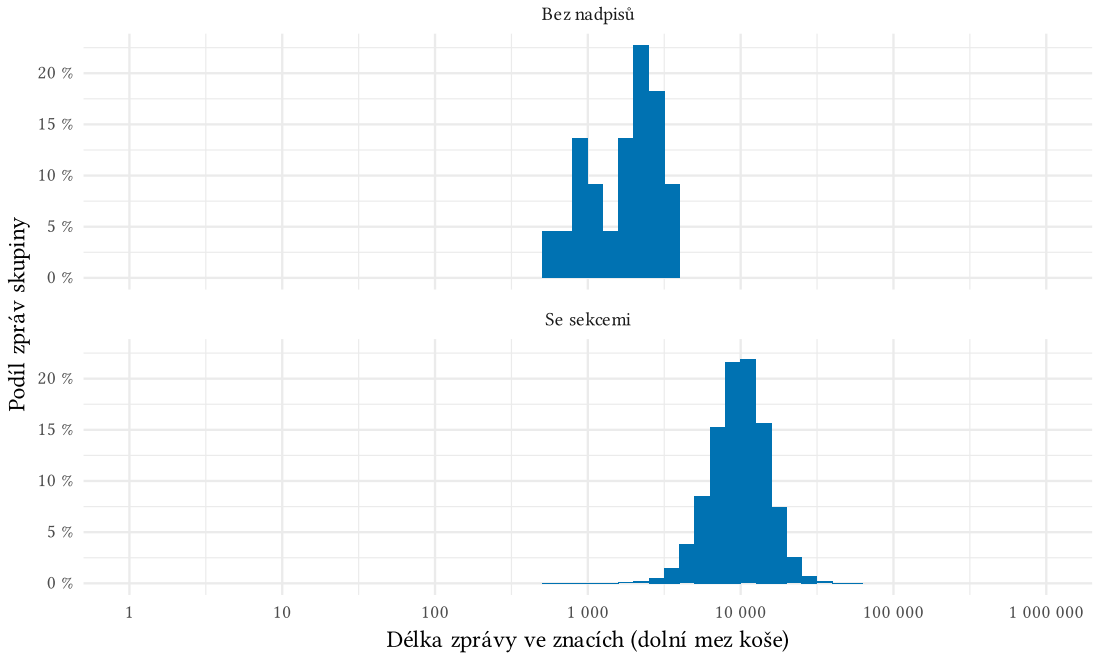
*Zdroj:* text z `discharge` rozdělený parserem sekcí; délka těla je bez okrajových bílých znaků.

## 4.4 Zprávy bez nadpisů

Bez nadpisů je 22 zpráv korpusu (< 0,1 %). Medián jejich délky je 1 874 znaků proti 9 849 znaků ve zprávách se sekcemi, p95 je 3 258 znaků proti 18 620 znaků.

Tabulka 6: Zprávy bez nadpisů a zprávy se sekcemi: počet, podíl a délky zprávy ve znacích.

| Skupina | Zprávy | Podíl (%) | Medián délky | p95 délky |
|---|---|---|---|---|
| Bez nadpisů | 22 | < 0,1 | 1 874 | 3 258 |
| Se sekcemi | 331 582 | 100,0 | 9 849 | 18 620 |




Obrázek 5: Rozdělení délky zpráv bez nadpisů a zpráv se sekcemi (podíl v rámci skupiny).

# 5 Shrnutí a rozhodnutí

Dokument ověřil seed lexikon sekcí na vstupním korpusu. Pro další práci z toho plyne:

- **Pokrytí.** Aspoň jednu sekci lexikonu má 100,0 % zpráv korpusu, žádnou hlavičku 0,0 %. Korpus obsahuje 99 417 unikátních hlaviček.
- **Kandidáti na doplnění.** Kandidáti na doplnění lexikonu (hlavičky mimo lexikon s pokrytím aspoň 50 %): `Mental Status` (77,7 %), `Level of Consciousness` (76,1 %), `Activity Status` (75,8 %), `HEENT` (65,1 %), `General` (50,8 %) a `Neuro` (50,6 %). Do lexikonu patří jen samostatná sekce šablony; pole a podnadpisy uvnitř jiné sekce sekcemi nejsou a lexikon je nepřebírá, i když je má většina zpráv.
- **Mrtvá synonyma.** Lexikon neobsahuje žádné mrtvé synonymum.
- **Opakování.** V aspoň 5 % zpráv se opakuje 1 synonymum: `Past Medical History` (10,0 %).
- **Pro parser.** Parser sekcí čte lexikon z `config/section_headers.json` a používá pravidlo hlavičky a normalizace z kapitoly 2; rozdělení zpráv je v kapitole 4.
- **Kostra.** Kostru šablony tvoří 17 sekcí s pokrytím aspoň 50 % (podle mediánu pozice): `allergies`, `chief_complaint`, `major_procedure`, `history_of_present_illness`, `past_medical_history`, `social_history`, `family_history`, `physical_exam`, `pertinent_results`, `hospital_course`, `medications_on_admission`, `discharge_medications`, `discharge_disposition`, `discharge_diagnosis`, `discharge_condition`, `discharge_instructions` a `followup_instructions`. Pořadí kostry dodržuje 99,6 % ze 331 558 zpráv s aspoň dvěma sekcemi kostry.
- **Strip D2.** Strip D2 odstraní sekci `discharge_diagnosis` u 318 522 zpráv korpusu (96,1 %) a tvoří 1,1 % jeho textu; ve zprávě se sekcí tvoří v mediánu 1,0 % textu zprávy.
- **Délky.** Nejdelší tělo má v mediánu sekce `hospital_course` (1 974 znaků), nejkratší sekce `discharge_disposition` (4 znaky). Text mimo sekce má medián 178 znaků. Tělo sekcí

`social_history` a `followup_instructions` je u většiny zpráv jen maska `___` (u 96,9 % a 100,0 % zpráv se sekcí): obsah odstranila de-identifikace, délka proto nepopisuje text.

- **Zprávy bez nadpisů.** Bez nadpisů je 22 zpráv korpusu (< 0,1 %). Medián jejich délky je 1 874 znaků proti 9 849 znaků ve zprávách se sekcemi, p95 je 3 258 znaků proti 18 620 znaků.

# 6 Omezení

Řádkově ukotvený výraz nevidí pole, které stojí na řádku za jiným polem, hlavičky bez dvojtečky ani hlavičky rozdělené na víc řádků. Pokrytí administrativních polí se proto neměří. Opakování je jen nepřímý signál falešné hranice: synonymum se může opakovat i ve zprávě, kde je každý výskyt skutečnou hlavičkou. Hranice 50 % pro kandidáty je popisná a nerozliší sekci šablony od pole, které má ve většině zpráv podsekce. Žebříček neukazuje hlavičky pod 1 % zpráv, takže vzácnou sekci šablony nemusí zveřejnit. Pozice počítá jen sekce lexikonu, takže pole a podnadpisy mimo lexikon pořadí nezkreslují, ale ani nepopisují. Pozice je pořadí mezi sekcemi, které zpráva má: chybí-li dřívější sekce, pozice všech pozdějších klesne o jedna, a IQR pozice proto měří i chybějící sekce, ne jen přeházené pořadí. Administrativní pole, které stojí až za první sekcí (například Attending za Allergies), parser počítá do těla předchozí sekce, takže tělo takové sekce je o toto pole delší. Strip odhaduje jednu sekci a nehlídá, že se její synonymum neobjeví jako hlavička uvnitř těla jiné sekce; parser bere první výskyt.

# Příloha A: provenance renderu

Tabulka 7 uvádí údaje, podle kterých lze render dohledat a zopakovat: revizi kódu, otisk zámku prostředí, zdroj dat a verze použitých nástrojů.

Tabulka 7: Provenance renderu.

| Položka | Hodnota |
|---|---|
| Revize kódu (commit) | 8dd759a835d336ce1c29aa62c847217d49dbe5bc |
| Necommitnuté změny | ne |
| Otisk pixi.lock (SHA-256) | 3b216e5b4bf1268d8009b79ea3150807df440a030a0fd0897287e6a22dd32504 |
| Zdroj dat | otisky CSV z config/mimic_tables.json |
| Otisk discharge.csv.gz (SHA-256) | 27bc552edaf81c2af322040cb7e8eb36417173b23c79405bb92fcf73bef2dbc5 |
| Otisk radiology.csv.gz (SHA-256) | 2c09bc76ee12d5f3b8f572deb7218fbaf3e59b32eccfdae14686e05ae099eebb |
| Otisk admissions.csv.gz (SHA-256) | a9584ed88e9ed664a2f66f86a5cf9fd175c8bb0af50e3b6115598b19e978384e |
| Otisk d_icd_diagnoses.csv.gz (SHA-256) | a81065bf45ccf74f589bec855bbb0a07b5c014907b34ff76fe20583a2c87cc79 |
| Otisk d_icd_procedures.csv.gz (SHA-256) | 2ac8afcb99fd16bce2e6c7ad445e3bd1dfd658e521823130ab08b66fdd3d6d4 |
| Otisk diagnoses_icd.csv.gz (SHA-256) | 47665a41b2a3ad990d6f314062d5bd6d29d467b0fd402dd94662044ec8b073d2 |
| Otisk omr.csv.gz (SHA-256) | 8280a8023203bddc6cc4419bd8cd253a015b8bc0bc53852ec92f98c7353f31e2 |
| Otisk patients.csv.gz (SHA-256) | 4c7507de7ecad8c5ba7647ea4d26018e88ff6672c5fc22ab59c2a5697d687cdd |
| Otisk pharmacy.csv.gz (SHA-256) | c9885721e4c968f0773145d7f6ba4d3cc3755d5600ee400ff95b1d3238053811 |
| Otisk prescriptions.csv.gz (SHA-256) | 0d8481c7d5d7c9ec2fea3fc543ddaaadb5a933cd22c7b9dda4289361e4d77199 |
| Otisk procedures_icd.csv.gz (SHA-256) | 3271397d0517131f84399b698cbb0c2f435aaab0f873a3806e13b097661596f7 |
| Otisk services.csv.gz (SHA-256) | 31c82ebee94e0c04d6966fbfec30579ec00f9c7816b80852f9580656e6183888 |
| Python | 3.13.16 |
| DuckDB | 1.5.6 |
| R | R version 4.5.3 (2026-03-11) |

# Literatura

Johnson, Alistair E. W., Lucas Bulgarelli, Lu Shen, et al. 2023. „MIMIC-IV, a freely accessible electronic health record dataset". *Scientific Data* 10 (1): 1. https://doi.org/10.1038/s41597-022--01899-x.

Johnson, Alistair, Lucas Bulgarelli, Tom Pollard, et al. 2024. *MIMIC-IV*. Verze 3.1. PhysioNet. https://doi.org/10.13026/kpb9-mt58.

Johnson, Alistair, Tom Pollard, Steven Horng, Leo Anthony Celi, a Roger Mark. 2023. *MIMIC--IV-Note: Deidentified free-text clinical notes*. Verze 2.2. PhysioNet. https://doi.org/10.13026/1n74-ne17.