Explorační analýza datové sady: hlavičky a lexikon sekcí

Martin Žoha

Abstrakt Dokument zjišťuje, které hlavičky začínají v propouštěcích zprávách vstupního korpusu oddíly, a ověřuje na nich seed lexikon sekcí šablony MIMIC. Počítá dokumentovou frekvenci všech hlaviček, pokrytí sekcí a synonym lexikonu, mrtvá synonyma a synonyma, která se ve zprávě opakují, což je signál falešné hranice sekce. Hlavičky mimo lexikon s vysokým pokrytím jmenuje jako kandidáty na doplnění, o kterých rozhodne autor.

Obsah

1 Úvod 1
2 Data a metody 2
3 Výsledky 3
3.1 Objevení hlaviček 3
3.2 Audit lexikonu 5
4 Shrnutí a rozhodnutí 7
5 Omezení 8
Příloha A: provenance renderu 8
Literatura 10

1 Úvod

Tento sešit je devátým z řady sešitů explorační analýzy a otevírá fázi zpracování struktury textu. Předchozí sešity popsaly korpus, diagnózy a jejich zmínky v textu. Propouštěcí zpráva MIMIC má ale vnitřní strukturu: je rozdělená na oddíly, jako jsou Chief Complaint, Hospital Course nebo Discharge Diagnosis. Parser sekcí, který vznikne později, bude oddíly rozpoznávat podle seznamu hlaviček, tedy lexikonu sekcí. Ten musí odpovídat datům, ne odhadu. Sešit si klade tyto cíle:

- zjistit, které hlavičky se v textu zpráv vyskytují a v kolika zprávách,
- změřit, jak lexikon sekcí šablony MIMIC tyto hlavičky pokrývá,
- najít mrtvá synonyma lexikonu a synonyma, která se ve zprávě opakují a nejspíš se používají i uvnitř těl sekcí,
- jmenovat hlavičky mimo lexikon, které má většina zpráv a které by do lexikonu mohly patřit.

Data pocházejí z MIMIC-IV (Johnson et al. 2024; A. E. W. Johnson et al. 2023) a MIMIC-IV-Note (A. Johnson et al. 2023), které podléhají smlouvě o užívání dat (DUA). Dokument proto

zveřejňuje jen agregáty. Řetězec hlavičky je popisek z dat, a zveřejní se proto jen hlavička, kterou má aspoň 1 % zpráv a nejméně 10 zpráv; podrobná pravidla jsou v kapitole 2.

Dokument je členěn takto. Kapitola 2 popisuje metody. Kapitola 3 uvádí výsledky. Kapitola 4 shrnuje rozhodnutí pro další práci a kapitola 5 jmenuje omezení. Příloha A dokumentuje provenance renderu.

2 Data a metody

Sešit čte propouštěcí zprávy (`discharge`). Dotazy provádí DuckDB nad parquetem a jsou v `eda/R/sections.R` s testy nad ručně vytvořenými tabulkami. Hlavičky se z textu vytáhnou jednou do dočasné tabulky a všechny další výpočty čtou jen ji.

Pojmy a jednotky jsou tyto:

- *populací* je vstupní korpus z pátého sešitu, tedy tentýž jako v sedmém a osmém sešitu: propouštěcí zprávy s kódem ICD, dlouhé aspoň 100 znaků a bez přesných duplicit. Vstupní korpus tvoří 331 604 zpráv. Jednotkou je zpráva a počítá se celý korpus, ne vzorek,
- *hlavička* je řádek, který po volitelném odsazení (mezery, tabulátory) začíná velkým písmenem a dalším písmenem, pokračuje až čtyřiceti sedmi znaky z množiny písmen, mezery, pomlčky, lomítka, ampersandu, závorek, apostrofu a tečky a končí dvojtečkou. Normalizovaný tvar zachyceného řetězce má aspoň 3 znaky. Výraz RE2 s režimem po řádcích (`(?m)`) je v konstantě `HEADER_PATTERN`. Číslice v něm nejsou, takže čas „10:30“ hlavičkou není. Hlavičku, která stojí na řádku za jiným polem, výraz nevidí,
- *normalizace* hlavičky je převod na malá písmena, sloučení bílých znaků do jedné mezery a odříznutí koncových mezer a teček. Je to jediná funkce (`normalized_sql`), kterou se normalizují hlavičky z textu i synonyma z lexikonu. Hlavička je v lexikonu nalezená, když se její normalizovaný tvar rovná normalizovanému synonymu; stejné pravidlo převezme parser sekcí. Zobrazuje se nejčastější původní zápis, při shodě první podle pořadí znaků (velká písmena před malými),
- *lexikon* je `config/section_headers.json`: 17 sekcí šablony MIMIC, každá s českým popiskem a celofrázovými synonymy (celkem 22 synonym), a seznam administrativních polí zprávy (8 polí), která nejsou sekcemi. Seed vychází z lexikonu předchozího projektu autora, jehož čísla byla předběžná. Oproti němu přidává sekce Major Surgical or Invasive Procedure a Discharge Disposition, zkratka HPI ze sekce Chief Complaint vypadla a vypouští podsekce (vitální funkce, chirurgická anamnéza) i generická jednoslovná synonyma, která by otevírala sekci uvnitř těla jiné sekce. Zkratky se nepřebírají, protože se na začátku řádku s dvojtečkou objevují i uvnitř těl. Synonyma jsou pravopisné varianty názvu sekce ze šablony MIMIC (člen, číslo, přípona -ation, pomlčka, mezera); vyřazeny jsou podnadpisy uvnitř sekcí (například Primary a Secondary Diagnosis, Hospital Course by Problem), alternativní názvy a zkratky. Čísla v tomto sešitu pocházejí z dat tohoto projektu,
- *dokumentová frekvence* hlavičky je počet zpráv, v nichž se vyskytuje aspoň jednou; podíl je vztažený k počtu zpráv korpusu. *Opakování* sekce je počet zpráv s aspoň dvěma výskyty kteréhokoli jejího synonyma; opakování synonyma je počet zpráv s aspoň dvěma výskyty téhož synonyma. Synonymum, které se ve zprávě objeví dvakrát, se nejspíš používá i uvnitř těla, a je tedy kandidátem na falešnou hranici sekce,
- *potlačení*: řetězec hlavičky je popisek z dat. Zveřejní se jen hlavička, kterou má aspoň 1 % zpráv korpusu a nejméně 10 zpráv. Samotný práh 10 zpráv nestačí, protože výraz zachytí i úlomky vět končící dvojtečkou. Žebříček uvádí nejvýše 40 hlaviček. Synonyma a klíče

sekcí pocházejí z konfigurace, ne z dat, a zveřejňují se všechna včetně nuly. Počty zpráv jsou metrika textu a nepotlačují se; počet unikátních hlaviček je číslo bez popisku,
- *rozhodnutí sešitu* jsou texty generované z dat: kandidáti na doplnění (hlavičky mimo lexikon s pokrytím aspoň 50 %), mrtvá synonyma a synonyma s opakováním aspoň v 5 % zpráv. Hranice 50 % je popisná, ne brána: odděluje „většina zpráv“ od podsekcí, o zařazení rozhoduje autor.

3 Výsledky

3.1 Objevení hlaviček

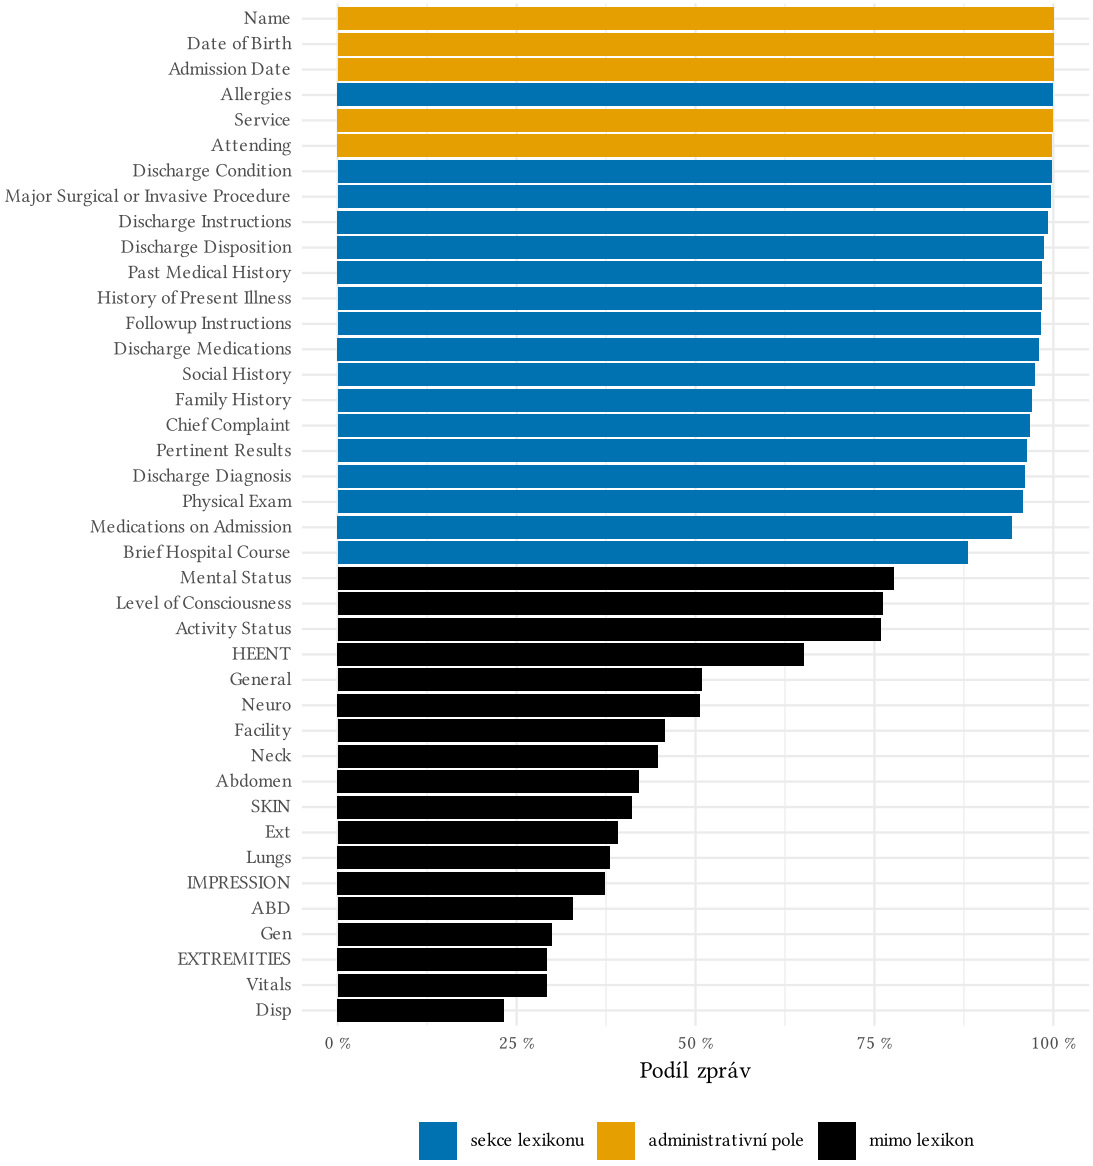
Aspoň jednu sekci lexikonu má 100,0 % zpráv korpusu, žádnou hlavičku 0,0 %. Korpus obsahuje 99 417 unikátních hlaviček.

Tabulka 1 a Obrázek 1 uvádějí hlavičky podle dokumentové frekvence a jejich zařazení: do sekce lexikonu, mezi administrativní pole, nebo mimo lexikon.

Tabulka 1: Nejčastější hlavičky vstupního korpusu podle dokumentové frekvence a jejich zařazení.

Hlavička	Zařazení	Zprávy	Podíl (%)
Name	administrativní pole	331 603	100,0
Date of Birth	administrativní pole	331 598	100,0
Admission Date	administrativní pole	331 593	100,0
Allergies	Alergie	331 478	100,0
Service	administrativní pole	331 392	99,9
Attending	administrativní pole	330 917	99,8
Discharge Condition	Stav při propuštění	330 735	99,7
Major Surgical or Invasive Procedure	Významný chirurgický nebo invazivní výkon	330 244	99,6
Discharge Instructions	Pokyny při propuštění	329 038	99,2
Discharge Disposition	Místo určení po propuštění	327 295	98,7
Past Medical History	Dřívější anamnéza	326 449	98,4
History of Present Illness	Anamnéza současného onemocnění	326 206	98,4
Followup Instructions	Pokyny k navazující péči	325 605	98,2
Discharge Medications	Léky při propuštění	324 856	98,0
Social History	Sociální anamnéza	322 783	97,3
Family History	Rodinná anamnéza	321 464	96,9
Chief Complaint	Hlavní obtíže	320 472	96,6
Pertinent Results	Významné výsledky	319 149	96,2
Discharge Diagnosis	Diagnóza při propuštění	318 168	95,9
Physical Exam	Fyzikální vyšetření	317 360	95,7
Medications on Admission	Léky při přijetí	312 557	94,3
Brief Hospital Course	Průběh hospitalizace	291 741	88,0
Mental Status	mimo lexikon	257 535	77,7
Level of Consciousness	mimo lexikon	252 410	76,1
Activity Status	mimo lexikon	251 520	75,8
HEENT	mimo lexikon	215 963	65,1
General	mimo lexikon	168 607	50,8
Neuro	mimo lexikon	167 760	50,6
Facility	mimo lexikon	151 512	45,7
Neck	mimo lexikon	148 144	44,7
Abdomen	mimo lexikon	139 566	42,1
SKIN	mimo lexikon	136 483	41,2
[illegible]	mimo lexikon	[illegible]	[illegible]

Zdroj: text z `discharge`; zařazení podle `config/section_headers.json`.



Obrázek 1: Pokrytí nejčastějších hlaviček obarvené podle zařazení.

3.2 Audit lexikonu

Tabulka 2 uvádí, v kolika zprávách se vyskytuje hlavička každé sekce lexikonu a v kolika se opakuje; Tabulka 3 totéž pro jednotlivá synonyma včetně mrtvých.

Tabulka 2: Sekce lexikonu: zprávy s hlavičkou sekce a zprávy, kde se hlavička sekce opakuje.

Sekce	Popisek	Zprávy s hlavičkou (%)	Zprávy s opakováním (%)
allergies	Alergie	100,0	1,3
chief_complaint	Hlavní obtíže	96,6	0,5
major_procedure	Významný chirurgický nebo invazivní výkon	99,6	0,0
history_of_present_illness	Anamnéza současného onemocnění	98,4	1,2
past_medical_history	Dřívější anamnéza	98,4	10,0
social_history	Sociální anamnéza	97,3	0,7
family_history	Rodinná anamnéza	96,9	2,1
physical_exam	Fyzikální vyšetření	95,9	6,8
pertinent_results	Významné výsledky	96,2	0,3
hospital_course	Průběh hospitalizace	88,0	0,5
medications_on_admission	Léky při přijetí	94,3	0,1
discharge_medications	Léky při propuštění	98,0	0,0
discharge_disposition	Místo určení po propuštění	98,7	0,0
discharge_diagnosis	Diagnóza při propuštění	96,1	0,0
discharge_condition	Stav při propuštění	99,7	0,2
discharge_instructions	Pokyny při propuštění	99,2	0,8
followup_instructions	Pokyny k navazující péči	98,3	0,0

Zdroj: text z `discharge`; sekce a synonyma jsou hodnoty z `config/section_headers.json`, ne z dat.

Tabulka 3: Synonyma lexikonu: zprávy se synonymem a zprávy, kde se synonymum opakuje.

Sekce	Synonymum	Zprávy se synonymem (%)	Zprávy s opakováním (%)
allergies	Allergies	100,0	1,3
chief_complaint	Chief Complaint	96,6	0,5
major_procedure	Major Surgical or Invasive Procedure	99,6	0,0
history_of_present_illness	History of Present Illness	98,4	1,2
history_of_present_illness	History of the Present Illness	0,0	0,0
past_medical_history	Past Medical History	98,4	10,0
social_history	Social History	97,3	0,7
family_history	Family History	96,9	2,1
physical_exam	Physical Exam	95,7	5,0
physical_exam	Physical Examination	2,0	0,1
pertinent_results	Pertinent Results	96,2	0,3
hospital_course	Brief Hospital Course	88,0	0,5
medications_on_admission	Medications on Admission	94,3	0,1
discharge_medications	Discharge Medications	98,0	0,0
discharge_disposition	Discharge Disposition	98,7	0,0
discharge_diagnosis	Discharge Diagnosis	95,9	0,0
discharge_diagnosis	Discharge Diagnoses	0,1	0,0
discharge_condition	Discharge Condition	99,7	0,2
discharge_instructions	Discharge Instructions	99,2	0,8
followup_instructions	Followup Instructions	98,2	0,0
followup_instructions	Follow-up Instructions	0,1	0,0
followup_instructions	Follow up Instructions	0,0	0,0

Lexikon neobsahuje žádné mrtvé synonymum. V aspoň 5 % zpráv se opakuje 1 synonymum: `Past Medical History` (10,0 %).

4 Shrnutí a rozhodnutí

Dokument ověřil seed lexikon sekcí na vstupním korpusu. Pro další práci z toho plyne:

- **Pokrytí.** Aspoň jednu sekci lexikonu má 100,0 % zpráv korpusu, žádnou hlavičku 0,0 %. Korpus obsahuje 99 417 unikátních hlaviček.
- **Kandidáti na doplnění.** Kandidáti na doplnění lexikonu (hlavičky mimo lexikon s pokrytím aspoň 50 %): `Mental Status` (77,7 %), `Level of Consciousness` (76,1 %), `Activity Status` (75,8 %), `HEENT` (65,1 %), `General` (50,8 %) a `Neuro` (50,6 %). Do lexikonu patří jen

samostatná sekce šablony; pole a podnadpisy uvnitř jiné sekce sekcemi nejsou a lexikon je nepřebírá, i když je má většina zpráv.
- **Mrtvá synonyma.** Lexikon neobsahuje žádné mrtvé synonymum.
- **Opakování.** V aspoň 5 % zpráv se opakuje 1 synonymum: `Past Medical History` (10,0 %).
- **Pro parser.** Parser sekcí čte lexikon z `config/section_headers.json` a převezme pravidlo hlavičky a normalizace z kapitoly 2.

5 Omezení

Řádkově ukotvený výraz nevidí pole, které stojí na řádku za jiným polem, hlavičky bez dvojtečky ani hlavičky rozdělené na víc řádků. Pokrytí administrativních polí se proto neměří. Opakování je jen nepřímý signál falešné hranice: synonymum se může opakovat i ve zprávě, kde je každý výskyt skutečnou hlavičkou. Hranice 50 % pro kandidáty je popisná a nerozliší sekci šablony od pole, které má ve většině zpráv podsekce. Žebříček neukazuje hlavičky pod 1 % zpráv, takže vzácnou sekci šablony nemusí zveřejnit.

Příloha A: provenance renderu

Tabulka 4 uvádí údaje, podle kterých lze render dohledat a zopakovat: revizi kódu, otisk zámku prostředí, zdroj dat a verze použitých nástrojů.

Tabulka 4: Provenance renderu.

Položka	Hodnota
Revize kódu (commit)	0dd71a9425ec71eaad44ad6ec508584f85d50d5c
Necommitnuté změny	ne
Otisk pixi.lock (SHA-256)	3b216e5b4bf1268d8009b79ea3150807df440a030a0fd0897287e6a22dd32504
Zdroj dat	otisky CSV z config/mimic_tables.json
Otisk discharge.csv.gz (SHA-256)	27bc552edaf81c2af322040cb7e8eb36417173b23c79405bb92fcf73bef2dbc5
Otisk radiology.csv.gz (SHA-256)	2c09bc76ee12d5f3b8f572deb7218fbaf3e59b32eccfdae14686e05ae099eebb
Otisk admissions.csv.gz (SHA-256)	a9584ed88e9ed664a2f66f86a5cf9fd175c8bb0af50e3b6115598b19e978384e
Otisk d_icd_diagnoses.csv.gz (SHA-256)	a81065bf45ccf74f589bec855bbb0a07b5c014907b34ff76fe20583a2c87cc79
Otisk d_icd_procedures.csv.gz (SHA-256)	2ac8afcb99fd16bce2e6c7ad445e3bd1dfd658e52182313 0ab08b66fdd3d6d4
Otisk diagnoses_icd.csv.gz (SHA-256)	47665a41b2a3ad990d6f314062d5bd6d29d467b0fd402dd94662044ec8b073d2
Otisk omr.csv.gz (SHA-256)	8280a8023203bddc6cc4419bd8cd253a015b8bc0bc53852ec92f98c7353f31e2
Otisk patients.csv.gz (SHA-256)	4c7507de7ecad8c5ba7647ea4d26018e88ff6672c5fc22ab59c2a5697d687cdd
Otisk pharmacy.csv.gz (SHA-256)	c9885721e4c968f0773145d7f6ba4d3cc3755d5600ee400ff95b1d3238053811
Otisk prescriptions.csv.gz (SHA-256)	0d8481c7d5d7c9ec2fea3fc543ddaaadb5a933cd22c7b9dda4289361e4d77199
Otisk procedures_icd.csv.gz (SHA-256)	3271397d0517131f84399b698cbb0c2f435aaab0f873a3806e13b097661596f7
Otisk services.csv.gz (SHA-256)	31c82ebee94e0c04d6966fbfec30579ec00f9c7816b80852f9580656e6183888
Python	3.13.16
DuckDB	1.5.6
R	R version 4.5.3 (2026-03-11)

Literatura

Johnson, Alistair E. W., Lucas Bulgarelli, Lu Shen, et al. 2023. „MIMIC-IV, a freely accessible electronic health record dataset". *Scientific Data* 10 (1): 1. https://doi.org/10.1038/s41597-022--01899-x.

Johnson, Alistair, Lucas Bulgarelli, Tom Pollard, et al. 2024. *MIMIC-IV*. Verze 3.1. PhysioNet. https://doi.org/10.13026/kpb9-mt58.

Johnson, Alistair, Tom Pollard, Steven Horng, Leo Anthony Celi, a Roger Mark. 2023. *MIMIC--IV-Note: Deidentified free-text clinical notes*. Verze 2.2. PhysioNet. https://doi.org/10.13026/1n74-ne17.