Explorační analýza datové sady: hlavičky, lexikon a kostra sekcí

Martin Žoha

Abstrakt Dokument zjišťuje, které hlavičky začínají v propouštěcích zprávách vstupního korpusu oddíly, a ověřuje na nich seed lexikon sekcí šablony MIMIC. Počítá dokumentovou frekvenci všech hlaviček, pokrytí sekcí a synonym lexikonu, mrtvá synonyma a synonyma, která se ve zprávě opakují, což je signál falešné hranice sekce. Hlavičky mimo lexikon s vysokým pokrytím jmenuje jako kandidáty na doplnění, o kterých rozhodne autor. Zprávy pak rozdělí parserem sekcí a zjistí kostru šablony (pořadí sekcí, jejich pokrytí a konzistenci pořadí), počet sekcí na zprávu, délky těl sekcí ve znacích, podíl textu, který odstraní vystřižení sekce Discharge Diagnosis, a zprávy bez nadpisů. Nakonec spočítá nejčastější tokeny, bigramy a trigramy těl sekcí v celém korpusu i po sekcích kostry, aby ukázal fráze šablony, které mají skoro všechny zprávy. Správnost hranic parseru ověří na sekci Brief Hospital Course proti referenčnímu datasetu MIMIC-IV-Ext-BHC (podíl shody a rozpad neshod) a změří, v kolika zprávách zůstane po stripu hlavička diagnostické sekce. Změří také dopad předzpracování TF-IDF (normalizace textu a rozvinutí zkratek diagnóz) na velikost slovníku a délku zprávy v tokenech a u zkratek diagnóz podíl zpráv bez kódu diagnózy.

Obsah

1 Úvod 2
2 Data a metody 2
3 Výsledky 6
3.1 Objevení hlaviček 6
3.2 Audit lexikonu 8
4 Segmentace a kostra šablony 10
4.1 Kostra šablony 10
4.2 Sekce na zprávu 13
4.3 Délky těl sekcí 14
4.4 Zprávy bez nadpisů 15
4.5 Tokeny a n-gramy 16
5 Validace parseru proti MIMIC-IV-Ext-BHC 19
5.1 Zbytek po stripu 23
6 Předzpracování pro TF-IDF 23
7 Shrnutí a rozhodnutí 24
8 Omezení 26
Příloha A: provenance renderu 27

Literatura 29

1 Úvod

Tento sešit je devátým z řady sešitů explorační analýzy a otevírá fázi zpracování struktury textu. Předchozí sešity popsaly korpus, diagnózy a jejich zmínky v textu. Propouštěcí zpráva MIMIC má ale vnitřní strukturu: je rozdělená na oddíly, jako jsou Chief Complaint, Hospital Course nebo Discharge Diagnosis. Parser sekcí rozpoznává oddíly podle seznamu hlaviček, tedy lexikonu sekcí (kapitola 4 používá parser k rozdělení zpráv). Lexikon musí odpovídat datům, ne odhadu. Sešit si klade tyto cíle:

- zjistit, které hlavičky se v textu zpráv vyskytují a v kolika zprávách,
- změřit, jak lexikon sekcí šablony MIMIC tyto hlavičky pokrývá,
- najít mrtvá synonyma lexikonu a synonyma, která se ve zprávě opakují a nejspíš se používají i uvnitř těl sekcí,
- jmenovat hlavičky mimo lexikon, které má většina zpráv a které by do lexikonu mohly patřit,
- rozdělit zprávy na sekce a popsat kostru šablony: pořadí sekcí, jejich pokrytí a konzistenci pořadí,
- změřit počet sekcí na zprávu a délky těl sekcí ve znacích,
- zjistit, kolik zpráv má sekci Discharge Diagnosis a jaký podíl textu odstraní její vystřižení (ablace D2),
- popsat zprávy bez jediného nadpisu,
- změřit, v kolika zprávách zůstane po stripu D2 hlavička diagnostické sekce i s diagnózou pod ní,
- ověřit hranice sekce Brief Hospital Course proti referenčnímu datasetu MIMIC-IV-Ext-BHC,
- spočítat nejčastější tokeny a n-gramy těl sekcí (celkem i po sekcích kostry) a najít fráze šablony, které nic nerozlišují,
- změřit, o kolik předzpracování TF-IDF (normalizace textu a rozvinutí zkratek diagnóz) zmenší slovník a změní délku zprávy v tokenech, a u zkratek diagnóz podíl zpráv bez kódu diagnózy (zkratka AF je víceznačná).

Data pocházejí z MIMIC-IV (Johnson et al. 2024; A. E. W. Johnson et al. 2023), MIMIC-IV-Note (A. Johnson et al. 2023) a MIMIC-IV-Ext-BHC (Aali et al. 2025, 2024), které podléhají smlouvě o užívání dat (DUA). Dokument proto zveřejňuje jen agregáty. Řetězec hlavičky je popisek z dat, a zveřejní se proto jen hlavička, kterou má aspoň 1 % zpráv a nejméně 10 zpráv; podrobná pravidla jsou v kapitole 2.

Dokument je členěn takto. Kapitola 2 popisuje metody. Kapitola 3 uvádí výsledky hlaviček a lexikonu, kapitola 4 výsledky rozdělení zpráv na sekce a frekvenci tokenů a n-gramů a kapitola 5 validaci parseru proti MIMIC-IV-Ext-BHC a kapitola 6 dopad předzpracování TF-IDF. Kapitola 7 shrnuje rozhodnutí pro další práci a kapitola 8 jmenuje omezení. Příloha A dokumentuje provenance renderu.

2 Data a metody

Sešit čte propouštěcí zprávy (`discharge`). Dotazy provádí DuckDB nad parquetem a jsou v `eda/R/sections.R` (hlavičky a lexikon) a `eda/R/segments.R` (segmentace a kostra) s testy nad ručně vytvořenými tabulkami. Hlavičky se z textu vytáhnou jednou do dočasné tabulky

a audit lexikonu čte jen ji. Segmentaci zprávy na sekce dělá parser sekcí, ne dotaz: kapitola o segmentaci čte druhou dočasnou tabulku, kterou naplní parser.

Pojmy a jednotky jsou tyto:

- *populací* je vstupní korpus z pátého sešitu, tedy tentýž jako v sedmém a osmém sešitu: propouštěcí zprávy s kódem ICD, dlouhé aspoň 100 znaků a bez přesných duplicit. Vstupní korpus tvoří 331 604 zpráv. Jednotkou je zpráva a počítá se celý korpus, ne vzorek,
- *hlavička* je řádek, který po volitelném odsazení (mezery, tabulátory) začíná velkým písmenem a dalším písmenem, pokračuje až čtyřiceti sedmi znaky z množiny písmen, mezery, pomlčky, lomítka, ampersandu, závorek, apostrofu a tečky a končí dvojtečkou. Normalizovaný tvar zachyceného řetězce má aspoň 3 znaky. Výraz RE2 s režimem po řádcích (`(?m)`) je v konstantě `HEADER_PATTERN`. Číslice v něm nejsou, takže čas „10:30“ hlavičkou není. Hlavičku, která stojí na řádku za jiným polem, výraz nevidí,
- *normalizace* hlavičky je převod na malá písmena, sloučení bílých znaků do jedné mezery a odříznutí koncových mezer a teček. Je to jediná funkce (`normalized_sql`), kterou se normalizují hlavičky z textu i synonyma z lexikonu. Hlavička je v lexikonu nalezená, když se její normalizovaný tvar rovná normalizovanému synonymu; stejné pravidlo používá parser sekcí (`domain/section_headers.py`), který rozděluje zprávy v kapitole 4. Zobrazuje se nejčastější původní zápis, při shodě první podle pořadí znaků (velká písmena před malými),
- *lexikon* je `config/section_headers.json`: 17 sekcí šablony MIMIC, každá s českým popiskem a celofrázovými synonymy (celkem 22 synonym), a seznam administrativních polí zprávy (8 polí), která nejsou sekcemi. Seed vychází z lexikonu předchozího projektu autora, jehož čísla byla předběžná. Oproti němu přidává sekce Major Surgical or Invasive Procedure a Discharge Disposition, zkratka HPI ze sekce Chief Complaint vypadla a vypouští podsekce (vitální funkce, chirurgická anamnéza) i generická jednoslovná synonyma, která by otevírala sekci uvnitř těla jiné sekce. Zkratky se nepřebírají, protože se na začátku řádku s dvojtečkou objevují i uvnitř těl. Synonyma jsou pravopisné varianty názvu sekce ze šablony MIMIC (člen, číslo, přípona -ation, pomlčka, mezera); vyřazeny jsou podnadpisy uvnitř sekcí (například Primary a Secondary Diagnosis, Hospital Course by Problem), alternativní názvy a zkratky. Čísla v tomto sešitu pocházejí z dat tohoto projektu,
- *dokumentová frekvence* hlavičky je počet zpráv, v nichž se vyskytuje aspoň jednou; podíl je vztažený k počtu zpráv korpusu. *Opakování* sekce je počet zpráv s aspoň dvěma výskyty kteréhokoli jejího synonyma; opakování synonyma je počet zpráv s aspoň dvěma výskyty téhož synonyma. Synonymum, které se ve zprávě objeví dvakrát, se nejspíš používá i uvnitř těla, a je tedy kandidátem na falešnou hranici sekce,
- *práh popisků hlaviček*: řetězec hlavičky je popisek z dat. Zveřejní se jen hlavička, kterou má aspoň 1 % zpráv korpusu a nejméně 10 zpráv. Samotný práh 10 zpráv nestačí, protože výraz zachytí i úlomky vět končící dvojtečkou. Žebříček uvádí nejvýše 40 hlaviček. Synonyma a klíče sekcí pocházejí z konfigurace, ne z dat, a zveřejňují se všechna včetně nuly. Počty zpráv jsou metrika textu a uvádějí se přesně; počet unikátních hlaviček je číslo bez popisku,
- *rozhodnutí sešitu* jsou texty generované z dat: kandidáti na doplnění (hlavičky mimo lexikon s pokrytím aspoň 50 %), mrtvá synonyma a synonyma s opakováním aspoň v 5 % zpráv. Hranice 50 % je popisná, ne brána: odděluje „většina zpráv“ od podsekcí, o zařazení rozhoduje autor,
- *segmentace*: zprávu rozdělí parser sekcí (`split_sections` v `domain/section_headers.py`) voláním z R přes reticulate po dávkách 2 000 zpráv; sešit pravidlo hranice nekopíruje.

Hranicí je první výskyt sekce v textu, opakovaná hlavička je jen text těla. Část `other` je text před první hlavičkou a text od administrativního pole lexikonu do další hlavičky, protože šablona MIMIC má pole Attending za sekcí Allergies; hranicí je první výskyt pole na začátku řádku a sousední části `other` se slijí. Hlavičku sekce tvoří text od začátku řádku po dvojtečku, tělo je text do další hlavičky nebo administrativního pole. *Pozice* sekce je její pořadí mezi sekcemi lexikonu ve zprávě od 0 (`other` se nepočítá). `span_chars` je délka hlavičky a těla dohromady, takže součet přes zprávu je délka zprávy. `body_chars` je délka těla bez okrajových bílých znaků. Tělo, které je po ořezu jen maska de-identifikace `___`, nese příznak; jeho délka (3 znaky) nepopisuje obsah, protože ten odstranila de-identifikace. Do R přicházejí jen tyto délky, příznaky, pozice a offsety těla v textu zprávy (`body_start`, `body_end`, v code pointech), ne text,

- *kostra šablony* jsou sekce lexikonu, které má aspoň 50 % zpráv, seřazené podle mediánu pozice (při shodě podle pokrytí sestupně a pak podle pořadí v lexikonu). *Konzistence pořadí* je podíl zpráv s aspoň dvěma sekcemi kostry, v nichž sekce jdou v pořadí kostry. *Matice precedence* uvádí pro dvojici sekcí kostry podíl zpráv, kde řádek předchází sloupec, mezi zprávami, které mají obě sekce,
- *strip D2* je vystřižení diagnostických sekcí ze zprávy. Odstraní sekce, které lexikon označuje příznakem `diagnostic` (dnes `discharge_diagnosis`). Podíl odstraněného textu je součet `span_chars` těchto sekcí lomený součtem délek zpráv. Příznak čte sešit z téhož lexikonu jako funkce stripu `strip_diagnostic_sections` (`domain/section_headers.py`) a sekce dělí týmž parserem, takže podíl odpovídá tomu, co strip odstraní,
- *zprávy bez nadpisů* jsou zprávy, jejichž jedinou částí je `other`. Délka zprávy je součet `span_chars`,
- *zbytek po stripu*: strip vystřihne jen první výskyt diagnostické sekce, takže opakovaná hlavička `Discharge Diagnosis:` v těle jiné sekce zůstane i s diagnózou pod ní. Zbytek je zpráva s diagnostickou sekcí, v jejíž ponechané části (hlavička a tělo jiné sekce, vyříznuté od začátku části) stojí řádek hlavičky, jehož normalizovaný tvar je synonymem diagnostické sekce. Jmenovatelem jsou zprávy s diagnostickou sekcí. Sloupec „opakování“ v tabulce sekcí číslo přeceňuje, protože počítá i druhý výskyt uvnitř těla samotné diagnostické sekce, který strip odstraní spolu s ní,
- *validace proti BHC*: MIMIC-IV-Ext-BHC (Aali et al. 2025, 2024) obsahuje pro zprávy MIMIC-IV-Note sekci Brief Hospital Course vytaženou regulárním výrazem autorů datasetu (`target`). Dataset vyřadil zprávy bez sekce Sex a s BHC kratší než 100 znaků; výraz sám zveřejněný není, a porovnává se proto s jeho výstupem. Populací je průnik vstupního korpusu a BHC přes `note_id`; zprávy jen v BHC a jen v korpusu se uvádějí zvlášť a nejsou chybou parseru. Porovnává se úsek hlavička + tělo sekce `hospital_course` (začátek úseku je `body_end - span_chars`) s `target` po čištění ze skriptu `clin-bhc-summ` (`bhc_clean_sql`): sloučit mezery, odstranit čtyři zápisy hlavičky, zalomení na mezeru, sloučit bílé znaky (výčet Unicode bílých znaků, protože `\s` v RE2 je jen ASCII). Čistí se jen náš úsek, protože `target` už čištěním prošel; druhé čištění by slité řádky odstranilo. Obě strany se oříznou o okrajové mezery, což je odchylka od jejich skriptu, kompenzující mezeru po hlavičce a neznámý konec jejich výrazu. Že `target` čištěním prošel, kapitola ověřuje jen zčásti: mezi spárovanými zprávami počítá targety, které mají dvě mezery za sebou nebo jiný bílý znak než mezeru, tedy ty, které nemohly projít kroky sloučení mezer, zalomení a sloučení bílých znaků. Odstranění hlaviček takhle přesně ověřit nejde. Kategorie jsou disjunktní v pořadí kontrol: sekce nenalezena, shoda, reference obsahuje celou naši následující sekci (náš úsek je

vlastní prefix `target` a zbytek `target` začíná celou vyčištěnou a oříznutou částí, která v naší zprávě následuje hned za `hospital_course`; administrativní pole `other` se nebere, protože kategorie mluví o sekci lexikonu a pole sekcí není, i když ho reference obsahuje celé), náš konec dřív (náš úsek je vlastní prefix), náš konec později (prefix je `target`), náš začátek dřív (`target` leží uvnitř našeho úseku), náš začátek později (náš úsek leží uvnitř `target`) a jiná neshoda. Kategorie „náš začátek dřív“ zachytí falešný první výskyt hlavičky jen tehdy, když mezi ním a skutečnou hlavičkou nestojí jiná hlavička lexikonu; jinak úsek skončí před skutečným BHC a zpráva padne do jiné neshody, takže kategorie je dolní odhad četnosti falešného prvního výskytu. Medián rozdílu délky (znaky po čištění) se uvádí u kategorií, kde má smysl. Kategorie „reference obsahuje celou naši následující sekci“ popisuje vztah k referenci, ne správnost hranic: tutéž podmínku splní skutečná sekce, kterou reference polkla, i podnadpis uvnitř Brief Hospital Course. Rozliší je tabulka příčin pro zprávy obou kategorií, kde je náš úsek vlastním prefixem `target`. Měří čtyři vyčerpávající skupiny: obsah celé následující sekce v referenci, polohu sekce Medications on Admission (chybí, před Brief Hospital Course, sama úsek uřízla, za hlavičkou, která ho uřízla), zápis hlavičky, která úsek uřízla (synonymum lexikonu včetně velikosti písmen, verzálky, jiný zápis, administrativní pole, Brief Hospital Course je poslední částí zprávy), a opakování hlavičky téže sekce. Opakování se hledá od začátku následující části (ne až za jejím koncem, aby se našla skutečná hlavička v těle téže části) a bere se jako aspoň dvě shody s normalizovanými synonymy sekce, protože první shoda je hlavička části samotná. Falešný podnadpis uvnitř Brief Hospital Course by se projevil opakující se hlavičkou, skutečná sekce polknutá referencí hlavičkou jedinou. Doplňkové skupiny se do 100 % nesčítají: souběh měří průnik vlastností, který marginály neukážou (podpis polknuté jediné sekce: reference obsahuje celou sekci, Medications on Admission chybí a hlavička se neopakuje; podpis podnadpisu: hlavička se opakuje nebo Medications on Admission stojí za uříznutím), a odsazení počítá hlavičky odsazené mezerou nebo tabulátorem. Hlavička se bere bez úvodních mezer a tabulátorů a bez dvojtečky a porovná se se synonymy dané sekce rovností řetězců (včetně velikosti písmen),

- *tokeny a n-gramy*: text těla vyřízne DuckDB z `discharge` podle offsetů z parseru, takže pravidlo hranice sekce zůstává jen v parseru a n-gramy se přiřadí téže sekci, s jakou počítá strip D2. *Token* je maximální úsek písmen a–z délky aspoň 2 po převodu na malá písmena (konstanta `TOKEN_SQL`): maska `___`, čísla, časy, dávkování a jednopísmenné úseky vypadnou, „x-ray“ dá „ray“. Hlavičky sekcí se nepočítají a n-gram nepřechází přes hranici části zprávy. Text `other`, včetně administrativních polí, se počítá do celku. Stop slova jsou přesně `ENGLISH_STOP_WORDS` ze scikit-learn, tedy totéž, co použije TF-IDF se `stop_words="english"`; vypadnou i negace „no“, „not“ a „nor“. Odfiltrují se před skládáním n-gramů, stejně jako v `TfidfVectorizer`, takže „shortness of breath“ dá bigram „shortness breath“. N-gramy mají délku 1 až 3. Žebříček řadí podle *dokumentové frekvence* n-gramu (počet zpráv, v nichž se vyskytuje aspoň jednou), pak podle počtu výskytů a řetězce. U celku se n-gram ve dvou sekcích téže zprávy počítá jednou. Tabulka celku uvádí 15 nejčastějších n-gramů pro každou délku, tabulka po sekcích 5 nejčastějších pro každou sekci kostry a délku. *Fráze šablony* je n-gram, který má aspoň 50 % zpráv,
- *práh popisků n-gramů*: n-gram je popisek z dat. Zveřejní se jen n-gram, který má aspoň 1 % zpráv (u sekce zpráv s touto sekcí) a nejméně 10 zpráv; brána je na dokumentové frekvenci, ne na výskytech, aby se nezveřejnila vzácná fráze nebo jméno opakované v jedné zprávě. Brána je v dotazu, takže mezivýsledek pod ní do R nepřijde,

- *zveřejnění u segmentace*: všechny výstupy jsou metriky textu a korpusu (počty zpráv, délky, pozice) s popisky z konfigurace, takže se uvádějí přesně; řetězce z textu se v kapitole neukazují,
- *předzpracování pro TF-IDF*: sešit nepočítá tokeny vlastním výrazem, ale volá přes reticulate (`eda_preprocessing.py`) analyzér téhož vectorizeru, který používá trénink (`tfidf_vectorizer` v `infrastructure/sklearn_classifier.py`). Varianta „bez předzpracování“ je vectorizer ablace `en-logreg-nonorm` (výchozí tokenizace se snížením písmen, `___` a čísla zůstávají tokeny), varianta „s předzpracováním“ vectorizer hlavních řádků (věk, značky `___` a čísla nahradí zástupné tokeny, zkratky pětice se rozvinou). Tokeny se tedy liší od frekvenční analýzy výše (`TOKEN_SQL`: jen písmena a–z, bez čísel a masky): tam jde o čitelné n-gramy, tady o tokeny, které vidí model. *Slovník* je počet distinct tokenů analyzéru nad celým korpusem před prořezáním: `min_df`, `max_df` a `max_features` filtrují až při `fit`, takže jde o horní mez slovníku modelu učeného jen na trénovacích foldech. Počítá ho DuckDB jako sjednocení distinct tokenů po dávkách 2 000 zpráv. *Tokeny na zprávu* jsou délka výstupu analyzéru. *Výskyt zkratky* je jedno rozvinutí, tedy shoda zkratky pětice (rozlišuje velikost písmen, ASCII hranice slova, `DM2` před `DM`) v normalizovaném textu. *Kód diagnózy* mají zprávy, jejichž přijetí má ICD s předponou diagnózy z `config/diagnosis_candidates.json`, tytéž předpony jako sešity 7 a 8. *Podíl bez kódu* je podíl zpráv se zkratkou, které kód diagnózy nemají. Je to nepřímý ukazatel nesouladu zkratky a kódu, ne odhad víceznačnosti,
- *zveřejnění u předzpracování*: tokeny na zprávu, slovník a výskyty zkratek jsou metriky textu a korpusu a uvádějí se přesně. Zkratky pochází z konfigurace. Podíl zpráv se zkratkou bez kódu diagnózy se uvádí u každé zkratky, kterou má aspoň jedna zpráva; bez výskytu je podíl nedefinovaný.

3 Výsledky

3.1 Objevení hlaviček

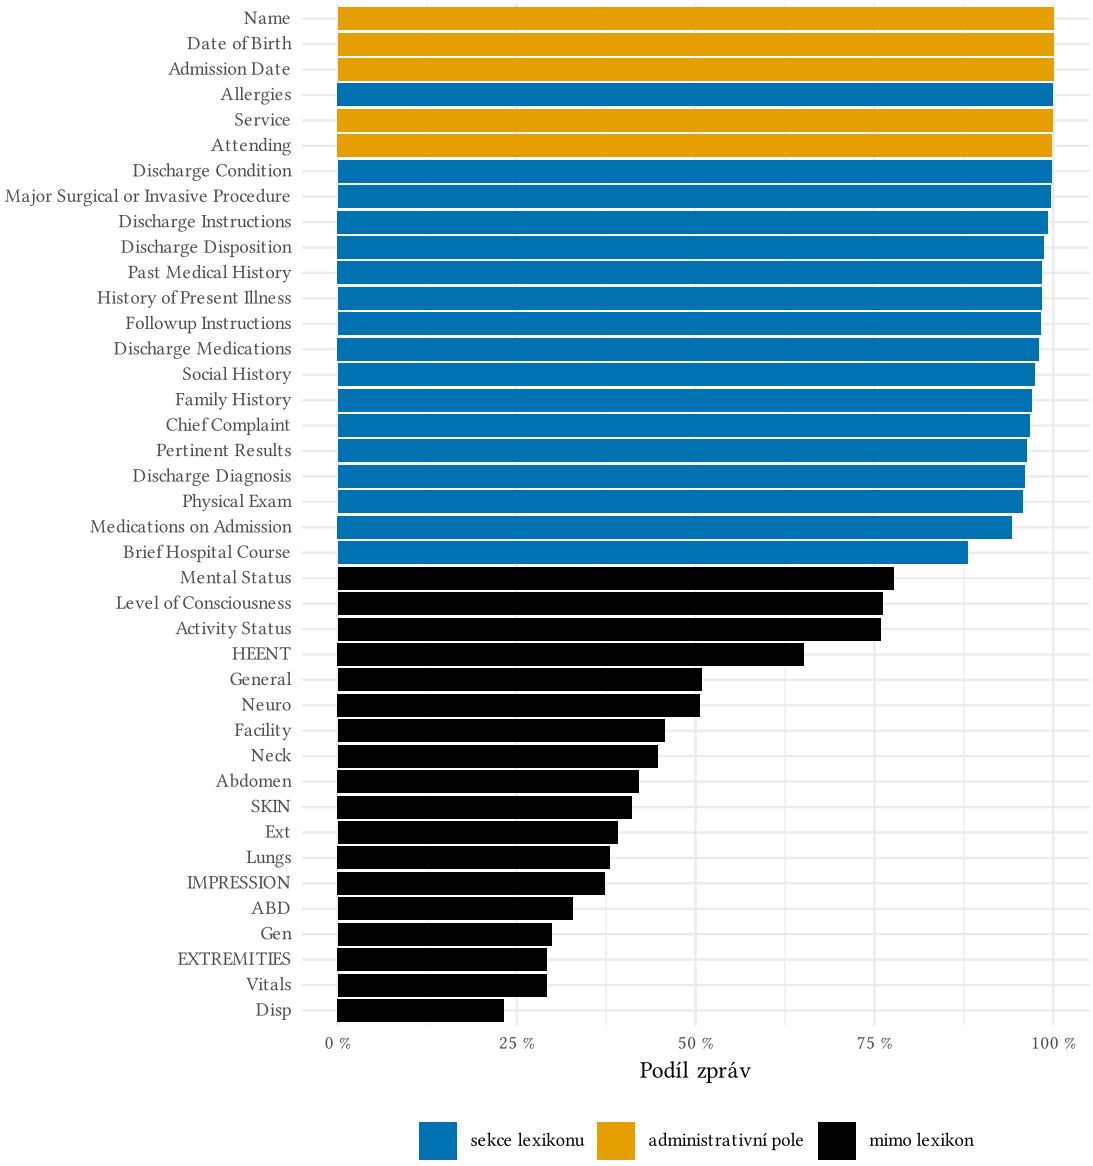
Aspoň jednu sekci lexikonu má 100,0 % zpráv korpusu, žádnou hlavičku 0,0 %. Korpus obsahuje 99 417 unikátních hlaviček.

Tabulka 1 a Obrázek 1 uvádějí hlavičky podle dokumentové frekvence a jejich zařazení: do sekce lexikonu, mezi administrativní pole, nebo mimo lexikon.

Tabulka 1: Nejčastější hlavičky vstupního korpusu podle dokumentové frekvence a jejich zařazení.

Hlavička	Zařazení	Zprávy	Podíl (%)
Name	administrativní pole	331 603	100,0
Date of Birth	administrativní pole	331 598	100,0
Admission Date	administrativní pole	331 593	100,0
Allergies	Alergie	331 478	100,0
Service	administrativní pole	331 392	99,9
Attending	administrativní pole	330 917	99,8
Discharge Condition	Stav při propuštění	330 735	99,7
Major Surgical or Invasive Procedure	Významný chirurgický nebo invazivní výkon	330 244	99,6
Discharge Instructions	Pokyny při propuštění	329 038	99,2
Discharge Disposition	Místo určení po propuštění	327 295	98,7
Past Medical History	Dřívější anamnéza	326 449	98,4
History of Present Illness	Anamnéza současného onemocnění	326 206	98,4
Followup Instructions	Pokyny k navazující péči	325 605	98,2
Discharge Medications	Léky při propuštění	324 856	98,0
Social History	Sociální anamnéza	322 783	97,3
Family History	Rodinná anamnéza	321 464	96,9
Chief Complaint	Hlavní obtíže	320 472	96,6
Pertinent Results	Významné výsledky	319 149	96,2
Discharge Diagnosis	Diagnóza při propuštění	318 168	95,9
Physical Exam	Fyzikální vyšetření	317 360	95,7
Medications on Admission	Léky při přijetí	312 557	94,3
Brief Hospital Course	Průběh hospitalizace	291 741	88,0
Mental Status	mimo lexikon	257 535	77,7
Level of Consciousness	mimo lexikon	252 410	76,1
Activity Status	mimo lexikon	251 520	75,8
HEENT	mimo lexikon	215 963	65,1
General	mimo lexikon	168 607	50,8
Neuro	mimo lexikon	167 760	50,6
Facility	mimo lexikon	151 512	45,7
Neck	mimo lexikon	148 144	44,7
Abdomen	mimo lexikon	139 566	42,1
SKIN	mimo lexikon	136 483	41,2
[illegible]	mimo lexikon	[illegible]	[illegible]

Zdroj: text z `discharge`; zařazení podle `config/section_headers.json`.



Obrázek 1: Pokrytí nejčastějších hlaviček obarvené podle zařazení.

3.2 Audit lexikonu

Tabulka 2 uvádí, v kolika zprávách se vyskytuje hlavička každé sekce lexikonu a v kolika se opakuje; Tabulka 3 totéž pro jednotlivá synonyma včetně mrtvých.

Tabulka 2: Sekce lexikonu: zprávy s hlavičkou sekce a zprávy, kde se hlavička sekce opakuje.

Sekce	Popisek	Zprávy s hlavičkou (%)	Zprávy s opakováním (%)
allergies	Alergie	100,0	1,3
chief_complaint	Hlavní obtíže	96,6	0,5
major_procedure	Významný chirurgický nebo invazivní výkon	99,6	< 0,1
history_of_present_illness	Anamnéza současného onemocnění	98,4	1,2
past_medical_history	Dřívější anamnéza	98,4	10,0
social_history	Sociální anamnéza	97,3	0,7
family_history	Rodinná anamnéza	96,9	2,1
physical_exam	Fyzikální vyšetření	95,9	6,8
pertinent_results	Významné výsledky	96,2	0,3
hospital_course	Průběh hospitalizace	88,0	0,5
medications_on_admission	Léky při přijetí	94,3	0,1
discharge_medications	Léky při propuštění	98,0	< 0,1
discharge_disposition	Místo určení po propuštění	98,7	< 0,1
discharge_diagnosis	Diagnóza při propuštění	96,1	< 0,1
discharge_condition	Stav při propuštění	99,7	0,2
discharge_instructions	Pokyny při propuštění	99,2	0,8
followup_instructions	Pokyny k navazující péči	98,3	< 0,1

Zdroj: text z `discharge`; sekce a synonyma jsou hodnoty z `config/section_headers.json`, ne z dat.

Tabulka 3: Synonyma lexikonu: zprávy se synonymem a zprávy, kde se synonymum opakuje.

Sekce	Synonymum	Zprávy se synonymem (%)	Zprávy s opakováním (%)
allergies	Allergies	100,0	1,3
chief_complaint	Chief Complaint	96,6	0,5
major_procedure	Major Surgical or Invasive Procedure	99,6	< 0,1
history_of_present_illness	History of Present Illness	98,4	1,2
history_of_present_illness	History of the Present Illness	< 0,1	0,0
past_medical_history	Past Medical History	98,4	10,0
social_history	Social History	97,3	0,7
family_history	Family History	96,9	2,1
physical_exam	Physical Exam	95,7	5,0
physical_exam	Physical Examination	2,0	0,1
pertinent_results	Pertinent Results	96,2	0,3
hospital_course	Brief Hospital Course	88,0	0,5
medications_on_admission	Medications on Admission	94,3	0,1
discharge_medications	Discharge Medications	98,0	< 0,1
discharge_disposition	Discharge Disposition	98,7	< 0,1
discharge_diagnosis	Discharge Diagnosis	95,9	< 0,1
discharge_diagnosis	Discharge Diagnoses	0,1	< 0,1
discharge_condition	Discharge Condition	99,7	0,2
discharge_instructions	Discharge Instructions	99,2	0,8
followup_instructions	Followup Instructions	98,2	< 0,1
followup_instructions	Follow-up Instructions	0,1	0,0
followup_instructions	Follow up Instructions	< 0,1	0,0

Lexikon neobsahuje žádné mrtvé synonymum. V aspoň 5 % zpráv se opakuje 1 synonymum: `Past Medical History` (10,0 %).

4 Segmentace a kostra šablony

Zprávy vstupního korpusu rozdělil parser sekcí. Kapitola popisuje kostru šablony, počet sekcí na zprávu, délky těl sekcí, zprávy bez nadpisů a nejčastější tokeny a n-gramy.

4.1 Kostra šablony

Kostru šablony tvoří 17 sekcí s pokrytím aspoň 50 % (podle mediánu pozice): `allergies`, `chief_complaint`, `major_procedure`, `history_of_present_illness`, `past_medical_history`, `social_history`, `family_history`,

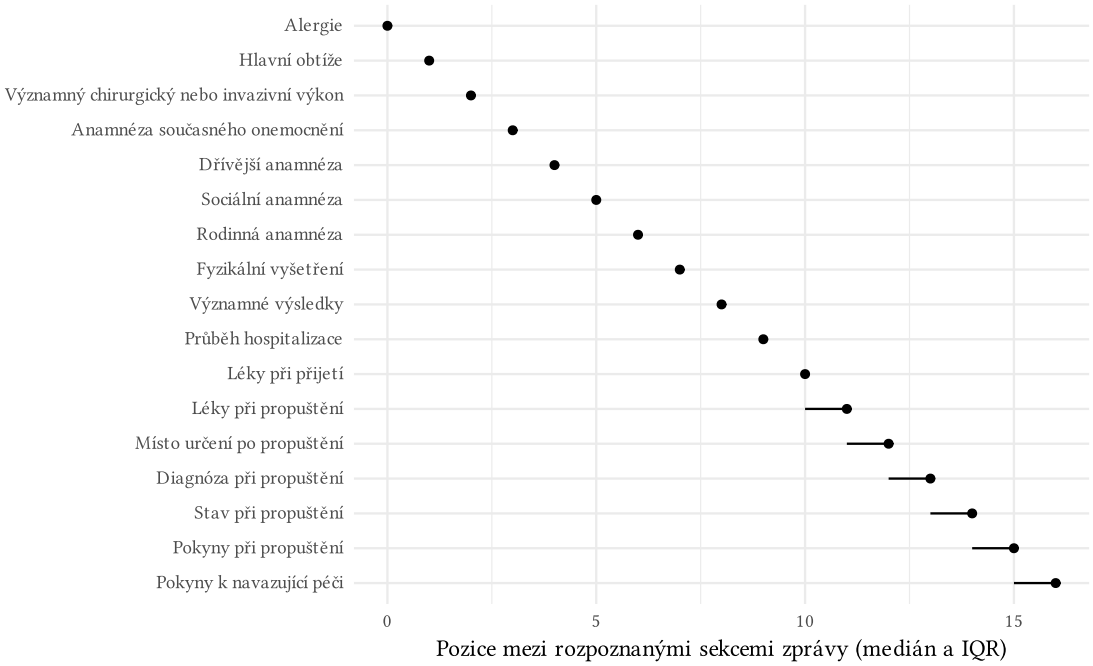
`physical_exam`, `pertinent_results`, `hospital_course`, `medications_on_admission`, `discharge_medications`, `discharge_disposition`, `discharge_diagnosis`, `discharge_condition`, `discharge_instructions` a `followup_instructions`. Pořadí kostry dodržuje 99,6 % ze 331 558 zpráv s aspoň dvěma sekcemi kostry.

Tabulka 4 uvádí všechny sekce lexikonu s pokrytím, mediánem pozice a IQR (rozdíl třetího a prvního kvartilu pozice); kostru tvoří sekce označené „ano“. Obrázek 2 ukazuje medián a IQR pozice sekcí kostry a Obrázek 3 matici precedence.

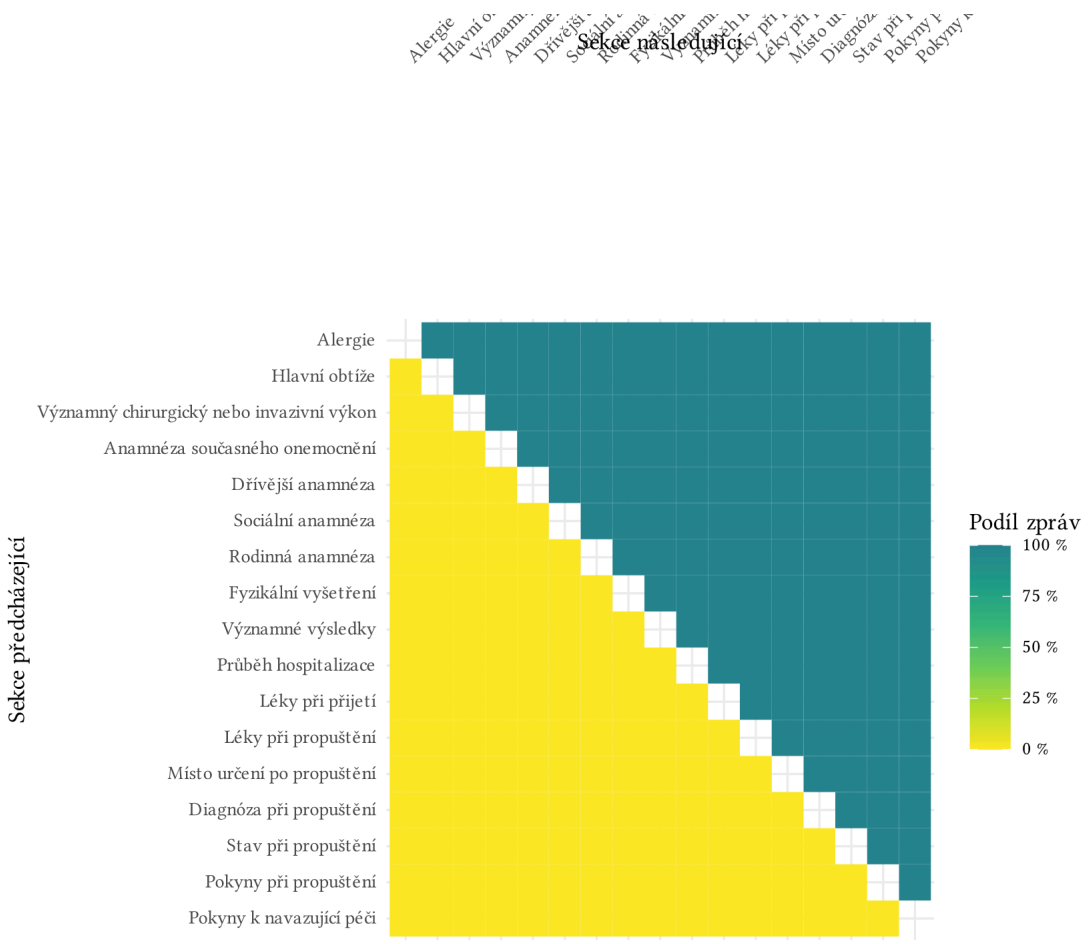
Tabulka 4: Sekce lexikonu v pořadí kostry: pokrytí, medián a IQR pozice mezi rozpoznanými sekcemi zprávy.

Sekce	Popisek	V kostře	Pokrytí (%)	Medián pozice	IQR pozice
`allergies`	Alergie	ano	100,0	0,0	0,0
`chief_complaint`	Hlavní obtíže	ano	96,6	1,0	0,0
`major_procedure`	Významný chirurgický nebo invazivní výkon	ano	99,6	2,0	0,0
`history_of_present_illness`	Anamnéza současného onemocnění	ano	98,4	3,0	0,0
`past_medical_history`	Dřívější anamnéza	ano	98,4	4,0	0,0
`social_history`	Sociální anamnéza	ano	97,3	5,0	0,0
`family_history`	Rodinná anamnéza	ano	96,9	6,0	0,0
`physical_exam`	Fyzikální vyšetření	ano	95,9	7,0	0,0
`pertinent_results`	Významné výsledky	ano	96,2	8,0	0,0
`hospital_course`	Průběh hospitalizace	ano	88,0	9,0	0,0
`medications_on_admission`	Léky při přijetí	ano	94,3	10,0	0,0
`discharge_medications`	Léky při propuštění	ano	98,0	11,0	1,0
`discharge_disposition`	Místo určení po propuštění	ano	98,7	12,0	1,0
`discharge_diagnosis`	Diagnóza při propuštění	ano	96,1	13,0	1,0
`discharge_condition`	Stav při propuštění	ano	99,7	14,0	1,0
`discharge_instructions`	Pokyny při propuštění	ano	99,2	15,0	1,0
`followup_instructions`	Pokyny k navazující péči	ano	98,3	16,0	1,0

Zdroj: text z `discharge` rozdělený parserem sekcí; sekce jsou hodnoty z `config/section_headers.json`.



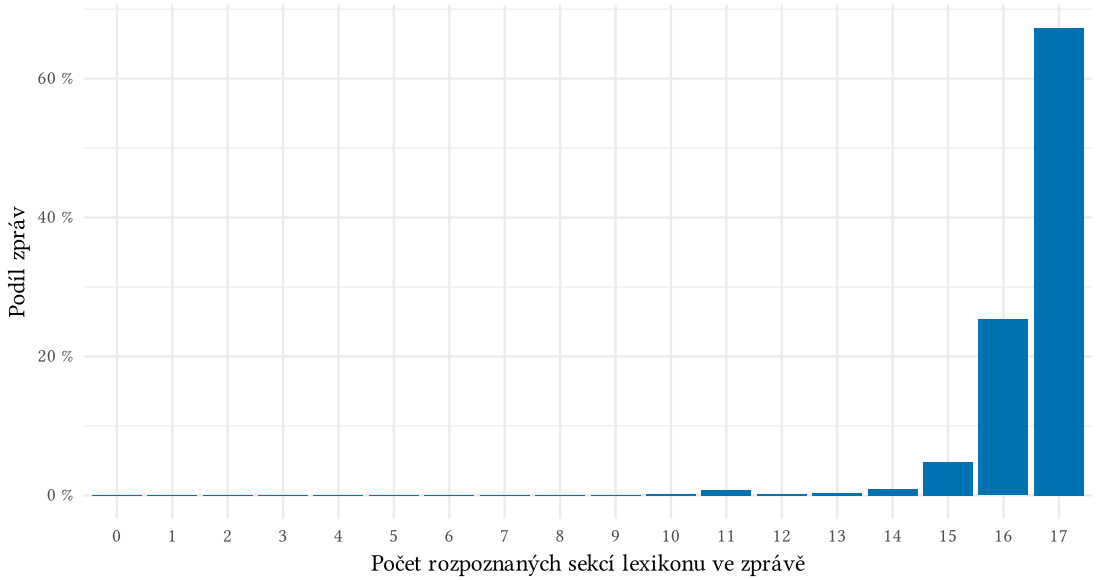
Obrázek 2: Medián a IQR pozice sekcí kostry mezi rozpoznanými sekcemi zprávy.



Obrázek 3: Matice precedence: podíl zpráv, kde sekce v řádku předchází sekci ve sloupci, mezi zprávami s oběma sekcemi.

4.2 Sekce na zprávu

Počet rozpoznaných sekcí lexikonu na zprávu: medián 17 (p10 16, p75 17, p95 17, maximum 17). Žádnou sekci nemá 22 zpráv (< 0,1 %).



Obrázek 4: Rozdělení počtu rozpoznaných sekcí lexikonu ve zprávě.

4.3 Délky těl sekcí

Nejdelší tělo má v mediánu sekce `hospital_course` (1 974 znaků), nejkratší sekce `discharge_disposition` (4 znaky). Text mimo sekce má medián 178 znaků. Tělo sekcí `social_history` a `followup_instructions` je u většiny zpráv jen maska `___` (u 96,9 % a 100,0 % zpráv se sekcí): obsah odstranila de-identifikace, délka proto nepopisuje text.

Tabulka 5 uvádí délky těl sekcí ve znacích v pořadí kostry a poslední řádek patří textu mimo sekce, sečtenému za zprávu.

Tabulka 5: Délky těl sekcí ve znacích: zprávy se sekcí, medián, 75. a 95. percentil a podíl těl, která jsou jen maska ___.

Sekce	Popisek	Zprávy se sekcí	Medián	p75	p95	Jen maska (%)
allergies	Alergie	331 478	43	46	88	1,4
chief_complaint	Hlavní obtíže	320 472	19	29	59	0,4
major_procedure	Významný chirurgický nebo invazivní výkon	330 244	13	44	159	0,1
history_of_present_illness	Anamnéza současného onemocnění	326 207	1 302	1 910	3 023	< 0,1
past_medical_history	Dřívější anamnéza	326 449	249	493	1 383	< 0,1
social_history	Sociální anamnéza	322 783	3	3	3	96,9
family_history	Rodinná anamnéza	321 464	65	126	303	0,3
physical_exam	Fyzikální vyšetření	318 005	834	1 302	2 207	< 0,1
pertinent_results	Významné výsledky	319 149	1 671	3 108	6 876	< 0,1
hospital_course	Průběh hospitalizace	291 741	1 974	3 111	5 615	0,0
medications_on_admission	Léky při přijetí	312 557	311	550	1 067	< 0,1
discharge_medications	Léky při propuštění	324 856	717	1 072	1 782	< 0,1
discharge_disposition	Místo určení po propuštění	327 295	4	33	33	< 0,1
discharge_diagnosis	Diagnóza při propuštění	318 522	67	128	271	0,1
discharge_condition	Stav při propuštění	330 735	124	150	184	< 0,1
discharge_instructions	Pokyny při propuštění	329 038	866	1 458	3 174	< 0,1
followup_instructions	Pokyny k navazující péči	325 920	3	3	3	100,0
other	Text mimo sekce	331 604	178	180	187	0,0

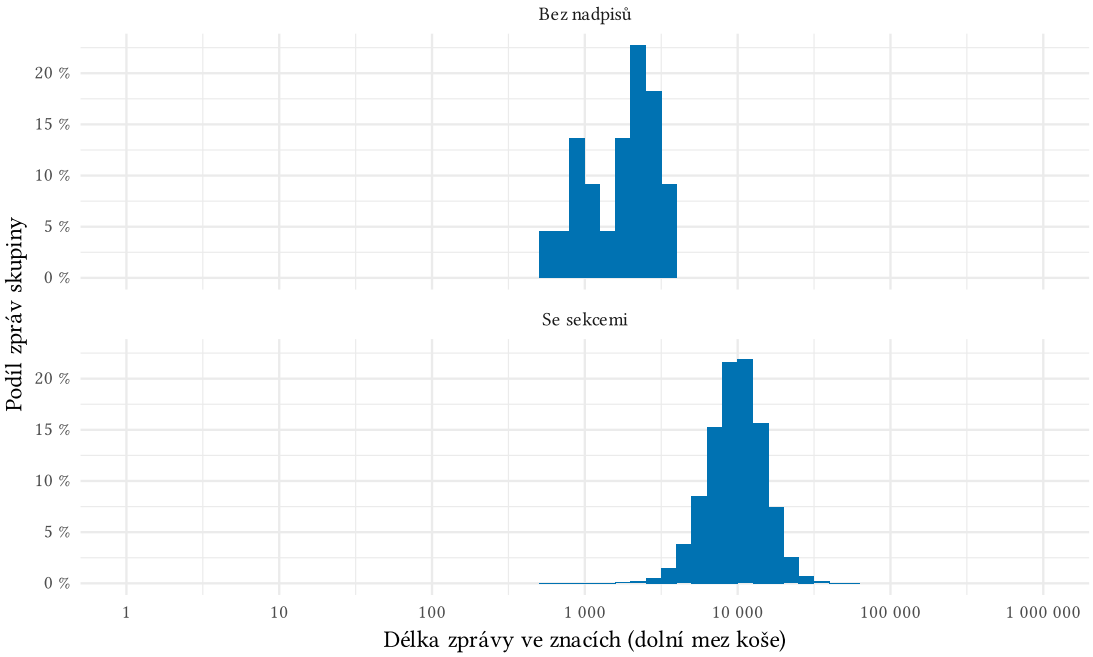
Zdroj: text z `discharge` rozdělený parserem sekcí; délka těla je bez okrajových bílých znaků.

4.4 Zprávy bez nadpisů

Bez nadpisů je 22 zpráv korpusu (< 0,1 %). Medián jejich délky je 1 874 znaků proti 9 849 znaků ve zprávách se sekcemi, p95 je 3 258 znaků proti 18 620 znaků.

Tabulka 6: Zprávy bez nadpisů a zprávy se sekcemi: počet, podíl a délky zprávy ve znacích.

Skupina	Zprávy	Podíl (%)	Medián délky	p95 délky
Bez nadpisů	22	< 0,1	1 874	3 258
Se sekcemi	331 582	100,0	9 849	18 620



Obrázek 5: Rozdělení délky zpráv bez nadpisů a zpráv se sekcemi (podíl v rámci skupiny).

4.5 Tokeny a n-gramy

Nejčastější je token `admission` (100,0 % zpráv), bigram `date birth` (100,0 % zpráv) a trigram `date birth sex` (100,0 % zpráv). Aspoň 50 % zpráv má 141 tokenů, 47 bigramů a 36 trigramů; jsou to fráze šablony, které nic nerozlišují.

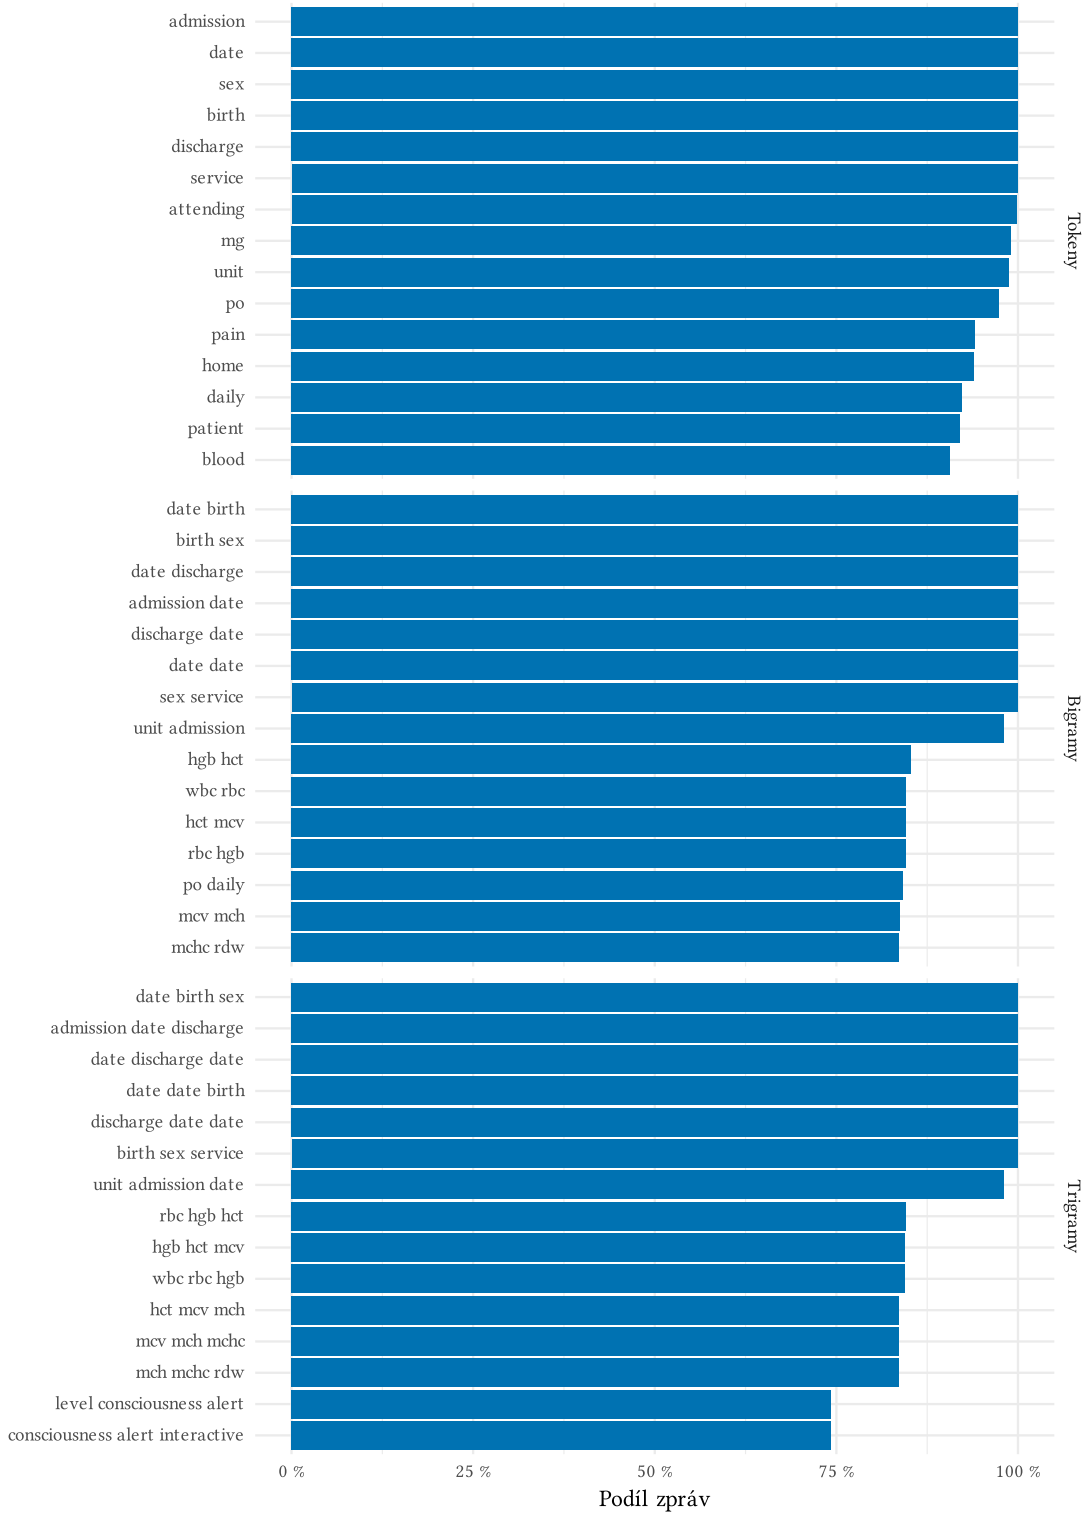
Tabulka 7 uvádí nejčastější tokeny, bigramy a trigramy těl sekcí celého korpusu a Obrázek 6 je ukazuje graficky. Tabulka 8 uvádí pro každou sekci kostry 5 nejčastějších n-gramů od každé délky s podílem zpráv, které sekci mají; bez stop slov.

Tabulka 7: Nejčastější tokeny, bigramy a trigramy těl sekcí vstupního korpusu podle dokumentové frekvence.

Délka	N-gram	Zprávy	Podíl (%)	Výskyty
1	admission	331 604	100,0	1 259 324
1	date	331 604	100,0	1 111 908
1	sex	331 604	100,0	338 807
1	birth	331 604	100,0	336 375
1	discharge	331 603	100,0	1 412 451
1	service	331 392	99,9	560 421
1	attending	330 931	99,8	345 404
1	mg	328 444	99,0	6 583 080
1	unit	327 662	98,8	607 682
1	po	323 019	97,4	4 857 445
1	pain	311 842	94,0	2 643 753
1	home	311 343	93,9	1 177 244
1	daily	305 905	92,3	3 317 846
1	patient	305 007	92,0	2 664 918
1	blood	300 360	90,6	3 323 806
2	date birth	331 604	100,0	332 003
2	birth sex	331 604	100,0	331 775
2	date discharge	331 603	100,0	333 359
2	admission date	331 603	100,0	331 838
2	discharge date	331 593	100,0	332 069
2	date date	331 589	100,0	331 852
2	sex service	331 379	99,9	331 381
2	unit admission	325 235	98,1	325 426
2	hgb hct	282 819	85,3	569 572
2	wbc rbc	280 453	84,6	567 133
2	hct mcv	280 335	84,5	558 391
2	rbc hgb	280 306	84,5	558 553
2	po daily	279 235	84,2	1 901 314
2	mcv mch	277 534	83,7	551 866
2	mchc rdw	277 356	83,6	551 548
3	date birth sex	331 604	100,0	331 775
3	admission date discharge	331 602	100,0	331 637
3	date discharge date	331 593	100,0	331 612
3	[illegible]	[illegible]	[illegible]	[illegible]

Tabulka 8: Nejčastější n-gramy po sekcích kostry: podíl zpráv se sekcí.

Sekce	Délka	Nejčastější n-gramy (podíl zpráv se sekcí)
allergies	1	allergies (41,9 %); known (41,0 %); drug (32,4 %); reactions (31,3 %); adverse (31,3 %)
allergies	2	known allergies (40,9 %); adverse drug (31,3 %); allergies adverse (31,3 %); drug reactions (31,3 %); allergies drugs (9,7 %)
allergies	3	adverse drug reactions (31,3 %); allergies adverse drug (31,3 %); known allergies adverse (31,2 %); having known allergies (9,7 %); known allergies drugs (9,7 %)
chief_complaint	1	pain (26,2 %); abdominal (10,0 %); chest (6,8 %); left (6,0 %); right (5,9 %)
chief_complaint	2	abdominal pain (9,1 %); chest pain (5,8 %); shortness breath (3,9 %); nausea vomiting (2,4 %); mental status (1,9 %)
chief_complaint	3	altered mental status (1,7 %)
major_procedure	1	placement (8,8 %); left (8,7 %); right (8,3 %); artery (3,2 %); catheterization (2,9 %)
major_procedure	2	cardiac catheterization (2,0 %); line placement (1,7 %); coronary artery (1,6 %); artery bypass (1,6 %); saphenous vein (1,2 %)
major_procedure	3	coronary artery bypass (1,5 %); left anterior descending (1,2 %); left internal mammary (1,1 %); internal mammary artery (1,0 %)
history_of_present_illness	1	pain (71,7 %); patient (60,7 %); denies (53,2 %); ed (52,9 %); history (46,1 %)
history_of_present_illness	2	chest pain (39,2 %); abdominal pain (34,2 %); nausea vomiting (27,4 %); year old (25,8 %); shortness breath (25,5 %)
history_of_present_illness	3	ed initial vitals (12,5 %); nausea vomiting diarrhea (12,0 %); chills night sweats (10,1 %); denies chest pain (9,6 %); ed initial vs (8,9 %)
past_medical_history	1	hypertension (32,3 %); history (31,8 %); htn (24,5 %); past (23,1 %); disease (22,4 %)
past_medical_history	2	past medical (15,8 %); medical history (15,3 %); surgical history (9,2 %); atrial fibrillation (7,6 %); past surgical (7,2 %)
past_medical_history	3	past medical history (14,7 %); past surgical history (7,0 %); coronary artery disease (4,7 %); cardiac risk factors (3,8 %); past oncologic history (3,5 %)
social_history	1	history (1,7 %); denies (1,6 %); use (1,4 %); lives (1,3 %); tobacco (1,2 %)
social_history	2	–
social_history	3	–
family_history	1	mother (37,9 %); father (37,8 %); history (27,3 %); cancer (26,6 %); family (25,8 %)
[illegible]	2	[illegible]
[illegible]	3	[illegible] year (69,4 %)



Obrázek 6: Nejčastější tokeny, bigramy a trigramy těl sekcí: podíl zpráv.

5 Validace parseru proti MIMIC-IV-Ext-BHC

Počet spárovaných zpráv: 269 893. Úsek `hospital_course` se shoduje s targetem BHC u 94,5 % spárovaných zpráv (254 929 zpráv). Shoda nebo reference, která obsahuje celou naši násle-

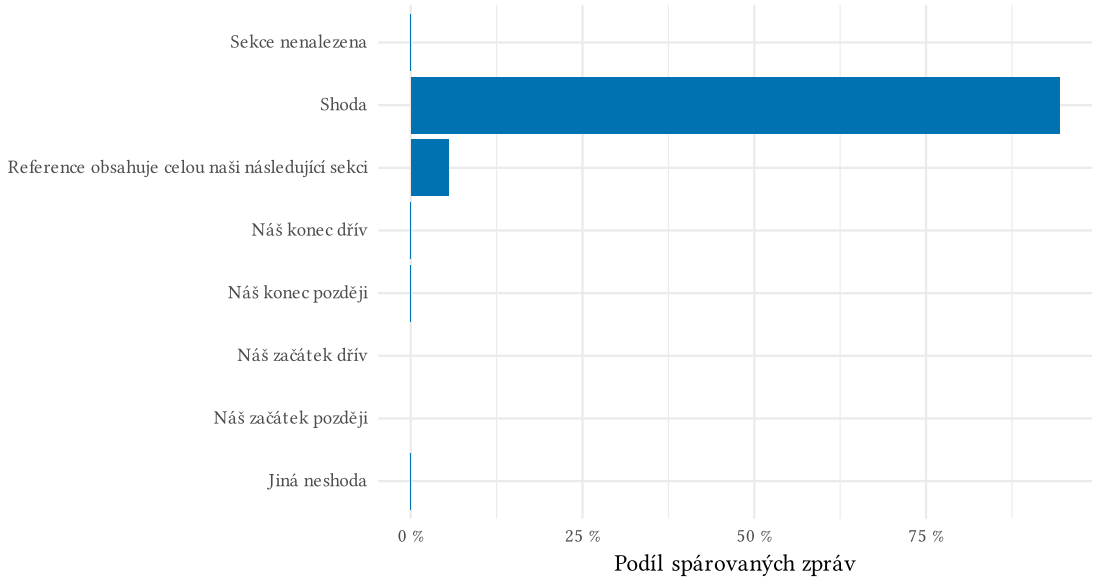
dující sekci (a případně víc), je u 100,0 % spárovaných zpráv (269 788 zpráv); to popisuje vztah k referenci, ne správnost hranic, protože tutéž podmínku splní i podnadpis uvnitř BHC. Neshody: Sekce nenalezena: 3 zprávy; Reference obsahuje celou naši následující sekci: 14 859 zpráv; Náš konec dřív: 64 zpráv; Náš konec později: 32 zpráv; Náš začátek dřív: 0 zpráv; Náš začátek později: 1 zpráva; Jiná neshoda: 5 zpráv. Mimo průnik zůstávají zprávy jen v BHC (140 zpráv) a jen v korpusu (61 711 zpráv); nejsou to chyby parseru, protože BHC vyřadil zprávy bez sekce Sex a s BHC kratší než 100 znaků a korpus filtruje podle ICD, délky a duplicit. Target čištěním zjevně neprošel (dvě mezery za sebou nebo jiný bílý znak než mezera) u 0,0 % spárovaných zpráv (0 zpráv).

Tabulka 9 a Obrázek 7 uvádějí rozpad zpráv podle shody úseku `hospital_course` s targetem BHC.

Tabulka 9: Shoda úseku `hospital_course` s targetem MIMIC-IV-Ext-BHC: zprávy, podíl spárovaných zpráv a medián rozdílu délky ve znacích.

Kategorie	Zprávy	Podíl (%)	Medián rozdílu délky
Sekce nenalezena	3	< 0,1	–
Shoda	254 929	94,5	–
Reference obsahuje celou naši následující sekci	14 859	5,5	996
Náš konec dřív	64	< 0,1	26
Náš konec později	32	< 0,1	159
Náš začátek dřív	0	0,0	–
Náš začátek později	1	< 0,1	11 960
Jiná neshoda	5	< 0,1	–

Zdroj: text z `discharge` rozdělený parserem sekcí; `target` z MIMIC-IV-Ext-BHC.



Obrázek 7: Shoda úseku `hospital_course` s targetem MIMIC-IV-Ext-BHC: podíl spárovaných zpráv.

Za sekcí `hospital_course` nejčastěji následuje: Léky při propuštění (14 187 zpráv, 95,1 %); Místo určení po propuštění (616 zpráv, 4,1 %); Léky při přijetí (65 zpráv, 0,4 %). Z těchto zpráv následuje diagnostická sekce u 0,2 % z nich (23 zpráv); strip D2 u těchto zpráv odstraní spolu s ní i text, který BHC počítá do Brief Hospital Course. Tabulka 10 uvádí pro zprávy, kde je náš úsek vlastním prefixem `target` (kategorie „náš konec dřív“ a „reference obsahuje celou naši následující sekci“), část zprávy, která následuje hned za sekcí `hospital_course`, tedy čí hlavička náš úsek uřízla.

Tabulka 10: Zprávy, kde je náš úsek vlastním prefixem targetu, podle části, která následuje za sekcí `hospital_course`: zprávy a podíl z těchto zpráv.

Sekce	Popisek	Zprávy	Podíl (%)
`discharge_medications`	Léky při propuštění	14 187	95,1
`discharge_disposition`	Místo určení po propuštění	616	4,1
`medications_on_admissio`	Léky při přijetí	65	0,4
`discharge_diagnosis`	Diagnóza při propuštění	23	0,2
`discharge_condition`	Stav při propuštění	15	0,1
`past_medical_history`	Dřívější anamnéza	5	< 0,1
`physical_exam`	Fyzikální vyšetření	4	< 0,1
`discharge_instructions`	Pokyny při propuštění	4	< 0,1
`followup_instructions`	Pokyny k navazující péči	2	< 0,1
`social_history`	Sociální anamnéza	1	< 0,1
`other`	Administrativní pole	1	< 0,1

Zdroj: text z `discharge` rozdělený parserem sekcí; sekce a popisky z `config/section_headers.json`, administrativní pole je část `other` za sekcí.

Populace: 14 923 zpráv s koncem dřív (náš úsek je vlastním prefixem targetu). Reference obsahuje celou naši následující sekci u 99,6 % zpráv (14 859 zpráv). Medications on Admission ve zprávě chybí u 99,2 % zpráv (14 798 zpráv), stojí před Brief Hospital Course u < 0,1 % zpráv (2 zprávy), sama úsek uřízla u 0,4 % zpráv (65 zpráv) a stojí až za hlavičkou, která úsek uřízla, u 0,4 % zpráv (58 zpráv). Hlavička, která úsek uřízla, je zapsaná jako synonymum lexikonu u 99,8 % zpráv (14 891 zpráv), verzálkami u 0,1 % zpráv (8 zpráv) a jinak u 0,2 % zpráv (23 zpráv); administrativní pole je to u < 0,1 % zpráv (1 zpráva) a BHC je poslední částí zprávy u 0,0 % zpráv (0 zpráv). Hlavička téže sekce se ve zprávě znovu vyskytuje v následující části nebo za ní u 0,8 % zpráv (112 zpráv), neopakuje se u 99,2 % zpráv (14 810 zpráv) a bez následující sekce je < 0,1 % zpráv (1 zpráva). Souběh: polknutá jediná sekce u 99,1 % zpráv (14 794 zpráv) (reference obsahuje celou naši následující sekci, Medications on Admission chybí a hlavička se neopakuje), podnadpis u 0,8 % zpráv (125 zpráv) (hlavička se opakuje nebo Medications on Admission stojí za uříznutím). Odsazená je hlavička u 0,0 % zpráv (0 zpráv). Rozklad popisuje, co úsek uřízlo, a sám nerozhoduje, zda je hranice parseru správná. Tabulka 11 rozkládá tytéž zprávy podle vlastností, které rozliší skutečnou sekci polknutou referencí od podnadpisu uvnitř Brief Hospital Course.

Tabulka 11: Zprávy, kde je náš úsek vlastním prefixem targetu, podle vlastností hlavičky, která úsek uřízla, a polohy Medications on Admission: zprávy a podíl z těchto zpráv; skupiny kromě souběhu a odsazení dávají po 100 %.

Skupina	Vlastnost	Zprávy	Podíl (%)
Reference	Obsahuje celou naši následující sekci	14 859	99,6
	Neobsahuje	64	0,4
Léky při přijetí	Sekce chybí	14 798	99,2
	Stojí před Brief Hospital Course	2	< 0,1
	Sama úsek uřízla	65	0,4
	Stojí za hlavičkou, která úsek uřízla	58	0,4
Hlavička, která úsek uřízla	Zápis synonyma lexikonu	14 891	99,8
	Verzálky	8	0,1
	Jiný zápis	23	0,2
	Administrativní pole	1	< 0,1
	BHC je poslední část zprávy	0	0,0
Opakování hlavičky	Opakuje se v následující části nebo za ní	112	0,8
	Neopakuje se	14 810	99,2
	Bez následující sekce	1	< 0,1
Souběh	Podpis polknuté jediné sekce	14 794	99,1
	Podpis podnadpisu	125	0,8
Odsazení	Odsazená hlavička	0	0,0

Zdroj: text z `discharge` rozdělený parserem sekcí; poloha sekcí a zápis hlaviček z tabulky `note_sections_input` a z textu zprávy, synonyma z `config/section_headers.json`.

5.1 Zbytek po stripu

Hlavička diagnostické sekce i s diagnózou pod ní zůstane po stripu D2 u < 0,1 % zpráv s diagnostickou sekcí (37 zpráv z 318 522). Liší se od sloupce „opakování“ v tabulce sekcí, který počítá i druhý výskyt uvnitř těla samotné diagnostické sekce; ten strip odstraní spolu s ní, takže sloupec zbytek přeceňuje.

6 Předzpracování pro TF-IDF

Slovník analyzéru před prořezáním má bez předzpracování 381 548 tokenů, s předzpracováním 343 138 tokenů (změna o −10,1 %). Zpráva má bez předzpracování v mediánu 1 475 tokenů (p95 2 760), s předzpracováním 1 545 tokenů (p95 2 882).

Tabulka 12 uvádí velikost slovníku a tokeny na zprávu před a po předzpracování.

Tabulka 12: Předzpracování pro TF-IDF: velikost slovníku analyzéru před prořezáním a tokeny na zprávu bez předzpracování a s ním.

Varianta	Slovník (tokeny)	Medián tokenů na zprávu	p95 tokenů	Průměr tokenů
Bez předzpracování	381 548	1 475	2 760	1572,5
S předzpracováním	343 138	1 545	2 882	1645,2

Zdroj: analyzér `tfidf_vectorizer` nad propouštěcími zprávami vstupního korpusu; výchozí tokenizace TF-IDF, ne `TOKEN_SQL` frekvenční analýzy.

Zpráv se zkratkou AF je bez kódu diagnózy 28,7 %, u ostatních zkratek v mediánu 15,4 %. Tabulka 13 uvádí u každé zkratky pětice počet rozvinutí a podíl zpráv se zkratkou bez kódu diagnózy.

Tabulka 13: Zkratky diagnóz pětice: přesné výskyty (počet rozvinutí) a podíl zpráv se zkratkou bez kódu diagnózy; pomlčka značí nedefinovaný podíl zkratky bez výskytu.

Zkratka	Diagnóza	Výskyty	Zprávy bez kódu diagnózy (%)
`AF`	Fibrilace síní	18 465	28,7
`CKD`	Chronické onemocnění ledvin	73 619	5,9
`COPD`	CHOPN	115 708	18,9
`DM`	Diabetes mellitus	103 794	24,9
`DM2`	Diabetes mellitus	33 771	9,0
`ESRD`	Chronické onemocnění ledvin	50 017	15,4

Zdroj: zkratky a kanonické tvary z `config/diagnosis_candidates.json`, kódy diagnóz z `diagnoses_icd` podle předpon téhož souboru.

7 Shrnutí a rozhodnutí

Dokument ověřil seed lexikon sekcí na vstupním korpusu. Pro další práci z toho plyne:

- **Pokrytí.** Aspoň jednu sekci lexikonu má 100,0 % zpráv korpusu, žádnou hlavičku 0,0 %. Korpus obsahuje 99 417 unikátních hlaviček.
- **Kandidáti na doplnění.** Kandidáti na doplnění lexikonu (hlavičky mimo lexikon s pokrytím aspoň 50 %): `Mental Status` (77,7 %), `Level of Consciousness` (76,1 %), `Activity Status` (75,8 %), `HEENT` (65,1 %), `General` (50,8 %) a `Neuro` (50,6 %). Do lexikonu patří jen samostatná sekce šablony; pole a podnadpisy uvnitř jiné sekce sekcemi nejsou a lexikon je nepřebírá, i když je má většina zpráv.
- **Mrtvá synonyma.** Lexikon neobsahuje žádné mrtvé synonymum.
- **Opakování.** V aspoň 5 % zpráv se opakuje 1 synonymum: `Past Medical History` (10,0 %).
- **Pro parser.** Parser sekcí čte lexikon z `config/section_headers.json` a používá pravidlo hlavičky a normalizace z kapitoly 2; rozdělení zpráv je v kapitole 4.
- **Kostra.** Kostru šablony tvoří 17 sekcí s pokrytím aspoň 50 % (podle mediánu pozice): `allergies`, `chief_complaint`, `major_procedure`,

history_of_present_illness, past_medical_history, social_history, family_history, physical_exam, pertinent_results, hospital_course, medications_on_admission, discharge_medications, discharge_disposition, discharge_diagnosis, discharge_condition, discharge_instructions a followup_instructions. Pořadí kostry dodržuje 99,6 % ze 331 558 zpráv s aspoň dvěma sekcemi kostry.

- **Strip D2.** Strip D2 odstraní sekci discharge_diagnosis u 318 522 zpráv korpusu (96,1 %) a tvoří 1,1 % jeho textu; ve zprávě se sekcí tvoří v mediánu 1,0 % textu zprávy. Hlavička diagnostické sekce i s diagnózou pod ní zůstane po stripu D2 u < 0,1 % zpráv s diagnostickou sekcí (37 zpráv z 318 522). Liší se od sloupce „opakování“ v tabulce sekcí, který počítá i druhý výskyt uvnitř těla samotné diagnostické sekce; ten strip odstraní spolu s ní, takže sloupec zbytek přeceňuje. Strip proto zůstává u prvního výskytu diagnostické sekce: zbytek po něm je okrajový a jeho rozšíření na všechny výskyty by strip rozešlo se segmentací, kterou sešit měří. Zbytek uvádějí Omezení.
- **Délky.** Nejdelší tělo má v mediánu sekce hospital_course (1 974 znaků), nejkratší sekce discharge_disposition (4 znaky). Text mimo sekce má medián 178 znaků. Tělo sekcí social_history a followup_instructions je u většiny zpráv jen maska ___ (u 96,9 % a 100,0 % zpráv se sekcí): obsah odstranila de-identifikace, délka proto nepopisuje text.
- **Zprávy bez nadpisů.** Bez nadpisů je 22 zpráv korpusu (< 0,1 %). Medián jejich délky je 1 874 znaků proti 9 849 znaků ve zprávách se sekcemi, p95 je 3 258 znaků proti 18 620 znaků.
- **Validace parseru.** Počet spárovaných zpráv: 269 893. Úsek hospital_course se shoduje s targetem BHC u 94,5 % spárovaných zpráv (254 929 zpráv). Shoda nebo reference, která obsahuje celou naši následující sekci (a případně víc), je u 100,0 % spárovaných zpráv (269 788 zpráv); to popisuje vztah k referenci, ne správnost hranic, protože tutéž podmínku splní i podnadpis uvnitř BHC. Neshody: Sekce nenalezena: 3 zprávy; Reference obsahuje celou naši následující sekci: 14 859 zpráv; Náš konec dřív: 64 zpráv; Náš konec později: 32 zpráv; Náš začátek dřív: 0 zpráv; Náš začátek později: 1 zpráva; Jiná neshoda: 5 zpráv. Mimo průnik zůstávají zprávy jen v BHC (140 zpráv) a jen v korpusu (61 711 zpráv); nejsou to chyby parseru, protože BHC vyřadil zprávy bez sekce Sex a s BHC kratší než 100 znaků a korpus filtruje podle ICD, délky a duplicit. Target čištěním zjevně neprošel (dvě mezery za sebou nebo jiný bílý znak než mezera) u 0,0 % spárovaných zpráv (0 zpráv). Falešný první výskyt hlavičky Brief Hospital Course se projeví jen v kategoriích „náš začátek dřív“ a „jiná neshoda“, a ty mají dohromady jen jednotky zpráv; podnadpis uvnitř jejího těla, který parser přečte jako hlavičku jiné sekce, tyto kategorie nezachytí a ověřuje ho tabulka příčin. Za sekcí hospital_course nejčastěji následuje: Léky při propuštění (14 187 zpráv, 95,1 %); Místo určení po propuštění (616 zpráv, 4,1 %); Léky při přijetí (65 zpráv, 0,4 %). Z těchto zpráv následuje diagnostická sekce u 0,2 % z nich (23 zpráv); strip D2 u těchto zpráv odstraní spolu s ní i text, který BHC počítá do Brief Hospital Course. Populace: 14 923 zpráv s koncem dřív (náš úsek je vlastním prefixem targetu). Reference obsahuje celou naši následující sekci u 99,6 % zpráv (14 859 zpráv). Medications on Admission ve zprávě chybí u 99,2 % zpráv (14 798 zpráv), stojí před Brief Hospital Course u < 0,1 % zpráv (2 zprávy), sama úsek uřízla u 0,4 % zpráv (65 zpráv) a stojí až za hlavičkou, která úsek uřízla, u 0,4 % zpráv (58 zpráv). Hlavička, která úsek uřízla, je zapsaná jako synonymum lexikonu u 99,8 % zpráv (14 891 zpráv), verzálkami u 0,1 % zpráv (8 zpráv) a jinak u 0,2 % zpráv (23 zpráv); administrativní pole je to u < 0,1 % zpráv (1 zpráva) a BHC je poslední částí zprávy u 0,0 % zpráv (0 zpráv). Hlavička téže sekce se ve zprávě znovu vyskytuje v následující části nebo

za ní u 0,8 % zpráv (112 zpráv), neopakuje se u 99,2 % zpráv (14 810 zpráv) a bez následující sekce je < 0,1 % zpráv (1 zpráva). Souběh: polknutá jediná sekce u 99,1 % zpráv (14 794 zpráv) (reference obsahuje celou naši následující sekci, Medications on Admission chybí a hlavička se neopakuje), podnadpis u 0,8 % zpráv (125 zpráv) (hlavička se opakuje nebo Medications on Admission stojí za uříznutím). Odsazená je hlavička u 0,0 % zpráv (0 zpráv). Rozklad popisuje, co úsek uřízlo, a sám nerozhoduje, zda je hranice parseru správná. Hlavní experiment běží nad celou zprávou a strip uřízne konec BHC jen výjimečně, takže posunutá hranice na ně nemá vliv a uvádějí ji Omezení. Týká se hranic sekcí: úsek Brief Hospital Course je u zpráv s koncem dřív kratší než reference. Zda reference polkla celou skutečnou sekci, nebo parser přečetl podnadpis uvnitř Brief Hospital Course jako hlavičku, rozlišují opakování hlavičky a poloha Medications on Admission v tabulce Tabulka 11. Převažuje podpis polknuté jediné sekce: zpráva nemá sekci Medications on Admission, hlavička, která úsek uřízla, je jediným výskytem své sekce zapsaným jako synonymum lexikonu a reference obsahuje celou tuto sekci. Reference tedy končí Brief Hospital Course až na Medications on Admission a bez ní pokračuje přes další sekci, nejčastěji Discharge Medications; odchylka je na straně reference, ne parseru. Pravidlo prvního výskytu ani lexikon se proto nemění: úprava, která by hranici za Brief Hospital Course posunula, by u těchto zpráv zrušila skutečnou sekci Discharge Medications a vyrobila falešnou hranici, kterou by převzaly n--gramy po sekcích, strip D2 i varianta vstupu jen z Brief Hospital Course. Podpis podnadpisu (opakovaná hlavička nebo Medications on Admission až za uříznutím) má jen zlomek zpráv s koncem dřív a uvádějí ho Omezení. Pro variantu vstupu jen z Brief Hospital Course platí hranice parseru; reference BHC jako vstup pro tuto variantu nevyhovuje, protože u zpráv bez Medications on Admission obsahuje i léky při propuštění.

- **Předzpracování pro TF-IDF.** Slovník analyzéru před prořezáním má bez předzpracování 381 548 tokenů, s předzpracováním 343 138 tokenů (změna o −10,1 %). Zpráva má bez předzpracování v mediánu 1 475 tokenů (p95 2 760), s předzpracováním 1 545 tokenů (p95 2 882). Zpráv se zkratkou AF je bez kódu diagnózy 28,7 %, u ostatních zkratek v mediánu 15,4 %. Pro S40 z toho plyne podklad pro `min_df` (velikost slovníku před prořezáním je horní mez) a pro rozhodnutí o rozvinutí zkratky AF: vybočí-li podíl bez kódu u AF, rozvinutí by do zpráv bez fibrilace vkládalo „atrial fibrillation“.
- **Tokeny a n-gramy.** Nejčastější je token `admission` (100,0 % zpráv), bigram `date birth` (100,0 % zpráv) a trigram `date birth sex` (100,0 % zpráv). Aspoň 50 % zpráv má 141 tokenů, 47 bigramů a 36 trigramů; jsou to fráze šablony, které nic nerozlišují. Pro S40 (baseline TF--IDF + LR) z toho plyne argument pro `ngram_range` a `max_df`: n-gramy, které má většina zpráv, nic nerozlišují. Tokenizace sešitu se liší od výchozí v TF-IDF: ponechává jen písmena a–z, takže čísla a masku `___` vynechává. Počty frází šablony jsou podklad pro deduplikaci boilerplate (D26).

8 Omezení

Řádkově ukotvený výraz nevidí pole, které stojí na řádku za jiným polem, hlavičky bez dvojtečky ani hlavičky rozdělené na víc řádků. Pokrytí administrativních polí se proto neměří. Opakování je jen nepřímý signál falešné hranice: synonymum se může opakovat i ve zprávě, kde je každý výskyt skutečnou hlavičkou. Hranice 50 % pro kandidáty je popisná a nerozliší sekci šablony od pole, které má ve většině zpráv podsekce. Žebříček neukazuje hlavičky pod 1 % zpráv, takže vzácnou sekci šablony nemusí zveřejnit. Pozice počítá jen sekce lexikonu, takže pole a podnadpisy mimo lexikon pořadí nezkreslují, ale ani nepopisují. Pozice je pořadí

mezi sekcemi, které zpráva má: chybí-li dřívější sekce, pozice všech pozdějších klesne o jedna, a IQR pozice proto měří i chybějící sekce, ne jen přeházené pořadí. Frekvenční analýza nelemmatizuje, takže „fever“ a „fevers“ jsou dva tokeny, a ztrácí negace, protože „no“ a „not“ jsou stop slova: „no fever“ se spočítá jako „fever“. Výchozí tokenizace TF-IDF masku ___ a čísla jako tokeny ponechá, počty n-gramů z tohoto sešitu tedy nejsou přímo počty příznaků baseline; tokeny modelu měří kapitola 6. Slova z administrativních polí leží v části `other` a počítají se jen do celku, ne do sekcí. Bigram může spojit slova, mezi nimiž stálo stop slovo. N-gramy pod branou (1 % zpráv a nejméně 10 zpráv) se nezobrazí, takže vzácná, ale rozlišující fráze v žebříčku chybí. Strip vystřihne první výskyt diagnostické sekce a hlavičku uvnitř těla jiné sekce nehlídá; kolik zpráv tím zůstane se zbytkem diagnózy, měří kapitola 5.1, parser bere první výskyt. Validace proti BHC porovnává jen sekci Brief Hospital Course a jen na průniku korpusu a BHC; BHC vyřadil zprávy bez sekce Sex a s krátkým BHC, takže průnik nemusí být reprezentativní. Reference je výstup regulárního výrazu autorů, ne ruční anotace, a shoda s ním neznamená shodu s pravdou. Kategorie „náš začátek dřív“ je dolní odhad falešného prvního výskytu hlavičky. U zpráv, kde je náš úsek vlastním prefixem targetu (kategorie „náš konec dřív“ a „reference obsahuje celou naši následující sekci“), je sekce Brief Hospital Course kratší než reference. Rozklad uvádí, která část zprávy následuje za sekcí, zápis její hlavičky, její opakování ve zprávě a polohu Medications on Admission. Kategorie „reference obsahuje celou naši následující sekci“ sama správnost hranice nedokládá, protože ji splní i podnadpis uvnitř Brief Hospital Course; závěr o příčině stojí na souběhu vlastností v Tabulka 11, tedy na nepřímých znacích (opakování hlavičky, poloha Medications on Admission), ne na ruční kontrole hranic. Zprávy s podpisem podnadpisu mohou mít skutečně falešnou hranici uvnitř Brief Hospital Course; jejich podíl je okrajový a parser se kvůli nim nemění.

Slovník v kapitole 6 je slovník analyzéru před prořezáním nad celým korpusem, tedy horní mez slovníku modelu, který se učí jen na trénovacích foldech a s `min_df` a `max_df` z S40. Podíl zpráv se zkratkou bez kódu diagnózy je nepřímý ukazatel nesouladu zkratky a kódu, ne odhad víceznačnosti, protože kód neurčuje význam jednotlivého výskytu: afebrile se může psát i ve zprávě s kódem fibrilace a zpráva bez kódu může nést nekódovanou anamnézu.

Příloha A: provenance renderu

Tabulka 14 uvádí údaje, podle kterých lze render dohledat a zopakovat: revizi kódu, otisk zámku prostředí, zdroj dat a verze použitých nástrojů.

Tabulka 14: Provenance renderu.

Položka	Hodnota
Revize kódu (commit)	22439d2be1672e7cdfb5e98f161035833f437ee1
Necommitnuté změny	ne
Otisk pixi.lock (SHA-256)	d881b6d4b87cde36 4fa5123e81060e0a f6e07beb9e18e124 3698639b9b8c0c0a
Zdroj dat	otisky CSV z config/mimic_tables.json
Otisk discharge.csv.gz (SHA-256)	27bc552edaf81c2a f322040cb7e8eb36 417173b23c79405b b92fcf73bef2dbc5
Otisk radiology.csv.gz (SHA-256)	2c09bc76ee12d5f3 b8f572deb7218fba f3e59b32eccfdae1 4686e05ae099eebb
Otisk admissions.csv.gz (SHA-256)	a9584ed88e9ed664 a2f66f86a5cf9fd1 75c8bb0af50e3b61 15598b19e978384e
Otisk d_icd_diagnoses.csv.gz (SHA-256)	a81065bf45ccf74f 589bec855bbb0a07 b5c014907b34ff76 fe20583a2c87cc79
Otisk d_icd_procedures.csv.gz (SHA-256)	2ac8afcb99fd16b ce2e6c7ad445e3bd 1dfd658e52182313 0ab08b66fdd3d6d4
Otisk diagnoses_icd.csv.gz (SHA-256)	47665a41b2a3ad99 0d6f314062d5bd6d 29d467b0fd402dd9 4662044ec8b073d2
Otisk omr.csv.gz (SHA-256)	8280a8023203bddc 6cc4419bd8cd253a 015b8bc0bc53852e c92f98c7353f31e2
Otisk patients.csv.gz (SHA-256)	4c7507de7ecad8c5 ba7647ea4d26018e 88ff6672c5fc22ab 59c2a5697d687cdd
Otisk pharmacy.csv.gz (SHA-256)	c9885721e4c968f0 773145d7f6ba4d3c c3755d5600ee400f f95b1d3238053811
Otisk prescriptions.csv.gz (SHA-256)	0d8481c7d5d7c9ec 2fea3fc543ddaaad b5a933cd22c7b9dd a4289361e4d77199
Otisk procedures_icd.csv.gz (SHA-256)	3271397d0517131f 84399b698cbb0c2f 435aaab0f873a380 6e13b097661596f7
Otisk services.csv.gz (SHA-256)	31c82ebee94e0c04 d6966fbfec30579e c00f9c7816b80852 f9580656e6183888
Otisk mimic-iv-bhc.csv (SHA-256)	e45c09997b25d744 abb20573623885eb a052299cf2a721c1 8bbf5ca9a54989c1
Python	3.13.16
DuckDB	1.5.6
R	R version 4.5.3 (2026-03-11)

Literatura

Aali, Asad, Dave Van Veen, Yamin Ishraq Arefeen, et al. 2024. „A dataset and benchmark for hospital course summarization with adapted large language models". *Journal of the American Medical Informatics Association* 32 (3): 470–79. https://doi.org/10.1093/jamia/ocae312.

Aali, Asad, Dave Van Veen, Yamin Ishraq Arefeen, et al. 2025. *MIMIC-IV-Ext-BHC: Labeled Clinical Notes Dataset for Hospital Course Summarization*. Verze 1.2.0. PhysioNet. https://doi.org/10.13026/5gte-bv70.

Johnson, Alistair E. W., Lucas Bulgarelli, Lu Shen, et al. 2023. „MIMIC-IV, a freely accessible electronic health record dataset". *Scientific Data* 10 (1): 1. https://doi.org/10.1038/s41597-022--01899-x.

Johnson, Alistair, Lucas Bulgarelli, Tom Pollard, et al. 2024. *MIMIC-IV*. Verze 3.1. PhysioNet. https://doi.org/10.13026/kpb9-mt58.

Johnson, Alistair, Tom Pollard, Steven Horng, Leo Anthony Celi, a Roger Mark. 2023. *MIMIC--IV-Note: Deidentified free-text clinical notes*. Verze 2.2. PhysioNet. https://doi.org/10.13026/1n74-ne17.