Explorační analýza datové sady: hlavičky, lexikon a kostra sekcí

Martin Žoha

Abstrakt Dokument zjišťuje, které hlavičky začínají v propouštěcích zprávách vstupního korpusu oddíly, a ověřuje na nich seed lexikon sekcí šablony MIMIC. Počítá dokumentovou frekvenci všech hlaviček, pokrytí sekcí a synonym lexikonu, mrtvá synonyma a synonyma, která se ve zprávě opakují, což je signál falešné hranice sekce. Hlavičky mimo lexikon s vysokým pokrytím jmenuje jako kandidáty na doplnění, o kterých rozhodne autor. Zprávy pak rozdělí parserem sekcí a zjistí kostru šablony (pořadí sekcí, jejich pokrytí a konzistenci pořadí), počet sekcí na zprávu, délky těl sekcí ve znacích, podíl textu, který odstraní vystřižení sekce Discharge Diagnosis, a zprávy bez nadpisů. Nakonec spočítá nejčastější tokeny, bigramy a trigramy těl sekcí v celém korpusu i po sekcích kostry, aby ukázal fráze šablony, které mají skoro všechny zprávy.

Obsah

1 Úvod 1
2 Data a metody 2
3 Výsledky 4
3.1 Objevení hlaviček 4
3.2 Audit lexikonu 6
4 Segmentace a kostra šablony 8
4.1 Kostra šablony 8
4.2 Sekce na zprávu 11
4.3 Délky těl sekcí 12
4.4 Zprávy bez nadpisů 13
4.5 Tokeny a n-gramy 14
5 Shrnutí a rozhodnutí 17
6 Omezení 18
Příloha A: provenance renderu 19
Literatura 21

1 Úvod

Tento sešit je devátým z řady sešitů explorační analýzy a otevírá fázi zpracování struktury textu. Předchozí sešity popsaly korpus, diagnózy a jejich zmínky v textu. Propouštěcí zpráva MIMIC má ale vnitřní strukturu: je rozdělená na oddíly, jako jsou Chief Complaint, Hospital Course nebo Discharge Diagnosis. Parser sekcí rozpoznává oddíly podle seznamu hlaviček,

tedy lexikonu sekcí (kapitola 4 používá parser k rozdělení zpráv). Lexikon musí odpovídat datům, ne odhadu. Sešit si klade tyto cíle:

- zjistit, které hlavičky se v textu zpráv vyskytují a v kolika zprávách,
- změřit, jak lexikon sekcí šablony MIMIC tyto hlavičky pokrývá,
- najít mrtvá synonyma lexikonu a synonyma, která se ve zprávě opakují a nejspíš se používají i uvnitř těl sekcí,
- jmenovat hlavičky mimo lexikon, které má většina zpráv a které by do lexikonu mohly patřit,
- rozdělit zprávy na sekce a popsat kostru šablony: pořadí sekcí, jejich pokrytí a konzistenci pořadí,
- změřit počet sekcí na zprávu a délky těl sekcí ve znacích,
- zjistit, kolik zpráv má sekci Discharge Diagnosis a jaký podíl textu odstraní její vystřižení (ablace D2),
- popsat zprávy bez jediného nadpisu,
- spočítat nejčastější tokeny a n-gramy těl sekcí (celkem i po sekcích kostry) a najít fráze šablony, které nic nerozlišují.

Data pocházejí z MIMIC-IV (Johnson et al. 2024; A. E. W. Johnson et al. 2023) a MIMIC-IV-Note (A. Johnson et al. 2023), které podléhají smlouvě o užívání dat (DUA). Dokument proto zveřejňuje jen agregáty. Řetězec hlavičky je popisek z dat, a zveřejní se proto jen hlavička, kterou má aspoň 1 % zpráv a nejméně 10 zpráv; podrobná pravidla jsou v kapitole 2.

Dokument je členěn takto. Kapitola 2 popisuje metody. Kapitola 3 uvádí výsledky hlaviček a lexikonu a kapitola 4 výsledky rozdělení zpráv na sekce a frekvenci tokenů a n-gramů. Kapitola 5 shrnuje rozhodnutí pro další práci a kapitola 6 jmenuje omezení. Příloha A dokumentuje provenance renderu.

2 Data a metody

Sešit čte propouštěcí zprávy (`discharge`). Dotazy provádí DuckDB nad parquetem a jsou v `eda/R/sections.R` (hlavičky a lexikon) a `eda/R/segments.R` (segmentace a kostra) s testy nad ručně vytvořenými tabulkami. Hlavičky se z textu vytáhnou jednou do dočasné tabulky a audit lexikonu čte jen ji. Segmentaci zprávy na sekce dělá parser sekcí, ne dotaz: kapitola o segmentaci čte druhou dočasnou tabulku, kterou naplní parser.

Pojmy a jednotky jsou tyto:

- *populací* je vstupní korpus z pátého sešitu, tedy tentýž jako v sedmém a osmém sešitu: propouštěcí zprávy s kódem ICD, dlouhé aspoň 100 znaků a bez přesných duplicit. Vstupní korpus tvoří 331 604 zpráv. Jednotkou je zpráva a počítá se celý korpus, ne vzorek,
- *hlavička* je řádek, který po volitelném odsazení (mezery, tabulátory) začíná velkým písmenem a dalším písmenem, pokračuje až čtyřiceti sedmi znaky z množiny písmen, mezery, pomlčky, lomítka, ampersandu, závorek, apostrofu a tečky a končí dvojtečkou. Normalizovaný tvar zachyceného řetězce má aspoň 3 znaky. Výraz RE2 s režimem po řádcích (`(?m)`) je v konstantě `HEADER_PATTERN`. Číslice v něm nejsou, takže čas „10:30“ hlavičkou není. Hlavičku, která stojí na řádku za jiným polem, výraz nevidí,
- *normalizace* hlavičky je převod na malá písmena, sloučení bílých znaků do jedné mezery a odříznutí koncových mezer a teček. Je to jediná funkce (`normalized_sql`), kterou se normalizují hlavičky z textu i synonyma z lexikonu. Hlavička je v lexikonu nalezená, když se

její normalizovaný tvar rovná normalizovanému synonymu; stejné pravidlo používá parser sekcí (`domain/section_headers.py`), který rozděluje zprávy v kapitole 4. Zobrazuje se nejčastější původní zápis, při shodě první podle pořadí znaků (velká písmena před malými),

- *lexikon* je `config/section_headers.json`: 17 sekcí šablony MIMIC, každá s českým popiskem a celofrázovými synonymy (celkem 22 synonym), a seznam administrativních polí zprávy (8 polí), která nejsou sekcemi. Seed vychází z lexikonu předchozího projektu autora, jehož čísla byla předběžná. Oproti němu přidává sekce Major Surgical or Invasive Procedure a Discharge Disposition, zkratka HPI ze sekce Chief Complaint vypadla a vypouští podsekce (vitální funkce, chirurgická anamnéza) i generická jednoslovná synonyma, která by otevírala sekci uvnitř těla jiné sekce. Zkratky se nepřebírají, protože se na začátku řádku s dvojtečkou objevují i uvnitř těl. Synonyma jsou pravopisné varianty názvu sekce ze šablony MIMIC (člen, číslo, přípona -ation, pomlčka, mezera); vyřazeny jsou podnadpisy uvnitř sekcí (například Primary a Secondary Diagnosis, Hospital Course by Problem), alternativní názvy a zkratky. Čísla v tomto sešitu pocházejí z dat tohoto projektu,
- *dokumentová frekvence* hlavičky je počet zpráv, v nichž se vyskytuje aspoň jednou; podíl je vztažený k počtu zpráv korpusu. *Opakování* sekce je počet zpráv s aspoň dvěma výskyty kteréhokoli jejího synonyma; opakování synonyma je počet zpráv s aspoň dvěma výskyty téhož synonyma. Synonymum, které se ve zprávě objeví dvakrát, se nejspíš používá i uvnitř těla, a je tedy kandidátem na falešnou hranici sekce,
- *potlačení*: řetězec hlavičky je popisek z dat. Zveřejní se jen hlavička, kterou má aspoň 1 % zpráv korpusu a nejméně 10 zpráv. Samotný práh 10 zpráv nestačí, protože výraz zachytí i úlomky vět končící dvojtečkou. Žebříček uvádí nejvýše 40 hlaviček. Synonyma a klíče sekcí pocházejí z konfigurace, ne z dat, a zveřejňují se všechna včetně nuly. Počty zpráv jsou metrika textu a nepotlačují se; počet unikátních hlaviček je číslo bez popisku,
- *rozhodnutí sešitu* jsou texty generované z dat: kandidáti na doplnění (hlavičky mimo lexikon s pokrytím aspoň 50 %), mrtvá synonyma a synonyma s opakováním aspoň v 5 % zpráv. Hranice 50 % je popisná, ne brána: odděluje „většina zpráv“ od podsekcí, o zařazení rozhoduje autor,
- *segmentace*: zprávu rozdělí parser sekcí (`split_sections` v `domain/section_headers.py`) voláním z R přes reticulate po dávkách 2 000 zpráv; sešit pravidlo hranice nekopíruje. Hranicí je první výskyt sekce v textu, opakovaná hlavička je jen text těla. Část `other` je text před první hlavičkou a text od administrativního pole lexikonu do další hlavičky, protože šablona MIMIC má pole Attending za sekcí Allergies; hranicí je první výskyt pole na začátku řádku a sousední části `other` se slijí. Hlavičku sekce tvoří text od začátku řádku po dvojtečku, tělo je text do další hlavičky nebo administrativního pole. *Pozice* sekce je její pořadí mezi sekcemi lexikonu ve zprávě od 0 (`other` se nepočítá). `span_chars` je délka hlavičky a těla dohromady, takže součet přes zprávu je délka zprávy. `body_chars` je délka těla bez okrajových bílých znaků. Tělo, které je po ořezu jen maska de-identifikace `___`, nese příznak; jeho délka (3 znaky) nepopisuje obsah, protože ten odstranila de-identifikace. Do R přicházejí jen tyto délky, příznaky, pozice a offsety těla v textu zprávy (`body_start`, `body_end`, v code pointech), ne text,
- *kostra šablony* jsou sekce lexikonu, které má aspoň 50 % zpráv, seřazené podle mediánu pozice (při shodě podle pokrytí sestupně a pak podle pořadí v lexikonu). *Konzistence pořadí* je podíl zpráv s aspoň dvěma sekcemi kostry, v nichž sekce jdou v pořadí kostry. *Matice precedence* uvádí pro dvojici sekcí kostry podíl zpráv, kde řádek předchází sloupec, mezi zprávami, které mají obě sekce,

- *strip D2* je vystřižení sekce `discharge_diagnosis` ze zprávy. Podíl odstraněného textu je součet `span_chars` této sekce lomený součtem délek zpráv. Klíč sekce je konstanta sešitu `STRIP_SECTION`, kterou ověří lexikon,
- *zprávy bez nadpisů* jsou zprávy, jejichž jedinou částí je `other`. Délka zprávy je součet `span_chars`,
- *tokeny a n-gramy*: text těla vyřízne DuckDB z `discharge` podle offsetů z parseru, takže pravidlo hranice sekce zůstává jen v parseru a n-gramy se přiřadí téže sekci, s jakou počítá strip D2. *Token* je maximální úsek písmen a–z délky aspoň 2 po převodu na malá písmena (konstanta `TOKEN_SQL`): maska `___`, čísla, časy, dávkování a jednopísmenné úseky vypadnou, „x-ray“ dá „ray“. Hlavičky sekcí se nepočítají a n-gram nepřechází přes hranici části zprávy. Text `other`, včetně administrativních polí, se počítá do celku. Stop slova jsou přesně `ENGLISH_STOP_WORDS` ze scikit-learn, tedy totéž, co použije TF-IDF se `stop_words="english"`; vypadnou i negace „no“, „not“ a „nor“. Odfiltrují se před skládáním n-gramů, stejně jako v `TfidfVectorizer`, takže „shortness of breath“ dá bigram „shortness breath“. N-gramy mají délku 1 až 3. Žebříček řadí podle *dokumentové frekvence* n-gramu (počet zpráv, v nichž se vyskytuje aspoň jednou), pak podle počtu výskytů a řetězce. U celku se n-gram ve dvou sekcích téže zprávy počítá jednou. Tabulka celku uvádí 15 nejčastějších n-gramů pro každou délku, tabulka po sekcích 5 nejčastějších pro každou sekci kostry a délku. *Fráze šablony* je n-gram, který má aspoň 50 % zpráv,
- *potlačení u n-gramů*: n-gram je popisek z dat. Zveřejní se jen n-gram, který má aspoň 1 % zpráv (u sekce zpráv s touto sekcí) a nejméně 10 zpráv; brána je na dokumentové frekvenci, ne na výskytech, aby se nezveřejnila vzácná fráze nebo jméno opakované v jedné zprávě. Brána je v dotazu, takže mezivýsledek pod ní do R nepřijde,
- *potlačení u segmentace*: všechny výstupy jsou metriky textu a korpusu (počty zpráv, délky, pozice) s popisky z konfigurace, takže se nic nepotlačuje; řetězce z textu se v kapitole neukazují.

3 Výsledky

3.1 Objevení hlaviček

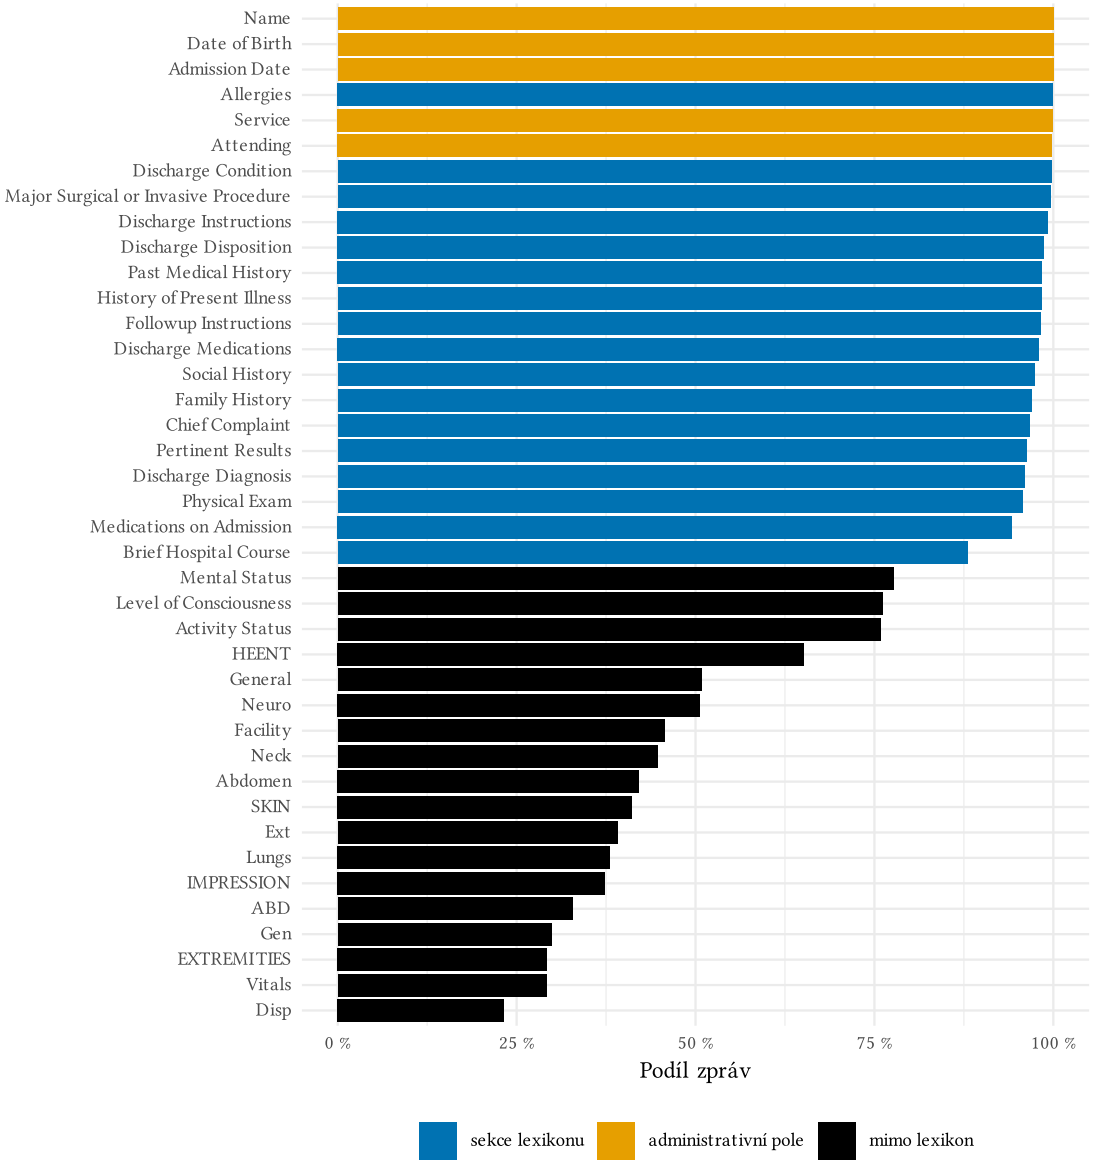
Aspoň jednu sekci lexikonu má 100,0 % zpráv korpusu, žádnou hlavičku 0,0 %. Korpus obsahuje 99 417 unikátních hlaviček.

Tabulka 1 a Obrázek 1 uvádějí hlavičky podle dokumentové frekvence a jejich zařazení: do sekce lexikonu, mezi administrativní pole, nebo mimo lexikon.

Tabulka 1: Nejčastější hlavičky vstupního korpusu podle dokumentové frekvence a jejich zařazení.

Hlavička	Zařazení	Zprávy	Podíl (%)
Name	administrativní pole	331 603	100,0
Date of Birth	administrativní pole	331 598	100,0
Admission Date	administrativní pole	331 593	100,0
Allergies	Alergie	331 478	100,0
Service	administrativní pole	331 392	99,9
Attending	administrativní pole	330 917	99,8
Discharge Condition	Stav při propuštění	330 735	99,7
Major Surgical or Invasive Procedure	Významný chirurgický nebo invazivní výkon	330 244	99,6
Discharge Instructions	Pokyny při propuštění	329 038	99,2
Discharge Disposition	Místo určení po propuštění	327 295	98,7
Past Medical History	Dřívější anamnéza	326 449	98,4
History of Present Illness	Anamnéza současného onemocnění	326 206	98,4
Followup Instructions	Pokyny k navazující péči	325 605	98,2
Discharge Medications	Léky při propuštění	324 856	98,0
Social History	Sociální anamnéza	322 783	97,3
Family History	Rodinná anamnéza	321 464	96,9
Chief Complaint	Hlavní obtíže	320 472	96,6
Pertinent Results	Významné výsledky	319 149	96,2
Discharge Diagnosis	Diagnóza při propuštění	318 168	95,9
Physical Exam	Fyzikální vyšetření	317 360	95,7
Medications on Admission	Léky při přijetí	312 557	94,3
Brief Hospital Course	Průběh hospitalizace	291 741	88,0
Mental Status	mimo lexikon	257 535	77,7
Level of Consciousness	mimo lexikon	252 410	76,1
Activity Status	mimo lexikon	251 520	75,8
HEENT	mimo lexikon	215 963	65,1
General	mimo lexikon	168 607	50,8
Neuro	mimo lexikon	167 760	50,6
Facility	mimo lexikon	151 512	45,7
Neck	mimo lexikon	148 144	44,7
Abdomen	mimo lexikon	139 566	42,1
SKIN	mimo lexikon	136 483	41,2
[illegible]	mimo lexikon	[illegible]	[illegible]

Zdroj: text z `discharge`; zařazení podle `config/section_headers.json`.



Obrázek 1: Pokrytí nejčastějších hlaviček obarvené podle zařazení.

3.2 Audit lexikonu

Tabulka 2 uvádí, v kolika zprávách se vyskytuje hlavička každé sekce lexikonu a v kolika se opakuje; Tabulka 3 totéž pro jednotlivá synonyma včetně mrtvých.

Tabulka 2: Sekce lexikonu: zprávy s hlavičkou sekce a zprávy, kde se hlavička sekce opakuje.

Sekce	Popisek	Zprávy s hlavičkou (%)	Zprávy s opakováním (%)
allergies	Alergie	100,0	1,3
chief_complaint	Hlavní obtíže	96,6	0,5
major_procedure	Významný chirurgický nebo invazivní výkon	99,6	< 0,1
history_of_present_illness	Anamnéza současného onemocnění	98,4	1,2
past_medical_history	Dřívější anamnéza	98,4	10,0
social_history	Sociální anamnéza	97,3	0,7
family_history	Rodinná anamnéza	96,9	2,1
physical_exam	Fyzikální vyšetření	95,9	6,8
pertinent_results	Významné výsledky	96,2	0,3
hospital_course	Průběh hospitalizace	88,0	0,5
medications_on_admission	Léky při přijetí	94,3	0,1
discharge_medications	Léky při propuštění	98,0	< 0,1
discharge_disposition	Místo určení po propuštění	98,7	< 0,1
discharge_diagnosis	Diagnóza při propuštění	96,1	< 0,1
discharge_condition	Stav při propuštění	99,7	0,2
discharge_instructions	Pokyny při propuštění	99,2	0,8
followup_instructions	Pokyny k navazující péči	98,3	< 0,1

Zdroj: text z discharge; sekce a synonyma jsou hodnoty z config/section_headers.json, ne z dat.

Tabulka 3: Synonyma lexikonu: zprávy se synonymem a zprávy, kde se synonymum opakuje.

Sekce	Synonymum	Zprávy se synonymem (%)	Zprávy s opakováním (%)
allergies	Allergies	100,0	1,3
chief_complaint	Chief Complaint	96,6	0,5
major_procedure	Major Surgical or Invasive Procedure	99,6	< 0,1
history_of_present_illness	History of Present Illness	98,4	1,2
history_of_present_illness	History of the Present Illness	< 0,1	0,0
past_medical_history	Past Medical History	98,4	10,0
social_history	Social History	97,3	0,7
family_history	Family History	96,9	2,1
physical_exam	Physical Exam	95,7	5,0
physical_exam	Physical Examination	2,0	0,1
pertinent_results	Pertinent Results	96,2	0,3
hospital_course	Brief Hospital Course	88,0	0,5
medications_on_admission	Medications on Admission	94,3	0,1
discharge_medications	Discharge Medications	98,0	< 0,1
discharge_disposition	Discharge Disposition	98,7	< 0,1
discharge_diagnosis	Discharge Diagnosis	95,9	< 0,1
discharge_diagnosis	Discharge Diagnoses	0,1	< 0,1
discharge_condition	Discharge Condition	99,7	0,2
discharge_instructions	Discharge Instructions	99,2	0,8
followup_instructions	Followup Instructions	98,2	< 0,1
followup_instructions	Follow-up Instructions	0,1	0,0
followup_instructions	Follow up Instructions	< 0,1	0,0

Lexikon neobsahuje žádné mrtvé synonymum. V aspoň 5 % zpráv se opakuje 1 synonymum: `Past Medical History` (10,0 %).

4 Segmentace a kostra šablony

Zprávy vstupního korpusu rozdělil parser sekcí. Kapitola popisuje kostru šablony, počet sekcí na zprávu, délky těl sekcí, zprávy bez nadpisů a nejčastější tokeny a n-gramy.

4.1 Kostra šablony

Kostru šablony tvoří 17 sekcí s pokrytím aspoň 50 % (podle mediánu pozice): `allergies`, `chief_complaint`, `major_procedure`, `history_of_present_illness`, `past_medical_history`, `social_history`, `family_history`,

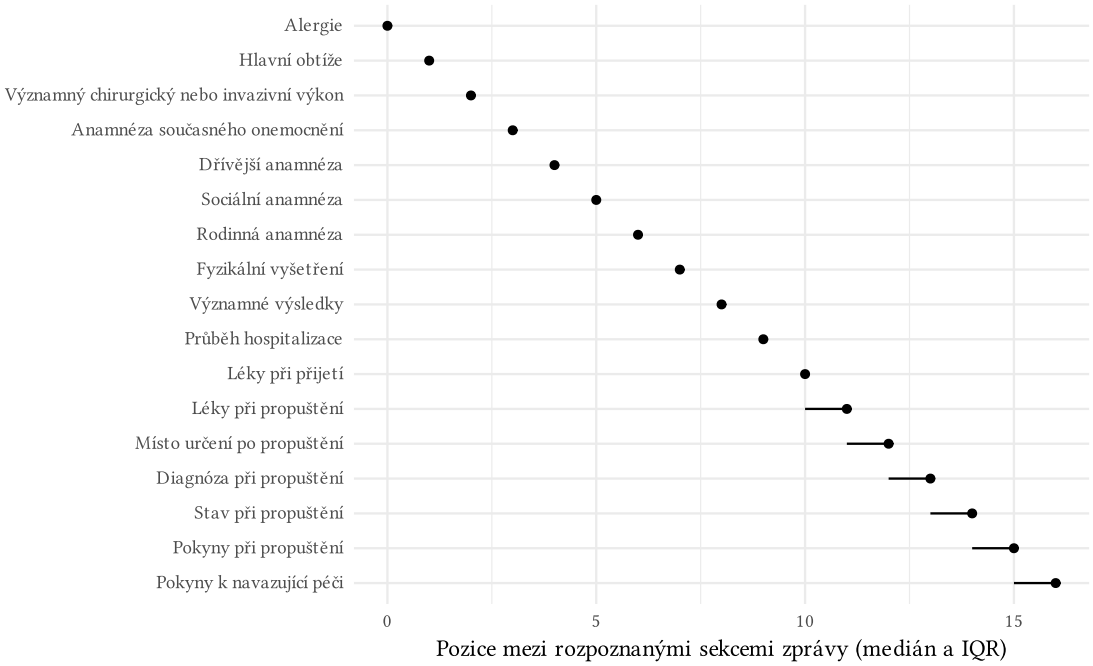
`physical_exam`, `pertinent_results`, `hospital_course`, `medications_on_admission`, `discharge_medications`, `discharge_disposition`, `discharge_diagnosis`, `discharge_condition`, `discharge_instructions` a `followup_instructions`. Pořadí kostry dodržuje 99,6 % ze 331 558 zpráv s aspoň dvěma sekcemi kostry.

Tabulka 4 uvádí všechny sekce lexikonu s pokrytím, mediánem pozice a IQR (rozdíl třetího a prvního kvartilu pozice); kostru tvoří sekce označené „ano“. Obrázek 2 ukazuje medián a IQR pozice sekcí kostry a Obrázek 3 matici precedence.

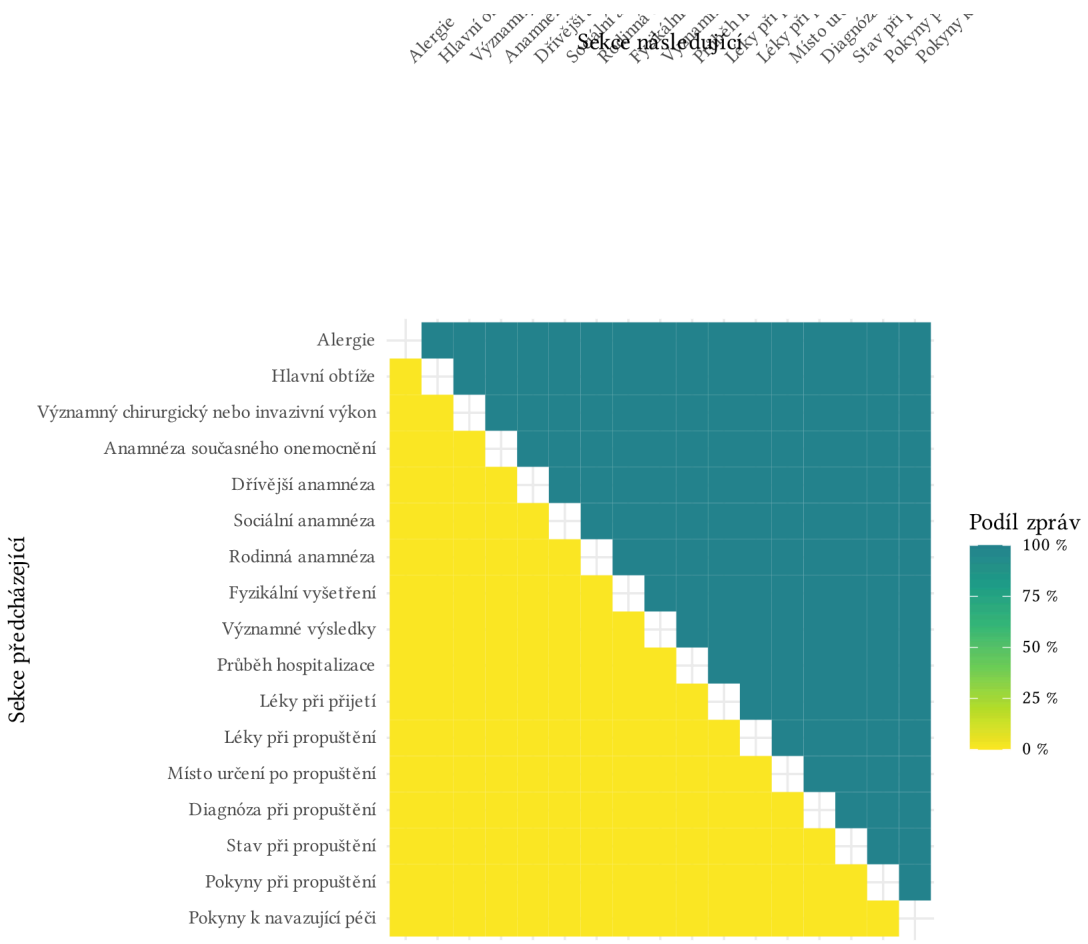
Tabulka 4: Sekce lexikonu v pořadí kostry: pokrytí, medián a IQR pozice mezi rozpoznanými sekcemi zprávy.

Sekce	Popisek	V kostře	Pokrytí (%)	Medián pozice	IQR pozice
`allergies`	Alergie	ano	100,0	0,0	0,0
`chief_complaint`	Hlavní obtíže	ano	96,6	1,0	0,0
`major_procedure`	Významný chirurgický nebo invazivní výkon	ano	99,6	2,0	0,0
`history_of_present_illness`	Anamnéza současného onemocnění	ano	98,4	3,0	0,0
`past_medical_history`	Dřívější anamnéza	ano	98,4	4,0	0,0
`social_history`	Sociální anamnéza	ano	97,3	5,0	0,0
`family_history`	Rodinná anamnéza	ano	96,9	6,0	0,0
`physical_exam`	Fyzikální vyšetření	ano	95,9	7,0	0,0
`pertinent_results`	Významné výsledky	ano	96,2	8,0	0,0
`hospital_course`	Průběh hospitalizace	ano	88,0	9,0	0,0
`medications_on_admission`	Léky při přijetí	ano	94,3	10,0	0,0
`discharge_medications`	Léky při propuštění	ano	98,0	11,0	1,0
`discharge_disposition`	Místo určení po propuštění	ano	98,7	12,0	1,0
`discharge_diagnosis`	Diagnóza při propuštění	ano	96,1	13,0	1,0
`discharge_condition`	Stav při propuštění	ano	99,7	14,0	1,0
`discharge_instructions`	Pokyny při propuštění	ano	99,2	15,0	1,0
`followup_instructions`	Pokyny k navazující péči	ano	98,3	16,0	1,0

Zdroj: text z `discharge` rozdělený parserem sekcí; sekce jsou hodnoty z `config/section_headers.json`.



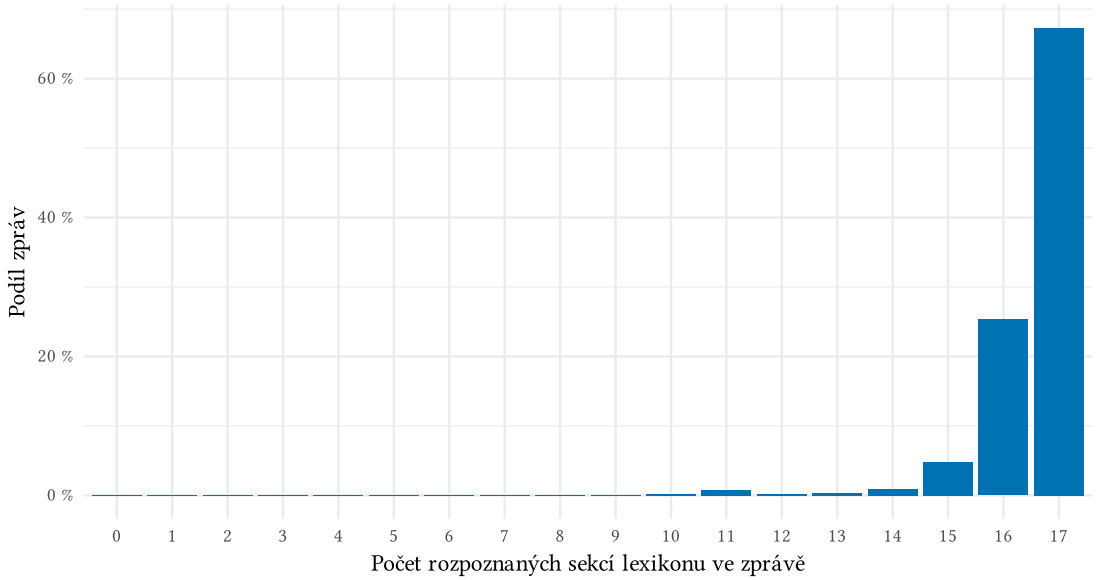
Obrázek 2: Medián a IQR pozice sekcí kostry mezi rozpoznanými sekcemi zprávy.



Obrázek 3: Matice precedence: podíl zpráv, kde sekce v řádku předchází sekci ve sloupci, mezi zprávami s oběma sekcemi.

4.2 Sekce na zprávu

Počet rozpoznaných sekcí lexikonu na zprávu: medián 17 (p10 16, p75 17, p95 17, maximum 17). Žádnou sekci nemá 22 zpráv (< 0,1 %).



Obrázek 4: Rozdělení počtu rozpoznaných sekcí lexikonu ve zprávě.

4.3 Délky těl sekcí

Nejdelší tělo má v mediánu sekce `hospital_course` (1 974 znaků), nejkratší sekce `discharge_disposition` (4 znaky). Text mimo sekce má medián 178 znaků. Tělo sekcí `social_history` a `followup_instructions` je u většiny zpráv jen maska `___` (u 96,9 % a 100,0 % zpráv se sekcí): obsah odstranila de-identifikace, délka proto nepopisuje text.

Tabulka 5 uvádí délky těl sekcí ve znacích v pořadí kostry a poslední řádek patří textu mimo sekce, sečtenému za zprávu.

Tabulka 5: Délky těl sekcí ve znacích: zprávy se sekcí, medián, 75. a 95. percentil a podíl těl, která jsou jen maska ___.

Sekce	Popisek	Zprávy se sekcí	Medián	p75	p95	Jen maska (%)
allergies	Alergie	331 478	43	46	88	1,4
chief_complaint	Hlavní obtíže	320 472	19	29	59	0,4
major_procedure	Významný chirurgický nebo invazivní výkon	330 244	13	44	159	0,1
history_of_present_illness	Anamnéza současného onemocnění	326 207	1 302	1 910	3 023	< 0,1
past_medical_history	Dřívější anamnéza	326 449	249	493	1 383	< 0,1
social_history	Sociální anamnéza	322 783	3	3	3	96,9
family_history	Rodinná anamnéza	321 464	65	126	303	0,3
physical_exam	Fyzikální vyšetření	318 005	834	1 302	2 207	< 0,1
pertinent_results	Významné výsledky	319 149	1 671	3 108	6 876	< 0,1
hospital_course	Průběh hospitalizace	291 741	1 974	3 111	5 615	0,0
medications_on_admission	Léky při přijetí	312 557	311	550	1 067	< 0,1
discharge_medications	Léky při propuštění	324 856	717	1 072	1 782	< 0,1
discharge_disposition	Místo určení po propuštění	327 295	4	33	33	< 0,1
discharge_diagnosis	Diagnóza při propuštění	318 522	67	128	271	0,1
discharge_condition	Stav při propuštění	330 735	124	150	184	< 0,1
discharge_instructions	Pokyny při propuštění	329 038	866	1 458	3 174	< 0,1
followup_instructions	Pokyny k navazující péči	325 920	3	3	3	100,0
other	Text mimo sekce	331 604	178	180	187	0,0

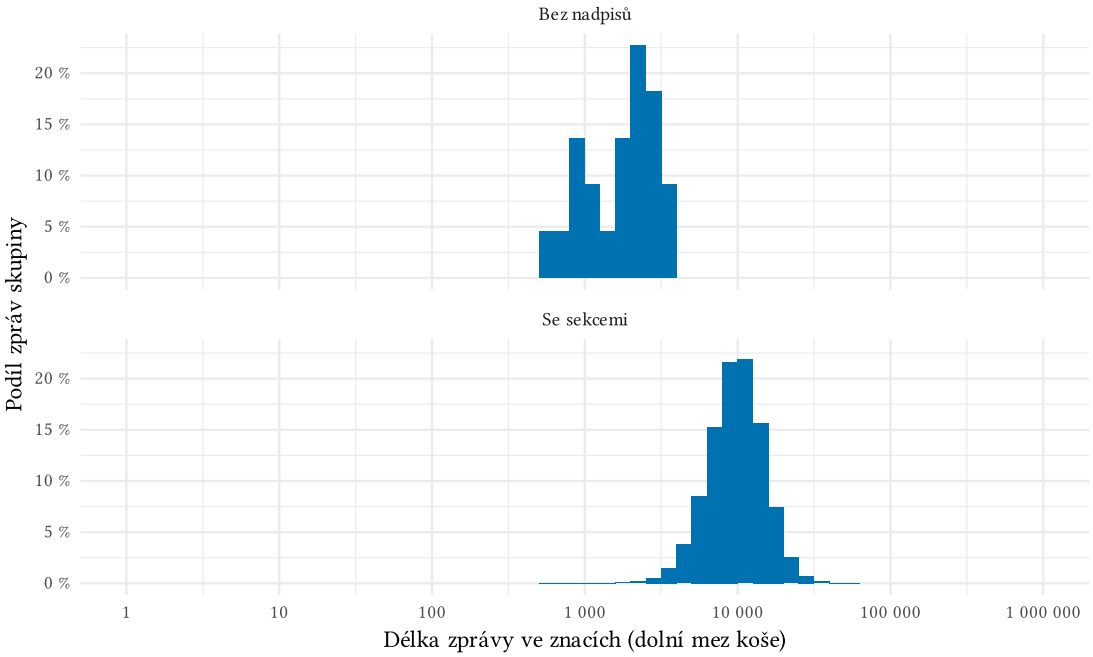
Zdroj: text z `discharge` rozdělený parserem sekcí; délka těla je bez okrajových bílých znaků.

4.4 Zprávy bez nadpisů

Bez nadpisů je 22 zpráv korpusu (< 0,1 %). Medián jejich délky je 1 874 znaků proti 9 849 znaků ve zprávách se sekcemi, p95 je 3 258 znaků proti 18 620 znaků.

Tabulka 6: Zprávy bez nadpisů a zprávy se sekcemi: počet, podíl a délky zprávy ve znacích.

Skupina	Zprávy	Podíl (%)	Medián délky	p95 délky
Bez nadpisů	22	< 0,1	1 874	3 258
Se sekcemi	331 582	100,0	9 849	18 620



Obrázek 5: Rozdělení délky zpráv bez nadpisů a zpráv se sekcemi (podíl v rámci skupiny).

4.5 Tokeny a n-gramy

Nejčastější je token `admission` (100,0 % zpráv), bigram `date birth` (100,0 % zpráv) a trigram `date birth sex` (100,0 % zpráv). Aspoň 50 % zpráv má 141 tokenů, 47 bigramů a 36 trigramů; jsou to fráze šablony, které nic nerozlišují.

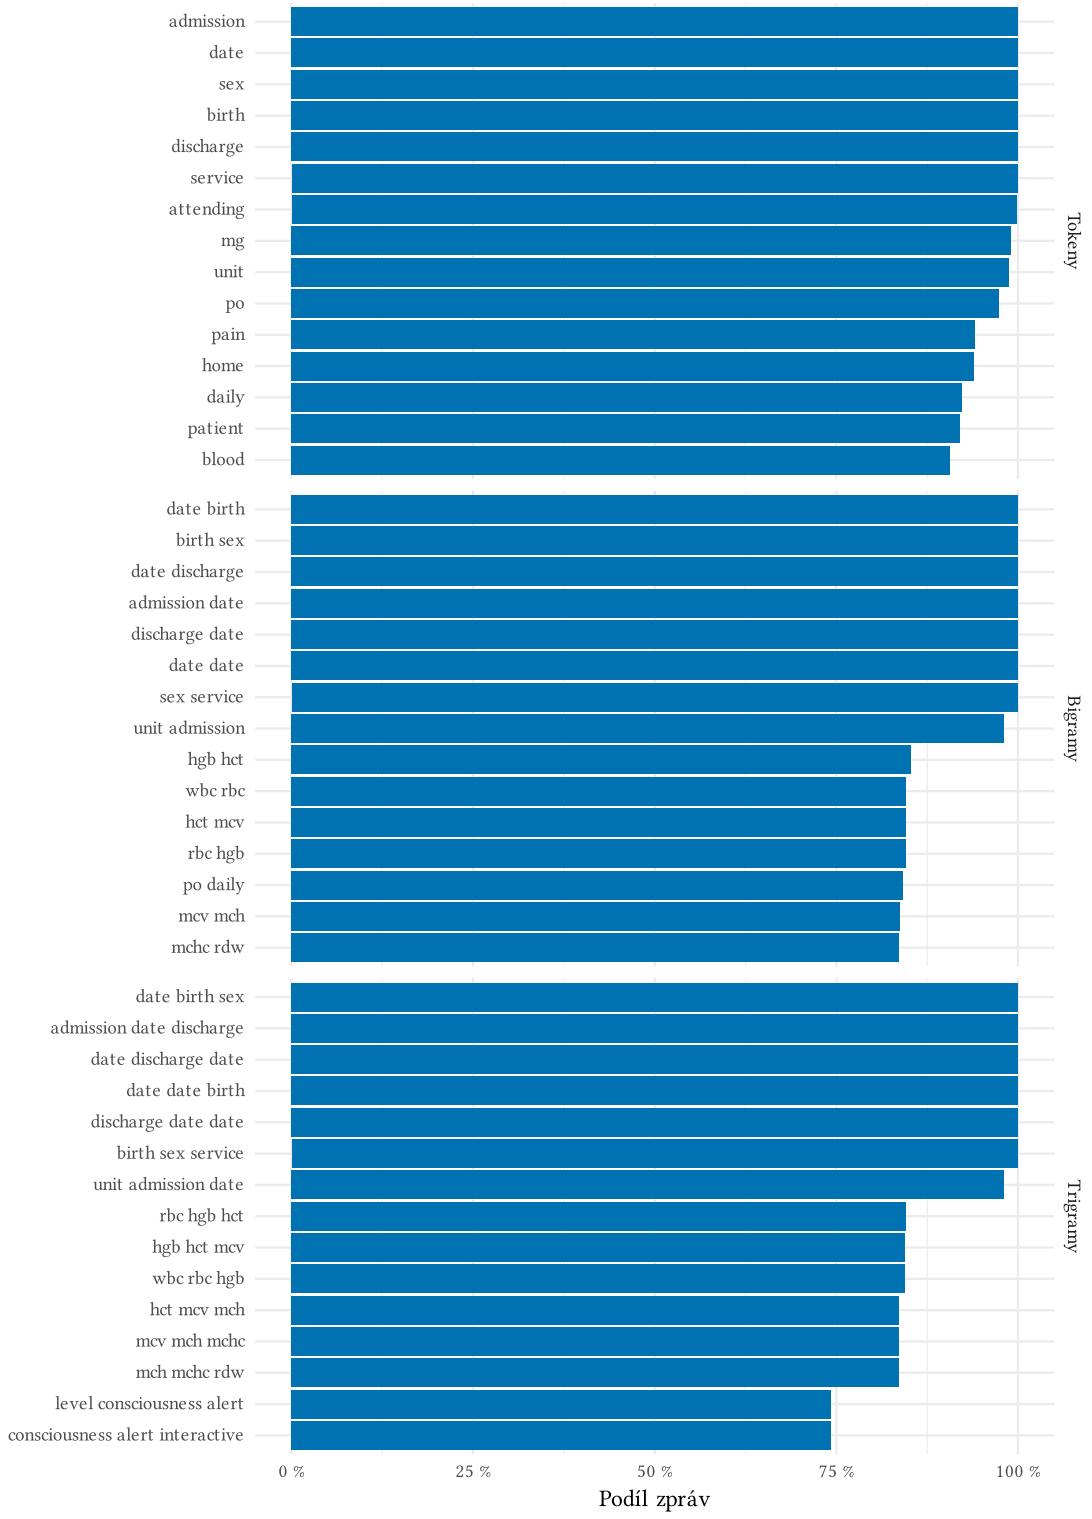
Tabulka 7 uvádí nejčastější tokeny, bigramy a trigramy těl sekcí celého korpusu a Obrázek 6 je ukazuje graficky. Tabulka 8 uvádí pro každou sekci kostry 5 nejčastějších n-gramů od každé délky s podílem zpráv, které sekci mají; bez stop slov.

Tabulka 7: Nejčastější tokeny, bigramy a trigramy těl sekcí vstupního korpusu podle dokumentové frekvence.

Délka	N-gram	Zprávy	Podíl (%)	Výskyty
1	admission	331 604	100,0	1 259 324
1	date	331 604	100,0	1 111 908
1	sex	331 604	100,0	338 807
1	birth	331 604	100,0	336 375
1	discharge	331 603	100,0	1 412 451
1	service	331 392	99,9	560 421
1	attending	330 931	99,8	345 404
1	mg	328 444	99,0	6 583 080
1	unit	327 662	98,8	607 682
1	po	323 019	97,4	4 857 445
1	pain	311 842	94,0	2 643 753
1	home	311 343	93,9	1 177 244
1	daily	305 905	92,3	3 317 846
1	patient	305 007	92,0	2 664 918
1	blood	300 360	90,6	3 323 806
2	date birth	331 604	100,0	332 003
2	birth sex	331 604	100,0	331 775
2	date discharge	331 603	100,0	333 359
2	admission date	331 603	100,0	331 838
2	discharge date	331 593	100,0	332 069
2	date date	331 589	100,0	331 852
2	sex service	331 379	99,9	331 381
2	unit admission	325 235	98,1	325 426
2	hgb hct	282 819	85,3	569 572
2	wbc rbc	280 453	84,6	567 133
2	hct mcv	280 335	84,5	558 391
2	rbc hgb	280 306	84,5	558 553
2	po daily	279 235	84,2	1 901 314
2	mcv mch	277 534	83,7	551 866
2	mchc rdw	277 356	83,6	551 548
3	date birth sex	331 604	100,0	331 775
3	admission date discharge	331 602	100,0	331 637
3	date discharge date	331 593	100,0	331 612
3	[illegible]	[illegible]	[illegible]	[illegible]

Tabulka 8: Nejčastější n-gramy po sekcích kostry: podíl zpráv se sekcí.

Sekce	Délka	Nejčastější n-gramy (podíl zpráv se sekcí)
allergies	1	allergies (41,9 %); known (41,0 %); drug (32,4 %); reactions (31,3 %); adverse (31,3 %)
allergies	2	known allergies (40,9 %); adverse drug (31,3 %); allergies adverse (31,3 %); drug reactions (31,3 %); allergies drugs (9,7 %)
allergies	3	adverse drug reactions (31,3 %); allergies adverse drug (31,3 %); known allergies adverse (31,2 %); having known allergies (9,7 %); known allergies drugs (9,7 %)
chief_complaint	1	pain (26,2 %); abdominal (10,0 %); chest (6,8 %); left (6,0 %); right (5,9 %)
chief_complaint	2	abdominal pain (9,1 %); chest pain (5,8 %); shortness breath (3,9 %); nausea vomiting (2,4 %); mental status (1,9 %)
chief_complaint	3	altered mental status (1,7 %)
major_procedure	1	placement (8,8 %); left (8,7 %); right (8,3 %); artery (3,2 %); catheterization (2,9 %)
major_procedure	2	cardiac catheterization (2,0 %); line placement (1,7 %); coronary artery (1,6 %); artery bypass (1,6 %); saphenous vein (1,2 %)
major_procedure	3	coronary artery bypass (1,5 %); left anterior descending (1,2 %); left internal mammary (1,1 %); internal mammary artery (1,0 %)
history_of_present_illness	1	pain (71,7 %); patient (60,7 %); denies (53,2 %); ed (52,9 %); history (46,1 %)
history_of_present_illness	2	chest pain (39,2 %); abdominal pain (34,2 %); nausea vomiting (27,4 %); year old (25,8 %); shortness breath (25,5 %)
history_of_present_illness	3	ed initial vitals (12,5 %); nausea vomiting diarrhea (12,0 %); chills night sweats (10,1 %); denies chest pain (9,6 %); ed initial vs (8,9 %)
past_medical_history	1	hypertension (32,3 %); history (31,8 %); htn (24,5 %); past (23,1 %); disease (22,4 %)
past_medical_history	2	past medical (15,8 %); medical history (15,3 %); surgical history (9,2 %); atrial fibrillation (7,6 %); past surgical (7,2 %)
past_medical_history	3	past medical history (14,7 %); past surgical history (7,0 %); coronary artery disease (4,7 %); cardiac risk factors (3,8 %); past oncologic history (3,5 %)
social_history	1	history (1,7 %); denies (1,6 %); use (1,4 %); lives (1,3 %); tobacco (1,2 %)
social_history	2	–
social_history	3	–
family_history	1	mother (37,9 %); father (37,8 %); history (27,3 %); cancer (26,6 %); family (25,8 %)
[illegible]	2	[illegible]
[illegible]	3	[illegible] year (69,4 %)



Obrázek 6: Nejčastější tokeny, bigramy a trigramy těl sekcí: podíl zpráv.

5 Shrnutí a rozhodnutí

Dokument ověřil seed lexikon sekcí na vstupním korpusu. Pro další práci z toho plyne:

- **Pokrytí.** Aspoň jednu sekci lexikonu má 100,0 % zpráv korpusu, žádnou hlavičku 0,0 %. Korpus obsahuje 99 417 unikátních hlaviček.
- **Kandidáti na doplnění.** Kandidáti na doplnění lexikonu (hlavičky mimo lexikon s pokrytím aspoň 50 %): `Mental Status` (77,7 %), `Level of Consciousness` (76,1 %), `Activity Status` (75,8 %), `HEENT` (65,1 %), `General` (50,8 %) a `Neuro` (50,6 %). Do lexikonu patří jen samostatná sekce šablony; pole a podnadpisy uvnitř jiné sekce sekcemi nejsou a lexikon je nepřebírá, i když je má většina zpráv.
- **Mrtvá synonyma.** Lexikon neobsahuje žádné mrtvé synonymum.
- **Opakování.** V aspoň 5 % zpráv se opakuje 1 synonymum: `Past Medical History` (10,0 %).
- **Pro parser.** Parser sekcí čte lexikon z `config/section_headers.json` a používá pravidlo hlavičky a normalizace z kapitoly 2; rozdělení zpráv je v kapitole 4.
- **Kostra.** Kostru šablony tvoří 17 sekcí s pokrytím aspoň 50 % (podle mediánu pozice): `allergies`, `chief_complaint`, `major_procedure`, `history_of_present_illness`, `past_medical_history`, `social_history`, `family_history`, `physical_exam`, `pertinent_results`, `hospital_course`, `medications_on_admission`, `discharge_medications`, `discharge_disposition`, `discharge_diagnosis`, `discharge_condition`, `discharge_instructions` a `followup_instructions`. Pořadí kostry dodržuje 99,6 % ze 331 558 zpráv s aspoň dvěma sekcemi kostry.
- **Strip D2.** Strip D2 odstraní sekci `discharge_diagnosis` u 318 522 zpráv korpusu (96,1 %) a tvoří 1,1 % jeho textu; ve zprávě se sekcí tvoří v mediánu 1,0 % textu zprávy.
- **Délky.** Nejdelší tělo má v mediánu sekce `hospital_course` (1 974 znaků), nejkratší sekce `discharge_disposition` (4 znaky). Text mimo sekce má medián 178 znaků. Tělo sekcí `social_history` a `followup_instructions` je u většiny zpráv jen maska `___` (u 96,9 % a 100,0 % zpráv se sekcí): obsah odstranila de-identifikace, délka proto nepopisuje text.
- **Zprávy bez nadpisů.** Bez nadpisů je 22 zpráv korpusu (< 0,1 %). Medián jejich délky je 1 874 znaků proti 9 849 znaků ve zprávách se sekcemi, p95 je 3 258 znaků proti 18 620 znaků.
- **Tokeny a n-gramy.** Nejčastější je token `admission` (100,0 % zpráv), bigram `date birth` (100,0 % zpráv) a trigram `date birth sex` (100,0 % zpráv). Aspoň 50 % zpráv má 141 tokenů, 47 bigramů a 36 trigramů; jsou to fráze šablony, které nic nerozlišují. Pro S40 (baseline TF-IDF + LR) z toho plyne argument pro `ngram_range` a `max_df`: n-gramy, které má většina zpráv, nic nerozlišují. Tokenizace sešitu se liší od výchozí v TF-IDF: ponechává jen písmena a–z, takže čísla a masku `___` vynechává. Počty frází šablony jsou podklad pro deduplikaci boilerplate (D26).

6 Omezení

Řádkově ukotvený výraz nevidí pole, které stojí na řádku za jiným polem, hlavičky bez dvojtečky ani hlavičky rozdělené na víc řádků. Pokrytí administrativních polí se proto neměří. Opakování je jen nepřímý signál falešné hranice: synonymum se může opakovat i ve zprávě, kde je každý výskyt skutečnou hlavičkou. Hranice 50 % pro kandidáty je popisná a nerozliší sekci šablony od pole, které má ve většině zpráv podsekce. Žebříček neukazuje hlavičky pod 1 % zpráv, takže vzácnou sekci šablony nemusí zveřejnit. Pozice počítá jen sekce lexikonu, takže pole a podnadpisy mimo lexikon pořadí nezkreslují, ale ani nepopisují. Pozice je pořadí mezi sekcemi, které zpráva má: chybí-li dřívější sekce, pozice všech pozdějších klesne o jedna, a IQR pozice proto měří i chybějící sekce, ne jen přeházené pořadí. Frekvenční analýza nelemmatizuje, takže „fever“ a „fevers“ jsou dva tokeny, a ztrácí negace, protože „no“ a „not“

jsou stop slova: „no fever“ se spočítá jako „fever“. Výchozí tokenizace TF-IDF v S40 masku `___` a čísla jako tokeny ponechá, počty z tohoto sešitu tedy nejsou přímo počty příznaků baseline. Slova z administrativních polí leží v části `other` a počítají se jen do celku, ne do sekcí. Bigram může spojit slova, mezi nimiž stálo stop slovo. N-gramy pod branou (1 % zpráv a nejméně 10 zpráv) se nezobrazí, takže vzácná, ale rozlišující fráze v žebříčku chybí. Strip odhaduje jednu sekci a nehlídá, že se její synonymum neobjeví jako hlavička uvnitř těla jiné sekce; parser bere první výskyt.

Příloha A: provenance renderu

Tabulka 9 uvádí údaje, podle kterých lze render dohledat a zopakovat: revizi kódu, otisk zámku prostředí, zdroj dat a verze použitých nástrojů.

Tabulka 9: Provenance renderu.

Položka	Hodnota
Revize kódu (commit)	ff5bc2d7465a27eaf67c85304c12df9dbc133fe7
Necommitnuté změny	ne
Otisk pixi.lock (SHA-256)	3b216e5b4bf1268d8009b79ea3150807df440a030a0fd0897287e6a22dd32504
Zdroj dat	otisky CSV z config/mimic_tables.json
Otisk discharge.csv.gz (SHA-256)	27bc552edaf81c2af322040cb7e8eb36417173b23c79405bb92fcf73bef2dbc5
Otisk radiology.csv.gz (SHA-256)	2c09bc76ee12d5f3b8f572deb7218fbaf3e59b32eccfdae14686e05ae099eebb
Otisk admissions.csv.gz (SHA-256)	a9584ed88e9ed664a2f66f86a5cf9fd175c8bb0af50e3b6115598b19e978384e
Otisk d_icd_diagnoses.csv.gz (SHA-256)	a81065bf45ccf74f589bec855bbb0a07b5c014907b34ff76fe20583a2c87cc79
Otisk d_icd_procedures.csv.gz (SHA-256)	a2ac8afcb99fd16bce2e6c7ad445e3bd1dfd658e521823130ab08b66fdd3d6d4
Otisk diagnoses_icd.csv.gz (SHA-256)	47665a41b2a3ad990d6f314062d5bd6d29d467b0fd402dd94662044ec8b073d2
Otisk omr.csv.gz (SHA-256)	8280a8023203bddc6cc4419bd8cd253a015b8bc0bc53852ec92f98c7353f31e2
Otisk patients.csv.gz (SHA-256)	4c7507de7ecad8c5ba7647ea4d26018e88ff6672c5fc22ab59c2a5697d687cdd
Otisk pharmacy.csv.gz (SHA-256)	c9885721e4c968f0773145d7f6ba4d3cc3755d5600ee400ff95b1d3238053811
Otisk prescriptions.csv.gz (SHA-256)	0d8481c7d5d7c9ec2fea3fc543ddaaadb5a933cd22c7b9dda4289361e4d77199
Otisk procedures_icd.csv.gz (SHA-256)	3271397d0517131f84399b698cbb0c2f435aaab0f873a3806e13b097661596f7
Otisk services.csv.gz (SHA-256)	31c82ebee94e0c04d6966fbfec30579ec00f9c7816b80852f9580656e6183888
Python	3.13.16
DuckDB	1.5.6
R	R version 4.5.3 (2026-03-11)

Literatura

Johnson, Alistair E. W., Lucas Bulgarelli, Lu Shen, et al. 2023. „MIMIC-IV, a freely accessible electronic health record dataset". *Scientific Data* 10 (1): 1. https://doi.org/10.1038/s41597-022--01899-x.

Johnson, Alistair, Lucas Bulgarelli, Tom Pollard, et al. 2024. *MIMIC-IV*. Verze 3.1. PhysioNet. https://doi.org/10.13026/kpb9-mt58.

Johnson, Alistair, Tom Pollard, Steven Horng, Leo Anthony Celi, a Roger Mark. 2023. *MIMIC--IV-Note: Deidentified free-text clinical notes*. Verze 2.2. PhysioNet. https://doi.org/10.13026/1n74-ne17.